



UNIVERSIDADE ESTADUAL PAULISTA
"JÚLIO DE MESQUITA FILHO"
Campus de São José do Rio Preto

André Furlan

Autenticação Biométrica de Locutores
Drasticamente Disfônicos Aprimorada pela
Imagined Speech

São José do Rio Preto

2022

André Furlan

Autenticação Biométrica de Locutores Drasticamente Disfônicos Aprimorada pela *Imagined Speech*

Tese apresentada como parte dos requisitos para obtenção do título de Doutor em Ciência da Computação, junto ao Programa de Pós-Graduação em Ciência da Computação, do Instituto de Biociências, Letras e Ciências Exatas da Universidade Estadual Paulista 'Júlio de Mesquita Filho', Campus de São José do Rio Preto.

Orientador: Prof. Dr. Rodrigo Capobianco Guido

São José do Rio Preto

2022

André Furlan

Autenticação Biométrica de Locutores Drasticamente Disfônicos Aprimorada pela *Imagined Speech*

Tese apresentada como parte dos requisitos para obtenção do título de Doutor em Ciência da Computação, junto ao Programa de Pós-Graduação em Ciência da Computação, do Instituto de Biociências, Letras e Ciências Exatas da Universidade Estadual Paulista 'Júlio de Mesquita Filho', Campus de São José do Rio Preto.

Comissão Examinadora

Prof. Dr. Rodrigo Capobianco Guido
UNESP – Câmpus de São José do Rio Preto
Orientador

Prof. Dr. Exemplo Jr
Universidade – Câmpus

Prof. Dr. Exempl2
Universidade – Câmpus

São José do Rio Preto
06 de Agosto de 2022

Agradecimentos

“Citação”
-O Autor.

Resumo

Abstract

Lista de ilustrações

Figura 1 – Residual learning: a building block.	15
Figura 2 – Comparação entre uma rede neural regular e uma rede neural residual .	16

Lista de tabelas

Sumário

1	INTRODUÇÃO	12
1.1	Considerações Iniciais e Objetivos	12
1.2	Estrutura do trabalho	12
2	REVISÃO BIBLIOGRÁFICA	13
2.1	Breve revisão dos conceitos utilizados neste trabalho	13
2.1.1	Redes neurais convolucionais	13
2.1.2	Treinamento e particionamento da série de dados	14
2.1.3	Funções de ativação	14
2.1.4	Funções de erro	14
2.1.5	Técnicas de treinamento de redes	14
2.1.5.1	Parada antecipada de treinamento	14
2.1.6	Redes neurais residuais	15
2.1.7	Sinais digitais e sub-amostragem (<i>downsampling</i>)	15
2.1.8	Caracterização dos processos de produção da voz humana	15
2.2	Estado-da-arte em Imagined Speech	17
3	ABORDAGEM PROPOSTA	18
3.1	A Base de sinais	18
3.1.1	Coleta dos sinais	18
3.1.2	Organização da base de sinais	18
3.2	Estrutura da estratégia proposta	18
3.3	Procedimentos	18
3.3.1	Procedimento 01	18
4	TESTES E RESULTADOS	19
4.1	Procedimento 01	19
5	CONCLUSÕES E TRABALHOS FUTUROS	20
	REFERÊNCIAS	21

1 Introdução

1.1 Considerações Iniciais e Objetivos

1.2 Estrutura do trabalho

2 Revisão bibliográfica

2.1 Breve revisão dos conceitos utilizados neste trabalho

2.1.1 Redes neurais convolucionais

Um dos classificadores usados nesse trabalho é baseado na tecnologia de redes neural as convolucionais, Das redes tem como principal característica a convolução aplicada aos dados de entrada segundo um segundo um "kernel", Nesse caso entende-se "kernel" Como uma série de valores que deve ser aplicados valor a valor Afim de preparar os dados para classificação de uma rede neural densa, no caso específico das redes neurais convolucionais Essa série de valores que serviram como filtro da entrada da rede neural convolucional, Na verdade, É apenas a aplicação da função de ativação em cada valor, Ou seja, se a função de ativação escolhida for a sigmóide, Aplicar-se-á Esta função a cada valor de entrada da rede, caso a função de ativação seja a Relu O mesmo será feito (PALIWAL,).

A aplicação do *kernel* também pode ser feita da seguinte forma: soma se os valores vezes seus respectivos pesos e aplica-se a função de ativação.

Um aspecto importante da preparação dos dados para treinamento chama-se *padding* Que consiste no aumento do vetor de entrada para que o vetor de saída tenha sempre o mesmo tamanho que o vetor de entrada. Em redes convolucionais O resultado terá sempre um número menor de itens do que a entrada, assim, é preciso adicionar zeros no início ou fim do vetor de entrada ou apenas no início (recomendado no caso de realização de previsões).

O *stride* ou passo é outro fator que influencia no tamanho da saída de uma convolução. O Passo é a quantidade de deslocamentos que uma janela de convolução deve realizar quando necessita avançar no vetor fornecido, quanto maior o passo menos valores serão fornecidos como resultado aumentando assim a necessidade de *padding* caso se necessite manter o tamanho do vetor de entrada para a próxima camada. Dependendo da fase da convolução, esse encurtamento necessário e desejável pois pode revelar padrões cujos os ruídos impediam de serem vistos.

TODO: Ver *wavenets no notebook*

(AMIDI; AMIDI,)

2.1.2 Treinamento e particionamento da série de dados

Quando do treinamento de uma rede necessita-se Que os dados usados para tal fim sejam particionados, Para tal, é necessário separar os dados em uma partição de treinamento, Outra de validação, e finalmente uma de teste.

2.1.3 Funções de ativação

As funções de ativação geralmente são aquelas cujo resultado varia entre -1 e 1 ou entre 0 e 1 caso sejam saturáveis como as *hiperbólicas* e *sigmóides* ou entre em zero e infinito como é o caso da *Relu* caso sejam não saturáveis.

2.1.4 Funções de erro

As funções de erro são usadas para computar a diferença entre os valores produzidos pelo modelo e os valores, de fato, desejados, dependendo dos resultados desejados se pode usar uma ou outra função de erro, na listagem abaixo estão descritas algumas funções de erro e seus usos recomendados.

- $erros = previsao - desejado$ → : Erro simples, não destaca nem suprime nenhuma característica.
- $mse = \frac{1}{n} * \sum_{n=1}^{tamanho} erros[n]^2$ → Média dos quadrados dos erros: Usada quando é necessário destacar os de maior valor. Então se o custo de erros grandes é importante para aplicação esta função é recomendada.
- $mae = \frac{1}{n} * \sum_{n=1}^{tamanho} |erros[n]|$ → Média dos valores absolutos: Usada quando os resultados são proporcionais ao erro.
- $mape = \frac{1}{n} * \sum_{n=1}^{tamanho} |erros[n]/desejado[n]|$ → Média da percentagem de erro absoluto: Informa o tamanho do erro comparado com o valor desejado.

2.1.5 Técnicas de treinamento de redes

2.1.5.1 Parada antecipada de treinamento

A técnica de parada antecipada de treinamento pode ser usada quando a rede neural por algum tempo pára de convergir, dessa forma é possível evitar o gasto desnecessário de processamento quando a rede pára de convergir. Esta técnica também ajuda a rede a evitar um *overffiting*.

2.1.6 Redes neurais residuais




Figura 1 – Residual learning: a building block.

De acordo com (HE et al., 2015) Redes neurais residuais são aquelas que "pulam" algumas camadas, ou seja, a saída de uma camada vai para a próxima mas também vai para uma outra mais à frente.

2.1.7 Sinais digitais e sub-amostragem (*downsampling*)

2.1.8 Caracterização dos processos de produção da voz humana

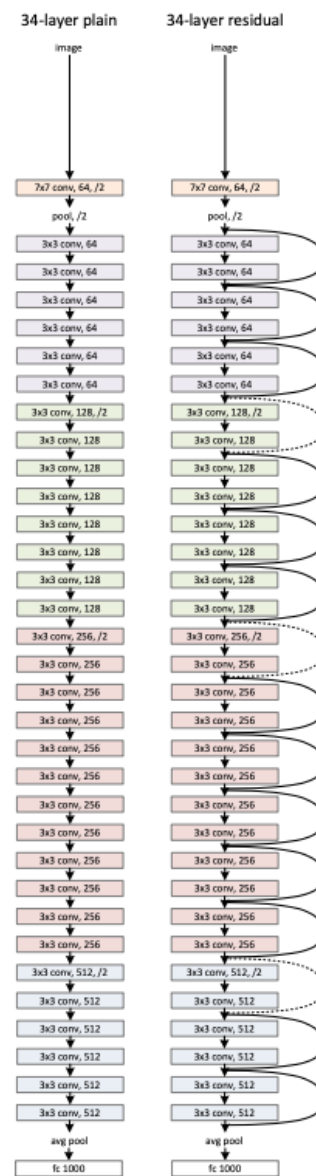


Figura 2 – Comparação entre uma rede neural regular e uma rede neural residual, a direita a rede neural regular percorre sequencialmente todas as suas camadas, a esquerda a rede neural residual "pula" algumas camadas reiteradamente.

2.2 Estado-da-arte em *Imagined Speech*

3 Abordagem proposta

3.1 A Base de sinais

3.1.1 Coleta dos sinais

3.1.2 Organização da base de sinais

3.2 Estrutura da estratégia proposta

3.3 Procedimentos

3.3.1 Procedimento 01

4 Testes e Resultados

4.1 Procedimento 01

5 Conclusões e Trabalhos Futuros

Referências

AMIDI, A.; AMIDI, S. *Convolutional Neural Networks cheatsheet*. Disponível em: <https://stanford.edu/~shervine/teaching/cs-230/cheatsheet-convolutional-neural-networks>.

HE, K. et al. Deep residual learning for image recognition. *CoRR*, abs/1512.03385, 2015. Disponível em: <http://arxiv.org/abs/1512.03385>.

PALIWAL, A. *Understand your convolution network with visualizations*. Disponível em: <https://towardsdatascience.com/understanding-your-convolution-network-with-visualizations-a4883441533b>.



UNIVERSIDADE ESTADUAL PAULISTA
"JÚLIO DE MESQUITA FILHO"
Campus de São José do Rio Preto

TERMO DE REPRODUÇÃO XEROGRÁFICA

Autorizo a reprodução xerográfica do presente Trabalho de Conclusão, na íntegra ou em partes,
para fins de pesquisa.

São José do Rio Preto, 06 de Agosto de 2022

André Furlan