

Autenticação Biométrica de Locutores Drasticamente Disfônicos Aprimorada pela *Imagined Speech*

André Furlan - ensismoebius@gmail.com

Universidade Estadual Paulista Júlio de Mesquita Filho

2024

Introdução

A autenticação biométrica tem sido amplamente adotada por fornecer individualização baseada em traços únicos dos indivíduos. No entanto, características físicas que diferem das esperadas pelo sistema podem dificultar ou impedir o acesso de certas pessoas, especialmente aquelas pertencentes a grupos étnicos minorizados ou com deficiências. No caso da autenticação por voz, a exigência de uma palavra-chave ou outro tipo de fonação pode criar barreiras adicionais. Para mitigar esse problema, este trabalho propõe um sistema de autenticação biométrica aprimorado pela fala imaginada.

- ▶ Criar um sistema de autenticação por voz aprimorado pela fala imaginada.
- ▶ Comparar o desempenho das estratégias de extração de características automatizadas com o uso de autoencoders com as que usam *Wavelet-Packet* de tempo discreto e engenharia paraconsistente de características.
- ▶ Criar uma base com dados de autenticação voz, fala imaginada e ambos os sinais simultâneos fornecendo a comunidade científica mais uma fonte de dados.

Estrutura da apresentação

Estrutura da apresentação

- ▶ Revisão de conceitos utilizados.
- ▶ Estado-da-arte em autenticação por voz e fala imaginada.
- ▶ Contextualização.
- ▶ Abordagem proposta.

Revisão de conceitos utilizados

Para desenvolver o trabalho, é necessário definir os conceitos de *downsampling*, filtros digitais *wavelets* e energia, que serão usados para a extração de características dos sinais. No processamento dos sinais de voz, serão revisadas as frequências fundamentais da voz, além das escalas BARK e MEL. Também será revisada a engenharia paraconsistente de características, método utilizado para verificar a qualidade das características extraídas. Em seguida, serão estudadas as bases das interfaces Humano-Máquina para eletroencefalograma, que coletarão dados das regiões do cérebro. Concluída essa etapa, serão revisadas as redes neurais de pulso, autoencoders e redes neurais residuais.

Sinais Digitais e Sub-amostragem (Downsampling)



Figura: Sub-amostragem

Mesmo depois de amostrados e quantizados (HAYKIN; MOHER, 2011) os sinais de EEG e voz, na maioria das vezes, precisam ser sub-amostrados para que se sejam viáveis o processamento e o armazenamento (POLIKAR et al., 1996).

Além disso o *downsampling* será fundamental no uso das transformadas *wavelet*.

Caracterização dos processos de produção da voz humana

Áreas de estudo

- ▶ fisiológica ou “fonética articulatória”.
- ▶ acústica ou “fonética acústica”.
- ▶ perceptual.

Caracterização dos processos de produção da voz humana

Vozeada versus não-vozeada

- ▶ vozeada: Pregas vocais.
- ▶ não vozeada: Sem pregas vocais.

Caracterização dos processos de produção da voz humana

Frequência fundamental da voz

- ▶ conhecida como F_0 .
- ▶ reflete a excitação pulmonar moldada pelas pregas vocais.
- ▶ componente periódico resultante da vibração das pregas vocais.
- ▶ a frequência de *pitch* (KREMER; GOMES, 2014)
- ▶ geralmente são apresentadas em Hz (FREITAS, 2013)

A alteração desta frequência (jitter) e/ou intensidade (shimmer) do *pitch* durante a fala é definida como entonação, porém, também pode indicar algum distúrbio ou doença relacionada ao trato vocal (WERTZNER; SCHREIBER; AMARO, 2005).

Caracterização dos processos de produção da voz humana

Formantes

Se referem as modificações feitas em F_0 pelas estruturas do sistema fonador (VALENÇA et al., 2014):

- ▶ $F_1 \rightarrow$ amplificação sonora na cavidade oral posterior, posição da língua no plano vertical.
- ▶ $F_2 \rightarrow$ cavidade oral anterior, posição da língua no plano horizontal.
- ▶ $F_3 \rightarrow$ cavidades à frente e atrás do ápice da língua.
- ▶ $F_4 \rightarrow$ formato da laringe e da faringe.

Bandas críticas de energia

Definições

Definem os intervalos em que serão calculadas as energias.


A energia de um sinal digital $s[\cdot]$ com M amostras é definida como

$$E = \sum_{i=0}^{M-1} (s_i)^2 \quad . \quad (1)$$

- ▶ **BARK:** 20, 100, 200, 300, 400, 510, 630, 770, 920, 1080, 1270, 1480, 1720, 2000, 2320, 2700, 3150, 3700, 4400, 5300, 6400, 7700, 9500, 12000, 15500 (ZWICKER, 1961).
- ▶ **MEL:** 20, 160, 394, 670, 1000, 1420, 1900, 2450, 3120, 4000, 5100, 6600, 9000, 14000 (BERANEK, 1949).

Bandas críticas de energia

Cálculo de vetores de características com MEL



- ▶ suporte compacto.
- ▶ análise multirresolução.
- ▶ wavelet regular e wavelet packet.
- ▶ variadas funções-filtro não-periódicas.
- ▶ análise detalhada em altas e baixas frequências.

Filtros digitais *wavelet*

Restrição de escopo

- ▶ wavelet packet
- ▶ domínio discreto.
- ▶ apenas transformadas diretas.
- ▶ não haverá reconstrução do sinal.
- ▶ construção dos vetores de características.

Filtros digitais *wavelet*

Resposta em frequência e linearidade

Tabela: Algumas das *wavelets* mais usadas e suas propriedades

Wavelet	Resposta em frequência	Resposta em fase
Haar	Pobre	Linear
Daubechies	mais próxima da ideal à medida que o suporte aumenta; <i>maximally-flat</i>	Não linear
Symmlets	mais próxima da ideal à medida que o suporte aumenta; não <i>maximally-flat</i>	Quase linear
Coiflets	mais próxima da ideal à medida que o suporte aumenta; não <i>maximally-flat</i>	Quase linear

Fonte: Elaborado pelo autor, 2022.

Filtros digitais *wavelet*

Algoritmo de Malat

- ▶ *Wavelet* Haar: $h[\cdot] = [\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}]$.
- ▶ Par ortogonal: $g[\cdot] = [\frac{1}{\sqrt{2}}, \frac{-1}{\sqrt{2}}]$.
- ▶ sinal: $s[\cdot] = [1, 2, 3, 4]$.

$$\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 & 0 \\ \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} & 0 & 0 \\ 0 & 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & 0 & \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} \end{pmatrix} \cdot \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \end{pmatrix} = \begin{pmatrix} \frac{3}{\sqrt{2}} \\ \frac{-1}{\sqrt{2}} \\ \frac{7}{\sqrt{2}} \\ \frac{-1}{\sqrt{2}} \end{pmatrix} \Rightarrow \left[\frac{3}{\sqrt{2}}, \frac{7}{\sqrt{2}}, \frac{-1}{\sqrt{2}}, \frac{-1}{\sqrt{2}} \right] .$$

Filtros digitais *wavelet*

Exemplo de *wavelet* regular e *packet*

Packet-wavelet para filtro haar = {0.5, 0.5}

Sinal	32	10	20	38	37	28	38	34	18	24	24	9	23	24	28	34
	h								g							
Nível 01	21	29	32,5	36	21	16,5	23,5	31	11	-9	4,5	2	-3	7,5	-0,5	-3
	h				g				g				h			
Nível 02	25	34,25	18,75	27,25	-4	-1,75	2,25	-3,75	10	1,25	-5,25	1,25	1	3,25	2,25	-1,75
	h		g		g		h		h		g		g		h	
Nível 03	29,62	23	-4,625	-4,25	-1,125	3	-2,875	-0,75	5,625	-2	4,375	-3,25	-1,125	2	2,125	0,25
	h		g		g		h		h		g		h		g	
Nível 04	26,3125	3,3125	-0,1875	-4,4375	0,9375	-2,0625	-1,0625	-1,8125	1,8125	3,8125	3,8125	0,5625	0,4375	-1,5625	0,9375	1,1875

	← resultado do passa-baixas (h)
	← resultado do passa-altas (g)

Comparação

Transformada wavelet regular

Sinal	32	10	20	38	37	28	38	34	18	24	24	9	23	24	28	34
Nível 01	21	29	32,5	36	21	16,5	23,5	31	11	-9	4,5	2	-3	7,5	-0,5	-3
Nível 02	25	34,25	18,75	27,25	-4	-1,75	2,25	-3,75	11	-9	4,5	2	-3	7,5	-0,5	-3
Nível 03	29,62	23	-4,625	-4,25	-4	-1,75	2,25	-3,75	11	-9	4,5	2	-3	7,5	-0,5	-3
Nível 04	26,3125	3,3125	-4,625	-4,25	-4	-1,75	2,25	-3,75	11	-9	4,5	2	-3	7,5	-0,5	-3

Transformada packet-wavelet

Sinal	32	10	20	38	37	28	38	34	18	24	24	9	23	24	28	34
Nível 01	21	29	32,5	36	21	16,5	23,5	31	11	-9	4,5	2	-3	7,5	-0,5	-3
Nível 02	25	34,25	18,75	27,25	-4	-1,75	2,25	-3,75	10	1,25	-5,25	1,25	1	3,25	2,25	-1,75
Nível 03	29,62	23	-4,625	-4,25	-1,125	3	-2,875	-0,75	5,625	-2	4,375	-3,25	-1,125	2	2,125	0,25
Nível 04	26,3125	3,3125	-0,1875	-4,4375	0,9375	-2,0625	-1,0625	-1,8125	1,8125	3,8125	3,8125	0,5625	0,4375	-1,5625	0,9375	1,1875




Filtros digitais *wavelet*

Porquê e *wavelet packet*?

- ▶ decompõe a aproximação e os detalhes
- ▶ proporciona um nível de decomposição maior

Engenharia paraconsistente de características


Os vetores de características proporcionam uma boa separação interclasses?(GUIDO, 2019)



- ▶ **Verdade:**
 $\alpha = 1$ e $\beta = 0$.
- ▶ **Ambiguidade:**
 $\alpha = 1$ e $\beta = 1$.
- ▶ **Falsidade:**
 $\alpha = 0$ e $\beta = 1$.
- ▶ **Indefinição:**
 $\alpha = 0$ e $\beta = 0$.

Engenharia paraconsistente de características

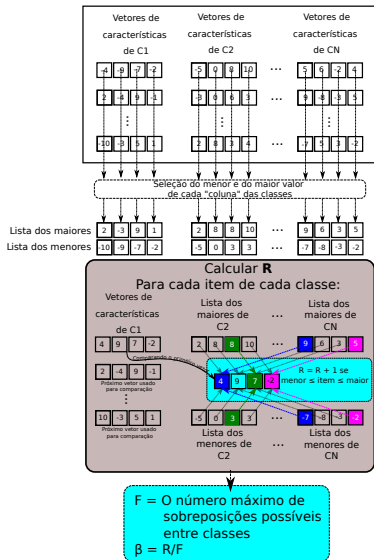
Cálculo de α



Menor similaridade intraclasse, α

Engenharia paraconsistente de características

Cálculo de β



Razão de sobreposição interclasse, β .

Engenharia paraconsistente de características

Graus de certeza e contradição

- ▶ Grau de certeza $\rightarrow G_1 = \alpha - \beta$.
- ▶ Grau de contradição $\rightarrow G_2 = \alpha + \beta - 1$.

Onde: $-1 \leq G_1 \leq 1$ e $-1 \leq G_2 \leq 1$.

Seja $P = (G_1, G_2)$

- ▶ $(-1,0) \rightarrow$ Falsidade;
- ▶ $(1,0) \rightarrow$ Verdade;
- ▶ $(0,-1) \rightarrow$ Indefinição;
- ▶ $(0,1) \rightarrow$ Ambiguidade.

Engenharia paraconsistente de características

Distancias no plano paraconsistente

As distâncias(D) do ponto $P = (G_1, G_2)$ dos limites supracitados. Tal cálculo pode ser feito da seguinte forma:

$$D_{-1,0} = \sqrt{(G_1 + 1)^2 + (G_2)^2} \quad ,$$

$$D_{1,0} = \sqrt{(G_1 - 1)^2 + (G_2)^2} \quad ,$$

$$D_{0,-1} = \sqrt{(G_1)^2 + (G_2 + 1)^2} \quad ,$$

$$D_{0,1} = \sqrt{(G_1)^2 + (G_2 - 1)^2} \quad ,$$

Estado-da-arte em autenticação por voz e fala imaginada

► Classificação e tratamento de EEG:

- O estudo de (PARK; LEE, 2023) explora o uso de EEG para fala imaginada com NA-MEMD e DTWPT, usando MRF-CNN para classificar sinais decompostos. A acurácia média foi 80,41%.
- Em (ABDULGHANI; WALTERS; ABED, 2023), utilizou-se Wavelet Scattering Transform (WST) e uma Rede Neural LSTM para classificar expressões imaginadas, alcançando 92,50% de acurácia.
- O estudo (MAHAPATRA; BHUYAN, 2023) usou DTWT para processar sinais EEG e alcançou acurácias de 98,18% e 71,60% nas bases MUSE e EPOC, respectivamente.
- A revisão em (SHAH et al., 2022) destacou o uso de filtros Wavelet e algoritmos SVM e CNN, sugerindo a inclusão de métricas como Precisão e Recall para uma visão mais completa.
- O estudo (MAHAPATRA; BHUYAN, 2022) aplicou uma combinação de TCN e CNN com FastICA e DTWT para sinais EEG, alcançando 96,49% de acurácia.
- (AGARWAL; KUMAR, 2022) usou DTWT e dois algoritmos (RF e SVM) para classificar letras imaginadas, obtendo 77,97% de acurácia. Utilizou também CAR para melhorar a SNR.

- ▶ O trabalho em (HERNÁNDEZ-DEL-TORO; REYES-GARCÍA; PINEDA, 2021) usou DTWT, EMD e características baseadas em teoria do caos, alcançando melhores resultados com RF, KNN, SVM e Regressão Logística.
- ▶ Em (MOCTEZUMA et al., 2019), CAR foi combinado com DTWT e TEO para melhorar a SNR, alcançando uma acurácia de 97% com 5 voluntários.
- ▶ (PANACHAKEL; RAMAKRISHNAN, 2021) usou janelas deslizantes e matrizes tridimensionais para classificar sinais EEG, alcançando acurácias de 79,7% a 95,5%.
- ▶ (TAMM; MUHAMMAD; MUHAMMAD, 2020) simplificou uma CNN com transferência de aprendizado, alcançando uma acurácia de 23,98% em uma base de dados reduzida.
- ▶ O estudo de (PANACHAKEL; RAMAKRISHNAN; ANANTHAPADMANABHA, 2019) aplicou transformadas Wavelet de nível 7 e obteve 57,15% de acurácia ao tratar separadamente os vetores de características.
- ▶ (PANACHAKEL; RAMAKRISHNAN; ANANTHAPADMANABHA, 2020) usou uma rede neural profunda e transformada wavelet para duas palavras, alcançando 71,8% de acurácia.

- ▶ A revisão em (SEN et al., 2023) mostrou que SVM, RF, HMM e GMM foram comuns, com técnicas profundas como CNN e RNN emergindo desde 2020.
- ▶ **Classificação e tratamento de voz:**
 - ▶ (WANG et al., 2023) combinou Res2Net com PWPE e ECA, alcançando menos de 8% de EER em contextos variados.
 - ▶ O estudo de (ALI et al., 2022) focou na classificação do gênero usando MFCC e LPC, alcançando 97,07% de acurácia com redes neurais artificiais.
 - ▶ (MENG; ALTAF; JUANG, 2020) introduziu o sistema AVA para autenticação ativa, com uma taxa média de WEER de 3% a 4%.
 - ▶ O estudo (GAO et al., 2021) explorou microfones em fones para criar impressões digitais auditivas, alcançando um EER de 3,64%.
 - ▶ (JIANG et al., 2023) usou sons de estalos para prevenção de spoofing, alcançando uma classificação baseada em vetores de características de 3 dimensões.
 - ▶ O estudo (ANDRÉ, 2021) comparou métodos baseados em distâncias e SVM, alcançando mais de 99% de precisão usando a escala BARK e wavelet Haar.

Os estudos analisados contribuíram para a construção do protocolo de coleta de dados, abordando a importância de filtrar interferências da rede elétrica local e a separabilidade dos canais EEG usando o algoritmo *FastICA*. A fase de extração de características é crucial para o desempenho dos algoritmos de classificação. Também é importante a separação dos indivíduos por sexo, destros e canhotos, além da consideração das ondas cerebrais α , β e θ isoladamente ou em conjunto. Técnicas como DTWT e CAR são comuns na literatura. Estudos demonstram que redes neurais profundas não necessariamente superam redes rasas, e o uso de sinais EEG separados por canal para aumentar a quantidade de dados é uma abordagem interessante. Além disso, técnicas para extração de características continuam como uma das partes mais importantes no projeto de sistemas de análise e reconhecimento de sinais.

Escalas de energia usadas

- ▶ Energia de Teager (TEO): Usada para extração de características em (MOCTEZUMA et al., 2019).
- ▶ Energia de bandas: Obtida usando DTWT para cada banda de frequência em (HERNÁNDEZ-DEL-TORO; REYES-GARCÍA; PINEDA, 2021).

Tipos de classificadores usados

- ▶ Redes Neurais Convolucionais (CNN): Usadas em (PANACHAKEL; RAMAKRISHNAN, 2021), (MAHAPATRA; BHUYAN, 2022).
- ▶ Redes Neurais Recorrentes LSTM (Long-Short Term Memory): Usadas em (ABDULGHANI; WALTERS; ABED, 2023).
- ▶ Support Vector Machines (SVM): Usadas em (SHAH et al., 2022), (HERNÁNDEZ-DEL-TORO; REYES-GARCÍA; PINEDA, 2021).

- ▶ Random Forest (RF): Usado em (AGARWAL; KUMAR, 2022), (HERNÁNDEZ-DEL-TORO; REYES-GARCÍA; PINEDA, 2021), (MOCTEZUMA et al., 2019).
- ▶ Bidirectional Recurrent Neural Networks: Usadas em (MAHAPATRA; BHUYAN, 2023).
- ▶ Deep Neural Networks (DNN): Usadas em (PANACHAKEL; RAMAKRISHNAN; ANANTHAPADMANABHA, 2019), (PANACHAKEL; RAMAKRISHNAN; ANANTHAPADMANABHA, 2020).
- ▶ Hidden Markov Model (HMM): Usado em (MENG; ALTAF; JUANG, 2020).
- ▶ Análise Discriminante e redes neurais artificiais: Usadas em (ALI et al., 2022).
- ▶ ResNet50 com transferência de aprendizado: Usado em (PANACHAKEL; RAMAKRISHNAN, 2021).

Técnicas de extração de características

Comparativo - Referências III

- ▶ Transformada Wavelet Discreta (DTWT): Usada em (MAHAPATRA; BHUYAN, 2023), (HERNÁNDEZ-DEL-TORO; REYES-GARCÍA; PINEDA, 2021).
- ▶ Empirical Mode Decomposition (EMD): Usada em (PARK; LEE, 2023).
- ▶ Wavelet Scattering Transform (WST): Usada em (ABDULGHANI; WALTERS; ABED, 2023) e (PANACHAKEL; RAMAKRISHNAN; ANANTHAPADMANABHA, 2019).
- ▶ FastICA (Independent Component Analysis): Usada em (MAHAPATRA; BHUYAN, 2022).
- ▶ Mel-Frequency Cepstral Coefficients (MFCC): Usada em (ALI et al., 2022), (MENG; ALTAF; JUANG, 2020).
- ▶ Linear Prediction Coefficients (LPC): Usados em (ALI et al., 2022).
- ▶ Teager Energy Operator (TEO): Usado em (MOCTEZUMA et al., 2019).
- ▶ Fourier Transform: Usada para alguns dados em (SEN et al., 2023).

- ▶ Common Average Referencing (CAR): Usado em (AGARWAL; KUMAR, 2022), (HERNÁNDEZ-DEL-TORO; REYES-GARCÍA; PINEDA, 2021), (MOCTEZUMA et al., 2019).
- ▶ Dimensionamento fractal e métodos da teoria do Caos: Usados em (HERNÁNDEZ-DEL-TORO; REYES-GARCÍA; PINEDA, 2021).

Escalas de energia usadas

- ▶ energia das bandas na escala BARK
- ▶ energia das bandas na escala MEL
- ▶ energia das bandas α , β , γ , θ e δ

Tipos de classificadores usados

- ▶ Redes neurais de pulso (SNN)
- ▶ Redes neurais residuais (RNN)

Técnicas de extração de características

- ▶ Transformada Wavelet Discreta (DTWT)
- ▶ Mel-Frequency Cepstral Coefficients (MFCC)
- ▶ Auto-encoders

Contextualização

- ▶ Transformada *Wavelet packet*: Boa resolução em relação às dimensões de tempo e frequência.
- ▶ Características mais disjuntas possíveis para “locutor autêntico” e “ataque de *voice spoofing*”.
- ▶ Engenharia paraconsistente de características.

Abordagem proposta

A Base de Sinais de Voz

Coleta dos dados

- ▶ 20 pessoas.
- ▶ Ambos sexos.
- ▶ Idades entre 7 e 67 anos.
- ▶ Dígitos falados de 0 a 9.
- ▶ Língua portuguesa e inglesa.
- ▶ Total de 820 sinais entre genuínos e falsificados.
- ▶ Quantização de 16 bits.
- ▶ Taxa de amostragem 44100Hz.

A Base de Sinais de Voz

Organização dos dados

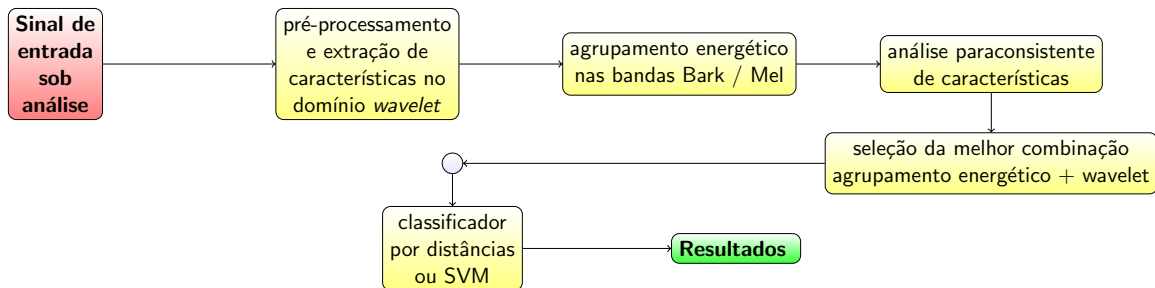
((abc))
Base
com
nivel
123

Figura: Organização da base de dados

Estrutura da Estratégia Proposta

Diagrama

Figura: Estrutura da estratégia proposta



Fonte: Elaborado pelo autor, 2021.

Estrutura da Estratégia Proposta

Wavelets usadas

- ▶ Haar.
- ▶ Beylkin com suporte 18.
- ▶ Vaidyanathan de suporte 24.
- ▶ Daubechies de suportes 4 até 76.
- ▶ Symmlets com suportes 8, 16 e 32.
- ▶ Coiflets com suportes 6, 12, 18, 24 e 30.

Estrutura da Estratégia Proposta

Métricas

- ▶ Tabela de confusão.
 - ▶ EER (Equal Error Rate).
 - ▶ Acurácia e seu respectivo desvio padrão.

Estrutura da Estratégia Proposta

Tabela de confusão

- ▶ **TP**: Quantidade de itens verdadeiros classificados como tal (*True Positive*).
- ▶ **TN**: Quantidade de itens falsos classificados como tal (*True Negative*).
- ▶ **FN**: Quantidade de itens verdadeiros classificados como falsos (*False Negative*).
- ▶ **FP**: Quantidade de itens falsos classificados como verdadeiros (*False Positive*).

Estrutura da Estratégia Proposta


Acurácia e EER


$$acuracia = \frac{TP + TN}{N} \quad , \quad (1)$$


São calculadas tabelas de confusão por um número suficiente de vezes até que **FAR = FRR = EER**, a cada ciclo os vetores de características são comutados de forma aleatória.

$$FAR = \frac{FP}{TN + FP} \quad , \quad (2)$$


$$FRR = \frac{FN}{TP + FN} \quad , \quad (3)$$

 ABDULGHANI, M. M.; WALTERS, W. L.; ABED, K. H. Imagined speech classification using eeg and deep learning. *Bioengineering (Basel)*, MDPI AG, Switzerland, v. 10, n. 6, p. 649–, 2023. ISSN 2306-5354.

 AGARWAL, P.; KUMAR, S. Electroencephalography based imagined alphabets classification using spatial and time-domain features. *International journal of imaging systems and technology*, John Wiley and Sons, Inc, Hoboken, USA, v. 32, n. 1, p. 111–122, 2022. ISSN 0899-9457.


 ALI, Y. M. et al. Speech-based gender recognition using linear prediction and mel-frequency cepstral coefficients. *Indonesian J Electric Eng Comput Sci*, v. 28, n. 2, p. 753–761, 2022.


Referências II

 ANDRÉ, F. *Caracterização de voice spoofing para fins de verificação de locutores com base na Transformada Wavelet e na Análise Paraconsistente de Características*. Dissertação (Mestrado) — Universidade Estadual Paulista - campus de São José do Rio Preto-SP, São José do Rio Preto, Brasil, 2021.

 BERANEK, L. L. *Acoustic Measurements*. [S.l.]: J. Wiley, 1949.

 FREITAS, S. Avaliação acústica e áudio percetiva na caracterização da voz humana. Faculdade de Engenharia da Universidade do Porto, 2013.

 GAO, Y. et al. Voice in ear: Spoofing-resistant and passphrase-independent body sound authentication. *Proc. ACM Interact. Mob. Wearable Ubiquitous Technol.*, Association for Computing Machinery, New York, NY, USA, v. 5, n. 1, mar 2021. Disponível em: <https://doi.org/10.1145/3448113>.

 GUIDO, R. C. Paraconsistent feature engineering [lecture notes]. *IEEE Signal Processing Magazine*, v. 36, n. 1, p. 154–158, Jan 2019.


 HAYKIN, S.; MOHER, M. *Sistemas de Comunicação-5*. [S.l.]: Bookman Editora, 2011.

Referências III


 HERNÁNDEZ-DEL-TORO, T.; REYES-GARCÍA, C. A.; PINEDA, L. Villaseñor. Toward asynchronous eeg-based bci: Detecting imagined words segments in continuous eeg signals. *arXiv.org*, Cornell University Library, arXiv.org, Ithaca, 2021. ISSN 2331-8422.

 JIANG, P. et al. Securing liveness detection for voice authentication via pop noises. *IEEE Transactions on Dependable and Secure Computing*, v. 20, n. 2, p. 1702–1718, 2023.


 KREMER, R. L.; GOMES, M. d. C. A eficiência do disfarce em vozes femininas: uma análise da frequência fundamental. *ReVEL*, v. 12, p. 23, 2014.

 MAHAPATRA, N. C.; BHUYAN, P. Multiclass classification of imagined speech vowels and words of electroencephalography signals using deep learning. *Advances in human-computer interaction*, Hindawi, New York, v. 2022, p. 1–10, 2022. ISSN 1687-5893.

Referências IV

 MAHAPATRA, N. C.; BHUYAN, P. Eeg-based classification of imagined digits using a recurrent neural network. *Journal of neural engineering*, IOP Publishing, England, v. 20, n. 2, p. 26040–, 2023. ISSN 1741-2560.


 MENG, Z.; ALTAF, M. U. B.; JUANG, B.-H. F. Active voice authentication. *DIGITAL SIGNAL PROCESSING*, v. 101, JUN 2020. ISSN 1051-2004.

 MOCTEZUMA, L. A. et al. Subjects identification using eeg-recorded imagined speech. *Expert Systems with Applications*, v. 118, p. 201–208, 2019. ISSN 0957-4174. Disponível em: [〈https://www.sciencedirect.com/science/article/pii/S0957417418306468〉](https://www.sciencedirect.com/science/article/pii/S0957417418306468).


 PANACHAKEL, J.; RAMAKRISHNAN, A. Decoding imagined speech from eeg using transfer learning. *IEEE Access*, PP, 10 2021.


 PANACHAKEL, J. T.; RAMAKRISHNAN, A.; ANANTHAPADMANABHA, T. Decoding imagined speech using wavelet features and deep neural networks. In: *2019 IEEE 16th India Council International Conference (INDICON)*. IEEE, 2019. Disponível em: [〈http://dx.doi.org/10.1109/INDICON47234.2019.9028925〉](http://dx.doi.org/10.1109/INDICON47234.2019.9028925).

 PANACHAKEL, J. T.; RAMAKRISHNAN, A. G.; ANANTHAPADMANABHA, T. V. *A Novel Deep Learning Architecture for Decoding Imagined Speech from EEG*. 2020.


 PARK, H.-j.; LEE, B. Multiclass classification of imagined speech eeg using noise-assisted multivariate empirical mode decomposition and multireceptive field convolutional neural network. *Frontiers in human neuroscience*, Frontiers Media S.A, v. 17, p. 1186594–1186594, 2023. ISSN 1662-5161.


 POLIKAR, R. et al. *The wavelet tutorial*. 1996.


 SEN, O. et al. Machine-learning methods for speech and handwriting detection using neural signals: A review. *Sensors*, v. 23, n. 12, 2023. ISSN 1424-8220. Disponível em: [〈https://www.mdpi.com/1424-8220/23/12/5575〉](https://www.mdpi.com/1424-8220/23/12/5575).


 SHAH, U. et al. The role of artificial intelligence in decoding speech from eeg signals: A scoping review. *Sensors (Basel, Switzerland)*, MDPI AG, Basel, v. 22, n. 18, p. 6975–, 2022. ISSN 1424-8220.


Referências VI

 TAMM, M.-O.; MUHAMMAD, Y.; MUHAMMAD, N. Classification of vowels from imagined speech with convolutional neural networks. *Computers*, MDPI, v. 9, n. 2, p. 46, 2020.

 VALENÇA, E. H. O. et al. Análise acústica dos formantes em indivíduos com deficiência isolada do hormônio do crescimento. Universidade Federal de Sergipe, 2014.

 WANG, S. et al. Voiceprint recognition under cross-scenario conditions using perceptual wavelet packet entropy-guided efficient-channel-attention-res2net-time-delay-neural-network model. *Mathematics*, v. 11, n. 19, 2023. ISSN 2227-7390. Disponível em: <https://www.mdpi.com/2227-7390/11/19/4205>.

 WERTZNER, H. F.; SCHREIBER, S.; AMARO, L. Análise da frequência fundamental, jitter, shimmer e intensidade vocal em crianças com transtorno fonológico. *Revista Brasileira de Otorrinolaringologia*, SciELO Brasil, v. 71, p. 582–588, 2005.

 ZWICKER, E. Subdivision of the Audible Frequency Range into Critical Bands (Frequenzgruppen). *The Journal of the Acoustical Society of America*, v. 33, n. 2, p. 248–248, 02 1961. ISSN 0001-4966. Disponível em: <https://doi.org/10.1121/1.1908630>.