UNIVERSIDADE ESTADUAL PAULISTA
"JÚLIO DE MESQUITA FILHO"
Campus de São José do Rio Preto

André Furlan

Autenticação Biométrica de Locutores Drasticamente Disfônicos Aprimorada pela *Imagined Speech*

São José do Rio Preto
2026

André Furlan

Autenticação Biométrica de Locutores Drasticamente Disfônicos Aprimorada pela *Imagined Speech*

Qualificação apresentada como parte dos requisitos para obtenção do título de Doutor em Ciência da Computação, junto ao Programa de Pós-Graduação em Ciência da Computação, do Instituto de Biociências, Letras e Ciências Exatas da Universidade Estadual Paulista 'Júlio de Mesquita Filho", Campus de São José do Rio Preto.

Orientador: Prof. Dr. Rodrigo Capobianco Guido

São José do Rio Preto

2026

ficha catalografica

André Furlan

Autenticação Biométrica de Locutores Drasticamente Disfônicos Aprimorada pela *Imagined Speech*

Qualificação apresentada como parte dos requisitos para obtenção do título de Doutor em Ciência da Computação, junto ao Programa de Pós-Graduação em Ciência da Computação, do Instituto de Biociências, Letras e Ciências Exatas da Universidade Estadual Paulista 'Júlio de Mesquita Filho", Campus de São José do Rio Preto.

Comissão Examinadora

Prof. Dr. Rodrigo Capobianco Guido
UNESP - Câmpus de São José do Rio Preto
Orientador

Profª Drª Liliane Santana Oliveira Kashiwabara
Universidade Positivo - Campus Londrina

Prof. Dr. Everthon Silva Fonseca
Instituto Federal de São Paulo - Câmpus São José do Rio Preto

São José do Rio Preto
13 de Novembro de 2026

Haha…

Agradecimentos

Agradece

"Citação"

-O Autor.

Resumo

A autenticação biométrica baseada em fala é comprometida quando o locutor apresenta disfonia severa, condição que altera as características acústicas da voz. As bases usadas não têm locutores disfônicos: a disfonia avaliada neste trabalho é **simulada**, por voz sussurrada sintética aplicada à voz de teste, e nenhum locutor disfônico real foi avaliado. Este trabalho investiga complementar a voz com sinais de eletroencefalograma (EEG) registrados durante a fala pronunciada e a fala imaginada. Comparam-se a extração manual de características, baseada na Transformada *Wavelet-Packet* de Tempo Discreto (DTWPT) com agrupamento energético, e a extração automatizada, por *autoencoders* convencionais e de pulsos e por análise de componentes principais (PCA). O extrator é selecionado pela engenharia paraconsistente de características, sem treinar classificador, e a autenticação usa uma rede neural de pulsos residual, avaliada na base pública de (CORETTO; GAREIS; RUFINER, 2017) (15 locutores) sob protocolo de verificação, em que os locutores de teste não aparecem no treino, com a Taxa de Erro Igual (EER) e a área sob a curva ROC (AUC) como métricas. O protocolo inclui controles: uma rede não pulsante gêmea da de pulsos, um classificador sem rede, frases vistas e não vistas no treino, disfonia simulada por voz sussurrada sintética e energia de inferência estimada na passagem de teste. A extração manual vence a seleção paraconsistente nos três sinais; levados ao mesmo classificador, porém, os extratores automatizados atingem EER que não se distingue do manual. A melhor configuração da grade principal, fusão tardia de voz e EEG de fala imaginada, atinge EER de 0,2205 e AUC de 0,8547, contra EER de 0,3180 da voz isolada; com 15 locutores, nenhuma das diferenças entre fontes é estatisticamente significativa, e a fusão não se distingue do EEG sozinho. A rede de pulsos não se distingue da sua gêmea não pulsante em EER e consome de 4,37 a 6,18 vezes mais energia estimada. Sob disfonia simulada, o EER da voz sobe e o das fusões se mantém, sem significância. Uma replicação confirmatória na BIOMEX-DB, com os vencedores congelados e 45 locutores, repete os resultados (EER médio de 0,2580, contra 0,2677 nas mesmas configurações) e torna significativas duas diferenças que a primeira base não detectava: a fusão tardia supera a voz, e a rede treinada supera o classificador sem rede. Como a base tem uma única sessão de gravação por locutor, os resultados de EEG devem ser lidos como limite superior do desempenho entre sessões.

Palavras-chave: biometria; autenticação de locutor; disfonia; análise paraconsistente; *imagined speech*; *wavelet*; *wavelet-packet*; redes neurais de pulso; EEG.

Abstract

Speech-based biometric authentication degrades when the speaker presents severe dysphonia, a condition that alters the acoustic characteristics of the voice. The databases used have no dysphonic speakers: the dysphonia evaluated in this work is **simulated**, by synthetic whispered voice applied to the test voice, and no real dysphonic speaker was evaluated. This work investigates complementing voice with electroencephalogram (EEG) signals recorded during overt and imagined speech. Handcrafted feature extraction, based on the Discrete Time Wavelet Packet Transform (DTWPT) with energy grouping, is compared with automated extraction by conventional and spiking autoencoders and by principal component analysis (PCA). The extractor is selected by Paraconsistent Feature Engineering, without training any classifier, and authentication uses a residual spiking neural network, evaluated on the public database of (CORETTO; GAREIS; RUFINER, 2017) (15 speakers) under a verification protocol, in which test speakers do not appear in training, with Equal Error Rate (EER) and area under the ROC curve (AUC) as metrics. The protocol includes controls: a non-spiking twin of the spiking network, a classifier with no network, phrases seen and unseen in training, dysphonia simulated by synthetic whispered voice, and inference energy estimated on the test pass. Handcrafted extraction wins the paraconsistent selection for the three signals; taken to the same classifier, however, the automated extractors reach an EER that cannot be told apart from the handcrafted one. The best configuration of the main grid, late fusion of voice and imagined-speech EEG, reaches an EER of 0.2205 and an AUC of 0.8547, against an EER of 0.3180 for voice alone; with 15 speakers, none of the differences between sources is statistically significant, and fusion cannot be told apart from EEG alone. The spiking network cannot be told apart from its non-spiking twin in EER and consumes 4.37 to 6.18 times more estimated energy. Under simulated dysphonia, the EER of voice rises and that of the fusions holds, without significance. A confirmatory replication on BIOMEX-DB, with the winners frozen and 45 speakers, repeats the results (mean EER of 0.2580, against 0.2677 for the same configurations) and makes significant two differences the first database could not detect: late fusion beats voice, and the trained network beats the classifier with no network. Since the database has a single recording session per subject, the EEG results should be read as an upper bound on cross-session performance.

Keywords: biometrics; speaker authentication; dysphonia; paraconsistent analysis; imagined speech; wavelet; wavelet-packet; spiking neural networks; EEG.

Lista de ilustrações

Figura 1 – Sub-amostragem 25
Figura 2 – Cálculo de vetores de características com bandas lineares 27
Figura 3 – Cálculo de vetores de características com bandas Mel 28
Figura 4 – Cálculo de vetores de características com bandas Bark 29
Figura 5 – Cálculo de vetores de características com LFCC 30
Figura 6 – Cálculo de vetores de características com MFCC 30
Figura 7 – Cálculo de vetores de características com BFCC 31
Figura 8 – Platôs maximamente planos Daubechies 34
Figura 9 – Platôs maximamente planos outros filtros 35
Figura 10 – Cálculo do coeficiente α. 40
Figura 11 – Cálculo de β 41
Figura 12 – O plano paraconsistente 42
Figura 13 – Sistema 10-20 e lobos cerebrais 47
Figura 14 – Lobos Frontal, Parietal, Occipital e Temporal 48
Figura 15 – Lobo frontal 48
Figura 16 – Lobo parietal 49
Figura 17 – Lobo temporal 49
Figura 18 – Visão geral do telencéfalo 50
Figura 19 – Afasias e seus sintomas 51
Figura 20 – Fluxograma de ajuste/aplicação da normalização 54
Figura 21 – Pulsos de um sinal ruidoso. 55
Figura 22 – Modelo RC 56
Figura 23 – Dispersão em Redes Neurais de Pulsos. 57
Figura 24 – Atividade dispersa de uma RNP 57
Figura 25 – Modelo RC para correntes 58
Figura 26 – Decaimento do potencial da membrana. 60
Figura 27 – Aumento do potencial da membrana. 62
Figura 28 – Gráfico do LIF 63
Figura 29 – Retropropagação Através do Tempo (BPTT) 66
Figura 30 – Fluxograma do algoritmo BPTT 67
Figura 31 – Normalização em Lote Dependente do Limiar (tdBN) 70
Figura 32 – Distribuição dos pesos na inicialização de He/Kaiming 73
Figura 33 – Fluxograma da inicialização de He/Kaiming 74
Figura 34 – Representação funcional de um autoencoder 76
Figura 35 – Exemplo esquemático de um autoencoder sub-completo 76
Figura 36 – Exemplo esquemático de um autoencoder supra-completo 77

Figura 37 – Representação funcional de um *denoising autoencoder* 79
Figura 38 – Bloco residual 80
Figura 39 – Comparação de redes profundas não residuais 81
Figura 40 – Obtenção do resíduo 82
Figura 41 – Organização da base de sinais 97
Figura 42 – Estratégia proposta 103
Figura 43 – Pipeline em duas fases 104
Figura 44 – As três codificações temporais do SNN-AE 108
Figura 45 – Fluxograma da Fase 00 110
Figura 46 – Disfonia simulada numa locução da base 115
Figura 47 – Fluxograma da Fase 01 118
Figura 48 – Demonstração numérica das transformadas Wavelet 168

Lista de tabelas

Tabela 1 – Particionamento espectral da DTWPT por sinal 32
Tabela 2 – Valores das escalas nos extremos e agrupamento resultante 33
Tabela 3 – Algumas das *wavelets* mais usadas e suas propriedades 35
Tabela 4 – Exemplo numérico da transformação *wavelet* 38
Tabela 5 – Exemplo numérico de *wavelet-packet* - porção das baixas frequências . 38
Tabela 6 – Exemplo numérico de *wavelet-packet* - porção das altas frequências . . 38
Tabela 7 – Tarefas cerebrais e suas regiões correspondentes 47
Tabela 8 – Trabalhos de identificação e autenticação por voz e por EEG 92
Tabela 9 – Distribuição da potência do EEG da base 94
Tabela 10 – Informação de locutor na entrada dos autoencoders 106
Tabela 11 – *Autoencoders* (voz) ordenados por $\bar{d}_{\text{pen}}$ crescente (menor = melhor) . . 123
Tabela 12 – *Autoencoders* (EEG de fala pronunciada) ordenados por $\bar{d}_{\text{pen}}$ crescente (menor = melhor) 124
Tabela 13 – *Autoencoders* (EEG de fala imaginada) ordenados por $\bar{d}_{\text{pen}}$ crescente (menor = melhor) 124
Tabela 14 – PCA (voz) ordenada por $\bar{d}_{\text{pen}}$ crescente (menor = melhor) 125
Tabela 15 – PCA (EEG de fala pronunciada) ordenada por $\bar{d}_{\text{pen}}$ crescente (menor = melhor) 125
Tabela 16 – PCA (EEG de fala imaginada) ordenada por $\bar{d}_{\text{pen}}$ crescente (menor = melhor) 125
Tabela 17 – Características manuais (voz) ordenadas por $\bar{d}_{\text{pen}}$ crescente (menor = melhor); † = vencedor do sinal 125
Tabela 18 – Características manuais (EEG de fala pronunciada) ordenadas por $\bar{d}_{\text{pen}}$ crescente (menor = melhor); † = vencedor do sinal 129
Tabela 19 – Características manuais (EEG de fala imaginada) ordenadas por $\bar{d}_{\text{pen}}$ crescente (menor = melhor); † = vencedor do sinal 130
Tabela 20 – Grade principal da Fase 01 (autenticação com a DSNN), ordenada por EER médio crescente 133
Tabela 21 – EER da DSNN e dos dois controles, por fonte e modo de texto (validação plana, características padronizadas) 135
Tabela 22 – Energia de inferência da DSNN e da rede gêmea 136
Tabela 23 – EER sob disfonia simulada, por nível de degradação da voz de teste (frases vistas, validação plana, características padronizadas) 136
Tabela 24 – Extratores comparados pelo mesmo classificador 138
Tabela 25 – Replicação na BIOMEX-DB 139
Tabela 26 – Disfonia simulada na BIOMEX-DB 140

Tabela 27 – Defeitos silenciosos encontrados durante o desenvolvimento 159
Tabela 28 – Arquivos e programas do experimento 162

Lista de abreviaturas e siglas

ANN *Artificial Neural Network* (Rede Neural Artificial) 23

AUC Área sob a Curva (*Area Under the Curve*) 94

BFCC Coeficientes Cepstrais em Frequência Bark (*Bark-Frequency Cepstral Coefficients*) 21

BN *Batch Normalization* (Normalização em Lote) 68

BPTT Retropropagação Através do Tempo (*Backpropagation Through Time*) 16

DCT Transformada Discreta de Cosseno 21

DFT Transformada Discreta de Fourier 29

DSNN *Deep Spiking Neural Network* (rede neural de pulsos profunda) 23

DTWPT Transformada *Wavelet-Packet* em Tempo Discreto 31

DTWT Transformada Wavelet em Tempo Discreto 85

EEG Eletroencefalograma 19

EER Taxa de Erro Igual 19

GRU *Gated Recurrent Unit* (Unidade Recorrente com Portas) 102

JSON *JavaScript Object Notation* 162

LFCC Coeficientes Cepstrais em Frequência Linear (*Linear-Frequency Cepstral Coefficients*) 21

LIF *Leaky Integrate and Fire* (Integra-e-Dispara com Vazamento) 56

LPC *Linear Predictive Coding* (Codificação por Predição Linear) 114

LSTM *Long Short-Term Memory* (Memória de Longo e Curto Prazo) 102

MFCC Coeficientes Cepstrais em Frequência Mel (*Mel-Frequency Cepstral Coefficients*) 21

PCA Análise de Componentes Principais (*Principal Component Analysis*) . . 17

RC Resistor-Capacitor 56

RNP Rede Neural de Pulsos 23

ROC Característica de Operação do Receptor (*Receiver Operating Characteristic*) 112

SNN *Spiking Neural Network* (rede neural de pulsos) 23

STDP Plasticidade Dependente do Tempo de Pulsos (*Spike-Timing-Dependent Plasticity*) 64

tdBN *Threshold-Dependent Batch Normalization* (Normalização em Lote Dependente do Limiar) 68

Sumário

1 INTRODUÇÃO 19
1.1 Contexto e problema 19
1.2 Lacuna e hipótese 20
1.3 Objetivos 20
1.4 Questões de pesquisa 21
1.5 Contribuições 22
1.6 Terminologia 22
1.7 Estrutura do trabalho 23

2 REVISÃO BIBLIOGRÁFICA 24
2.1 Conceitos utilizados 24
2.1.1 Sinais digitais e sub-amostragem (*downsampling*) 24
2.1.2 Caracterização dos processos de produção da voz humana 25
2.1.2.1 Sinais vozeados *versus* não-vozeados 25
2.1.2.2 Frequência fundamental da voz 25
2.1.2.3 Formantes 26
2.1.3 Escalas e energias dos sinais 26
2.1.3.1 Pré-ênfase do sinal de voz 26
2.1.3.2 Energia de um sinal 27
2.1.3.3 Energias em bandas lineares 27
2.1.3.4 Energias em bandas Mel 28
2.1.3.5 Energias em bandas Bark 28
2.1.3.6 Coeficientes LFCC 28
2.1.3.7 Coeficientes MFCC 29
2.1.3.8 Coeficientes BFCC 31
2.1.3.9 Aplicabilidade das escalas Bark e Mel ao EEG 31
2.1.4 Filtros digitais *wavelet* 34
2.1.4.1 O algoritmo de Mallat para a Transformada *Wavelet* 35
2.1.4.2 O algoritmo de Mallat e a Transformada *Wavelet-Packet* 37
2.1.5 Engenharia Paraconsistente de características 39
2.1.5.1 Vulnerabilidade de $D_{1,0}$ isolado e métrica penalizada por contradição 43
2.1.6 Fala imaginada 45
2.1.7 Interfaces Humano-Máquina e EEG 45
2.1.8 Sistema 10-20 e as áreas do cérebro 47
2.1.9 Normalização de Características de Entrada 51

2.1.9.1 Normalização por característica (áudio) . . . 52
2.1.9.2 Normalização por janela (EEG) . . . 52
2.1.9.3 Evitando vazamento de dados . . . 53
2.1.9.4 Exemplo numérico . . . 54
2.1.10 Redes Neurais de Pulsos (Spiking Neural Networks) . . . 54
2.1.10.1 Neurônio de Pulso . . . 56
2.1.10.2 Entendendo e modelando o LIF . . . 56
2.1.10.3 Outra interpretação do LIF . . . 63
2.1.10.4 Treinamento . . . 64
2.1.10.5 BPTT[1] em RNPs . . . 65
2.1.10.6 Gradiente substituto . . . 67
2.1.10.7 Normalização em Lote Dependente do Limiar (tdBN) . . . 68
2.1.10.8 Regularização da taxa de disparo . . . 70
2.1.10.9 Inicialização de Pesos . . . 72
2.1.10.10 Taxa de aprendizado por grupo de parâmetros . . . 74
2.1.11 *Autoencoders* . . . 75
2.1.11.1 Autoencoders sub-completos ou clássicos . . . 77
2.1.11.2 Autoencoders supra-completos . . . 77
2.1.11.3 *Autoencoders* regularizados . . . 77
2.1.11.4 *Denoising autoencoders* . . . 78
2.1.11.5 Colapso do latente no autoencoder pulsante e regularização da taxa de disparo . 79
2.1.12 Redes neurais residuais (ResNets) . . . 80
2.1.12.1 Aprendizado residual . . . 81
2.2 Estado da arte . . . 83
2.2.1 Protocolo de busca . . . 83
2.2.1.1 Critérios de inclusão e exclusão . . . 83
2.2.1.2 Base de dados e palavras-chaves . . . 83
2.2.1.3 Atualização da busca . . . 84
2.2.2 Trabalhos da busca original . . . 85
2.2.3 Atualização: trabalhos de 2023 a 2026 . . . 90
2.2.4 Síntese comparativa . . . 92
2.2.5 Implicações para esta tese . . . 93

3 ABORDAGEM PROPOSTA . . . 96
3.1 A Base de sinais . . . 96
3.1.1 Conferência da base contra o artigo e contra uma cópia independente . . . 97
3.2 A segunda base: replicação confirmatória na BIOMEX-DB . . . 98
3.3 Estrutura da estratégia proposta . . . 100

[1] Retropropagação Através do Tempo (*Backpropagation Through Time*)

3.3.1 Protocolo experimental em duas fases . . . 103
3.3.1.1 Fase 00 — construção e seleção do vetor de características . . . 104
3.3.1.1.1 O que os *autoencoders* e a PCA[2] leem: o espectro, e não a forma de onda. . . . 105
3.3.1.1.2 Codificação temporal e função de perda do treinamento. . . . 107
3.3.1.1.3 Comparação entre as codificações temporais: uma previsão que não se confirmou. . . . 107
3.3.1.1.4 Quão estável é a escolha. . . . 110
3.3.1.2 Fase 01 — autenticação com o vetor vencedor . . . 111
3.3.1.2.1 Arquitetura do classificador DSNN. . . . 111
3.3.1.2.2 Controles: o que a rede de pulsos acrescenta. . . . 112
3.3.1.2.3 Protocolo de verificação: como EER e AUC são calculados. . . . 112
3.3.1.2.4 Os quatro eixos da grade principal. . . . 113
3.3.1.2.5 Disfonia simulada. . . . 113
3.3.1.2.6 Comparação de extratores pelo classificador. . . . 116
3.3.1.2.7 Energia de inferência medida. . . . 116
3.3.1.2.8 Protocolo de treino, de repetição e de comparação. . . . 116
3.3.1.3 Configuração das execuções e transição entre fases . . . 118
3.3.2 Métricas . . . 119
3.3.3 Desenvolvimento e Validação de Algoritmos . . . 119

4 TESTES E RESULTADOS . . . 121
4.1 Fase 00 — Ranking por grau de verdade paraconsistente . . . 121
4.2 Fase 01 — Autenticação . . . 132
4.2.1 Grade principal . . . 132
4.2.2 Controles: o que a rede de pulsos acrescenta . . . 134
4.2.3 Energia de inferência . . . 135
4.2.4 Disfonia simulada . . . 136
4.2.5 Extratores comparados pelo classificador . . . 137
4.3 Replicação na BIOMEX-DB . . . 138
4.4 Retomada das questões de pesquisa . . . 140

5 CONCLUSÕES E TRABALHOS FUTUROS . . . 144
5.1 Síntese dos resultados . . . 144
5.2 Contribuições . . . 145
5.3 Limitações . . . 146
5.4 Trabalhos futuros . . . 147

REFERÊNCIAS . . . 149

[2] Análise de Componentes Principais (*Principal Component Analysis*)

APÊNDICE A – DEFEITOS ENCONTRADOS E CORRIGIDOS DURANTE O DESENVOLVIMENTO 159

APÊNDICE B – REPRODUTIBILIDADE 162

APÊNDICE C – REGULARIZAÇÃO EM REDES NEURAIS . . . 164
C.1 Decaimento de Peso (Regularização L2) 164
C.2 Penalidade de Esparsidade 165
C.3 Regularização da Taxa de Disparo em Redes Neurais de Pulsos . . 165

APÊNDICE D – APLICAÇÃO DE UM FILTRO *WAVELET* . . . 168

1 Introdução

1.1 Contexto e problema

A autenticação biométrica confere a identidade de uma pessoa por uma característica do próprio corpo ou do comportamento, em vez de algo que ela sabe ou possui. A voz é uma dessas características, com a vantagem de ser captada por um microfone comum (HANSEN; HASAN, 2015). Ela tem, porém, uma fragilidade que as outras biometrias compartilham em graus diferentes: o sistema compara a amostra de teste com a de cadastro e pressupõe que a característica não mudou entre as duas. Quando muda, o sistema falha com quem mais depende dele. Biometrias que funcionam pior para certos grupos já foram documentadas, como o reconhecimento facial em pessoas de pele mais escura (GROTHER; NGAN; HANAOKA, 2019).

A disfonia é um caso extremo dessa mudança. Uma pessoa cadastrada com a voz saudável que passa a ter a voz soprosa, rouca ou quase sem som apresenta, no teste, um sinal acusticamente diferente do cadastrado. A patologia, por si só, não impede a verificação: quando cadastro e teste são da mesma condição, falantes disfônicos são verificados pelo menos tão bem quanto os de controle (Tayebi Arasteh *et al.*, 2023). O problema é o descasamento entre a voz do cadastro e a do teste.

O eletroencefalograma (EEG[1]) registrado durante a fala oferece uma segunda fonte de identidade que não passa pelas pregas vocais. Ele carrega informação sobre quem fala (MOCTEZUMA *et al.*, 2019) e também sobre quem apenas *imagina* falar — a fala imaginada, em que nada é vocalizado (BRIGHAM; KUMAR, 2010; DERAKHSHESH *et al.*, 2025). Uma assinatura que existe sem fonação é, em princípio, imune à degradação da voz. O EEG também é considerado difícil de falsificar (ALBAIATI *et al.*, 2025). Os custos são práticos: exige touca e eletrodos, tempo de preparo, e sua assinatura muda entre sessões de gravação — em uma base com 345 sujeitos, o EER[2] de verificação passa de 6,7% com um dia entre cadastro e teste a 14,3% com um ano (FALLAHI; ARIAS-CABARCOS; STRUFE, 2025).

Um sistema que acompanhe o usuário, como o que este problema pede, precisa ainda de pouco consumo de energia. As redes neurais de pulsos são candidatas por processarem eventos esparsos em vez de valores contínuos; a vantagem, porém, depende da esparsidade da atividade e do modo como a energia é contada (DAMPFHOFFER *et al.*, 2023), e precisa ser medida em vez de presumida.

[1] Eletroencefalograma
[2] Taxa de Erro Igual

1.2 Lacuna e hipótese

As duas buscas bibliográficas desta tese (seção 2.2) encontraram autenticação pela voz, pela voz patológica e pelo EEG, inclusive pelo EEG da fala imaginada. A combinação de voz e EEG aparece em uma base gravada para biometria, avaliada em identificação de conjunto fechado (MORENO-RODRIGUEZ *et al.*, 2021). Nenhum trabalho encontrado avalia essa combinação em verificação com locutores que o sistema não viu no treino, nem o efeito de uma degradação da voz de teste sobre ela.

A **hipótese principal** é que o EEG registrado durante a fala, pronunciada ou imaginada, carrega informação de identidade que não depende da qualidade da voz, e que, combinado a ela, mantém a autenticação quando a voz de teste se degrada. Duas hipóteses secundárias acompanham as escolhas de método:

- o critério da engenharia paraconsistente de características, que mede a separabilidade das classes sem treinar classificador, escolhe os extratores que levam ao menor erro de autenticação;
- uma rede neural de pulsos atinge o mesmo erro de autenticação que uma rede convencional de mesmo grafo, com menor consumo de energia.

A degradação da voz avaliada nesta tese é simulada. As duas bases usadas (seção 3.1 e seção 3.2) não têm locutores disfônicos, e nenhum locutor disfônico real foi gravado ou avaliado. A disfonia é sintetizada sobre a voz de teste de locutores saudáveis, como voz sussurrada (subseção 3.3.1.2.5): um modelo de voz soprosa ou afônica, que não cobre rouquidão, aspereza nem tremor. O título nomeia o problema que motiva o trabalho, a autenticação de locutores com disfonia grave; os resultados medem a hipótese principal sob essa simulação, e não em pacientes.

1.3 Objetivos

O **objetivo geral** é avaliar se a combinação da voz com o EEG registrado durante a fala mantém a autenticação de locutores sob degradação da voz, e com quais extratores de características e classificador.

Os **objetivos específicos** são:

1. comparar a extração manual de características (Transformada *Wavelet-Packet* de Tempo Discreto com agrupamentos energéticos) com a extração automatizada (*auto-encoders* convencionais e de pulsos, e a PCA como referência linear), selecionando-as pela engenharia paraconsistente de características;

2. medir a autenticação pela voz, pelo EEG de fala pronunciada, pelo de fala imaginada e por suas fusões, sob um protocolo de verificação em que os locutores de teste não participam do treino. A voz e o EEG de fala pronunciada são gravados na mesma tentativa, ao mesmo tempo; o EEG de fala imaginada vem de outra tentativa do mesmo locutor e do mesmo enunciado, porque a base não tem fala imaginada com som (seção 3.1);

3. medir o efeito de uma disfonia simulada na voz de teste;

4. comparar a rede de pulsos com controles que isolem o que ela acrescenta — uma gêmea não pulsante e um classificador sem rede — em erro e em energia estimada.

1.4 Questões de pesquisa

As escolhas de extração e de protocolo são guiadas por quatro questões:

Questão 1 — Agrupamento espectral: o esquema de particionamento espectral influencia a qualidade da representação dos sinais? Para responder a essa questão, comparam-se três representações de Categoria 1 — *Linear-band energies*, *Mel-band energies* e *Bark-band energies* — que diferem segundo o critério de agrupamento das bandas de frequência sobre a representação wavelet. A comparação é conduzida apenas para o sinal de **voz**: as escalas Mel e Bark são cocleares, modelam a resolução em frequência da audição humana e, aplicadas ao EEG, degeneram no mesmo particionamento da escala linear (subseção 2.1.3.9).

Questão 2 — Transformação cepstral: a aplicação do logaritmo e da DCT[3] sobre as energias por banda melhora a representação dos sinais? Para responder a essa questão, cada representação de Categoria 1 é comparada com seu correspondente cepstral de Categoria 2: *Linear-band energies* versus LFCC[4], *Mel-band energies* versus MFCC[5] e *Bark-band energies* versus BFCC[6]. Em todos os pares, a única diferença entre as representações é a presença ou ausência da etapa cepstral.

Questão 3 — Autoencoders: os autoencoders conseguem gerar representações mais discriminativas do que as técnicas manuais? Para responder a essa questão, as representações de Categoria 1 e Categoria 2 são comparadas com as de Categoria 3, geradas por *autoencoders*, e com a PCA, incluída como referência linear. A comparação é feita de duas formas: na Fase 00 (subseção 3.3.1), pelo critério paraconsistente $D_{\text{penalizado}}$, que mede a separabilidade das classes *antes* de qualquer classificador; e

[3] Transformada Discreta de Cosseno
[4] Coeficientes Cepstrais em Frequência Linear (*Linear-Frequency Cepstral Coefficients*)
[5] Coeficientes Cepstrais em Frequência Mel (*Mel-Frequency Cepstral Coefficients*)
[6] Coeficientes Cepstrais em Frequência Bark (*Bark-Frequency Cepstral Coefficients*)

na Fase 01 (subseção 3.3.1.2), levando o melhor extrator de cada família ao mesmo classificador e medindo o EER.

Questão 4 — Dependência de texto: o desempenho de autenticação é afetado por o enunciado de teste ter sido visto no treino? Para responder a essa questão, o classificador é treinado com um mesmo conjunto de enunciados e testado, com outros locutores, em dois cenários: com esses mesmos enunciados (o cenário que a literatura chama de dependente de texto) e com enunciados que não participaram do treino (independente de texto). Como o conjunto de treino é idêntico nos dois, a diferença entre eles mede apenas o efeito de o enunciado ser conhecido.

1.5 Contribuições

As contribuições desta tese são de dois tipos. As **experimentais** são a avaliação da autenticação por voz, por EEG de fala pronunciada e imaginada e por suas fusões, sob verificação com locutores fora do treino e sob disfonia simulada, com testes estatísticos corrigidos para validação cruzada; e a comparação da rede de pulsos com dois controles, em erro e em energia medida na passagem de teste. As **de método** são:

1. a métrica $D_{\text{penalizado}}$ (subseção 2.1.5.1), que corrige o critério paraconsistente para não premiar extratores que emitem o mesmo vetor para toda entrada;

2. a medida da incerteza da seleção paraconsistente, pontuando cada extrator em subconjuntos de locutores;

3. o registro dos defeitos silenciosos encontrados durante o desenvolvimento, de como foram detectados e do que invalidaram (Apêndice A).

1.6 Terminologia

Para que um mesmo conceito tenha sempre o mesmo nome, o texto adota:

- **locutor**, para cada pessoa da base usada nesta tese, seja qual for o sinal analisado; **sujeito**, para as pessoas dos trabalhos de EEG citados;

- **fala pronunciada**, a fala vocalizada, e **fala imaginada**, a fala apenas imaginada, sem som;

- **dobra**, cada uma das partes da validação cruzada; "k-fold" só aparece no nome do esquema de validação;

- **rede neural de pulsos** (RNP[7]), o conceito; DSNN, SNN[8]-AE e ANN[9]-AE são nomes de modelos desta tese;
- **erro quadrático médio** (EQM), a perda de reconstrução dos *autoencoders*.

1.7 Estrutura do trabalho

O Capítulo 2 reúne a fundamentação: a definição dos conceitos utilizados está na seção 2.1 — incluindo a engenharia paraconsistente de características e a métrica $D_{\text{penalizado}}$ adotada como critério de seleção (subseção 2.1.5.1) — e a revisão do estado da arte, com a tabela comparativa dos trabalhos de identificação e autenticação por voz e por EEG, na seção 2.2.

O Capítulo 3 define a abordagem proposta: a organização da base de sinais (seção 3.1), a estrutura da estratégia (seção 3.3) e, dentro dela, o protocolo experimental em duas fases (subseção 3.3.1) — a Fase 00, que constrói e seleciona o vetor de características, e a Fase 01 (subseção 3.3.1.2), que treina o classificador de autenticação e onde estão descritos a arquitetura da DSNN[10], seus controles, o protocolo de verificação, os eixos experimentais, a disfonia simulada e a medida de energia. O capítulo encerra com as métricas adotadas.

O Capítulo 4 apresenta os resultados das duas fases e retoma, à luz deles, as quatro questões formuladas acima (seção 4.4). O Capítulo 5 retoma as hipóteses e discute as conclusões, as limitações e os trabalhos futuros. Os apêndices registram os defeitos encontrados e corrigidos durante o desenvolvimento (Apêndice A) e detalham as técnicas de regularização (Apêndice C).

---

[7] Rede Neural de Pulsos
[8] *Spiking Neural Network* (rede neural de pulsos)
[9] *Artificial Neural Network* (Rede Neural Artificial)
[10] *Deep Spiking Neural Network* (rede neural de pulsos profunda)

2 Revisão Bibliográfica

Para desenvolver o trabalho, é necessário definir os conceitos de *downsampling*, filtros digitais *wavelets* e energia, que serão usados para a extração de características dos sinais. No processamento dos sinais de voz, serão revisadas as frequências fundamentais da voz, além das escalas BARK, MEL e Lineares. Também será revisada a engenharia paraconsistente de características, método utilizado para verificar a qualidade das características extraídas. Em seguida, serão estudadas as bases das interfaces Humano-Máquina para eletroencefalograma, que coletaram os dados das regiões do cérebro assim como as próprias regiões cerebrais. Concluída essa etapa, serão revisadas as redes neurais de pulsos, autoencoders e redes neurais residuais.

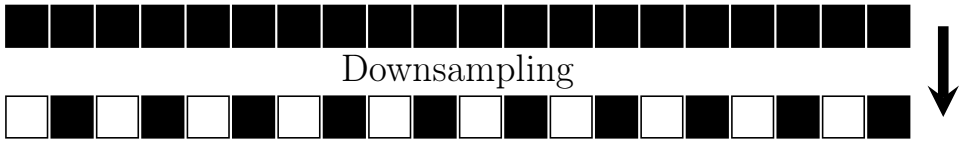
2.1 Conceitos utilizados

2.1.1 Sinais digitais e sub-amostragem (*downsampling*)

Sinais digitais, tanto de voz quanto de EEG, isto é, aqueles que estão amostrados e quantizados (HAYKIN; MOHER, 2011), constituem a base deste trabalho. Além do processo de digitalização, inerente ao ato de armazenar sinais em computadores, os mesmos podem sofrer, a depender da necessidade ou possibilidade, sub-amostragens ou *downsamplings* (POLIKAR *et al.*, 1996). Isso implica em uma estratégia de redução da dimensão e, ocorre após a conversão de domínio dos sinais com base em filtros digitais do tipo *wavelet*, a serem apresentados adiante. A Figura 1, na qual as partes pretas contêm dados e as brancas representam os elementos removidos, ilustra como o sinal é reamostrado. Tendo em vista que este trabalho está baseado em sinais digitais de voz e EEG com base em *wavelets*, o processo de sub-amostragem é parte integrante no processamento dos dados.

O fundamento teórico que legitima a sub-amostragem é o Teorema de Nyquist-Shannon (HAYKIN; MOHER, 2011), segundo o qual um sinal pode ser reconstruído sem perdas desde que a taxa de amostragem seja ao menos o dobro da frequência máxima presente no sinal — denominada frequência de Nyquist. Ao se reduzir à metade a taxa amostral sem essa precaução, componentes de frequência acima do novo limite de Nyquist se sobrepõem às frequências válidas, fenômeno conhecido como *aliasing*, corrompendo irreversivelmente o sinal. Neste trabalho, a sub-amostragem ocorre dentro da decomposição em *wavelets*: os filtros passa-baixa e passa-alta de cada nível limitam a banda do sinal antes da redução amostral, atuando como filtros anti-*aliasing* e garantindo que o critério de Nyquist seja respeitado em cada estágio da decomposição.

Figura 1 – Sub-amostragem



Fonte: Elaborado pelo autor, 2022.

2.1.2 Caracterização dos processos de produção da voz humana

A fala possui três grandes áreas de estudo: A fisiológica, também conhecida como fonética articulatória, a acústica, referida como fonética acústica, e ainda, a perceptual, que cuida da percepção da fala (KREMER; GOMES, 2014). Neste trabalho, o foco será apenas na questão acústica, pois não serão analisados aspectos da fisiologia relacionada à voz, mas sim os sinais sonoros propriamente ditos.

2.1.2.1 Sinais vozeados *versus* não-vozeados

Quando da análise dos sinais de voz, consideram-se as partes vozeadas e não-vozeadas. Aquelas são produzidas com a ajuda da vibração quase periódica das pregas vocais, enquanto estas praticamente não contam com participação da referida estrutura.

2.1.2.2 Frequência fundamental da voz

Também conhecida como F_0, é o componente periódico resultante da vibração das pregas vocais. Em termos de percepção, se pode interpretar F_0 como o tom da voz, isto é, o *pitch* (KREMER; GOMES, 2014). Vozes agudas têm uma frequência de *pitch* alta, enquanto vozes mais graves têm baixa. A alteração da frequência (jitter) e/ou intensidade (shimmer) do *pitch* durante a fala é definida como entonação, porém, também pode indicar algum distúrbio ou doença relacionada ao trato vocal (WERTZNER; SCHREIBER; AMARO, 2005).

A frequência fundamental da voz é o número de vezes na qual uma forma de onda característica, que reflete a excitação pulmonar moldada pelas pregas vocais, se repete por unidade de tempo. Sendo assim, as medidas de F_0 são geralmente apresentadas em Hz (FREITAS, 2013).

A medição de F_0 está sujeita a contaminações surgidas das variações naturais de *pitch* típicas da voz humana (FREITAS, 2013). A importância de se medir F_0 corretamente vem do fato de que, além de carregar boa parte da informação presente na fala, ela é a base para construção das outras medidas que compõem os sinais de voz, que são múltiplas de F_0.

2.1.2.3 Formantes

O sinal de excitação das pregas vocais é rico em harmônicas — frequências múltiplas da fundamental — que são atenuadas ou amplificadas pela geometria do trato vocal e nasal de cada locutor, gerando picos espectrais denominados formantes (VALENÇA *et al.*, 2014; FANT, 1960). Independentemente do idioma, cada formante apresenta articulações universais:

A primeira (F_1) é associada à cavidade oral posterior, reflete a altura da língua (/i/: ≈240 Hz; /u/: ≈300 Hz; /a/: ≈700 Hz).

A segunda (F_2), associada à cavidade oral anterior, codifica a posição horizontal da língua — vogais com recuo lingual e arredondamento labial apresentam F_2 baixo (/u/: ≈625 Hz; /o/: ≈780 Hz), vogais centrais apresentam F_2 intermediário (/a/: ≈1080 Hz) e vogais anteriores apresentam F_2 alto (/e/: ≈1800 Hz; /i/: ≈2250 Hz); articulações dentais e pré-palatais também elevam F_2, o arredondamento labial abaixa todas as formantes e a palatização eleva F_2 e F_3 e reduz F_1.

A terceira formante (F_3) está relacionada às cavidades em torno do ápice da língua, assume valores muito baixos (1500–1800 Hz) em articulações retroflexas — como o /r/ no inglês dos Estados Unidos — contra ≈2500 Hz nas vogais adjacentes.

Formantes acima de F_3 — notadamente F_4 (≈3400–3570 Hz), estão relacionadas à geometria da laringe e faringe. F_5 (≈4000–4655 Hz) — apresenta menor variação entre vogais e pouca distinção fonêmica, mas refletem propriedades anatômicas individuais do trato vocal (FANT, 1960).

Portanto, formantes caracterizam fortemente os locutores, e tais frequências, capturáveis pela Transformada *Wavelet*, são de suma importância na verificação de locutores.

2.1.3 Escalas e energias dos sinais

2.1.3.1 Pré-ênfase do sinal de voz

Antes de calcular energias e coeficientes espectrais do áudio, aplica-se a **pré-ênfase**, um filtro que realça as altas frequências. A motivação é física: no sinal de voz, a fonte glotal impõe uma queda espectral de cerca de -6 dB por oitava, de modo que as formantes superiores — justamente as mais discriminativas entre locutores (seção 2.1) — chegam atenuadas. A pré-ênfase compensa essa inclinação, equilibrando a energia entre bandas baixas e altas antes da extração de características (RABINER; JUANG, 1993).

Sejam $x[n]$ a amostra de áudio no instante n, $y[n]$ a amostra após a pré-ênfase e α o coeficiente de pré-ênfase (tipicamente $0{,}95 \leqslant \alpha \leqslant 0{,}97$; este trabalho usa $\alpha = 0{,}97$). O filtro é de primeira ordem:

$$y[n] = x[n] - \alpha\, x[n-1] \qquad . \tag{2.1}$$

Exemplo numérico. Para $\alpha = 0{,}97$ e as amostras $x = [1{,}0,\ 0{,}9,\ 0{,}6]$: $y[1] = 0{,}9 - 0{,}97 \times 1{,}0 = -0{,}07$ e $y[2] = 0{,}6 - 0{,}97 \times 0{,}9 = -0{,}273$. Trechos de variação lenta (baixa frequência) produzem saída pequena; transições rápidas (alta frequência) são realçadas.

2.1.3.2 Energia de um sinal

A energia de um sinal digital $s[\cdot]$ com M amostras é definida como

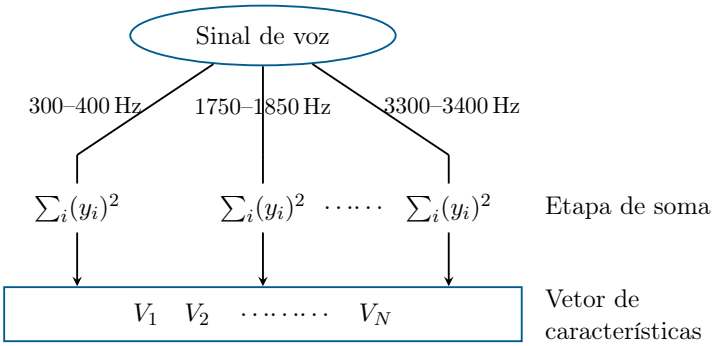
$$E = \sum_{i=0}^{M-1} (s_i)^2 \quad . \tag{2.2}$$

E pode ainda sofrer normalizações e ter a sua mensuração restrita a uma parte específica do sinal sob análise. Neste trabalho, as características extraídas são organizadas em três categorias: na **Categoria 1**, as energias por banda constituem diretamente o vetor de características; na **Categoria 2**, aplica-se adicionalmente o logaritmo e a Transformada Discreta Cosseno (DCT) sobre essas energias para obter coeficientes cepstrais. Por fim na **Categoria 3** utilizam-se *autoencoders* sobre os sinais janelados. A essas categorias soma-se a PCA, extrator de características linear clássico, usado como referência para a extração automatizada. As categorias 1 e 2 compreendem cada uma três esquemas de particionamento espectral — linear, Mel e Bark — resultando em seis tipos de representação descritos a seguir.

2.1.3.3 Energias em bandas lineares

No particionamento linear, as frequências são divididas em N bandas de largura constante e igualmente espaçadas. Para cada banda, a energia dos coeficientes da transformada wavelet correspondentes é acumulada, resultando no vetor $[E_1, E_2, \ldots, E_N]$, como ilustrado na Figura 2.

Figura 2 – Cálculo de vetores de características com bandas lineares

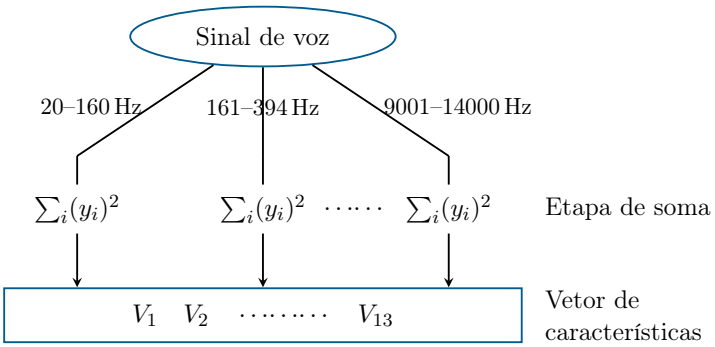


Fonte: Elaborado pelo autor, 2024.

2.1.3.4 Energias em bandas Mel

A escala Mel, advinda do termo *melody*, é uma escala perceptual independente que mapeia as frequências em bandas tonais percebidas pelo ouvido humano. Dentre as várias implementações, a adotada neste trabalho utiliza os seguintes limites de banda em Hz: **20, 160, 394, 670, 1000, 1420, 1900, 2450, 3120, 4000, 5100, 6600, 9000, 14000** (BERANEK, 1949). As energias calculadas nos 13 intervalos resultantes constituem diretamente o vetor de características $[E_1, E_2, \ldots, E_{13}]$, como mostrado na Figura 3.

Figura 3 – Cálculo de vetores de características com bandas Mel



Fonte: Elaborado pelo autor, 2024.

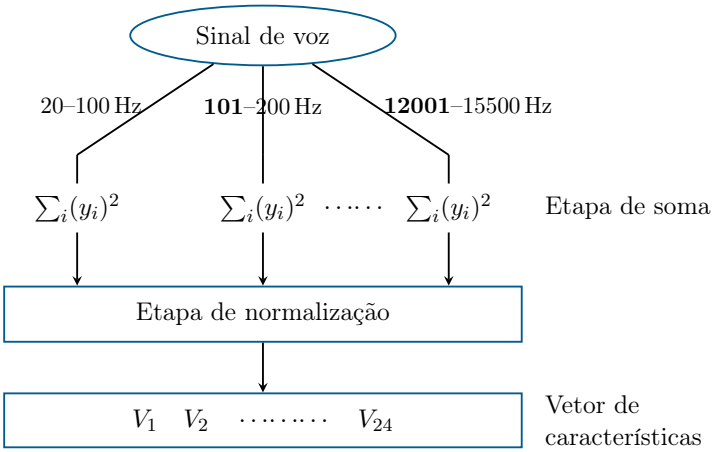
2.1.3.5 Energias em bandas Bark

A escala Bark foi definida tendo em mente vários tipos de sinais acústicos e corresponde ao conjunto de 25 bandas críticas da audição humana. Suas frequências-base de audiometria são, em Hz: **20, 100, 200, 300, 400, 510, 630, 770, 920, 1080, 1270, 1480, 1720, 2000, 2320, 2700, 3150, 3700, 4400, 5300, 6400, 7700, 9500, 12000, 15500** (ZWICKER, 1961). Assim como nos agrupamentos energéticos anteriores o sinal é separado nas bandas de frequências definidas (BOSI; GOLDBERG, 2002), resultando em um vetor de características com 24 componentes, como mostrado na Figura 4.

2.1.3.6 Coeficientes LFCC

Os coeficientes LFCC (*Linear Frequency Cepstral Coefficients*) distribuem os filtros de análise linearmente na faixa $[f_{\min}, f_{\max}]$, contrastando com as escalas Mel e Bark, que comprimem progressivamente as bandas em frequências mais altas para modelar a percepção auditiva humana. Essa compressão é vantajosa para reconhecimento de fala, mas prejudicial para verificação de locutores: as formantes superiores (F_3, F_4), associadas à geometria do trato vocal e à fonte glótica, são discriminativas entre locutores e residem justamente nas faixas descartadas pelas escalas perceptuais (ZHOU *et al.*, 2011; HANILÇI, 2018). Ao manter resolução espectral uniforme, o LFCC preserva esses componentes, sendo preferido ao MFCC para verificação de locutores, com custo computacional comparável (ALI *et al.*, 2022).

Figura 4 – Cálculo de vetores de características com bandas Bark



Fonte: Elaborado pelo autor, 2022.

O cálculo segue as etapas ilustradas na Figura 5: aplica-se a DFT[1] ao sinal janelado e distribui-se um banco de K filtros triangulares com centros equiespaçados linearmente (tipicamente entre 300 Hz e 3400 Hz (ZHOU *et al.*, 2011)):

$$f_k = f_{\min} + k\,\frac{f_{\max} - f_{\min}}{K+1}, \qquad k = 1, \ldots, K \qquad . \tag{2.3}$$

Exemplo numérico. Para $f_{\min} = 300$ Hz, $f_{\max} = 3400$ Hz e $K = 4$ filtros, tem-se $f_k = 300 + k \cdot \frac{3400-300}{5} = 300 + 620k$, resultando em $f_1 = 920$ Hz, $f_2 = 1540$ Hz, $f_3 = 2160$ Hz e $f_4 = 2780$ Hz. Seja E_k a energia logarítmica da banda k e N o número de coeficientes cepstrais desejado ($N \leqslant K$). E_k é então decorrelacionada pela Transformada Discreta de Cosseno (DCT) (ALI *et al.*, 2022), produzindo o coeficiente c_n de cada ordem n:

$$c_n = \sum_{k=1}^{K} \log(E_k)\,\cos\!\left(\pi n\,\frac{2k-1}{2K}\right), \qquad n = 0, \ldots, N-1 \qquad , \tag{2.4}$$

Exemplo numérico. Continuando com $K = 4$, suponha-se as energias logarítmicas já calculadas $\log(E_1) = 1$, $\log(E_2) = 2$, $\log(E_3) = 0{,}5$ e $\log(E_4) = 0$, e deseja-se $N = 2$ coeficientes (c_0 e c_1). Para $n = 0$ todos os cossenos valem 1, logo $c_0 = 1+2+0{,}5+0 = 3{,}5$. Para $n = 1$ os pesos $\cos\big(\pi(2k-1)/8\big)$ valem, para $k = 1, 2, 3, 4$: 0,9239, 0,3827, $-0{,}3827$ e $-0{,}9239$; logo

$$c_1 = 1(0{,}9239)+2(0{,}3827)+0{,}5(-0{,}3827)+0(-0{,}9239) = 0{,}9239+0{,}7654-0{,}1914 = 1{,}4979$$

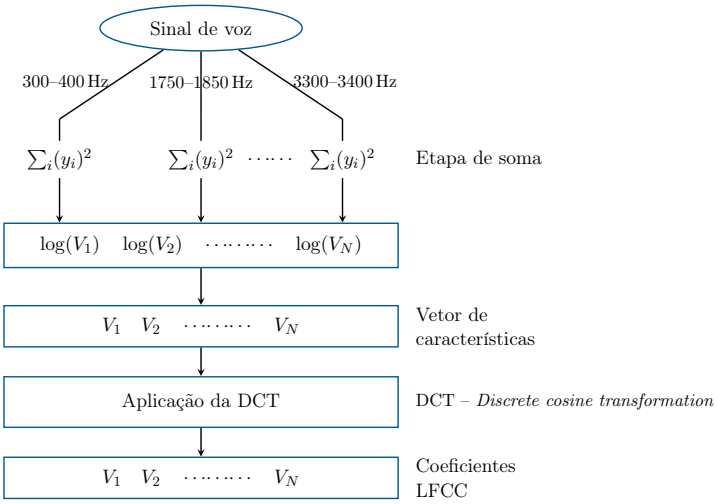
resultando no vetor final $[c_0, c_1, \ldots, c_{N-1}]$ de coeficientes LFCC.

2.1.3.7 Coeficientes MFCC

Os coeficientes MFCC (*Mel-frequency cepstral coefficients*) são obtidos aplicando-se o logaritmo às energias das bandas Mel e em seguida a Transformada Discreta Cosseno

[1] Transformada Discreta de Fourier

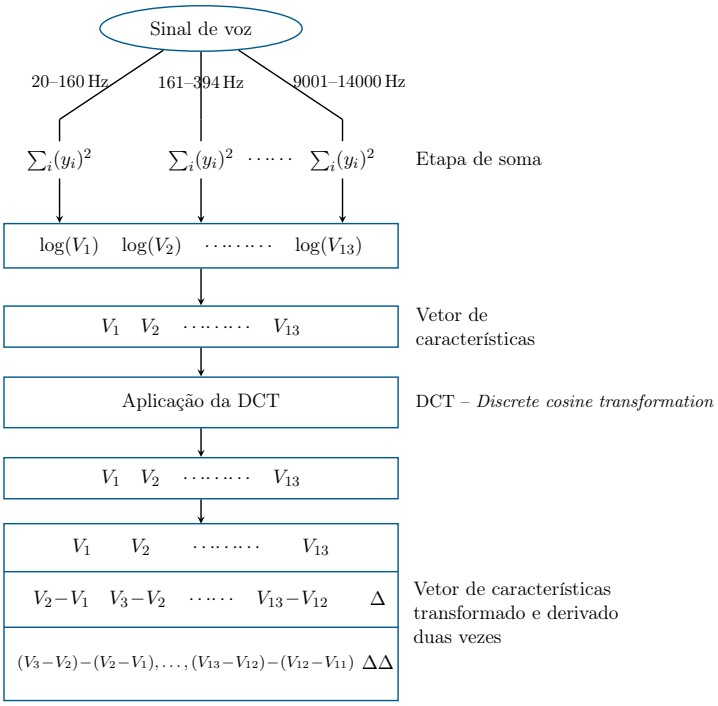
Figura 5 – Cálculo de vetores de características com LFCC



Fonte: Elaborado pelo autor, 2024.

(DCT) (SALOMON; MOTTA; BRYANT, 2007) para decorrelacionar os componentes, resultando em 13 coeficientes cepstrais $(V_1, V_2, \ldots, V_{13})$. Adicionalmente, são calculadas as primeiras e segundas derivadas temporais (Δ e $\Delta\Delta$), estendendo o vetor de características com informação dinâmica sobre a evolução temporal dos coeficientes, como ilustrado na Figura 6.

Figura 6 – Cálculo de vetores de características com MFCC

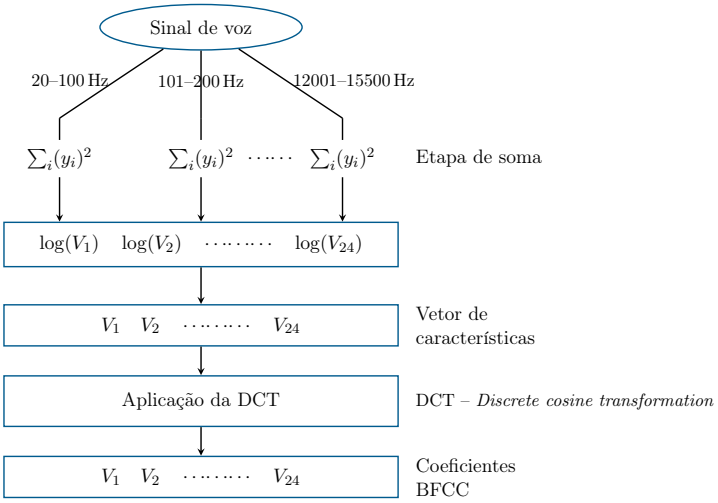


Fonte: Elaborado pelo autor, 2022.

2.1.3.8 Coeficientes BFCC

Os coeficientes BFCC (*Bark-frequency cepstral coefficients*) são obtidos aplicando-se o logaritmo às energias das bandas Bark e em seguida a Transformada Discreta Cosseno (DCT) para decorrelacionar os componentes, resultando em 24 coeficientes cepstrais como ilustrado na Figura 7.

Figura 7 – Cálculo de vetores de características com BFCC



Fonte: Elaborado pelo autor, 2024.

2.1.3.9 Aplicabilidade das escalas Bark e Mel ao EEG

As escalas Bark e Mel apresentadas acima não são escalas de frequência genéricas: ambas são **escalas cocleares**, isto é, modelos empíricos da resolução em frequência da *audição* humana. A Bark corresponde às bandas críticas da membrana basilar e a Mel a julgamentos perceptuais de igual distância tonal; ambas são definidas em Hz e calibradas sobre a faixa audível (≈ 24 Barks entre 0 e ≈ 16 kHz). Aplicá-las a um sinal de EEG — que não é som — carece de base fisiológica: não há membrana basilar segmentando o eletroencefalograma em bandas críticas. Esta subseção mostra que, além dessa objeção conceitual, o eixo da escala é *numericamente inócuo* para o EEG, e explica por quê.

Parâmetros concretos. O agrupamento parte da DTWPT[2] de nível 4, que particiona uniformemente o intervalo $[0, f_{Nyq}]$ em $2^4 = 16$ sub-bandas de largura $\Delta f = f_{Nyq}/16$. Os dois sinais deste trabalho diferem drasticamente em taxa de amostragem, e é daí que tudo decorre:

[2] Transformada *Wavelet-Packet* em Tempo Discreto

Tabela 1 – Particionamento espectral da DTWPT ($2^4 = 16$ sub-bandas uniformes) para cada sinal. A faixa de frequências do EEG (até a frequência de Nyquist) é cerca de 43 vezes mais estreita que a da voz.

	EEG	**Voz**
Taxa de amostragem f_s	1024 Hz	44100 Hz
Frequência de Nyquist f_{Nyq}	512 Hz	22050 Hz
Número de sub-bandas	16	16
Largura de cada sub-banda Δf	32 Hz	1378,125 Hz
Sub-banda 0 (faixa / centro)	0–32 Hz / 16 Hz	0–1378,1 Hz / 689,06 Hz
Sub-banda 15 (faixa / centro)	480–512 Hz / 496 Hz	20671,9–22050 Hz / 21360,9 Hz

Fonte: Elaborado pelo autor, 2026.

O mecanismo do agrupamento. Para *bark* e *mel*, cada sub-banda p tem sua frequência central $f_p = (p+\frac{1}{2})\Delta f$ mapeada pela escala, e o valor resultante é normalizado **pelo valor da escala na frequência de Nyquist do próprio sinal** antes de ser distribuído entre N bins ($N = 24$ para Bark, $N = 20$ para Mel):

$$\mathrm{bin}(p) = \left\lfloor \frac{\mathcal{S}(f_p)}{\mathcal{S}(f_{Nyq})} \cdot N \right\rfloor, \qquad \mathcal{S} \in \{\mathrm{Bark}, \mathrm{Mel}\}. \tag{2.5}$$

Sub-bandas que caem no mesmo bin têm seus coeficientes concatenados num único grupo; bins vazios são descartados. A escala *lfcc* não passa por isso: cada sub-banda é um grupo, dando sempre 16 grupos. A normalização por $\mathcal{S}(f_{Nyq})$ em Equação 2.5 é decisiva — ela remove qualquer ancoragem *absoluta* em Hz e estica a curva para preencher os N bins seja qual for a taxa de amostragem.

Por que o EEG degenera. Tanto Bark quanto Mel são aproximadamente *lineares* perto da origem ($\arctan x \approx x$ e $\log_{10}(1+x) \approx x/\ln 10$ para $x \ll 1$) e só se tornam fortemente compressivas em altas frequências. A faixa do EEG (0–512 Hz) está inteiramente nesse trecho quase-linear; a da voz (0–22 kHz) cobre justamente o trecho compressivo. A Tabela 2 quantifica isso: mede-se a razão entre o valor da escala no centro da última e da primeira sub-banda e compara-se com a razão que uma escala perfeitamente linear daria ($496/16 = 21360{,}9/689{,}06 = 31$).

Tabela 2 – Valores das escalas nos centros das sub-bandas extremas, grau de linearidade sobre a faixa usada, e número de grupos resultante. Para o EEG o mapeamento é injetor (16 sub-bandas → 16 grupos), degenerando exatamente na escala linear; para a voz há fusão real de sub-bandas.

Sinal	Escala	$\mathcal{S}(f_{Nyq})$	$\mathcal{S}(\text{centro}_0)$	$\mathcal{S}(\text{centro}_{15})$	Linearidade	Grupos
EEG	Bark	4,84	0,158	4,702	95,9%	**16**
EEG	Mel	618,66	25,47	603,68	76,5%	**16**
EEG	*lfcc*	—	—	—	(linear)	**16**
Voz	Bark	24,74	6,301	24,689	12,6%	9
Voz	Mel	3923,34	772,33	3888,68	16,2%	11
Voz	*lfcc*	—	—	—	(linear)	16

Fonte: Elaborado pelo autor, 2026.

Com 95,9% de linearidade (Bark) sobre a faixa do EEG, a Equação 2.5 vira uma função praticamente afim e monótona, e como há 24 (ou 20) bins para apenas 16 sub-bandas, o mapeamento resulta **injetor**: os bins obtidos são $[0, 2, 3, 5, 7, 8, 10, 11, 13, 14, 16, 17, 19, 20, 21, 23]$ para Bark e $[0, 2, 3, 5, 6, 8, 9, 10, 11, 13, 14, 15, 16, 17, 18, 19]$ para Mel — todos distintos. Nenhuma sub-banda funde com outra, cada grupo contém exatamente uma sub-banda, e o agrupamento coincide *termo a termo* com o da escala *lfcc*. Já para a voz, a compressão em altas frequências faz as sub-bandas superiores se aglomerarem: os bins da Bark são $[6, 12, 15, 17, 19, 20, 21, 21, 22, 22, 23, 23, 23, 23, 23, 23]$ — as seis últimas sub-bandas caem todas no bin 23 — restando 9 grupos; a Mel deixa 11. Aí, sim, a escala carrega informação: ela decide *quais* sub-bandas são somadas.

Consequência. Para o EEG, a "escala Bark" nunca foi Bark: era uma reescala linear disfarçada, produzindo um vetor de características idêntico ao da escala linear. Isso foi confirmado empiricamente sobre as execuções da Fase 00: nos 46 pares *wavelet* × categoria do EEG, as três escalas produziram D_{verdade} idêntico *bit a bit* — 46 de 46. As únicas exceções aparentes, da *wavelet* `daub32`, diferiam em $\approx 1{,}5 \times 10^{-6}$, ruído de ponto flutuante originado da reexecução isolada daquelas configurações. Das 138 configurações manuais de EEG, portanto, apenas 46 eram genuinamente distintas: 92 execuções eram duplicatas exatas. Por esse motivo o eixo da escala é aplicado somente à voz, e o EEG usa apenas a escala linear (Capítulo 3): 46 configurações manuais por condição de EEG, em vez de 138, sem perda de informação alguma.

Vale registrar a consequência metodológica de não ter percebido isso antes. Como as três variantes empatavam exatamente, o vencedor da Fase 00 para o EEG era determinado pela ordem de desempate da rotina de ranqueamento, e vinha rotulado como *bark*. Afirmar que "a escala Bark venceu para o EEG" seria falso: a Bark não produziu efeito algum, e o vetor vencedor é literalmente o da escala linear. A rotina de ranqueamento passou a detectar e reportar empates exatos de forma explícita, de modo que um desempate

arbitrário não possa ser confundido com um resultado experimental.

2.1.4 Filtros digitais *wavelet*

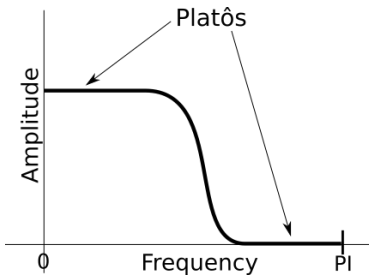
Filtros digitais *wavelet* têm sido utilizados com sucesso para suprir as deficiências de janelamento de sinal apresentadas pelas Transformadas de Fourier e de Fourier de Tempo Reduzido. *Wavelets* contam com variadas funções-filtro e têm tamanho de janela variável, o que permite uma análise multirresolução (ADDISON; WALKER; GUIDO, 2009). Particularmente, as *wavelets* proporcionam a análise do sinal de forma detalhada tanto no espectro de baixa frequência quanto no de alta contando com diferentes funções-base não periódicas diferentemente da tradicional transformada de Fourier que utilizam somente as bases periódicas senoidal e cossenoidal.

É importante observar que, quando se trata de Transformadas *Wavelet*, seis elementos estão presentes: dois filtros de análise, dois filtros de síntese e as funções ortogonais *scaling* e *wavelet*. No tocante a sua aplicação, só a transformada direta, e não a inversa, será usada na construção dos vetores de características. Portanto, os filtros de síntese, a função *scaling* e a função *wavelet* não serão elementos abordados aqui: eles somente interessariam caso houvesse a necessidade da transformada inversa.

No contexto dos filtros digitais baseados em *wavelets*, o tamanho da janela recebe o nome de **suporte**. Janelas definem o tamanho do filtro que será aplicado ao sinal. Quando esse é pequeno (limitado), se diz que a janela tem **um suporte compacto** (POLIKAR *et al.*, 1996).

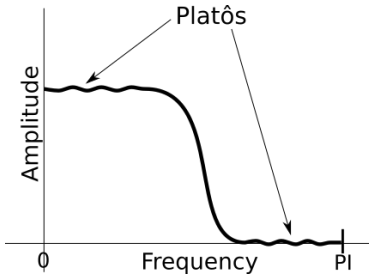
Se diz que uma *wavelet* tem boa **resposta em frequência** quando, na aplicação da mesma para filtragem, não são causadas muitas perturbações indesejadas ao sinal, no domínio da frequência. Os filtros *wavelet* de Daubechies (DAUBECHIES, 1992) se destacam nesse quesito por serem *maximamente planos* (*maximally-flat*) (BUTTERWORTH, 1930) (BIANCHI, 2007) nos platôs de resposta em frequência como indicado na Figura 8 ao contrário do que ocorre na Figura 9.

Figura 8 – Platôs maximamente planos em um filtro digital: característica da família de Daubechies



Fonte: Elaborado pelo autor, 2022.

Figura 9 – Platôs não maximamente planos de um filtro digital: características de outros filtros *wavelet*, distintos da família de Daubechies



Fonte: Elaborado pelo autor, 2022.

Além da resposta em frequência, na aplicação de um filtro digital *wavelet* também é possível considerar a **resposta em fase**, que constitui um atraso ou adiantamento do sinal filtrado em relação ao sinal original, ambos no domínio temporal. Esse deslocamento pode ser **linear**, **quase linear** ou **não linear**:

- na resposta em fase **linear**, há o mesmo deslocamento de fase para todos os componentes do sinal;
- quando a resposta em fase é **quase linear** existe uma pequena diferença no deslocamento dos diferentes componentes do sinal;
- finalmente, quando a resposta é **não linear**, acontece um deslocamento significativamente heterogêneo para as diferentes frequências que compõem o sinal.

Idealmente, é desejável que todo filtro apresente boa resposta em frequência e em fase linear. Características de fase e frequência de algumas famílias de filtros *wavelet* constam na Tabela 3.

Tabela 3 – Algumas das *wavelets* mais usadas e suas propriedades

Wavelet	Resposta em frequência	Resposta em fase
Haar	Pobre	Linear
Daubechies	mais próxima da ideal à medida que o suporte aumenta; *maximally-flat*	Não linear
Symmlets	mais próxima da ideal à medida que o suporte aumenta; não *maximally-flat*	Quase linear
Coiflets	mais próxima da ideal à medida que o suporte aumenta; não *maximally-flat*	Quase linear

Fonte: Elaborado pelo autor, 2022.

2.1.4.1 O algoritmo de Mallat para a Transformada *Wavelet*

Baseando-se no artigo (GUIDO, 2015), percebe-se que o algoritmo de Mallat faz com que aplicação das *wavelets* seja uma simples multiplicação de matrizes. O sinal que

deve ser transformado se torna uma matriz linear vertical. Os filtros passa-baixa e passa-alta tornam-se, nessa ordem, linhas de uma matriz quadrada que será completada segundo regras que serão mostradas mais adiante. É importante que essa matriz quadrada tenha a mesma dimensão que o sinal a ser transformado.

Para que seja possível a transformação *wavelet*, basta ter disponível o vetor do filtro passa-baixas calculado a partir da *mother wavelet*, que é a função geradora desse filtro, já que o passa-alta pode ser construído a partir da ortogonalidade do primeiro.

Determinar a ortogonal de um vetor significa construir um vetor, tal que, o produto escalar do vetor original com sua respectiva ortogonal seja nulo.

Considerando $h[\cdot]$ como sendo o vetor do filtro passa-baixas e $g[\cdot]$ seu correspondente ortogonal, tem-se que $h[\cdot] \cdot g[\cdot] = 0$.

Portanto, se $h[\cdot] = [a, b, c, d]$ então seu ortogonal será $g[\cdot] = [d, -c, b, -a]$ pois:

$$\begin{aligned} h[\cdot] \cdot g[\cdot] &= [a, b, c, d] \cdot [d, -c, b, -a] = (a \cdot d) + (b \cdot (-c)) + (c \cdot b) + (d \cdot (-a)) \\ &= ad - ad + bc - bc = 0 \quad . \end{aligned}$$

A título de exemplo, considera-se:

- o filtro passa baixa baseado na *wavelet* Haar: $h[\cdot] = [\frac{1}{\sqrt{2}}, \frac{1}{\sqrt{2}}]$
- o seu respectivo vetor ortogonal: $g[\cdot] = [\frac{1}{\sqrt{2}}, \frac{-1}{\sqrt{2}}]$
- e também o seguinte sinal-exemplo de entrada: $s = \{1, 2, 3, 4\}$

Se o tamanho do sinal a ser tratado é quatro e se pretende-se aplicar o filtro Haar, a seguinte matriz de coeficientes é construída:

$$\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 & 0 \\ \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} & 0 & 0 \\ 0 & 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \tag{2.6}$$

Tendo em vista que a dimensão do sinal sob análise é diferente da dimensão do filtro, basta completar cada uma das linhas da matriz de coeficientes com zeros. A matriz é montada de forma que ela seja ortogonal.

Uma matriz W é dita ortogonal quando suas linhas (e colunas) são mutuamente ortogonais e têm norma unitária, o que implica $W^T W = W W^T = I$, sendo I a matriz identidade e W^T a transposta de W. Essa propriedade garante que a transformada preserve a energia do sinal — isto é, $\|W.s\|^2 = \|s\|^2$ — e que a inversão seja obtida simplesmente por $W^{-1} = W^T$, sem necessidade de cálculo de inversa.

Montada a matriz de filtros, segue-se com os cálculos da transformada:

$$\begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 & 0 \\ \frac{1}{\sqrt{2}} & \frac{-1}{\sqrt{2}} & 0 & 0 \\ 0 & 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ 0 & 0 & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \cdot \begin{pmatrix} 1 \\ 2 \\ 3 \\ 4 \end{pmatrix} = \begin{pmatrix} \frac{3}{\sqrt{2}} \\ \frac{-1}{\sqrt{2}} \\ \frac{7}{\sqrt{2}} \\ \frac{-1}{\sqrt{2}} \end{pmatrix} \tag{2.7}$$

Realizada a multiplicação, é necessário montar o sinal filtrado. Isso é feito escolhendo, dentro do resultado, valores alternadamente de forma que o vetor resultante seja:

$$resultado = \left[\frac{3}{\sqrt{2}}, \frac{7}{\sqrt{2}}, \frac{-1}{\sqrt{2}}, \frac{-1}{\sqrt{2}}\right] \quad . \tag{2.8}$$

Percebe-se que, na transformação descrita na Equação 2.6, Equação 2.7 e Equação 2.8, a **aplicação dos filtros sobre o vetor de entrada ocorreu apenas uma vez**. Sendo assim, se diz que o sinal recebeu uma **transformação de nível 1**. A cada transformação, há uma separação do sinal em dois componentes: o de baixa e o de alta frequência.

Embora haja um limite, que será mencionado adiante, é possível aplicar mais de um nível de decomposição ao sinal. Para que se possa fazer isso, a Transformada *Wavelet* nível 2 deve considerar apenas a parte de baixas frequências da primeira transformada; a transformada de nível 3 deve considerar apenas a parte de baixas frequências da transformada nível 2, e assim consecutivamente.

A fim de facilitar o entendimento, para fabricar os exemplos numéricos mostrados na Tabela 4, Tabela 5 e Tabela 6, foi usado um filtro normalizado cujos coeficientes são $\{\frac{1}{2}, -\frac{1}{2}\}$. Os dados destacados em **verde** correspondem ao **vetor original** que será tratado. Cada uma das linhas são os resultados das transformações nos níveis 1, 2, 3 e 4, respectivamente. As partes em **azul** correspondem à porção de **baixas frequências**, enquanto que as partes em **laranja** correspondem às porções de **altas frequências**.

Percebe-se que na Tabela 4, a partir da transformação nível 2, apenas as partes de baixa frequência são modificadas. Isso implica que, no momento da implementação do algoritmo de Mallat **para níveis maiores que 1**, a abordagem será **recursiva**. Em outras palavras, a partir do nível 1 se deve aplicar Mallat apenas às porções de baixas-frequências geradas pela transformação anterior.

2.1.4.2 O algoritmo de Mallat e a Transformada *Wavelet-Packet*

Na Transformada *Wavelet-Packet*, os filtros aplicados são os mesmos da Transformada *Wavelet* e o procedimento recursivo de cálculo também é o mesmo, no entanto, realizada a transformação de nível 1, a transformada de nível 2 deve ser aplicada aos componentes de baixa e de alta frequência. Sendo assim a Transformada *Wavelet-Packet*

Tabela 4 – Exemplo numérico da transformação *wavelet* aplicada a um vetor. Tabela completa no Apêndice D.

Sinal	**32**	**10**	**20**	**38**	**37**	**28**	**38**	**34**	**18**	**24**	**24**	**9**	**23**	**24**	**28**	**34**
Nível 01	21	29	32,5	36	21	16,5	23,5	31	11	-9	4,5	2	-3	7,5	-0,5	-3
Nível 02	25	34,25	18,75	27,25	-4	-1,75	2,25	-3,75	11	-9	4,5	2	-3	7,5	-0,5	-3
Nível 03	29,62	23	-4,625	-4,25	-4	-1,75	2,25	-3,75	11	-9	4,5	2	-3	7,5	-0,5	-3
Nível 04	26,3125	3,3125	-4,625	-4,25	-4	-1,75	2,25	-3,75	11	-9	4,5	2	-3	7,5	-0,5	-3

Fonte: Elaborado pelo autor, 2022.

obtém um nível de detalhes em todo o espectro de frequência, maior do que uma transformação regular.

Os exemplos mostrados na Tabela 5 e Tabela 6 permitem perceber como se dão as transformações na porção de **baixa** e de **alta** frequências, respectivamente, após a transformação *wavelet-packet* de nível 1, 2, 3 e 4.

O *downsampling* aplicado às porções de alta frequência, fazem essas partes ficarem "espelhadas" no espectro (JENSEN; COUR-HARBO, 2001), ou seja, suas sequências ficam invertidas. Para resolver esse problema e preservar a ordem das sub-bandas no sinal transformado, os filtros são aplicados em ordem inversa nas porções de alta frequência. Isso altera como o algoritmo de Mallat deve ser implementado para a Transformada *Wavelet-Packet*, já que dessa vez é preciso se atentar a ordem da aplicação dos filtros passa-alta e passa-baixa.

Tabela 5 – Exemplo numérico de *wavelet-packet* Haar aplicada ao vetor da Tabela 4 (porção das baixas frequências). Tabela completa no Apêndice D.

Sinal	**32**	**10**	**20**	**38**	**37**	**28**	**38**	**34**
Nivel 01	21	29	32,5	36	21	16,5	23,5	31
Nivel 02	25	34,25	18,75	27,25	-4	-1,75	2,25	-3,75
Nivel 03	29,62	23	-4,625	-4,25	-1,125	3	-2,875	-0,75
Nivel 04	26,3125	3,3125	-0,1875	-4,4375	0,9375	-2,0625	-1,0625	-1,8125

Fonte: Elaborado pelo autor, 2022.

Tabela 6 – Exemplo numérico de *wavelet-packet* Haar aplicada ao vetor da Tabela 4 (porção das altas frequências). Tabela completa no Apêndice D.

Sinal	**18**	**24**	**24**	**9**	**23**	**24**	**28**	**34**
Nivel 01	11	-9	4,5	2	-3	7,5	-0,5	-3
Nivel 02	10	1,25	-5,25	1,25	1	3,25	2,25	-1,75
Nivel 03	5,625	-2	4,375	-3,25	-1,125	2	2,125	0,25
Nivel 04	1,8125	3,8125	3,8125	0,5625	0,4375	-1,5625	0,9375	1,1875

Fonte: Elaborado pelo autor, 2022.

2.1.5 Engenharia Paraconsistente de características

Nos processos de classificação, frequentemente surge a questão: "Os vetores de características criados proporcionam uma boa separação de classes?". A Engenharia Paraconsistente de Características (GUIDO, 2019), que usa a paraconsistência (COSTA; BÉZIAU; BUENO, 1998), (COSTA; ABE, 2000) é uma ferramenta que pode ser usada para responder essa questão.

O processo inicia-se após a aquisição dos vetores de características para cada classe C_n. Se o número de classes presentes for, por exemplo, quatro então estas poderão ser representadas por C_1, C_2, C_3, C_4.

Em seguida é necessário o cálculo de duas grandezas:

- a menor similaridade intraclasse, α.
- a razão de sobreposição interclasse, β.

α indica o quanto de similaridade os dados têm entre si, dentro de uma mesma classe, enquanto β é a razão de sobreposição entre diferentes classes. Idealmente, α deve ser maximizada e β minimizada assim, mesmo classificadores extremamente modestos podem apresentar um bom desempenho.

Particularmente, para calcular α e β, é necessária a normalização dos vetores de características de forma que todos os seus componentes estejam no intervalo entre 0 e 1. Em seguida, a obtenção de α se dá selecionando-se os maiores e os menores valores de cada uma das posições de todos os vetores de características para cada classe, gerando assim um vetor para os valores maiores e outro para os menores.

O **vetor de similaridade da classe**(svC_n) é obtido fazendo-se a diferença item-a-item dos maiores em relação aos menores. Finalmente, e para cada classe, é obtida a média dos valores para cada vetor de similaridade, sendo que α é o menor valor dentre essas médias. A Figura 10 contém uma ilustração do processo.

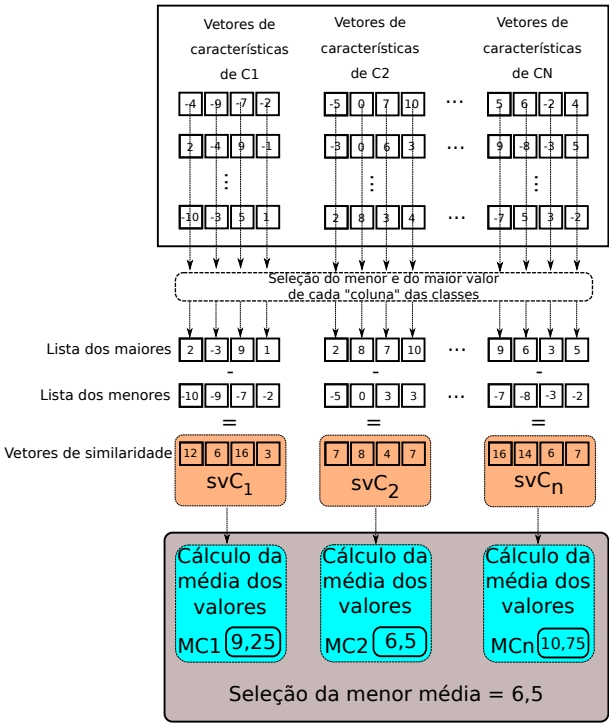
A obtenção de β, assim como ilustrado na Figura 11, também se dá selecionando os maiores e os menores valores de cada uma das posições de todos os vetores de características de cada classe, gerando assim um vetor para os valores maiores e outro para os menores.

Na sequência, realiza-se o cálculo de R cujo valor é a quantidade de vezes que um valor do vetor de características de uma classe se encontra entre os valores maiores e menores de outra classe.

Seja:

- N a quantidades de classes;

Figura 10 – Cálculo do coeficiente α.



Adaptado de (GUIDO, 2019)

- X a quantidade de vetores de características por classe;
- T o tamanho do vetor de características.

Então, F, que é o número máximo de sobreposições possíveis entre classes, é dado por (GUIDO, 2019):

$$F = N.(N-1).X.T \quad . \tag{2.9}$$

Finalmente, β é calculado da seguinte forma (GUIDO, 2019):

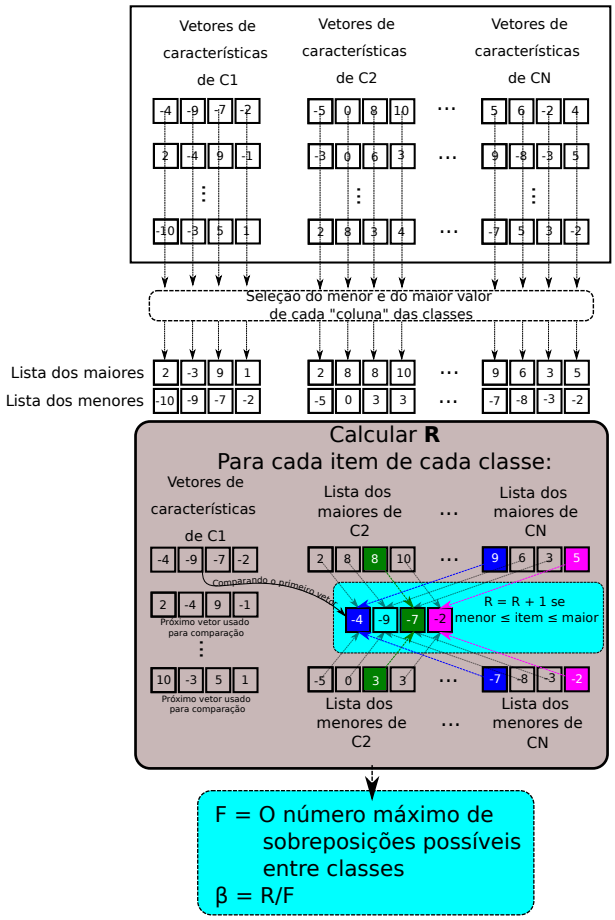
$$\beta = \frac{R}{F} \quad . \tag{2.10}$$

Exemplo numérico. Para $N = 4$ classes, $X = 10$ vetores por classe e $T = 5$ características por vetor, $F = 4 \times 3 \times 10 \times 5 = 600$. Se $R = 45$ sobreposições forem contadas, $\beta = 45/600 = 0{,}075$.

Neste ponto, é importante notar que $\alpha = 1$ sugere fortemente que os vetores de características de cada classe são similares e representam suas respectivas classes precisamente. Complementarmente, $\beta = 0$ sugere os vetores de características de classes diferentes não se sobrepõe (GUIDO, 2019).

Considerando os valores máximos e mínimos que α e β podem assumir é possível ter a seguinte interpretação:

Figura 11 – Cálculo de β: Os itens destacados em azul e rosa são aqueles pertencentes a classe C1 e CN que se sobrepõe, em verde, a sobreposição é entre C1 e C2. Para cada sobreposição verificada soma-se 1 ao valor R. Essa comparação é feita para todos os vetores de características de cada uma das classes.



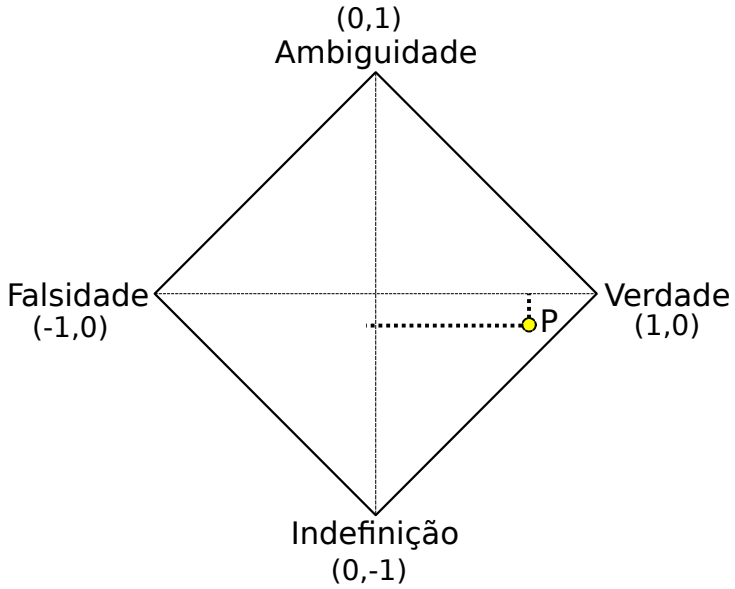
Adaptado de (GUIDO, 2019)

- Verdade → fé total ($\alpha = 1$) e nenhum descrédito ($\beta = 0$)
- Ambiguidade → fé total ($\alpha = 1$) e descrédito total ($\beta = 1$)
- Falsidade → fé nula ($\alpha = 0$) e descrédito total ($\beta = 1$)
- Indefinição → fé nula ($\alpha = 0$) e nenhum descrédito ($\beta = 0$) .

No entanto, é improvável que os valores de α e β assumam valores inteiros, como na listagem apresentada anteriormente, uma vez que $\alpha, \beta \in \mathbb{R}$ e estão restritos aos intervalos $0 \leqslant \alpha \leqslant 1$ e $0 \leqslant \beta \leqslant 1$,

Assim, para fins de visualização e maior rapidez na avaliação dos resultados, o **grau de certeza** (G_1) e o **grau de contradição** (G_2) devem ser calculados, esses valores são utilizados para criar o chamado **plano paraconsistente** ilustrado na Figura 12.

Figura 12 – O plano paraconsistente: O pequeno círculo $P(G_1, G_2)$ indica os graus de falsidade(-1,0), verdade(1, 0), indefinição(0,-1) e ambiguidade(0,1) de acordo com os valores do par ordenado (G_1, G_2)



Adaptado de (GUIDO, 2019)

G_1 e G_2 são obtidos pelas seguintes expressões (GUIDO, 2019):

$$G_1 = \alpha - \beta \quad , \tag{2.11}$$

$$G_2 = \alpha + \beta - 1 \quad , \tag{2.12}$$

Exemplo numérico. Continuando o exemplo anterior, seja $\alpha = 0{,}92$ (menor similaridade intraclasse medida) e $\beta = 0{,}075$ (calculado acima). Então $G_1 = 0{,}92 - 0{,}075 = 0{,}845$ e $G_2 = 0{,}92 + 0{,}075 - 1 = -0{,}005$: o ponto (G_1, G_2) fica próximo de $(1, 0)$, indicando boa separação entre classes. onde: $-1 \leqslant G_1$ e $1 \geqslant G_2$.

Os valores de G_1 e G_2, em conjunto, definem os graus entre verdade ($G_1 = 1$) e falsidade ($G_1 = -1$) e também os graus entre indefinição ($G_2 = -1$) e ambiguidade ($G_2 = 1$). Novamente, raramente tais valores inteiros serão alcançados já que G_1 e G_2 dependem de α e β.

Para se ter ideia em que área exatamente se encontram as classes avaliadas, as distâncias (D) do ponto $P = (G_1, G_2)$ até o limites supracitados podem ser computadas da seguinte forma (GUIDO, 2019):

$$D_{-1,0} = \sqrt{(G_1 + 1)^2 + (G_2)^2} \quad , \tag{2.13}$$

$$D_{1,0} = \sqrt{(G_1 - 1)^2 + (G_2)^2} \quad , \tag{2.14}$$

$$D_{0,-1} = \sqrt{(G_1)^2 + (G_2 + 1)^2} \quad , \tag{2.15}$$

$$D_{0,1} = \sqrt{(G_1)^2 + (G_2 - 1)^2} \qquad . \tag{2.16}$$

Exemplo numérico. Com $G_1 = 0{,}845$ e $G_2 = -0{,}005$ do exemplo anterior:

$$\begin{aligned} D_{-1,0} &= \sqrt{(1{,}845)^2 + (-0{,}005)^2} \approx 1{,}8451, \\ D_{1,0} &= \sqrt{(-0{,}155)^2 + (-0{,}005)^2} \approx 0{,}1551, \\ D_{0,-1} &= \sqrt{(0{,}845)^2 + (0{,}995)^2} \approx 1{,}3054, \\ D_{0,1} &= \sqrt{(0{,}845)^2 + (-1{,}005)^2} \approx 1{,}3131. \end{aligned}$$

$D_{1,0}$ é a menor distância, confirmando que (G_1, G_2) está mais próximo do ponto *"Verdade"*, ou seja, as classes deste exemplo estão bem separadas.

Na prática, ou seja, para fins de classificação, geralmente considera-se a distância em relação ao ponto *"(1,0)* $\rightarrow$ *Verdade"*, que é o ponto ótimo: quanto mais próximo o ponto (G_1, G_2) estiver de $(1, 0)$, mais os vetores de características das diferentes classes estão naturalmente separados. Isso implica, dentro da limitação de cada algoritmo, em resultados melhores.

2.1.5.1 Vulnerabilidade de $D_{1,0}$ isolado e métrica penalizada por contradição

$D_{1,0}$, usado isoladamente como critério de seleção na Fase 00 (Capítulo 3), tem uma fragilidade que só se manifesta quando um dos ramos de extração — os *autoencoders* — é capaz de produzir uma saída praticamente constante, o que ocorre quando o treinamento é insuficiente ou a taxa de aprendizado é excessivamente pequena. Como α mede a similaridade *dentro* de cada classe, uma rede que gera o mesmo vetor de características para toda e qualquer entrada atinge $\alpha = 1$ (dispersão intraclasse nula) — mas, pela própria definição de β como razão de sobreposição *entre* classes, essa mesma saída constante também força $\beta = 1$: se todas as classes ocupam o mesmo ponto do espaço de características, cada vetor de uma classe está necessariamente contido no intervalo de qualquer outra. O par $(\alpha, \beta) = (1, 1)$ corresponde exatamente ao vértice *Ambiguidade* do plano paraconsistente e produz

$$D_{1,0}\big|_{\alpha=\beta=1} = \sqrt{(1-1)^2 + 1^2} = \sqrt{2} \approx 1{,}4142 \qquad , \tag{2.17}$$

valor que, por ser relativamente baixo, pode colocar essa rede **sem nenhuma informação de classe** à frente de extratores genuinamente separáveis no ranking — o critério confunde "vetores idênticos entre si" (que também são, trivialmente, muito parecidos dentro de cada classe) com "vetores bem separados entre classes".

Esse não é um risco hipotético: durante o desenvolvimento desta tese, um *autoencoder* de pulsos cujo latente colapsou atingiu exatamente $\alpha = 1{,}0000$ e $\beta = 1{,}0000$, isto é, $D_{1,0} = 1{,}4142$, valor que o colocaria à frente do extrator manual vencedor no sinal de EEG (Apêndice A, item 2). O mecanismo do colapso é discutido em subseção 2.1.11.5; o

ponto relevante aqui é que o critério de seleção, por si só, não protegia contra esse tipo de degenerescência.

A generalização do problema fica clara ao observar que $\alpha = \beta$ força $G_2 = \alpha+\beta-1 = 2\alpha - 1$ e $G_1 = \alpha - \beta = 0$, ou seja, $(\alpha, \beta) = (k, k)$ desliza sobre o eixo $G_1 = 0$ conforme k varia — o eixo que liga exatamente os vértices *Ambiguidade* $(0, 1)$ e *Indefinição* $(0, -1)$. Como $D_{1,0}$ só enxerga a distância até *Verdade*, ele é cego à proximidade de um ponto desse eixo, que é sempre um estado degenerado: em $(0, 1)$ há concordância perfeita mas sem qualquer poder discriminativo (*Ambiguidade*); em $(0, -1)$ não há concordância nem estrutura alguma (*Indefinição*).

A correção, portanto, precisa penalizar a proximidade desse eixo sem abrir mão da informação já contida em $D_{1,0}$. O grau de contradição G_2 (Equação 2.12) é exatamente a coordenada que mede essa proximidade: seus dois polos, $G_2 = +1$ e $G_2 = -1$, são justamente os vértices *Ambiguidade* e *Indefinição*. Uma primeira tentativa, mais literal — recompensar a proximidade de *Verdade* e penalizar apenas a proximidade de *Ambiguidade* e *Indefinição*, isto é, maximizar $D_{0,1} + D_{0,-1} - D_{1,0}$ — foi testada e descartada: por não penalizar $G_2 = 0$ oposto, isto é, o eixo G_1, essa formulação deixa de penalizar a proximidade do vértice *Falsidade* $(-1, 0)$, e o critério simplesmente desloca o problema — passa a favorecer configurações próximas de *Falsidade* em vez de *Ambiguidade*, já que nada as distingue nessa fórmula. Confirmou-se isso empiricamente: sob essa métrica, a pior codificação testada (a mais próxima de *Falsidade* entre as avaliadas) passava a vencer o ranking.

A métrica adotada preserva $D_{1,0}$ — que já penaliza *Falsidade*, por ser o vértice mais distante de *Verdade* — e soma a ele um termo proporcional a $|G_2|$, o valor absoluto do grau de contradição:

$$D_{\text{penalizado}} = D_{1,0} + \lambda\,|G_2| \qquad , \tag{2.18}$$

em que λ é um peso a determinar. Um critério natural para escolher λ é exigir que os três vértices não-*Verdade* — *Falsidade*, *Ambiguidade* e *Indefinição* — sejam penalizados igualmente, sem viés entre as três formas de degenerescência. Calculando $D_{\text{penalizado}}$ em cada um:

$$\begin{aligned}
\text{Falsidade } (-1,0): &\quad D_{1,0} = 2,\ G_2 = 0 \ \Rightarrow\ D_{\text{penalizado}} = 2,\\
\text{Ambiguidade } (0,1): &\quad D_{1,0} = \sqrt{2},\ G_2 = 1 \ \Rightarrow\ D_{\text{penalizado}} = \sqrt{2} + \lambda,\\
\text{Indefinição } (0,-1): &\quad D_{1,0} = \sqrt{2},\ G_2 = -1 \ \Rightarrow\ D_{\text{penalizado}} = \sqrt{2} + \lambda \qquad .
\end{aligned}$$

Ambiguidade e Indefinição já chegam empatadas por simetria; impondo que também se igualem a Falsidade,

$$\sqrt{2} + \lambda = 2 \implies \lambda = 2 - \sqrt{2} \approx 0{,}5858 \qquad , \tag{2.19}$$

valor que torna os três vértices degenerados igualmente penalizados ($D_{\text{penalizado}} = 2$), preservando $D_{\text{penalizado}} = 0$ apenas em *Verdade*.

Exemplo numérico. Para o caso degenerado discutido acima ($\alpha = \beta = 1$, $G_1 = 0$, $G_2 = 1$, $D_{1,0} = \sqrt{2}$): $D_{\text{penalizado}} = \sqrt{2} + 0{,}5858 \times 1 \approx 2{,}4142$ — o pior valor possível, e não mais um dos melhores. Já para o exemplo numérico apresentado mais acima nesta seção ($G_1 = 0{,}845$, $G_2 = -0{,}005$, $D_{1,0} \approx 0{,}1551$): $D_{\text{penalizado}} \approx 0{,}1551 + 0{,}5858 \times 0{,}005 \approx 0{,}1580$ — praticamente inalterado, pois esse ponto já está longe do eixo Ambiguidade–Indefinição.

Como $D_{\text{penalizado}}$ é função apenas de α e β, ele pode ser recalculado sobre resultados já obtidos sem repetir experimento algum. Todos os *rankings* do Capítulo 4 usam $D_{\text{penalizado}}$, e o efeito da penalização sobre o vencedor de cada sinal é discutido ali.

2.1.6 Fala imaginada

A fala imaginada é um fenômeno em que uma pessoa "ouve"a si mesma falando internamente, sem produzir som. As regiões cerebrais usadas na fala imaginada são similares às que estão envolvidas na fala verbal, englobando áreas do córtex motor e pré-motor, além de outras áreas associadas à linguagem e a fala.

A ativação cerebral durante processos linguísticos (incluindo a fala imaginada) envolve as seguintes regiões (PINTO, 2012), (VANDERAH, 2020), (VASKOVIĆ; OSIKA; MCLAREN, 2024):

- **área de Broca**: Localizada no lobo frontal dominante, é crucial para a produção da fala.
- **área de Wernicke**: Situada no lobo temporal e parietal esquerdo, é fundamental para a compreensão da linguagem.
- **córtex motor e pré-motor**: Envolvidos na execução e planejamento dos movimentos necessários para a articulação da fala.
- **giro supramarginal**: Associado à integração sensorial e ao planejamento motor da fala.
- **giro supratemporal e médio**: Responsáveis pelo processamento da compreensão linguística e pela articulação durante a repetição de sílabas.

Na maioria dos casos, o lobo dominante é o esquerdo, em pessoas canhotas a probabilidade de ser o direito, embora baixa, é maior.

A localização de tais áreas serão mostradas na subseção 2.1.7.

2.1.7 Interfaces Humano-Máquina e EEG

Entre os métodos de Interface Cérebro-Computador (BCI), o Eletroencefalograma (EEG) se destaca como o sistema mais econômico e simples de implementar. O EEG regis-

tra as atividades elétricas do cérebro captando-as através de eletrodos colocados ao longo do couro cabeludo. No entanto possui algumas peculiaridades como alta sensibilidade a interferência eletromagnética e dificuldade em capturar o sinal devido a posicionamentos subótimos dos eletrodos no couro cabeludo. Portanto, um dos aspectos fundamentais que qualquer sistema de processamento de EEG deve ter é a tolerância ao ruído (BIDGOLY; BIDGOLY; AREZOUMAND, 2020).

As atividades elétricas surgem dos fluxos de corrente iônica induzidos pela ativação sináptica sincronizada dos neurônios do cérebro. Elas se manifestam como flutuações de voltagem rítmicas com amplitude variando de 5 a 100μV e com frequência entre 0,5 e 40 Hz (BIDGOLY; BIDGOLY; AREZOUMAND, 2020; MECARELLI, 2019; MASTRANGELO BARBARA SCELSAM, 2019). Para cada tipo de ação realizada, o cérebro trabalha segundo as bandas listadas logo abaixo (SANEI; CHAMBERS, 2021).

Para captação de sinais de EEG usam-se eletrodos que podem ser do tipo úmido ou seco. Os úmidos são colocados usando gel condutivo e são menos propensos a gerar artefatos provocados por movimentos no sinal captado. Artefatos são interferências eletromagnéticas causadas, por exemplo, pelos músculos ao piscar dos olhos. Os eletrodos secos não precisam do gel, mas são mais sensíveis a tais ruídos.

- **Delta (0,5–4Hz)**: A onda mais lenta e geralmente a de maior amplitude. A banda Delta é observada em bebês e durante o sono profundo em adultos com amplitude registrada de até 350 μV.
- **Theta (4–8Hz)**: Observada em crianças, adultos sonolentos e durante a recordação de memórias. A amplitude da onda Theta é tipicamente inferior a 100μV.
- **Alpha (8–12Hz)**: Geralmente a banda de frequência dominante, aparecendo durante a consciência relaxada ou quando os olhos estão fechados. Essas ondas têm amplitudes normalmente inferiores a 50 μV.
- **Beta (12–25Hz)**: Associada ao pensamento, concentração ativa e atenção focada. A amplitude da onda Beta é normalmente inferior a 30 μV.
- **Gamma (acima de 25Hz)**: Observada durante o processamento sensorial múltiplo. Os padrões Gamma têm a menor amplitude, no entanto, até o presente momento não foram encontradas fontes consensuais em relação a tais valores.

As amplitudes das bandas Delta e Gamma não foram encontradas quando procuradas nas principais bases de dados.

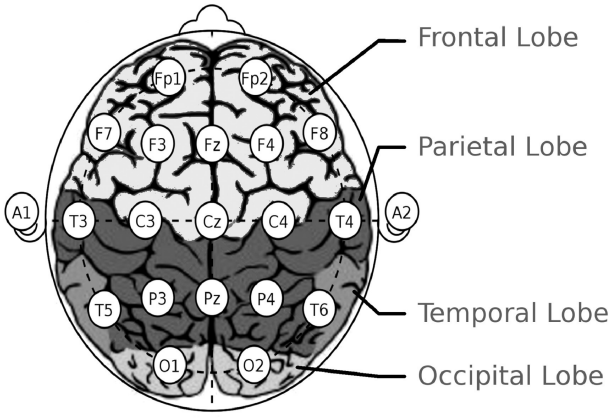
De acordo com (BIDGOLY; BIDGOLY; AREZOUMAND, 2020) e (VICENTE, 2023), para a maioria das tarefas realizadas pelo cérebro, existem regiões associadas a elas, conforme pode ser visto na Tabela 7.

2.1.8 Sistema 10-20 e as áreas do cérebro

Tabela 7 – Tarefas cerebrais e suas regiões correspondentes

Região	Canais	Tarefas
Lobo frontal	Fp1, Fp2, Fpz, Fz, F3, F7, F4, F8	Memória, concentração, emoções.
Lobo parietal	P3, P4, Pz	Resolução de problemas, atenção, sentido do tato.
Lobo temporal	T3, T5, T4, T6	Memória, reconhecimento de faces, audição, palavras e percepção social.
Lobo occipital	O1, O2, Oz	Leitura, visão.
Cerebelo		Controle motor, equilíbrio.
Córtex senso-motor	C3, C4, Cz	Atenção, processamento mental, controle motor fino, integração sensorial.

Figura 13 – Posicionamento dos eletrodos de acordo com o padrão 10-20. Números ímpares são atribuídos aos eletrodos no hemisfério esquerdo, e números pares são atribuídos aos eletrodos no hemisfério direito.



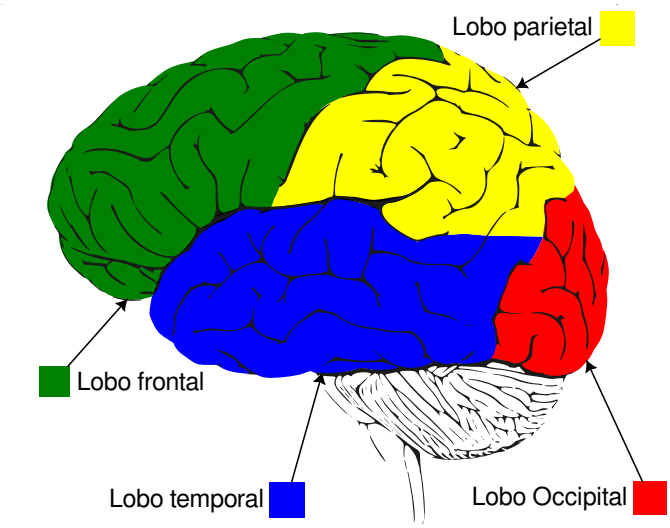
Fonte: (BIDGOLY; BIDGOLY; AREZOUMAND, 2020)

Segundo (ABDULGHANI; WALTERS; ABED, 2023a) e (PINTO, 2012), em se tratando da produção e articulação da fala, a área de Wernicke é responsável por garantir que a mesma faça sentido enquanto que a área de Broca garante que seja produzida de forma fluente portanto, já que a investigação desse trabalho também envolve a fala pronunciada, uma atenção especial deve ser dada a essas regiões. De acordo com a Figura 16, Figura 17 e a Figura 13 os eletrodos frontais e temporais esquerdos F7 e T5 podem estar mais próximos da área de Wernicke e os eletrodos Fp1, F3 e F7 da área de Broca.

No entanto, é importante ressaltar que a fala imaginada, diferentemente da fonada, não mobiliza os córtex motores de forma intensa, ativando de modo mais distribuído as

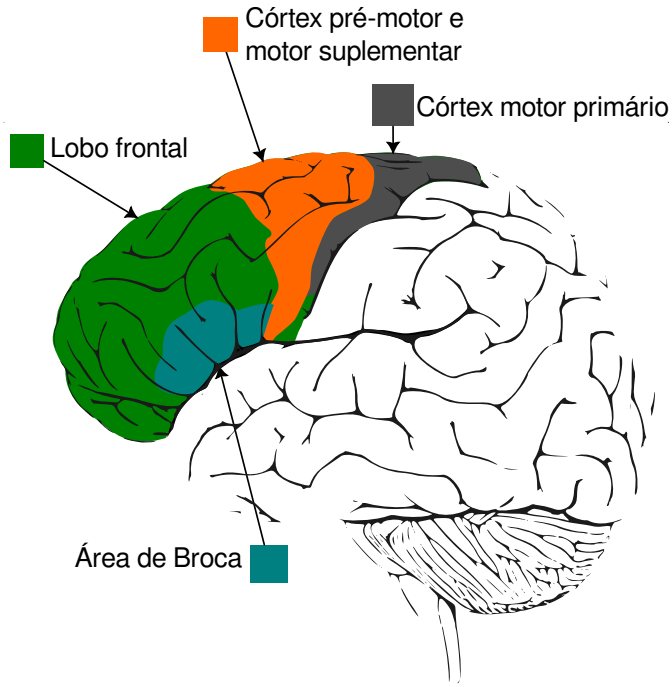
regiões corticais associadas à linguagem e ao processamento fonológico. De acordo com (FLINKER *et al.*, 2015) e (DEWITT; RAUSCHECKER, 2013), tais ativações se estendem por regiões temporais e parietais bilaterais, não se restringindo ao hemisfério dominante como ocorre na maioria dos processos de fala pronunciada.

Figura 14 – Principais regiões do cérebro: Lobos Frontal, Parietal, Occipital e Temporal



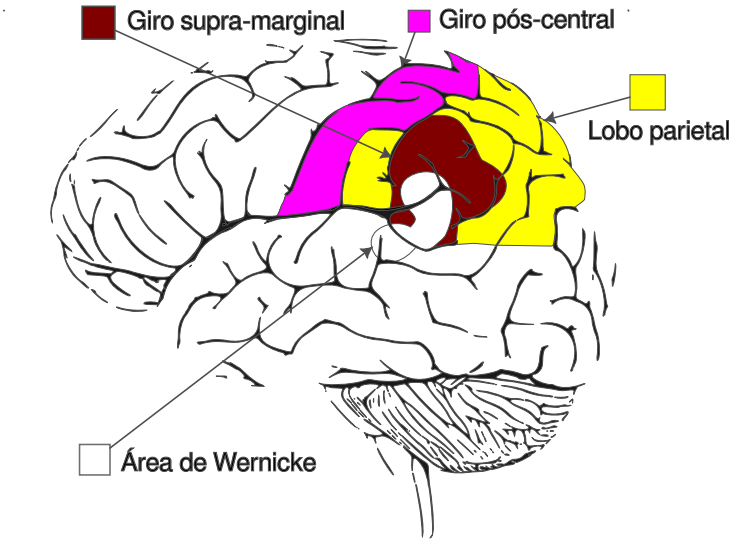
Fonte: Elaborado pelo autor, 2024.

Figura 15 – Áreas relacionadas a fala no lobo frontal: A área de Broca geralmente se encontra no hemisfério esquerdo.



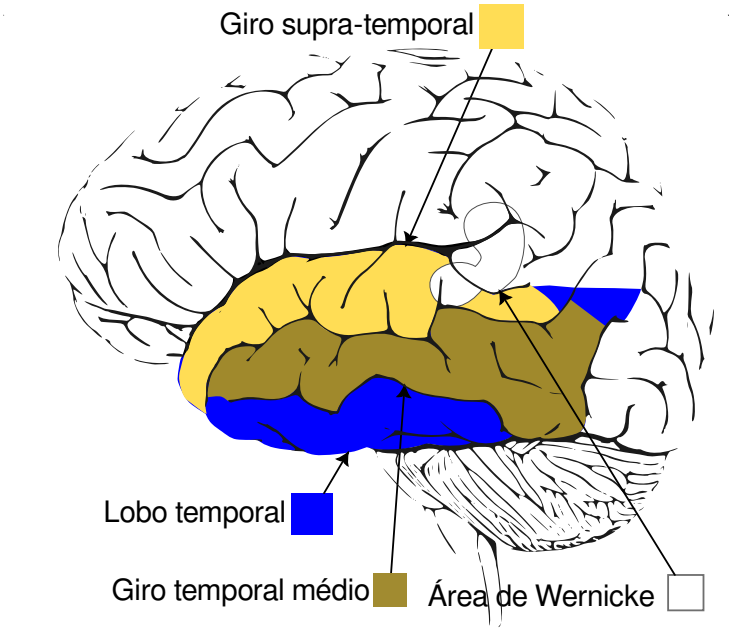
Fonte: Elaborado pelo autor, 2024.

Figura 16 – Áreas relacionadas a fala no lobo parietal: A área de Wernicke também ocupa parte do lobo temporal e geralmente se encontra no hemisfério esquerdo.



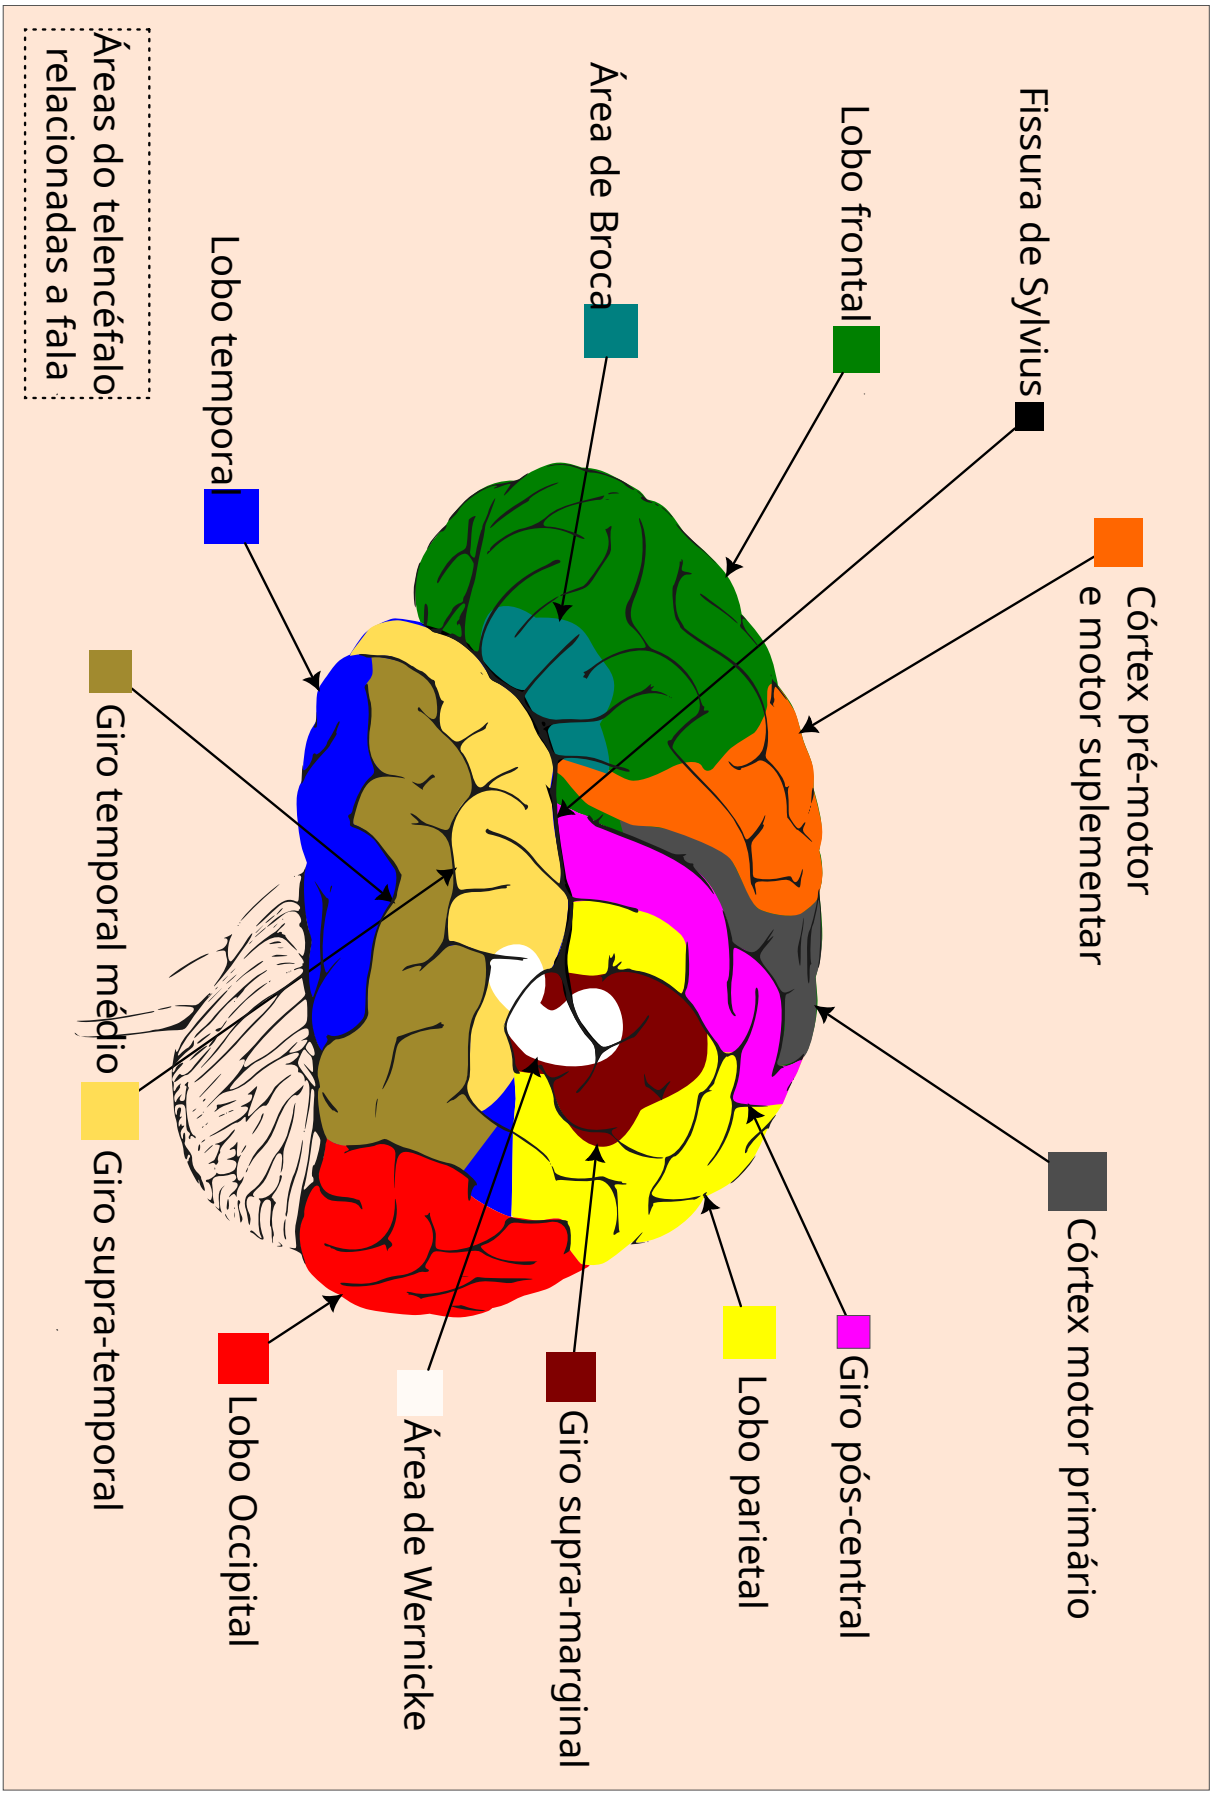
Fonte: Elaborado pelo autor, 2024.

Figura 17 – Áreas relacionadas a fala no lobo temporal: A área de Wernicke também ocupa parte do lobo parietal e geralmente se encontra no hemisfério esquerdo.



Fonte: Elaborado pelo autor, 2024.

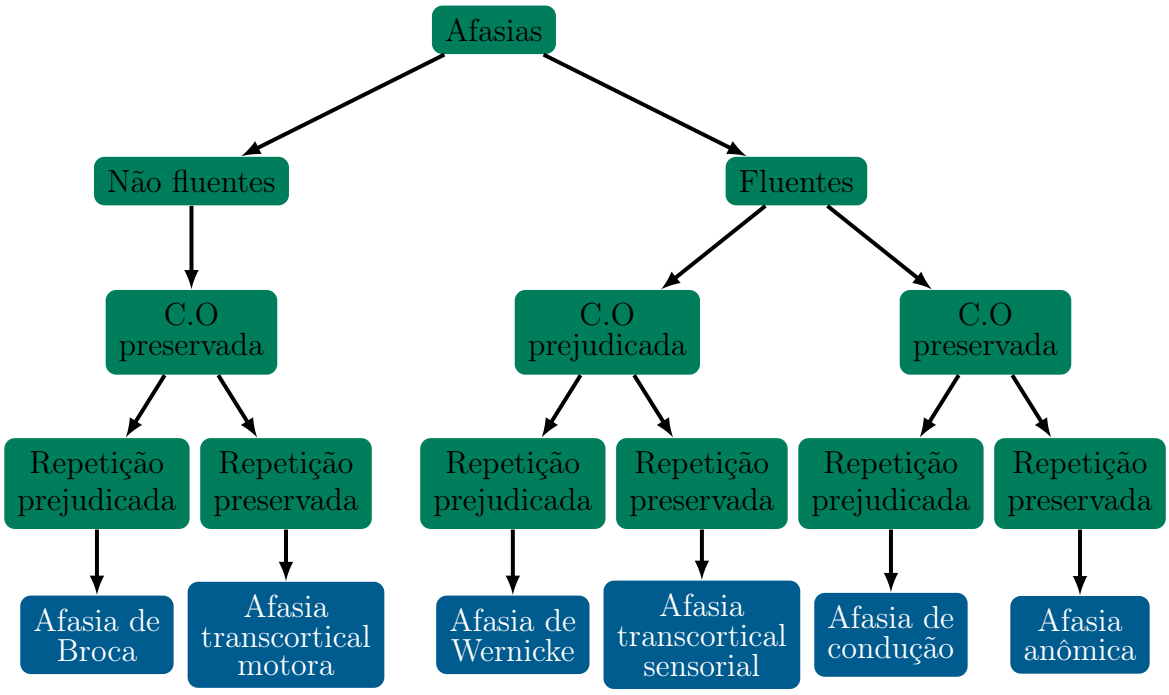
Figura 18 – Visão geral do telencéfalo e as áreas relacionadas à fala, tais regiões avizinham-se da fissura de Sylvius, sendo então chamadas de perissilvianas. O lobo occipital não contêm regiões relacionadas a fala (PINTO, 2012)



Fonte: Elaborado pelo autor, 2024.

O processamento fonológico se dá na região perissilviana do hemisfério dominante, já o semântico inclui áreas corticais de ambos os hemisférios para dar significado às palavras, nas áreas frontais, temporais e parietais, a articulação das palavras acontece. Quando se dá uma lesão em áreas como a de Wernicke, Broca ou em suas vizinhanças à condição resultante se dá o nome de **afasia** que podem ser fluentes (fala com ritmo normal porém incoerente) ou não-fluentes (dificuldade e esforço na produção da fala mas, preservam a compreensão) (PINTO, 2012). Portanto a fala tanto fonada quanto imaginada se realiza em quase todo o telencéfalo tendo como diferença a mobilização dos córtex motores quando o locutor ou locutora emite algum som.

Figura 19 – Afasias e seus sintomas: Sendo C.O. a compreensão oral. As afasias são resultado de lesões: Na área de Broca (Afasia de Broca), nas regiões superiores ou anteriores a área de Broca (Afasia transcortical motora), na área de Wernicke (Afasia de Wernicke) e finalmente ao redor da área de Wernicke (Afasia transcortical sensorial).



Fonte: Adaptado de (PINTO, 2012).

2.1.9 Normalização de Características de Entrada

Não é possível somar metros com quilogramas sem antes convertê-los a uma unidade comum; uma rede neural tem o mesmo problema com características de entrada em escalas diferentes. Se uma característica varia entre 0 e 1 e outra entre 0 e 10 000, o gradiente da segunda domina a atualização dos pesos, e a rede aprende com ela, ignorando a primeira. Reescalonar as entradas para uma faixa comparável, com média próxima de zero, remove essa assimetria e estabiliza e acelera o treinamento por gradiente (LECUN *et al.*, 1998).

Para alimentar os classificadores, este trabalho usa duas estratégias de padronização (*z-score*), uma para o áudio e outra para o EEG, porque as duas modalidades têm comportamentos estatísticos opostos, detalhados a seguir. Uma terceira normalização — a escala mín-máx para o intervalo $[0, 1]$ — é usada em contexto distinto: a engenharia paraconsistente de características (seção 2.1) exige que todos os componentes dos vetores estejam em $[0, 1]$ para que os coeficientes α e β fiquem bem definidos; essa escala é aplicada apenas na etapa de avaliação paraconsistente, não na entrada dos classificadores.

Antes de apresentar as fórmulas das duas padronizações *z-score*, definem-se os símbolos comuns:

- $x_{i,j}$ — valor bruto (não normalizado) na amostra/linha i e característica/coluna j;
- $x'_{i,j}$ — valor normalizado correspondente;
- ε — constante pequena de estabilidade numérica, que evita divisão por zero quando a dispersão calculada é nula (padrão 10^{-6}).

2.1.9.1 Normalização por característica (áudio)

Em um vetor de características de áudio, cada coluna tem significado físico fixo. Como o significado da coluna não muda, sua escala também não muda de amostra para amostra: é uma propriedade da característica, não da amostra.

A estratégia decorrente é: medir, uma vez, a média e o desvio-padrão de cada coluna usando os dados de treino, e reutilizar essas duas constantes para normalizar qualquer amostra, de treino ou de teste. Sejam μ_j a média e σ_j o desvio-padrão da característica (coluna) j, calculados sobre M amostras de treino:

$$x'_{i,j} = \frac{x_{i,j} - \mu_j}{\sqrt{\sigma_j^2 + \varepsilon}}, \qquad \mu_j = \frac{1}{M}\sum_{i=1}^{M} x_{i,j}, \qquad \sigma_j^2 = \frac{1}{M}\sum_{i=1}^{M}(x_{i,j} - \mu_j)^2, \tag{2.20}$$

μ_j e σ_j são calculados uma vez, a partir do treino, e depois reaplicados sem recálculo a qualquer amostra nova — o porquê está na subseção 2.1.9.3. A técnica é conhecida na literatura de reconhecimento de fala como **normalização de média e variância no domínio cepstral** (*Cepstral Mean and Variance Normalization*, CMVN), usada para tornar sistemas de reconhecimento robustos a variações de canal e ruído (VIIKKI; LAURILA, 1998).

2.1.9.2 Normalização por janela (EEG)

O EEG tem o problema oposto. A amplitude de um sinal de EEG não é uma propriedade estável do canal: ela muda de sessão para sessão e de sujeito para sujeito,

por impedância variável dos eletrodos, ganho diferente do amplificador e deslocamento da linha de base (LOTTE *et al.*, 2018). Duas gravações do mesmo canal, em sessões diferentes, podem ter amplitudes diferentes mesmo representando o mesmo tipo de atividade cerebral.

A estratégia do áudio não se aplica aqui: um par (μ, σ) fixo, calculado no treino, não prevê nem corrige o deslocamento de uma sessão nova. A solução inverte a lógica — ao invés de normalizar **por coluna** usando estatísticas fixas do treino, normaliza-se **por linha** (por janela), recalculando a média e o desvio-padrão a cada janela, no momento em que ela é processada. Seja F o número de pontos (características) dentro da janela i:

$$x'_{i,j} = \frac{x_{i,j} - \mu_i}{\sqrt{\sigma_i^2 + \varepsilon}}, \qquad \mu_i = \frac{1}{F}\sum_{j=1}^{F} x_{i,j}, \qquad \sigma_i^2 = \frac{1}{F}\sum_{j=1}^{F}(x_{i,j} - \mu_i)^2, \tag{2.21}$$

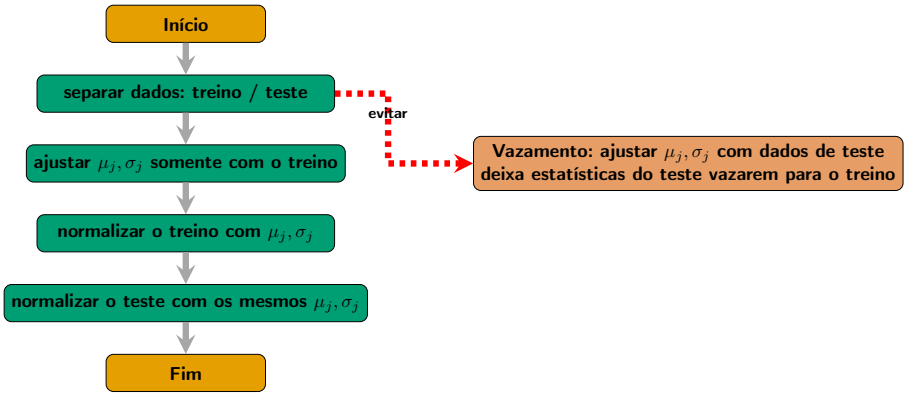
Cada janela corrige seu próprio nível DC e sua própria escala, o que torna o resultado robusto a variações entre sessões, ao custo da amplitude absoluta do sinal — informação pouco confiável no EEG bruto (LOTTE *et al.*, 2018).

2.1.9.3 Evitando vazamento de dados

Imagine estudar para uma prova já sabendo as respostas certas: o desempenho na prova deixaria de refletir o quanto se aprendeu. É isso que acontece quando as estatísticas de normalização são calculadas usando dados que, depois, servirão para avaliar o modelo — **vazamento de dados** (*data leakage*): informação do conjunto de teste influenciando, ainda que indiretamente, o modelo treinado, o que infla as métricas de validação (KAUFMAN *et al.*, 2012).

Por isso, na normalização por característica (Equação 2.20), μ_j e σ_j são calculados exclusivamente com dados de treino e depois aplicados, sem reajuste, a amostras de teste. A Figura 20 ilustra o fluxo correto e o erro a evitar. A normalização por janela do EEG (Equação 2.21) está livre desse risco por construção: como nenhuma estatística global é ajustada a partir do treino, cada janela — de treino ou de teste — é normalizada de forma independente e idêntica.

Figura 20 – Fluxograma de ajuste (*fit*) e aplicação (*transform*) da normalização por característica: as estatísticas μ_j, σ_j são calculadas exclusivamente com o conjunto de treino e depois aplicadas, sem reajuste, tanto ao treino quanto ao teste. Ajustar as estatísticas usando dados de teste (caminho tracejado) causa vazamento de dados.



Fonte: Elaborado pelo autor, 2026.

2.1.9.4 Exemplo numérico

Áudio (por característica). Seja a característica j observada em $M = 4$ amostras de treino: $x_{\cdot,j} = [2,\ 4,\ 4,\ 6]$. Tem-se $\mu_j = (2+4+4+6)/4 = 4$ e $\sigma_j^2 = \left[(2-4)^2+(4-4)^2+(4-4)^2+(6-4)^2\right]/4 = 8/4 = 2$, logo $\sqrt{\sigma_j^2+\varepsilon} \approx 1{,}4142$. Uma amostra de teste com $x_{i,j} = 5$ (nunca vista no ajuste) é normalizada com essas mesmas constantes: $x'_{i,j} = (5-4)/1{,}4142 \approx 0{,}7071$.

EEG (por janela). Seja uma janela com $F = 4$ pontos: $x_{i,\cdot} = [10,\ 12,\ 14,\ 16]\,\mu V$. Tem-se $\mu_i = 13$ e $\sigma_i^2 = \left[(10-13)^2+(12-13)^2+(14-13)^2+(16-13)^2\right]/4 = 20/4 = 5$, logo $\sqrt{\sigma_i^2+\varepsilon} \approx 2{,}2361$. Cada ponto é normalizado com as estatísticas **da própria janela**: $x'_{i,1} = (10-13)/2{,}2361 \approx -1{,}3416$, e assim por diante — se a próxima janela chegar com um deslocamento de linha de base de $+50\,\mu V$ (artefato comum entre sessões), ela recalcula sua própria μ_i e o resultado normalizado permanece na mesma escala, sem estatística herdada da janela anterior.

2.1.10 Redes Neurais de Pulsos (Spiking Neural Networks)

Redes Neurais (RNs), conforme definido aqui como *uma rede multicamadas, totalmente conectada, com ou sem camadas recorrentes ou convolucionais*, exigem que todos os neurônios sejam ativados tanto na fase de *feed-forward* quanto na de *backpropagation*. Isso implica que cada unidade na rede deve processar alguns dados, resultando em consumo de energia (ESHRAGHIAN *et al.*, 2023).

Em contrapartida o neurônio biológico dispara apenas quando um certo nível de sinais excitatórios (voltagem) se acumula acima de um limiar em seu citoplasma, per-

manecendo inativo quando não há sinal, portanto, esse tipo de processamento é muito eficiente em termos de consumo de energia.

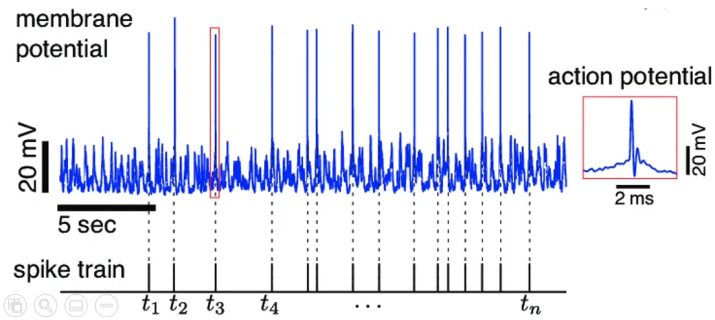
O sistema sensorial dos sistemas neurológicos biológicos converte dados externos, como luz, odores, toque, sabores e outros, em pulsos. Um pulso é uma alteração na voltagem que é propagada transmitindo informações (KASABOV, 2019). Esses pulsos são então transmitidos ao longo da cadeia neuronal sendo processados, gerando uma resposta ao ambiente.

Para obter as vantagens mencionadas, as RNP assim como seus referenciais biológicos, em vez de empregar valores de ativação contínuos, como as RNs, utilizam **pulsos** em suas camadas. As RNPs também podem ter entradas contínuas e manter suas propriedades.

Uma RNP **não é** uma simulação um-para-um de neurônios. Em vez disso, ela aproxima certas capacidades computacionais de propriedades biológicas específicas que serão explicadas mais a diante. Caso haja interesse em algo do tipo existem modelos mais biologicamente precisos como o **neurônio Hodgkin-Huxley** (GERSTNER *et al.*, 2014) ou ainda outros que exploram a não linearidade dos dendritos e outras características neurais (JONES; KORDING, 2020) criando modelos muito mais próximos aos neurônios naturais, obtendo resultados bastante interessantes.

Como pode ser visto na Figura 21, os neurônios das RNPs, com os parâmetros corretos, são muito tolerantes a ruídos porque atuam como um **filtro passa-baixa**. Eles geram pulsos mesmo quando um nível considerável de interferência está presente. Tais neurônios são muito sensíveis ao tempo, sendo ótimos para processar fluxos de dados (ESHRAGHIAN *et al.*, 2023).

Figura 21 – Sinal ruidoso e os pulsos produzidos por uma **simulação** de neurônio de pulso (RNP/LIF) em resposta a esse sinal, ilustrando o comportamento de disparo por limiar discutido no texto. Note que é necessário um acúmulo de sinal suficiente antes que os pulsos comecem a ser exibidos



Fonte: (GOODMAN *et al.*, 2022)

2.1.10.1 Neurônio de Pulso

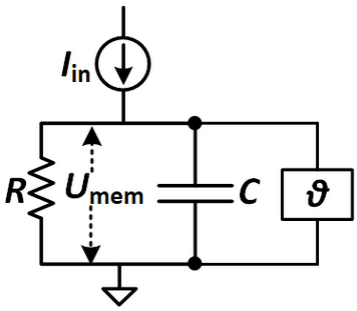
O foco deste trabalho é nos neurônios LIF[3] porque são mais simples, mais eficientes e atualmente generalizam melhor para a maioria dos problemas (GOODMAN *et al.*, 2022).

2.1.10.2 Entendendo e modelando o LIF

O LIF é um dos modelos de neurônios mais simples em RNPs, ainda assim, pode ser aplicado com sucesso na maioria dos problemas em que as RNPs podem ser usadas, tal estrutura, assim como um neurônio de RN, recebe a soma das entradas ponderadas, mas, em vez de passá-lo diretamente para sua função de ativação, algum *vazamento* é aplicado, diminuindo em algum grau o valor soma com o passar do tempo.

O LIF se assemelha com circuitos RC[4], como pode ser visto na Figura 22. Aqui, R é a resistência ao vazamento da corrente, I_{in} é a corrente de entrada, C é a capacitância, U_{mem} representa o potencial acumulado e ϑ é um interruptor que permite que o capacitor se descarregue (ou seja, emita um pulso) quando um determinado limiar de potencial é alcançado.

Figura 22 – O modelo RC



Fonte: (ESHRAGHIAN *et al.*, 2023)

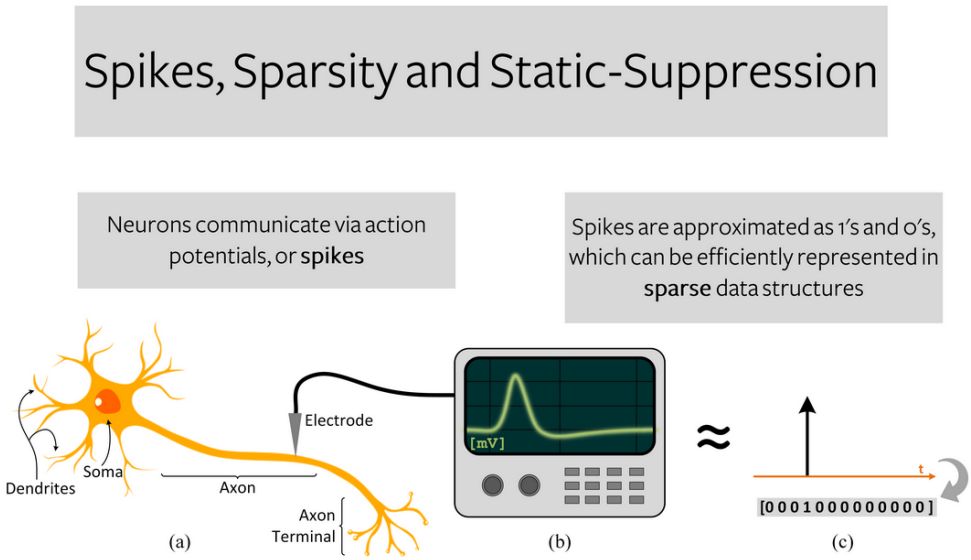
Ao contrário do neurônio Hodgkin-Huxley, os pulsos são representados como **uns** dispersamente distribuídos em uma sequência de **zeros**, como ilustrado na Figura 23 e Figura 24. Essa abordagem simplifica os modelos e reduz a potência computacional necessária em hardware convencional e neuromórfico além de requerer menos armazenamento.

Como resultado do mencionado acima, em RNP, a informação é codificada no formato de *tempo* e/ou *taxa* de pulsos, proporcionando consequentemente grandes capacidades de processamento de fluxos de dados, mas limitando o processamento de dados estáticos.

O modelo LIF é governado pelas equações abaixo (ESHRAGHIAN *et al.*, 2023).

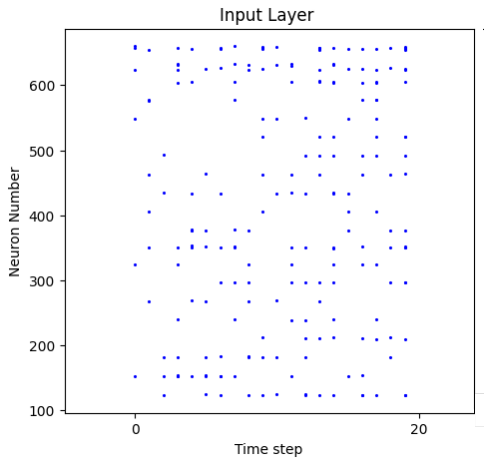
[3] *Leaky Integrate and Fire* (Integra-e-Dispara com Vazamento)
[4] Resistor-Capacitor

Figura 23 – Dispersão em Redes Neurais de Pulsos.



Fonte: (ESHRAGHIAN *et al.*, 2023)

Figura 24 – Atividade dispersa de uma simulação RNP: O eixo horizontal representa o momento no qual os dados estão sendo processados e o vertical representa o número do neurônio (índice) na RNP. Note que, na maior parte do tempo, muito poucos neurônios são ativados.



Fonte: Elaborado pelo autor, 2023.

Considerando que Q é uma medida de carga elétrica e $V_{\text{mem}}(t)$ é a diferença de potencial na membrana em um determinado tempo t, então a capacitância do neurônio C é dada pela Equação 2.22.

$$C = \frac{Q}{V_{mem}(t)} \tag{2.22}$$

Portanto, a carga do neurônio pode ser expressa pela Equação 2.23.

$$Q = C.V_{mem}(t) \tag{2.23}$$

Para saber como essa carga muda ao longo do tempo (ou seja, medir a corrente), podemos derivar Q como na Equação 2.24. Essa expressão representa a corrente I_C na parte capacitiva do neurônio.

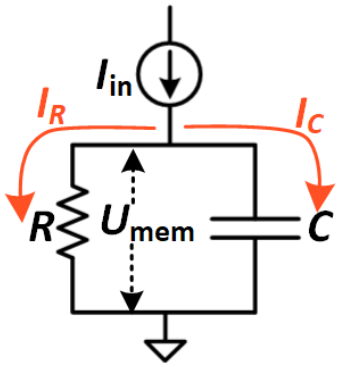
$$I_C = \frac{dQ}{dt} = C.\frac{dV_{mem}(t)}{dt} \tag{2.24}$$

Para calcular a corrente total passando pela parte resistiva do circuito, podemos usar a lei de Ohm:

$$V_{mem}(t) = R.I_R \implies I_R = \frac{V_{mem}(t)}{R} \tag{2.25}$$

Então, considerando que a corrente total não muda, como pode ser visto na Figura 25, temos a corrente total de entrada I_{in} do neurônio como na Equação 2.26.

Figura 25 – Modelo RC para correntes: $I_{in} = I_R + I_C$



Fonte: (ESHRAGHIAN *et al.*, 2023)

$$I_{in}(t) = I_R + I_C \implies I_{in}(t) = \frac{V_{mem}(t)}{R} + C.\frac{dV_{mem}(t)}{dt} \tag{2.26}$$

Portanto, para descrever a variação de potencial da membrana passiva, temos a Equação 2.27.

$$\begin{gathered} I_{in}(t) = \frac{V_{mem}(t)}{R} + C.\frac{dV_{mem}(t)}{dt} \implies \\ I_{in}(t) - \frac{V_{mem}(t)}{R} = C.\frac{dV_{mem}(t)}{dt} \implies \\ \boxed{R.I_{in}(t) - V_{mem}(t) = R.C.\frac{dV_{mem}(t)}{dt}} \end{gathered} \tag{2.27}$$

Já que o lado direito da equação $\left(\frac{dV_{mem}(t)}{dt}\right)$ expressa uma grandeza em $voltagem/s$ e o esquerdo $(R.I_{in}(t) - V_{mem}(t))$ em $voltagem$ apenas, conclui-se pela igualdade, que $R.C$ é uma unidade de tempo. Definindo $\tau = R.C$ como a **constante de tempo da membrana**, obtemos tensões em ambos os lados chegando na Equação 2.28 que **descreve o circuito RC**.

$$\begin{aligned} R.I_{in}(t) - V_{mem}(t) &= R.C.\frac{dV_{mem}(t)}{dt} \implies \\ R.I_{in}(t) - V_{mem}(t) &= \tau.\frac{dV_{mem}(t)}{dt} \implies \\ \boxed{\tau.\frac{dV_{mem}(t)}{dt} &= R.I_{in}(t) - V_{mem}(t)} \end{aligned} \tag{2.28}$$

Exemplo numérico. Para $R = 5\,\Omega$ e $C = 1\,F$ (os mesmos valores usados nas implementações a seguir), a constante de tempo é $\tau = R.C = 5 \times 1 = 5$.

Quando não há corrente de entrada no neurônio $I_{in} = 0$ ocorre um decaimento em sua voltagem que pode ser modelado, além disso, R e C não mudam e podem ser resumidos em $\tau = R.C$ que é uma constante. Portanto, atribuindo um potencial inicial $V_{mem}(0)$, se obtêm uma curva exponencial, como visto na Equação 2.29.

$$\begin{aligned} \tau.\frac{dV_{mem}(t)}{dt} &= \cancel{R.I_{in}(t)} - V_{mem}(t) \implies \\ \tau.\frac{dV_{mem}(t)}{dt} &= -V_{mem}(t) = \\ \frac{dV_{mem}(t)}{dt} &= \frac{-V_{mem}(t)}{\tau} = \\ \frac{dV_{mem}(t)}{V_{mem}(t)} &= \frac{-dt}{\tau} = \\ \int \frac{1}{V_{mem}(t)}.dV_{mem}(t) &= \int \frac{-1}{\tau}.dt = \\ \ln(|V_{mem}(t)|) &= -\frac{1}{\tau}.\int dt = \\ \ln(|V_{mem}(t)|) &= -\frac{1}{\tau}.t = \\ e^{\ln(|V_{mem}(t)|)} &= e^{-\frac{t}{\tau}} = \\ V_{mem}(t) &= e^{-\frac{t}{\tau}} \implies \end{aligned} \tag{2.29}$$

Considerando um valor inicial de $V_{mem}(t) = V_{mem}(0)$ em $t = 0 \implies$

$$\boxed{V_{mem}(t) = V_{mem}(0).e^{-\frac{t}{\tau}}}$$

Exemplo numérico. Com $\tau = 5$ (do exemplo acima) e $V_{mem}(0) = 1$, o potencial em $t = 1$ é $V_{mem}(1) = 1 \times e^{-1/5} = e^{-0,2} \approx 0{,}8187$. Repetindo a operação

implementada no Algoritmo 2.1, a discretização de Euler com $dt = 1$ dá $V_{mem}(1) = V_{mem}(0) + \frac{dt}{\tau}(-V_{mem}(0)) = 1 + \frac{1}{5}(-1) = 0{,}8$, próximo do valor exato 0,8187.

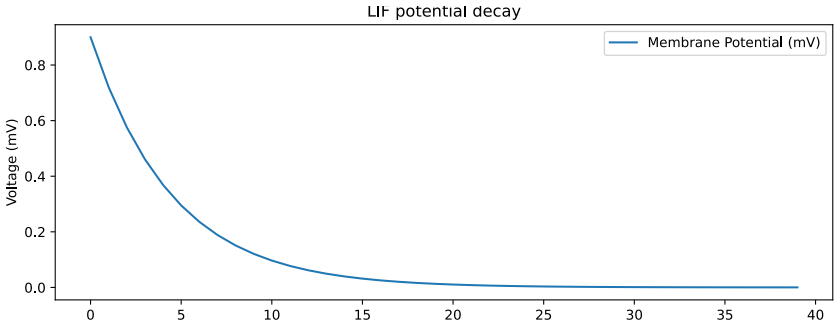
Então, pode-se dizer que: Na ausência de uma entrada I_{in}, o potencial da membrana decai exponencialmente, como ilustrado na Figura 26 e implementado no Algoritmo 2.1.

```
double lif(double V_mem, double dt = 1, double I_in = 0, double R = 5,
    double C = 1) {

  double tau = R * C;
  V_mem = V_mem + (dt / tau) * (-V_mem + I_in * R);
  return V_mem;
}
```

Algoritmo 2.1 – Implementação em C++ da decaimento do potencial de ação de um LIF: $I_{in} = 0$

Figura 26 – Decaimento do potencial da membrana.



Fonte: Elaborado pelo autor, 2023.

Com os resultados da Equação 2.28, é possível calcular o aumento da voltagem, na presença de uma corrente de entrada, conforme mostrado na Equação 2.30.

$$\tau.\frac{dV_{mem}(t)}{dt} = R.I_{in}(t) - V_{mem}(t) = \frac{dV_{mem}(t)}{dt} + \frac{V_{mem}(t)}{\tau} = \frac{R.I_{in}(t)}{\tau} \tag{2.30}$$

A Equação 2.30 se encaixa na categoria de equação diferencial ordinária (EDO) de primeira ordem, portanto, para resolvê-la se determina o fator de integração f definido na Equação 2.31:

$$
\begin{aligned}
f = e^{\int P(x)dx} \mid \frac{dy}{dx} + P(x).y = Q(x) \therefore \\
x = t \\
y = V_{mem}(t) \\
P(x) = \frac{1}{\tau} \\
Q(x) = \frac{R.I_{in}}{\tau} \implies \\
e^{\int \frac{1}{\tau} dx} = e^{\frac{1}{\tau} \cdot \int dt} = \boxed{e^{\frac{t}{\tau}}}
\end{aligned}
\tag{2.31}
$$

Fazendo a substituição do fator na Equação 2.32:

$$
\begin{aligned}
\text{Substituindo em: } (f.y)' = f.Q(x) \implies \\
(e^{\frac{t}{\tau}}.V_{mem}(t))' = \frac{R.I_{in}(t)}{\tau}.e^{\frac{t}{\tau}} \implies \\
\int (e^{\frac{t}{\tau}}.V_{mem}(t))' = \int \frac{R.I_{in}(t)}{\tau}.e^{\frac{t}{\tau}} dt \implies \\
\boxed{e^{\frac{t}{\tau}}.V_{mem}(t) = \frac{R.I_{in}(t)}{\tau}. \int e^{\frac{t}{\tau}} dt}
\end{aligned}
\tag{2.32}
$$

Que resolvendo pelo método da substituição na Equação 2.33. É importante manter a constante de integração c_1 até o fim: descartá-la precocemente anula o termo exponencial e leva a um resultado que não decai com t, contradizendo o comportamento físico esperado.

$$
\begin{aligned}
u = \frac{t}{\tau} \implies \frac{du}{dt} = \frac{1}{\tau} \implies dt = du.\tau \therefore \\
\int e^u du.\tau = \tau. \int e^u du = \tau.e^u + c_1 = \tau.e^{\frac{t}{\tau}} + c_1 \implies \\
e^{\frac{t}{\tau}}.V_{mem}(t) = \frac{R.I_{in}(t)}{\tau} \left(\tau.e^{\frac{t}{\tau}} + c_1\right) = R.I_{in}(t).e^{\frac{t}{\tau}} + c_2 \implies \\
V_{mem}(t) = R.I_{in}(t) + c_2.e^{-\frac{t}{\tau}} \implies \\
\text{Considerando: } V_{mem}(t=0) = 0 \implies 0 = R.I_{in} + c_2 \implies c_2 = -R.I_{in} \implies \\
\boxed{V_{mem}(t) = I_{in}(t).R\left(1 - e^{-\frac{t}{\tau}}\right)}
\end{aligned}
\tag{2.33}
$$

Exemplo numérico. Usando os mesmos valores do Algoritmo 2.2 ($R = 5$, $C = 1$, logo $\tau = R.C = 5$) com $I_{in} = 1$ e $V_{mem}(0) = 0$, o potencial em $t = 1$ pela solução exata é

$$V_{mem}(1) = 1 \times 5 \times \left(1 - e^{-1/5}\right) = 5 \times (1 - 0{,}8187) = 5 \times 0{,}1813 \approx 0{,}9066.$$

Já a iteração discreta do Algoritmo 2.2, com passo $dt = 1$, calcula $V_{mem}(1) = V_{mem}(0) + \frac{dt}{\tau}\big(-V_{mem}(0) + I_{in}.R\big) = 0 + \frac{1}{5}(0 + 5) = 1{,}0$: um passo de Euler tão grosseiro ($dt = \tau$) já

se aproxima da assíntota $R.I_{in} = 5$, superestimando ligeiramente o valor exato 0,9066 — a diferença entre as duas soluções é retomada na Equação 2.35.

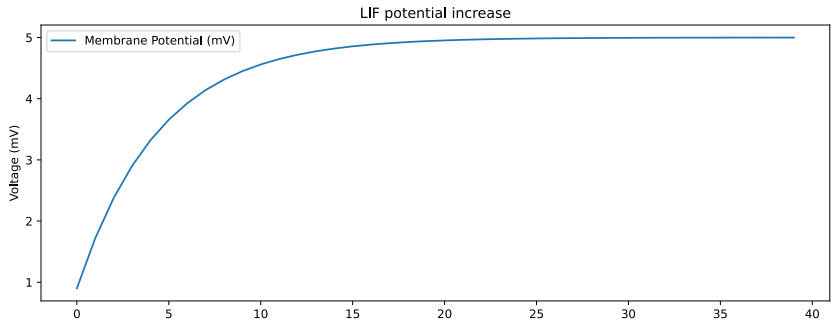
Note que quando os potenciais de ação aumentam, ainda há um comportamento exponencial, como se pode notar na Figura 27 e no Algoritmo 2.2.

```
double lif(double V_mem, double dt = 1, double I_in = 1, double R = 5,
    double C = 1) {

  double tau = R * C;
  V_mem = V_mem + (dt / tau) * (-V_mem + I_in * R);
  return V_mem;
}
```

Algoritmo 2.2 – Implementação em C++ do potencial de ação decrescente de um LIF: $I_{in} = 1$

Figura 27 – Aumento do potencial da membrana.



Fonte: Elaborado pelo autor, 2023.

Levando em consideração um certo **limiar** que determina um *reset* na voltagem do neurônio e dois tipos de *resets* (para zero e subtração do limiar), finalmente é possível modelar o comportamento completo do LIF, conforme ilustrado na Figura 28 e implementado no Algoritmo 2.3:

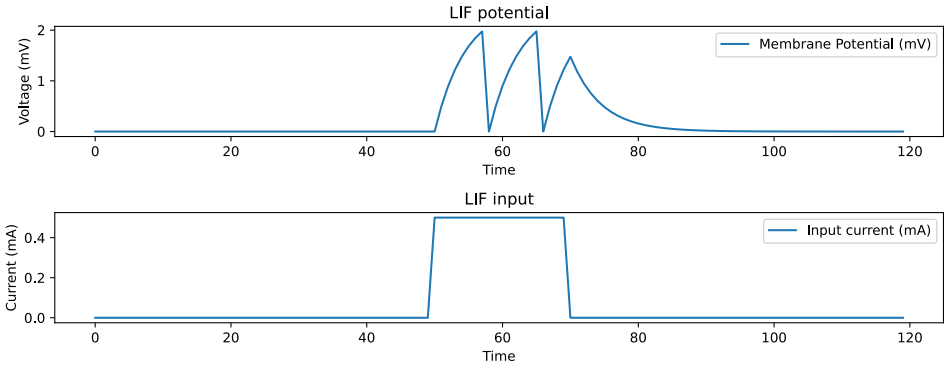
```
double lif(double V_mem, double dt = 1, double I_in = 1, double R = 5,
    double C = 1, double V_thresh = 2, bool reset_zero = true) {

  double tau = R * C;
  V_mem = V_mem + (dt / tau) * (-V_mem + I_in * R);
  if (V_mem > V_thresh) {
    if (reset_zero) {
      V_mem = 0;
    } else {
      V_mem = V_mem - V_thresh;
    }
  }
```

```
12    return V_mem;
13 }
```

Algoritmo 2.3 – Implementação em C++ da simulação completa do potencial de ação de um LIF: $I_{in} = 1$, $V_{thresh} = 2$ is threshold

Figura 28 – Gráfico do LIF simulado completo: Foram fornecidos 0,5 mA de corrente no intervalo de tempo de 51 a 70.



Fonte: Elaborado pelo autor, 2023.

2.1.10.3 Outra interpretação do LIF

Começando com a Equação 2.28 e usando o Método de Euler para resolver o modelo LIF:

$$\tau . \frac{dV_{\text{mem}}(t)}{dt} = R.I_{\text{in}}(t) - V_{\text{mem}}(t) \tag{2.34}$$

Resolvendo a derivada na Equação 2.35, obtemos o potencial da membrana para qualquer tempo $t + \Delta t$ no futuro:

$$\begin{aligned} \tau . \frac{V_{\text{mem}}(t+\Delta t) - V_{\text{mem}}(t)}{\Delta t} &= R.I_{\text{in}}(t) - V_{\text{mem}}(t) = \\ V_{\text{mem}}(t+\Delta t) - V_{\text{mem}}(t) &= \frac{\Delta t}{\tau} . (R.I_{\text{in}}(t) - V_{\text{mem}}(t)) = \\ \boxed{V_{\text{mem}}(t+\Delta t) &= V_{\text{mem}}(t) + \frac{\Delta t}{\tau} . (R.I_{\text{in}}(t) - V_{\text{mem}}(t))} \end{aligned} \tag{2.35}$$

Exemplo numérico. Com $R = 5$, $\tau = 5$, $I_{\text{in}} = 1$, $\Delta t = 1$ e partindo de $V_{\text{mem}}(0) = 0$: $V_{\text{mem}}(1) = 0 + \frac{1}{5}(5 \times 1 - 0) = 1{,}0$. Este é exatamente o passo de Euler já calculado ao final da seção anterior — a Equação 2.35 é a regra geral por trás daquela iteração, e do Algoritmo 2.3.

Nota de implementação. A Equação 2.35 e o Algoritmo 2.3 têm propósito didático: expõem o circuito RC subjacente e sua discretização por Euler explícito, na

qual a corrente de entrada é escalada por R. A implementação do neurônio LIF de fato usada para gerar todos os resultados experimentais deste trabalho — tanto na forma de passo único quanto na variante desenrolada no tempo usada para BPTT (próxima seção) — adota, em vez disso, a recorrência exata do decaimento exponencial por passo:

$$V_{\text{mem}}(t + \Delta t) = \beta \cdot V_{\text{mem}}(t) + I_{\text{in}}(t), \qquad \beta = e^{-\Delta t/\tau}, \qquad \tau = R.C. \tag{2.36}$$

Essa forma é a solução exata da parte homogênea (o decaimento) da Equação 2.28 a cada passo — mais precisa que o passo de Euler linear $(1 - \Delta t/\tau)$ da Equação 2.35 — e corresponde à convenção usual da literatura de RNPs treináveis, também adotada pela biblioteca *snnTorch* (ESHRAGHIAN *et al.*, 2023), usada como referência de corretude para essa camada durante o desenvolvimento deste trabalho. Diferentemente da Equação 2.35, R não escala $I_{\text{in}}(t)$ nessa recorrência — R (junto com C) influencia **apenas** a taxa de decaimento β via $\tau = R.C$; a corrente de entrada é somada diretamente ao potencial já decaído. Isso é uma simplificação deliberada em relação ao circuito RC ideal (cuja solução exata seria $V_{\text{mem}}(t + \Delta t) = \beta \cdot V_{\text{mem}}(t) + R.I_{\text{in}}(t).(1 - \beta)$), não um erro de discretização: por não reintroduzir o termo $R.(1 - \beta)$, o ganho efetivo do sinal de entrada permanece constante e independente de τ, o que simplifica o treinamento de R, C e V_{th} como parâmetros aprendíveis sem acoplar sua otimização à escala da entrada.

2.1.10.4 Treinamento

Como as RNPs são treinadas? Esta ainda é uma questão com múltiplas respostas. Um neurônio RNP tem o comportamento de sua função de ativação parecido com uma **função de passo**. Portanto, em princípio, não podemos usar soluções baseadas em descida de gradiente porque esse tipo de função **não é** diferenciável (KASABOV, 2019).

Mas existem algumas ideias que podem lançar alguma luz sobre este assunto: algumas observações *in vivo/in vitro* mostram que os cérebros, em geral, aprendem fortalecendo/enfraquecendo e adicionando/removendo sinapses, criando novos neurônios ou adotando até mesmo outros mecanismos como pacotes de RNA; contudo, segundo (KASABOV, 2019), há outras formas empregadas:

- **STDP**[5]: Se um neurônio pré-sináptico dispara **antes** do pós-sináptico, há um fortalecimento na conexão, mas se o neurônio pós-sináptico disparar antes, então há um enfraquecimento.
- **Descida de Gradiente Emprestada**: Aproxima a função de passo usando outra função matemática, que é diferenciável (como uma sigmoide), para treinar a rede. Essas aproximações são usadas apenas na fase de *backpropagation*, enquanto mantêm o comportamento original na fase do *feed-forward*.

[5] Plasticidade Dependente do Tempo de Pulsos (*Spike-Timing-Dependent Plasticity*)

- **Algoritmos Evolutivos**: Usam a seleção dos hiperparâmetros mais aptos ao longo de muitas gerações de redes.

- **Reservatório/Computação Dinâmica**: estratégia que evita treinar a rede recorrente mantendo o **reservatório** — uma rede recorrente com pesos e conectividade fixos — e treinando apenas a camada de saída (KASABOV, 2019).

- **ESN e LSM**: as **Redes de estado de eco** (*Echo State Networks* — ESN) usam neurônios de saída contínua no reservatório; as **Máquinas de estado líquido** (*Liquid State Machines* — LSM) usam neurônios pulsantes no reservatório e uma camada de saída simples que lê apenas o estado atual (MAASS; NATSCHLäGER; MARKRAM, 2002).

2.1.10.5 BPTT em RNPs

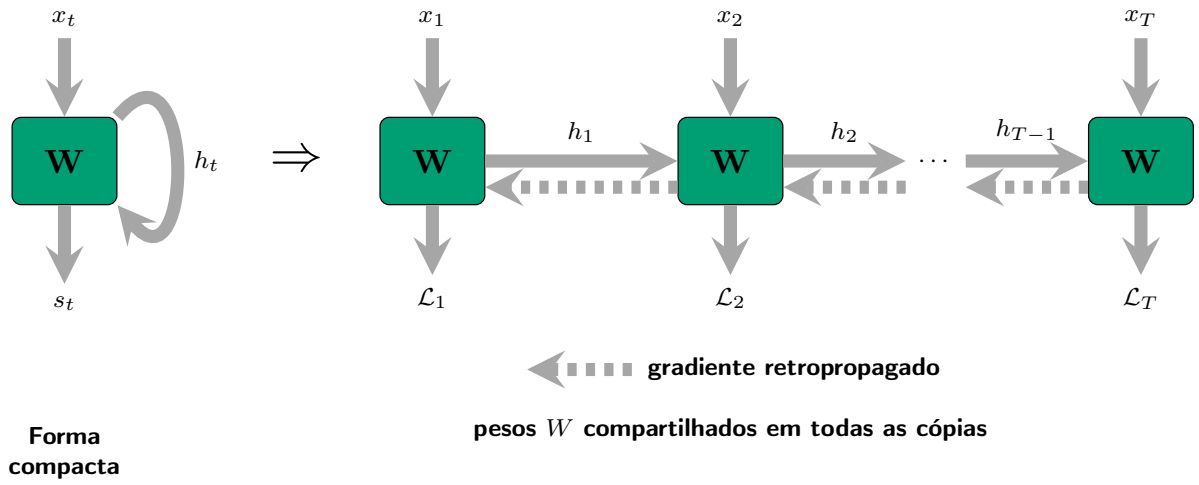
Redes recorrentes processam sequências: a saída em cada instante t depende da entrada atual x_t e do estado interno h_{t-1} da etapa anterior. Isso cria dependências temporais que a retropropagação padrão não trata.

O BPTT resolve isso *desenrolando* a rede no tempo, como ilustrado na Figura 29: a rede é replicada T vezes, sendo T o passo temporal, com todas essas cópias compartilhando os mesmos pesos W. Na propagação direta (*forward*), o estado interno avança da esquerda para a direita: $h_t = f(h_{t-1}, x_t; W)$. Seja $\mathcal{L}$ a perda total da sequência e $\mathcal{L}_t$ a contribuição do passo t para essa perda. Na retropropagação (*backward*), o gradiente percorre o caminho inverso (da última cópia até a primeira) acumulando a contribuição de cada passo (ESHRAGHIAN *et al.*, 2023):

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}} = \sum_{t=1}^{T} \frac{\partial \mathcal{L}_t}{\partial \mathbf{W}} \tag{2.37}$$

Exemplo numérico. Para uma sequência com $T = 3$ passos e gradientes por passo $\partial\mathcal{L}_1/\partial W = 0{,}2$, $\partial\mathcal{L}_2/\partial W = -0{,}5$ e $\partial\mathcal{L}_3/\partial W = 0{,}9$, o gradiente total acumulado é $\partial\mathcal{L}/\partial W = 0{,}2 - 0{,}5 + 0{,}9 = 0{,}6$.

Figura 29 – Retropropagação Através do Tempo: à esquerda, rede recorrente na forma compacta com conexão recorrente h_t; à direita, a mesma rede *desenrolada* em T cópias. Setas azuis: propagação direta; setas vermelhas tracejadas: retropropagação do gradiente. Os pesos W são compartilhados em todas as cópias.



Fonte: Elaborado pelo autor, 2025.

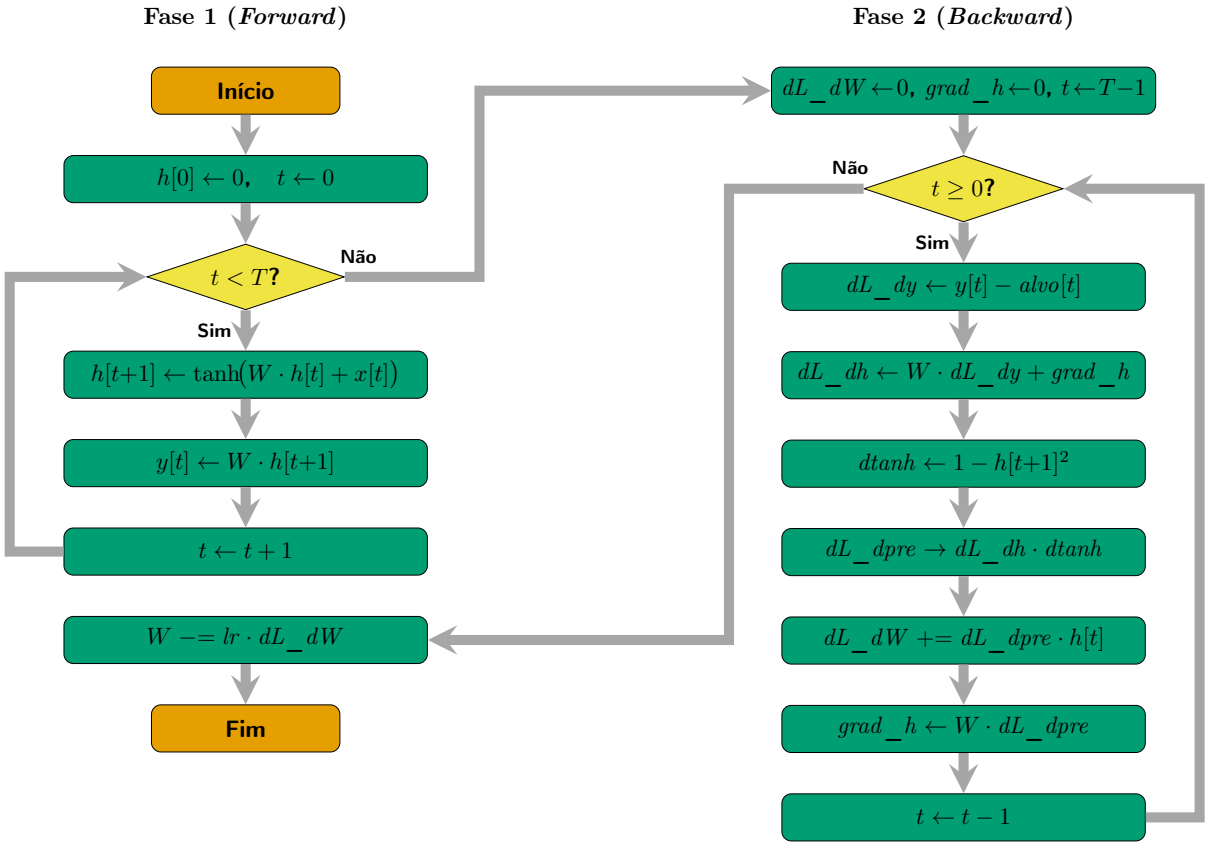
O Algoritmo 2.4 apresenta o algoritmo simplificado: o loop *forward* armazena os estados $h[t]$ na memória; o loop *backward* percorre o tempo ao contrário acumulando o gradiente ∇_W. Neste exemplo, W denota os pesos da rede, $y[t] = W \cdot h[t{+}1]$ a saída da rede no instante t, $alvo[t]$ o valor alvo correspondente e lr a taxa de aprendizagem. A Figura 30 detalha o fluxo de execução completo com as duas fases e todas as variáveis envolvidas.

```
/* ---- Forward: armazena estados ---- */
float h[T+1];
h[0] = 0.0f;
for (int t = 0; t < T; t++) {
    h[t+1] = tanh(W * h[t] + x[t]); /* recorrencia  */
    y[t]   = W *h[t+1];             /* saida        */
}
/* ---- Backward: percorre ao contrario ---- */
float dL_dW = 0.0f;
float grad_h = 0.0f;  /* gradiente acumulado da etapa seguinte */
for (int t = T-1; t >= 0; t--) {
    float dL_dy   = y[t] - alvo[t];        /* erro na saida       */
    float dL_dh   = W *dL_dy + grad_h;    /* output + recorrencia*/
    float dtanh   = 1.0f - h[t+1] * h[t+1];/* derivada de tanh    */
    float dL_dpre = dL_dh * dtanh;
    dL_dW  += dL_dpre * h[t];  /* acumula gradiente de W              */
    grad_h  = W * dL_dpre;     /* propaga para a etapa anterior (t-1) */
}
```

```
19 W -= lr * dL_dW;  /* atualiza pesos */
```

Algoritmo 2.4 – BPTT simplificado: propagação direta seguida de retropropagação no tempo.

Figura 30 – Fluxograma do algoritmo BPTT simplificado. Fase 1 (*forward*): computa e armazena $h[t]$ e $y[t]$ para cada passo t. Fase 2 (*backward*): percorre os passos em ordem inversa, acumula o gradiente $\partial\mathcal{L}/\partial W$ e propaga $grad_h$ para a etapa anterior.



Fonte: Elaborado pelo autor, 2025.

2.1.10.6 Gradiente substituto

Antes da fórmula, definem-se os símbolos: $\tilde{S}$ é o pulso aproximado (a versão suave e diferenciável da função de disparo, usada apenas no *backward*); V_{mem} é o potencial de membrana já apresentado; V_{th} é o limiar de disparo do neurônio; e $\beta > 0$ é um hiperparâmetro que controla a inclinação da aproximação em torno de V_{th}. O gradiente substituto exponencial utilizado neste trabalho é definido como (ESHRAGHIAN *et al.*, 2023):

$$\frac{\partial \tilde{S}}{\partial V_{mem}} = \beta \cdot e^{-\beta |V_{mem} - V_{th}|} \tag{2.38}$$

Exemplo numérico. Com $\beta = 5$ e $V_{th} = 1{,}0$: exatamente no limiar ($V_{mem} = 1{,}0$) o gradiente vale seu máximo, $5 \times e^{0} = 5{,}0$; a 0,2 do limiar ($V_{mem} = 1{,}2$) ele cai para $5 \times e^{-5\times 0{,}2} = 5 \times e^{-1} \approx 5 \times 0{,}3679 = 1{,}8394$ — ilustrando o decaimento rápido da influência do gradiente à medida que o potencial se afasta do limiar de disparo.

Valores maiores de β produzem uma função mais próxima da derivada da função em degrau, enquanto valores menores resultam em uma aproximação mais suave e numericamente estável. A função é centrada em V_{th} e decai exponencialmente ao se afastar do ponto de disparo, ponderando mais os gradientes próximos ao limiar do neurônio e atenuando contribuições distantes do mesmo.

2.1.10.7 Normalização em Lote Dependente do Limiar (tdBN)

A **tdBN**[6] é uma camada de normalização proposta por (ZHENG *et al.*, 2021) para viabilizar o treinamento direto de RNPs profundas. Trata-se de uma adaptação da BN[7] (IOFFE; SZEGEDY, 2015) ao domínio pulsante.

Motivação. A BN clássica normaliza uma pré-ativação para média zero e variância unitária, $N(0, 1)$, considerando apenas a dimensão do lote. Em uma RNP, contudo, a corrente de membrana de um neurônio é uma distribuição sobre as amostras **e** sobre os T passos de tempo, e o disparo depende da comparação dessa corrente com o limiar V_{th}. Normalizar para variância unitária é, portanto, cego ao limiar: se $V_{th} \neq 1$, a entrada normalizada ou raramente cruza o limiar (poucos disparos) ou o satura (disparos em excesso) (ZHENG *et al.*, 2021). Além disso, ao empilhar muitas camadas pulsantes, o potencial de membrana — e o gradiente retropropagado — tende a desaparecer ou explodir, o que impede o treinamento de redes profundas e pode levar ao **problema da ausência de disparos** (*No-Spike Problem*), em que uma camada inteira deixa de disparar e, como o gradiente substituto só é não-nulo em torno do limiar, deixa de ser ajustada (ZHENG *et al.*, 2021).

Formulação matemática. Seja a pré-ativação em formato *tempo-maior* $X \in \mathbb{R}^{(T\cdot B)\times F}$, em que T é o número de passos de tempo, B é o tamanho do lote e F é o número de canais (características). Para o canal k, sejam $X_{k,i}$ os seus $N = T \cdot B$ valores agrupados sobre o lote e o tempo. Definem-se a média e a variância **por canal**, agrupadas sobre lote e tempo:

$$\mu_k = \frac{1}{N}\sum_{i=1}^{N} X_{k,i}, \qquad \sigma_k^2 = \frac{1}{N}\sum_{i=1}^{N} \left(X_{k,i} - \mu_k\right)^2, \tag{2.39}$$

onde μ_k é a média do canal k e σ_k^2 a sua variância. A normalização e a transformação afim dependente do limiar são

[6] *Threshold-Dependent Batch Normalization* (Normalização em Lote Dependente do Limiar)
[7] *Batch Normalization* (Normalização em Lote)

$$\hat{X}_{k,i} = \frac{X_{k,i} - \mu_k}{\sqrt{\sigma_k^2 + \varepsilon}}, \qquad Y_{k,i} = \gamma_k \left(\alpha\, V_{th}\, \hat{X}_{k,i}\right) + \beta_k, \tag{2.40}$$

em que $\hat{X}_{k,i}$ é o valor padronizado (média zero, variância unitária); ε é uma constante de estabilidade numérica (padrão 10^{-5}); V_{th} é o limiar de disparo do neurônio LIF a jusante; α é um hiperparâmetro que define a dispersão alvo (padrão $\alpha = 1$); e γ_k e β_k são, respectivamente, a escala e o deslocamento aprendíveis do canal k. Note-se que o fator αV_{th} multiplica **apenas** o termo normalizado — o deslocamento β_k não é escalonado. Com $\gamma_k = 1$ e $\beta_k = 0$, a saída segue a distribuição $N\big(0, (\alpha V_{th})^2\big)$, propriedade que define a tdBN (ZHENG *et al.*, 2021).

Derivação. A tdBN decorre de duas modificações sobre a BN. Primeiro, as estatísticas (Equação 2.39) são calculadas sobre $N = T \cdot B$ valores — lote e tempo agrupados — pois todos eles influenciam decisões de disparo; isso distingue a tdBN de esquemas por passo, como a BNTT (KIM; PANDA, 2021). Segundo, deseja-se que uma fração fixa de neurônios dispare, independentemente da profundidade. Se $\hat{X} \sim N(0,1)$, então $\alpha V_{th}\hat{X} \sim N(0, (\alpha V_{th})^2)$ e a probabilidade de ultrapassar o limiar é

$$P\big(\alpha V_{th}\, \hat{X} > V_{th}\big) = P\Big(\hat{X} > \tfrac{1}{\alpha}\Big) = 1 - \Phi\big(\tfrac{1}{\alpha}\big)\,, \tag{2.41}$$

onde Φ é a função de distribuição acumulada da normal padrão. Essa fração depende **somente** de α — não da profundidade, de T ou da escala da entrada. Para $\alpha = 1$ obtém-se $1 - \Phi(1) \approx 15{,}9\%$ de neurônios acima do limiar, um regime de disparo saudável e não-saturado. (ZHENG *et al.*, 2021) demonstram ainda, via teoria da *Block Dynamical Isometry*, que esse fator αV_{th} mantém a norma do gradiente de cada bloco próxima da unidade, evitando o seu desaparecimento ou explosão e permitindo o treinamento de redes com dezenas de camadas.

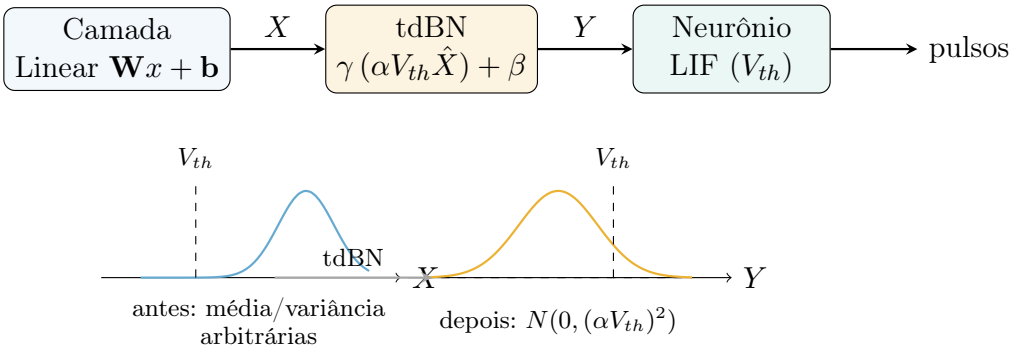
Exemplo numérico. Considere-se um único canal ($F = 1$), com $T = 2$, $B = 2$ (logo $N = 4$), $\gamma = 1$, $\beta = 0$ e $\varepsilon = 10^{-5}$. Sejam as entradas $X = [\,0,\ 2,\ 4,\ 6\,]$ (cujos dois passos de tempo têm médias distintas, 1 e 5, ilustrando o agrupamento sobre o tempo). Tem-se:

$$\begin{aligned} \mu &= (0+2+4+6)/4 = 3, \\ \sigma^2 &= \big[(0-3)^2 + (2-3)^2 + (4-3)^2 + (6-3)^2\big]/4 = 20/4 = 5, \\ 1/\sqrt{\sigma^2+\varepsilon} &\approx 0{,}447214, \\ \hat{X} &= (X-3)\cdot 0{,}447214 = [-1{,}3416,\ -0{,}4472,\ 0{,}4472,\ 1{,}3416]. \end{aligned} \tag{2.42}$$

Aplicando a escala dependente do limiar com $\alpha = 1$: para $V_{th} = 1$ (escala 1) obtém-se $Y = [-1{,}3416,\ -0{,}4472,\ 0{,}4472,\ 1{,}3416]$, ou seja, $N(0,1)$; para $V_{th} = 2$ (escala

2) obtém-se $Y = [-2{,}6833,\ -0{,}8944,\ 0{,}8944,\ 2{,}6833]$, com desvio-padrão exatamente igual a $\alpha V_{th} = 2$, isto é, $N(0,4) = N(0,(\alpha V_{th})^2)$. A Figura 31 ilustra esse efeito: a tdBN recentra e reescala a corrente de modo que uma fração controlada da distribuição ultrapasse o limiar.

Figura 31 – Normalização em Lote Dependente do Limiar (tdBN): inserida entre a camada Linear e o neurônio LIF, ela agrupa as estatísticas sobre lote e tempo e reescala a corrente para a distribuição $N(0,(\alpha V_{th})^2)$, mantendo uma fração controlada de neurônios acima do limiar V_{th} a cada passo.



Fonte: Elaborado pelo autor, 2026.

Vantagens. Por compartilhar γ e β entre os passos de tempo, a transformação afim da tdBN pode ser **incorporada aos pesos** da camada Linear anterior em tempo de inferência, sem custo computacional adicional — ao contrário de esquemas com parâmetros por passo, como BNTT (KIM; PANDA, 2021) e TEBN (DUAN *et al.*, 2022) (ZHENG *et al.*, 2021). Além disso, ao fixar a dispersão em αV_{th}, a tdBN preserva a norma do gradiente em profundidade e mitiga estruturalmente o problema da ausência de disparos.

Limitações. Um único par escala/deslocamento por canal é menos expressivo do que esquemas que atribuem parâmetros distintos a cada passo de tempo; para valores muito pequenos de T, a TEBN (DUAN *et al.*, 2022) pode superá-la. A tdBN também pressupõe uma população de lote e tempo suficientemente grande para estimativas estáveis de média e variância. Variantes posteriores, como a MPBN (GUO *et al.*, 2023), normalizam o potencial de membrana após a sua atualização, antes da função de disparo.

2.1.10.8 Regularização da taxa de disparo

Enquanto a tdBN (subseção 2.1.10.7) ataca o problema da ausência de disparos **estruturalmente** — reescalando a corrente para que uma fração fixa de neurônios ultrapasse o limiar, independentemente da profundidade — uma segunda estratégia, complementar, atua sobre a **função de perda**: penalizar a taxa média de disparo de cada camada pulsante quando ela sai de uma faixa-alvo $[r_{min}, r_{max}]$. Diferente da tdBN, essa penalidade não garante estruturalmente uma taxa de disparo saudável — ela apenas

empurra o gradiente nessa direção — mas dispensa qualquer camada de normalização adicional e se aplica mesmo quando a rede pulsante já está construída sem tdBN, como é o caso do *autoencoder* de RNP deste trabalho (subseção 2.1.11.5).

Formulação. Seja $S_l \in \mathbb{R}^{N_l}$ o tensor de pulsos (0 ou 1) emitido pela camada pulsante l ao longo do lote e do tempo, com N_l elementos. A taxa de disparo dessa camada é a sua média:

$$r_l = \frac{1}{N_l} \sum_{i=1}^{N_l} S_{l,i}. \tag{2.43}$$

A penalidade, somada à perda de reconstrução (ou de classificação), é uma função de banda quadrática — nula dentro da faixa-alvo, crescendo quadraticamente fora dela:

$$\mathcal{L}_{fr} = \lambda \sum_{l} \Big[\max(0,\, r_{min} - r_l)^2 + \max(0,\, r_l - r_{max})^2 \Big], \tag{2.44}$$

em que $\lambda \geq 0$ é o peso da regularização (inerte quando $\lambda = 0$), r_{min} é a borda inferior da faixa (guarda contra neurônios mortos) e r_{max} é a borda superior (guarda contra disparo excessivo, que satura a seletividade do neurônio). Sua derivada em relação a cada pulso individual é constante dentro de uma mesma camada:

$$\frac{\partial \mathcal{L}_{fr}}{\partial S_{l,i}} = \frac{2\lambda\big(r_l - \mathrm{clamp}(r_l,\, r_{min},\, r_{max})\big)}{N_l}, \qquad \forall i, \tag{2.45}$$

ou seja, o efeito da regularização sobre o *backward* é somar essa mesma constante a todo elemento do gradiente que chega na saída da camada pulsante l, imediatamente antes de retropropagá-lo através do neurônio LIF. Quando r_l já está dentro da faixa, o gradiente adicional é zero e a regularização não interfere no treinamento.

Exemplo numérico. Considere $\lambda = 0{,}1$, faixa $[r_{min}, r_{max}] = [0{,}05,\ 0{,}80]$ e uma camada com $N_l = 1024$ elementos disparando a uma taxa $r_l = 0{,}02$ (abaixo da borda inferior, sinal de colapso). O termo de clamp vale $\mathrm{clamp}(0{,}02;\, 0{,}05;\, 0{,}80) = 0{,}05$, e o gradiente adicional é

$$\frac{2 \times 0{,}1 \times (0{,}02 - 0{,}05)}{1024} = \frac{2 \times 0{,}1 \times (-0{,}03)}{1024} \approx -5{,}86 \times 10^{-6}, \tag{2.46}$$

um empurrão negativo (uniforme, em todo elemento do gradiente) que incentiva o otimizador a aumentar a corrente de entrada da camada, elevando a taxa de disparo até que ela reentre na faixa-alvo.

Limitação conhecida. A penalidade opera sobre a taxa **média** da camada, um sinal agregado. Uma camada pode satisfazer $r_l \in [r_{min}, r_{max}]$ mesmo com uma distribuição desigual entre neurônios — alguns disparando muito, outros nunca — sem que a média o

revele. A eficácia depende também de r_{min} estar acima do ponto de equilíbrio para o qual o treinamento convergeria de outra forma: se a rede já converge, sem regularização, para uma taxa dentro da faixa (o que ocorre, por exemplo, com a taxa observada na inicialização de He/Kaiming — subseção 2.1.11.5), a penalidade permanece inerte durante boa parte do treinamento e só atua quando a taxa realmente cruza a borda.

2.1.10.9 Inicialização de Pesos

Antes do treinamento, os pesos de cada camada precisam receber valores iniciais. Essa escolha não é um detalhe: se os pesos começam grandes demais, os sinais crescem a cada camada até saturar (explosão); se começam pequenos demais, os sinais encolhem até desaparecer (desvanecimento). Em ambos os casos o gradiente também degenera e a rede não aprende (GLOROT; BENGIO, 2010). Uma boa inicialização mantém a variância do sinal aproximadamente constante ao longo da profundidade.

Antes de apresentar a fórmula, definem-se os símbolos utilizados:

- W — matriz de pesos de uma camada, com elemento W_{ij};
- n_{in} — número de entradas de cada neurônio (o *fan-in*, isto é, o número de colunas de W);
- $\mathcal{U}(a, b)$ — distribuição uniforme contínua no intervalo $[a, b]$, da qual cada peso é sorteado;
- ℓ — o limite que delimita esse intervalo;
- b — o vetor de vieses (*bias*) da camada.

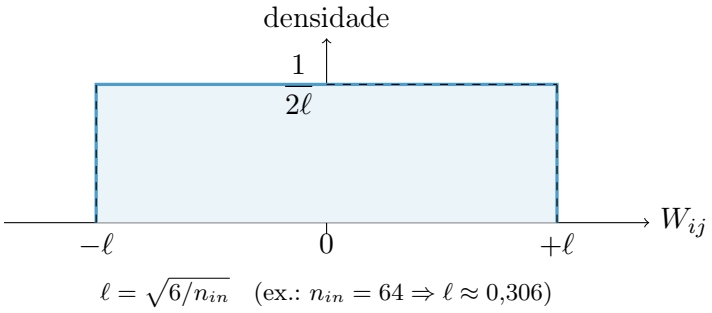
Este trabalho utiliza a inicialização de **He** (também chamada de **Kaiming**), na sua forma uniforme, indicada para ativações do tipo retificadora e para os neurônios de pulso (HE *et al.*, 2015b). Cada peso é sorteado de forma independente e os vieses começam em zero:

$$\ell = \sqrt{\frac{6}{n_{in}}}, \qquad W_{ij} \sim \mathcal{U}(-\ell,\, +\ell), \qquad b = 0. \tag{2.47}$$

A escolha de $\ell = \sqrt{6/n_{in}}$ não é arbitrária. Para a distribuição uniforme em $[-\ell, \ell]$, a variância de cada peso é $\ell^2/3 = 2/n_{in}$. Esse valor é justamente o que (HE *et al.*, 2015b) demonstram manter a variância das ativações estável entre camadas quando a não-linearidade descarta cerca de metade dos sinais (como o retificador ou o disparo do neurônio). Assim, quanto mais entradas um neurônio possui (maior n_{in}), menor o intervalo de sorteio — evitando que a soma de muitas entradas cresça sem controle.

Exemplo numérico. Para uma camada com $n_{in} = 64$ entradas, tem-se $\ell = \sqrt{6/64} = \sqrt{0{,}09375} \approx 0{,}306$. Portanto cada peso é sorteado uniformemente no intervalo $[-0{,}306,\ +0{,}306]$, como ilustra a Figura 32, e todos os vieses iniciam em 0.

Figura 32 – Distribuição uniforme dos pesos na inicialização de He/Kaiming: cada peso é igualmente provável dentro de $[-\ell, +\ell]$, com $\ell = \sqrt{6/n_{in}}$, e densidade constante igual a $1/(2\ell)$.



Fonte: Elaborado pelo autor, 2026.

Reprodutibilidade. O sorteio dos pesos usa um gerador de números pseudoaleatórios. Se esse gerador for iniciado a partir de uma **semente** fixa, a mesma sequência de pesos é obtida a cada execução, tornando os experimentos reprodutíveis. Neste trabalho, ambos os classificadores — a rede residual e a rede neural de pulsos — semeiam o gerador com a semente do experimento, de modo que uma mesma configuração produz sempre os mesmos pesos iniciais. O Algoritmo 2.5 descreve o procedimento em C simplificado, e a Figura 33 apresenta o mesmo procedimento como fluxograma.

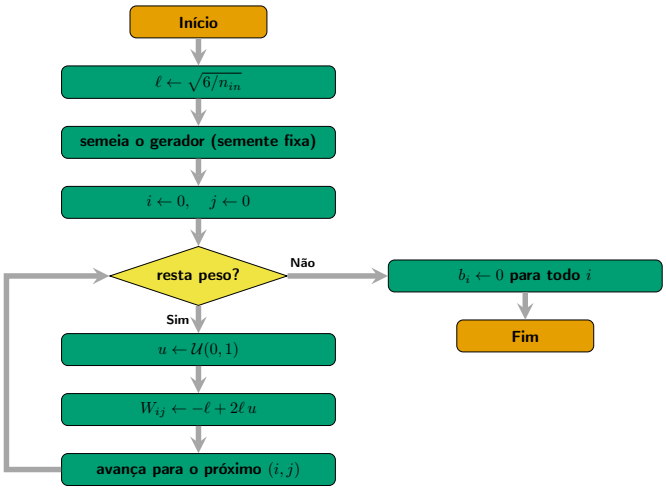
```c
/* n_in   : numero de entradas do neuronio (fan-in)   */
/* n_out  : numero de neuronios da camada             */
/* semente: valor fixo -> mesmos pesos a cada execucao */
void inicializa_kaiming(float W[n_out][n_in], float b[n_out],
                        int n_in, int n_out, unsigned int semente)
{
    float limite = sqrtf(6.0f / (float) n_in); /* l = raiz(6 / n_in) */
    semeia_gerador(semente);                   /* torna o sorteio
   determinista */

    for (int i = 0; i < n_out; i++) {
        for (int j = 0; j < n_in; j++) {
            float u = sorteia_uniforme_0_1();   /* u em [0, 1)
   */
            W[i][j] = -limite + 2.0f * limite * u; /* u em [-l, +l]
   */
        }
        b[i] = 0.0f;                           /* vies comeca em zero
   */
    }
```

```
}
```

Algoritmo 2.5 – Inicialização de He/Kaiming uniforme de uma camada, com gerador semeado para reprodutibilidade.

Figura 33 – Fluxograma da inicialização de He/Kaiming: calcula-se o limite ℓ, semeia-se o gerador, percorrem-se todos os pesos sorteando cada um em $[-\ell, +\ell]$ e, ao final, zeram-se os vieses.



Fonte: Elaborado pelo autor, 2026.

Vale registrar que a inicialização de He é uma evolução da inicialização de **Xavier** (ou Glorot), que usa $\ell = \sqrt{6/(n_{in} + n_{out})}$ e foi concebida para ativações simétricas como a tangente hiperbólica (GLOROT; BENGIO, 2010). A forma de He ajusta o fator para não-linearidades retificadoras, sendo por isso a mais adequada às redes deste trabalho.

2.1.10.10 Taxa de aprendizado por grupo de parâmetros

Uma RNP treinada por retropropagação tem dois tipos de parâmetro qualitativamente distintos: os pesos e vieses das camadas Lineares, de um lado, e os parâmetros biofísicos do neurônio LIF (R, C e V_{th}), do outro. Os primeiros só aparecem multiplicando ou somando o sinal; os segundos entram na constante de tempo $\tau = R \cdot C$ (Equação 2.28) e no próprio limiar de disparo — uma atualização grande demais pode levar τ a um valor absurdo ou deslocar V_{th} para fora da faixa em que o neurônio dispara de forma útil. Por essa razão, este trabalho usa uma taxa de aprendizado menor para o segundo grupo: um fator de escala interno de 0,1 aplicado sobre a taxa global, isto é, $\eta_{\text{biofísico}} \approx 10^{-4}$ quando $\eta_{\text{global}} = 10^{-3}$. Esse fator 0,1 é uma escolha de engenharia deste trabalho, e não um valor extraído da literatura.

Mecanismo. O otimizador Adam implementado aceita um multiplicador de taxa de aprendizado por parâmetro: dado o vetor achatado de parâmetros do modelo $\theta_1, \ldots, \theta_n$ e um vetor de escalas $s_1, \ldots, s_n$, a taxa efetiva do parâmetro i é

$$\eta_i = \eta_{\text{global}} \times s_i \,, \tag{2.48}$$

de modo que $s_i = 1$ mantém a taxa global e $s_i = 0{,}1$ aplica a redução — em ambos os casos o restante da atualização de Adam (médias móveis dos gradientes, correção de viés) segue idêntico. A intenção de projeto era popular esse vetor com $s_i = 0{,}1$ exatamente nas posições correspondentes a R, C e V_{th}, e $s_i = 1$ em todas as demais.

Como as posições são identificadas. Marcar explicitamente quais posições do vetor θ são biofísicas exigiria mudar a interface comum de todas as camadas. A implementação usa, em vez disso, uma regularidade da própria rede: R, C e V_{th} são, em todo neurônio LIF, tensores escalares 1×1, e nenhum peso ou viés o é. O vetor de escalas é, então,

$$s_i = \begin{cases} 0{,}1 & \text{se } \theta_i \text{ tem exatamente 1 elemento} \\ 1{,}0 & \text{caso contrário} \end{cases} \tag{2.49}$$

O mesmo critério de tamanho é o que exclui vieses e parâmetros biofísicos do decaimento de peso. Um teste automatizado verifica a distinção: com um parâmetro 1×1 e um 2×2 recebendo o mesmo gradiente, um passo do Adam desloca o primeiro por $\eta_{\text{global}} \times 0{,}1$ e o segundo pelo η_{global} completo. Uma versão anterior aplicava o fator a todos os parâmetros, o que reduzia em dez vezes a taxa de toda a rede; o defeito está registrado no Apêndice A (item 1).

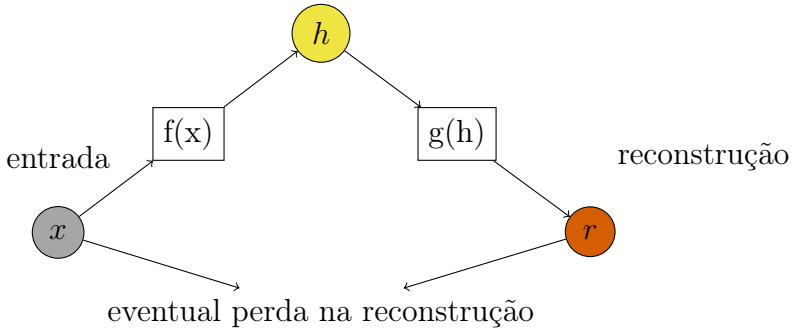
2.1.11 *Autoencoders*

Como ilustrado na Figura 34 *autoencoders* são redes neurais treinadas para reconstruir seus dados de entrada. Elas consistem respectivamente em: Uma função codificadora $f(x)$ que gera um estado h, denotada como $h = f(x)$ e uma função decodificadora $g(x)$ que produz uma reconstrução r, denotada como $r = g(h)$. O estado h representa um **código**, uma representação da entrada que pode ser comprimida ou não (GOODFELLOW; BENGIO; COURVILLE, 2016). Tais funções se traduzem em camadas como ilustrado na Figura 35 cujos neurônios são todos unidades ativas com ou sem funções de ativação. É importante destacar que um *autoencoder* pode ser tão raso como o mostrado na Figura 34.

O principal objetivo de um *autoencoder* é aprender uma representação dos dados de entrada na camada de **código** e, em seguida, reconstruir os dados de entrada com a maior precisão possível usando o decodificador.

Considerando-se que a reconstrução r seja razoável, isso significa que o estado h contém dados suficientes para representar a informação em sua essência, sendo assim, *autoencoders* são ótimos produtores de vetores de características. Hipoteticamente é pos-

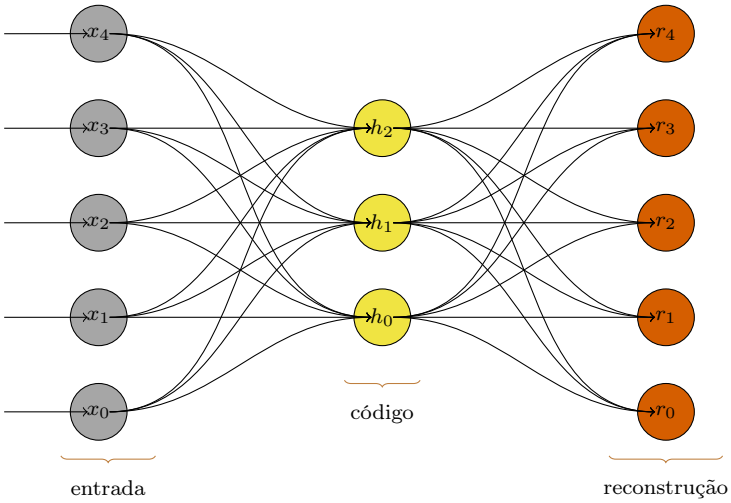
Figura 34 – Representação funcional de um *autoencoder*: Sendo o vetor x uma entrada, então o vetor h é estado resultante da aplicação de uma função codificadora f sobre x: $h = f(x)$, portanto r é a reconstrução de x a partir h através de uma função decodificadora g: $r = g(h)$. Tal processo pode ou não implicar em uma perda de informação.



Fonte: Elaborado pelo autor, 2024.

sível criar *autoencoders* cuja camada de código seja apenas um número inteiro caso tanto o codificador quanto o decodificador sejam grandes e complexos o suficiente, mas isso se mostraria inútil caso se necessitasse algum tipo de representação da informação original que fosse significativa, ademais, excluindo-se casos triviais, segundo (GOODFELLOW; BENGIO; COURVILLE, 2016) isso ainda não se verificou na prática.

Figura 35 – Exemplo esquemático de um *autoencoder* sub-completo ou clássico: Os nós de entrada estão em cinza, a camada de código em amarelo contêm as características codificadas e finalmente a camada de reconstrução em vermelho contêm uma cópia aproximada da entrada.



Fonte: Elaborado pelo autor, 2024.

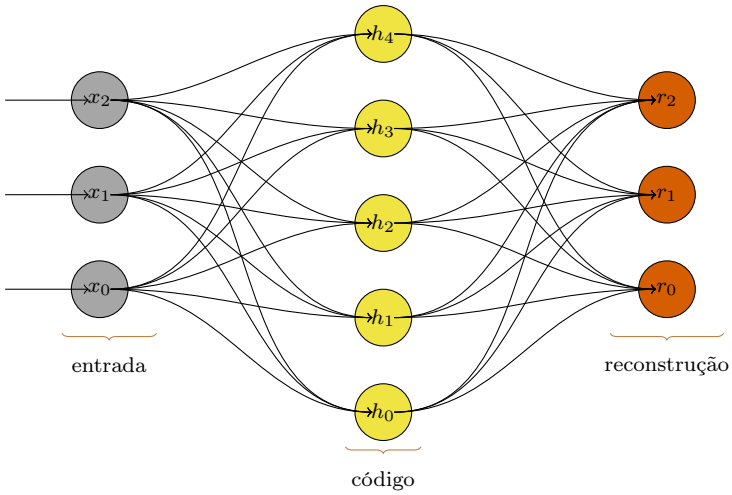
Em se tratando de treinamento, as técnicas já conhecidas e testadas para redes neurais em geral (como, por exemplo, *gradient descent* com *minibatch* ou estocástico) podem ser usadas (GOODFELLOW; BENGIO; COURVILLE, 2016) incluindo as formas de regularização como será exposto mais adiante.

2.1.11.1 Autoencoders sub-completos ou clássicos

Esse tipo de rede neural, como ilustrado na Figura 35, tem sua camada de código limitada em dimensionalidade para apenas aproximar a entrada e priorizar certos aspectos dos dados extraindo dessa forma os componentes mais cruciais e significativos de um conjunto de dados (GOODFELLOW; BENGIO; COURVILLE, 2016). Um autoencoder clássico age de forma muito semelhante ao algoritmo *Principal Component Analysis* (PCA) (BENGIO; COURVILLE; VINCENT, 2014).

2.1.11.2 Autoencoders supra-completos

Figura 36 – Exemplo esquemático de um *autoencoder* supra-completo.



Fonte:Elaborado pelo autor, 2024.

Como mostrado na Figura 36, ao contrário dos autoencoders sub-completos, os supra-completos têm sua camada de código com uma **dimensão maior** do que os dados de entrada. Dessa forma as características dos dados de entrada podem ser codificadas mais de uma vez e uma reconstrução perfeita é atingida. Até o momento estruturas assim são consideradas inúteis já que não conseguem extrair características significativas a não ser que sejam aplicadas técnicas de regularização (BENGIO; COURVILLE; VINCENT, 2014).

2.1.11.3 *Autoencoders* regularizados

Segundo (BENGIO; COURVILLE; VINCENT, 2014) uma das formas de regularização é justamente a limitação da dimensão da camada de código, a mesma aplicada aos *autoencoders* sub-completos, como estes já foram explicados apresentar-se-ão a seguir outras formas de regularização.

Considerando que *autoencoders* devem ser treinados para minimizar uma função de erro E que compara a entrada original x com a reconstrução r então um autoencoder

regularizado deve ter adicionado a essa função um termo de regularizador ϕ como a mostrado na Equação 2.50 que é um termo que pode corresponder a uma regularização L1, L2, $\Omega(h)$ (discutidas na seção C.1).

$$E(x, r) + \phi \tag{2.50}$$

Segundo (GOODFELLOW; BENGIO; COURVILLE, 2016) usando técnicas de regularização é possível até mesmo para um *autoencoder* supra-completo que o mesmo extraia características úteis para uso. Tais técnicas devem prover a seguintes propriedades para a rede:

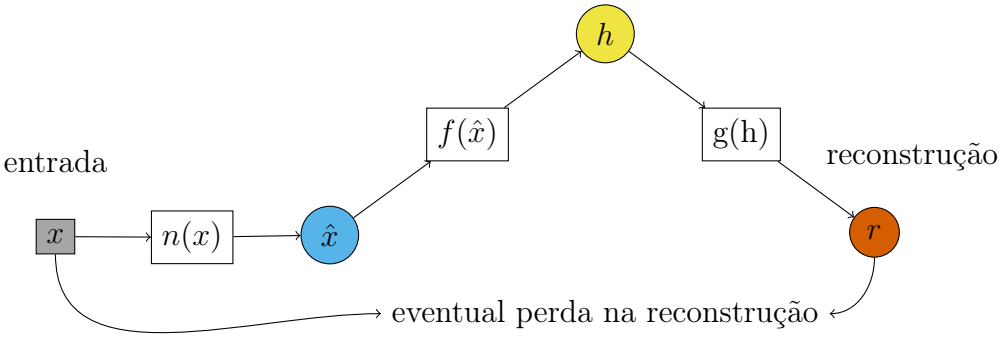
- dispersão: É a tendência de ativar apenas uma pequena quantidade das unidades (também conhecidas como dimensões) da camada de código para qualquer entrada dada criando uma representação mais compacta.

- pequena variação no gradiente: Garantir pouca amplitude nos valores dos gradientes em relação as variações ou ruídos de uma entrada evita que grandes flutuações ocorram na camada de código proporcionando um comportamento estável.

2.1.11.4 *Denoising autoencoders*

Tais redes também podem ser caracterizadas como *autoencoders* regularizados. Porém há diferenças: Aqui o foco não é criar funções de regularização e sim adicionar ruídos **apenas** na informação de entrada mas mantendo a intactos os dados que serão comparados na função de erro como mostra a Figura 37. Um *autoencoder* treinado dessa forma, além de ser mais resiliente a ruídos, também adquire uma funcionalidade de preencher falhas nos dados de entrada quando o componente adicionador de ruído é removido e os dados são diretamente apresentados a rede.

Figura 37 – Representação funcional de um *denoising autoencoder*: Sendo o vetor x uma entrada e n um função que adiciona um ruído aleatório então a informação com ruído $\hat{x}$ é definida como $\hat{x} = n(x)$, portanto o vetor h é resultado da aplicação de uma função codificadora f sobre x: $h = f(x)$, finalmente r é a reconstrução de x a partir h através de uma função decodificadora g: $r = g(h)$. É importante notar que r é comparada com x e não com $\hat{x}$.



Fonte: Elaborado pelo autor, 2024.

2.1.11.5 Colapso do latente no autoencoder pulsante e regularização da taxa de disparo

Um *autoencoder* de pulsos só transmite informação pelo latente se os neurônios do codificador disparam. Esta subseção mostra por que, na inicialização usual, eles quase não disparam, o que acontece então com o treino, e a defesa adotada.

Por que o codificador nasce quase mudo. Na menor configuração usada nesta tese, o codificador é uma camada Linear de 256 entradas para 16 neurônios LIF, seguida de uma Linear para um latente de 8 valores. Com a codificação direta ($T = 1$), o neurônio LIF não acumula carga entre passos e se reduz a um teste de limiar sobre a saída da primeira Linear: todo o poder de discriminação do codificador depende de quantos desses 16 neurônios disparam. Um teste sobre essa camada, com pesos inicializados por He/Kaiming (subseção 2.1.10.9) e entradas uniformes em $[0, 1]$, mediu a taxa de disparo em função da escala dos pesos:

Escala dos pesos	1×	2×	5×	10×	20×
Taxa de disparo	8,30%	24,51%	35,45%	37,11%	39,06%

Na escala da inicialização (1×), apenas 8,3% das combinações neurônio×amostra disparam (85 de 1024). É o **problema da ausência de disparos** de subseção 2.1.10.7: pré-ativação quase sempre abaixo do limiar ⇒ poucos disparos ⇒ gradiente substituto próximo de zero na maioria dos neurônios ⇒ esses neurônios deixam de ser ajustados e permanecem mudos.

O que o treino faz com um latente mudo. Um *autoencoder* treinado por erro quadrático médio cujo latente carrega pouca informação converge para a solução trivial:

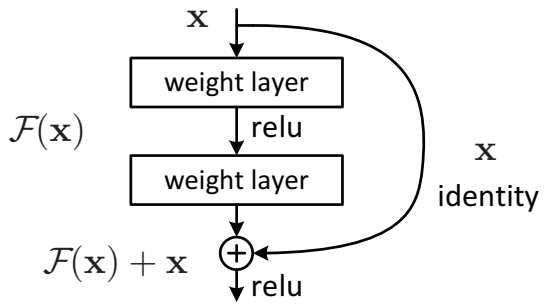
o decodificador ignora o latente e emite a média do conjunto de treino, que é a saída de menor erro quadrático quando nada distingue as amostras. A saída fica constante, e o vetor de características também: $\alpha = \beta = 1$, o vértice *Ambiguidade* de subseção 2.1.5.1.

A defesa adotada. A regularização da taxa de disparo (subseção 2.1.10.8) penaliza camadas cuja taxa média sai de uma faixa $[r_{min}, r_{max}]$. Aplicada às camadas LIF do codificador, ela empurra os neurônios mudos de volta para a região em que o gradiente substituto existe. Todos os SNN-AE desta tese usam $\lambda = 0{,}5$, $r_{min} = 0{,}10$ e $r_{max} = 0{,}80$: r_{min} fica acima da taxa de 8,3% medida na inicialização, para que a penalidade atue desde o início do treino, e r_{max} é o mesmo do classificador. A regularização trata o colapso do latente, não a sobreposição entre classes: um latente que varia entre amostras pode ainda separar mal os locutores, e é $D_{\text{penalizado}}$ que mede isso.

2.1.12 Redes neurais residuais (ResNets)

Segundo (HE *et al.*, 2015a) a ideia-chave por trás das *ResNets* é a inclusão de conexões de salto como ilustrado na Figura 38, também conhecidas como mapeamentos de identidade, permitindo que a saída de uma camada seja adicionada elemento-a-elemento diretamente à entrada de uma camada subsequente. Para que isso aconteça é importante que tanto a saída quanto a entrada tenham a mesma dimensão.

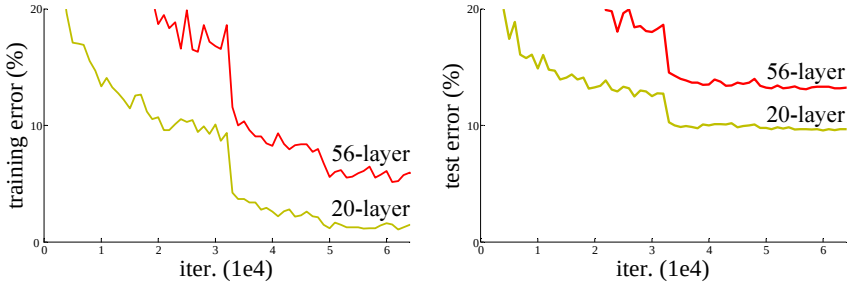
Figura 38 – Bloco Residual: x contorna as camada intermediárias $F(x)$ via uma função identidade somando-se a própria $F(x)$ ao final do bloco.



Fonte: (HE *et al.*, 2015a)

Quando uma rede chega a um certo limite de acurácia, se pode pensar que adicionando mais camadas o desempenho da mesma melhore, no entanto, na prática isso não se verifica. O que se observa em redes mais profundas pode ser exatamente o contrário como mostrado na Figura 39.

Figura 39 – Desempenho de duas redes neurais não residuais com 56 e 20 camadas. A esquerda a taxa de erro durante o treinamento, a direita a taxa de erro em relação ao conjunto de testes.



Fonte: (HE *et al.*, 2015a)

Redes neurais muito profundas podem sofrer de problemas como o desaparecimento ou explosão do gradiente, onde os gradientes (ou seja, as direções para ajustar os pesos da rede) se tornam muito pequenos ou grandes à medida que são retro-propagados. Isso pode dificultar o treinamento eficaz das camadas mais profundas.

Então já que, empiricamente, as redes com menos camadas estão expostas a menos problemas de otimização, é possível juntar várias dessas formando assim uma rede mais profunda e com mais hiperparâmetros que podem ser ajustados. Isso, aliado as técnicas de regularização, diminui a ocorrência do desaparecimento ou explosão de gradientes. (HE *et al.*, 2015a).

Em vez de aprender a mapear diretamente de x para y, as camadas da rede aprendem a mapear de x para a diferença entre x e y, ou seja, para o **resíduo**. Isso simplifica o treinamento, pois a rede precisa apenas ajustar os resíduos, em vez de aprender a mapear completamente as entradas para as saídas.

Além das características já expostas, as redes residuais não adicionam complexidade computacional além da adição elemento-a-elemento. Isso facilita a comparação com redes não residuais com o mesmo número de hiperparâmetros.

2.1.12.1 Aprendizado residual

Considerando então x como a entrada de uma rede, $f(\cdot)$ como uma série de camadas cujas sucessivas aproximações, via treinamento, resultam em um desejado estado intermediário na camada escondida h, então o que se convenciona chamar de resíduo r é dado na Equação 2.51 considerando que h e x tenham a mesma dimensão. Esta é uma reformulação didática, feita pelo autor deste trabalho, da ideia central de (HE *et al.*, 2015a) — o artigo original expressa o mesmo conceito através da função $y = F(x) + x$, em que $F(x)$ é o mapeamento residual aprendido pelas camadas.

$$r = h - x \tag{2.51}$$

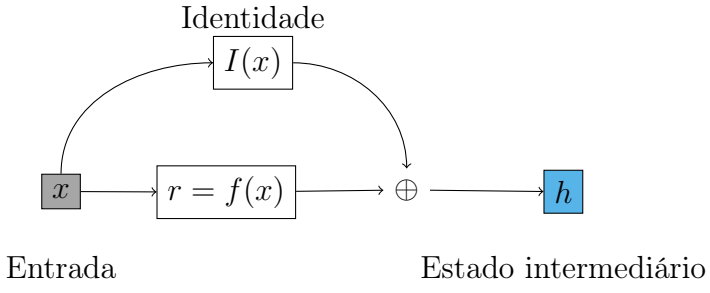
Considerando o resíduo, então se reformula o estado h como mostrado na Equação 2.52 demonstrando que, para se mapear x em h basta que $f(\cdot)$ atue sobre r, ou seja, que as aproximações sucessivas sejam feitas sobre o resíduo r.

$$h = r + x \tag{2.52}$$

Exemplo numérico. Sejam $x = [0{,}80,\ 0{,}50]$ a entrada e $h = [0{,}85,\ 0{,}40]$ o estado intermediário desejado. Pela Equação 2.51, o resíduo é $r = h - x = [0{,}05,\ -0{,}10]$. Aplicando a Equação 2.52, $h = r + x = [0{,}05 + 0{,}80,\ -0{,}10 + 0{,}50] = [0{,}85,\ 0{,}40]$, recuperando exatamente h: a camada só precisa aprender o pequeno ajuste r, não o estado h inteiro.

Se à rede não profunda forem adicionadas camadas cuja única função é receber uma entrada e devolvê-la sem modificações (função identidade) então é trivial que uma rede possa atingir grandes profundidades. No entanto segundo (HE *et al.*, 2015a) em redes profundas os otimizadores tem dificuldade em aprender tais funções identidade levando a degradação do desempenho como mostrado na Figura 39. Nas redes residuais se os mapeamentos identidade (também chamados de conexões de atalho) forem ótimos os otimizadores podem simplesmente zerar todos os pesos das camadas intermediárias de um bloco residual.

Figura 40 – Obtenção do resíduo: Se x é um vetor de entrada na rede e $I(\cdot)$ é uma função identidade cujo valor é diretamente somado $\oplus$ com o resultado produzido pelas várias camadas representadas por $f(\cdot)$, h é um vetor representando um estado intermediário de uma rede neural.



Fonte: Elaborado pelo autor, 2024.

O bloco residual mostrado na Figura 40 torna mais fácil para a rede se aproximar de funções identidade pois basta a mesma zerar os pesos constituintes das camadas representadas por $f(\cdot)$. $f(\cdot)$ é flexível e portanto pode ter n camadas constituintes, essa estrutura pode ser usada múltiplas vezes sozinha ou em conjunto com outras estruturas em uma rede.

2.2 Estado da arte

Esta seção reúne os trabalhos sobre autenticação por fala e por sinais cerebrais. A busca original cobriu de 30/03/2019 a 30/03/2024 e foi atualizada até 12/11/2026 com termos que cobrem o núcleo da tese: biometria por EEG, identificação pela fala imaginada, fusão multimodal, redes de pulso e verificação de locutor com voz patológica. A seção termina com uma tabela comparativa (Tabela 8) e com o que esses trabalhos implicam para as escolhas desta tese.

2.2.1 Protocolo de busca

A busca original seguiu as bases de dados, as palavras-chave e os critérios da subseção 2.2.1.1 e da subseção 2.2.1.2; a atualização está na subseção 2.2.1.3.

2.2.1.1 Critérios de inclusão e exclusão

- publicados entre 30/03/2019 e 30/03/2024 além de outros trabalhos relevantes para construção da base teórica.
- que correspondam às palavras-chave de pesquisa constantes na listagem constante na subseção 2.2.1.2
- cujo *abstract* contenha as bases de dados usadas, os resultados e a metodologia brevemente descritos.
- que tratam de autenticação por EEG e/ou voz, e, quando da falta dos mesmos, que pelo menos auxiliem no tema estudado

2.2.1.2 Base de dados e palavras-chaves

- Web of Science [8]:
  - palavras chave: voice *AND* authentication
  - filtros aplicados: *Publication date*: 2019-03-30 *to* 2024-03-30
- Google Scholar [9]:
  - palavras chave: +voice +authentication
  - filtros aplicados: *Período específico...* 2019 - 2024; *Incluir citações*;
- Athena [10]:

[8] https://www.webofscience.com/ (Acesso restrito por VPN)
[9] https://scholar.google.com
[10] https://unesp.primo.exlibrisgroup.com/discovery/search?vid=55UNESP_INST:UNESP (Necessita autenticação da Central de Acessos da UNESP)

  - palavras chave: *Qualquer campo contém* Imagined Speech; *E qualquer campo contém* EEG; *E qualquer campo contém* wavelet
  - filtros aplicados: *Data inicial:* 30/03/2019; *Data final:* 30/03/2024; *Idiomas:* Excluir Coreano e Japonês

- Athena:
  - palavras chave: *Qualquer campo contém* authentication; *E qualquer campo contém* voice
  - filtros aplicados: *Data inicial:* 30/03/2019; *Data final:* 30/03/2024; *Idiomas:* Excluir Coreano e Japonês; *Excluir artigos de newsletter*

2.2.1.3 Atualização da busca

A busca original não tinha termos para autenticação por EEG, fusão multimodal nem redes de pulso, que são o núcleo desta tese, e terminava 30 meses antes da data de fechamento do texto. A atualização, feita em 12/11/2026, cobriu de 30/03/2019 a essa data com as combinações abaixo, em duas fontes: o Athena (com o índice central do serviço de descoberta, acessado pela rede da UNESP), filtrado por data de publicação entre 2019 e 2026, e um mecanismo de busca acadêmica na *web*, que alcança *preprints* e anais de congresso. Os metadados de cada trabalho selecionado (autores, veículo, ano, DOI) foram conferidos na base Crossref, e os de *preprints*, no arXiv:

- *EEG biometric AND* (*authentication OR equal error rate*) — 146 resultados no Athena;
- (*imagined speech OR inner speech OR covert speech*) *AND EEG AND* (*identification OR authentication OR biometric*) — 17;
- *EEG AND* (*voice OR speaker*) *AND* (*authentication OR biometric*) *AND* (*fusion OR multimodal*) — 6;
- *spiking AND* (*EEG OR speaker OR voice*) *AND* (*identification OR authentication OR verification*) — 32, nenhum sobre identificação de pessoas;
- *speaker verification AND* (*dysphonia OR dysarthria OR pathological voice OR pathological speech*) — 10;
- *spiking neural network AND* (*energy efficiency OR energy consumption*) *AND* (*ANN OR artificial neural network*) — 157.

Os critérios de inclusão foram os da subseção 2.2.1.1, com o período estendido; dos resultados, foram lidos os títulos dos 40 primeiros de cada combinação, ordenados por relevância, e os resumos dos selecionados. A atualização foi repetida no Web

of Science [PENDENTE: registrar data, combinações, contagens e trabalhos novos] . Os trabalhos que ela acrescenta estão na subseção 2.2.3.

2.2.2 Trabalhos da busca original

O primeiro estudo consultado (PARK; LEE, 2023) aborda o uso de EEG para captação de fala imaginada usando as técnicas de decomposição de sinal NA-MEMD (*multivariate empirical mode decomposition*) e DTWPT e a arquitetura de redes neurais MRF-CNN. A NA-MEMD é uma extensão do EMD (*Empirical mode decomposition*) para sinais multivariados permitindo a decomposição de sinais. O MRF-CNN é uma arquitetura de rede neural convolucional profunda que utiliza características estatísticas extraídas dos sinais decompostos como entrada para o classificador. Foram utilizadas técnicas de validação cruzada e divisão de dados para treinamento e teste do classificador. Os dados EEG foram coletados dos nove sujeitos saudáveis, estes tiveram que imaginar as vogais "a", "e", "i", "o", "u". O estudo atingiu uma média de 80,41% de classificações corretas.

Em (ABDULGHANI; WALTERS; ABED, 2023b) usa *Wavelet Scattering Transform* (WST), técnica que aplica sobre o sinal transformadas wavelet combinadas com operações não lineares, para extração de características para posterior classificação por uma Rede Neural LSTM(*Long-Short term memory*) recorrente. Os quatro sujeitos imaginaram as seguintes expressões: *"up", "down", "left"e "right"*. Em testes a acurácia alcançada foi 92,50%.

Com o fim de remover ruídos e artefatos causados por movimentos musculares relacionados à região da cabeça em (MAHAPATRA; BHUYAN, 2023) foi usada a DTWT[11] para processar os sinais EEG, que foram obtidos a partir das bases de dados EPOC e MUSES (VIVANCOS, 2023). Depois da filtragem e geração de características, variações de Redes Neurais Recorrentes Bidirecionais foram empregadas na classificação das classes compostas pelos dígitos de 0 a 9. Foram alcançadas acurácias máximas de 98,18% na base MUSE e 71,60% na EPOC.

Nesta revisão (SHAH *et al.*, 2022) que foi feita segundo as orientações constantes no protocolo PRISMA-ScR foram selecionados 34 trabalhos que analisaram palavras e expressões imaginadas, nestes, a técnica mais usada para extração de características foram os filtros Wavelet e os algoritmos de classificação mais proeminentes foram as *Support Vector Machines*(SVM) e as Redes Neurais Convolucionais. É reportado que os estudos utilizam poucos tipos de métricas limitando-se na maioria dos casos a acurácia, a revisão sugere que também sejam usadas métricas como: Precisão, *Recall*, Taxa de erro de palavras (Word Error Rate), AUC (Área Under the Curve), Sensitividade, Especificidade e Média Quadrática a fim de se oferecer uma visão mais geral dos resultados.

[11] Transformada Wavelet em Tempo Discreto

Uma combinação de redes neurais convolucionais temporais (TCN) e convolucionais tradicionais (CNN) foi usada no estudo (MAHAPATRA; BHUYAN, 2022) para classificar sinais de EEG pré-processados pelo algoritmo de Análise Independente de Componentes (*FastICA*) a fim de proporcionar uma melhor separação dos canais e por DTWT para remoção de artefatos e criação dos vetores de características. Os sinais foram obtidos da base (CORETTO; GAREIS; RUFINER, 2017) que é composta por sinais produzidos por 15 sujeitos falantes de espanhol com as vogais "a", "e", "i", "o", "u"e com os comandos *"arriba", "abajo", "derecha"e "isquierda"*. O estudo alcançou uma acurácia de 96,49%.

Para classificar as letras do alfabeto imaginadas em inglês por 13 sujeitos o estudo (AGARWAL; KUMAR, 2022) usou a DTWT para remoção ruídos e separação de bandas de frequência do sinal a ser classificado por dois algoritmos simultaneamente: Árvores Aleatórias (ou *Random Forrest*)(RF) e SVM. O estudo alcançou uma acurácia média entre as classificações de todos os elementos do alfabeto de 77,97%. Neste trabalho também foi utilizado o método *Common Average Referecing*(CAR) que, via a subtração de uma média dos sinais captados em um certo intervalo de tempo, procura remover interferências induzidas em todos os eletrodos por variáveis ambientais aumentando a relação sinal/interferência (*Signal-to-noise ratio*)(SNR). Uma interessante constatação desse trabalho é de que as ondas cerebrais α, β e θ, quando consideradas sozinhas, melhoram o desempenho dos classificadores.

Aqui (HERNÁNDEZ-DEL-TORO; REYES-GARCÍA; PINEDA, 2021) usa os seguintes métodos de extração de características: DTWT (para obtenção da energia de bandas), EMD, dimensões fractais e características extraídas segundo metodos da teoria do caos. Os dados foram obtidos a fim de se criar 3 bases de dados contendo as palavras em espanhol *"arriba", "abajo", "derecha"e "isquierda"*, a primeira continha informações de 27 pessoas, a segunda também 27 e a terceira 20. Na primeira e segunda bases, a taxa de captura foi de 128Hz e na terceira 500Hz, esta foi subamostrada para 128Hz a posteriori. Para remoção de ruído o método CAR foi usado. Os classificadores usados foram RF, *K-nearest-neighbors*(KNN), SVM e Regressão Logística. Para avaliação as métricas Pontuação F1 (PF1), Precisão e *Recall* foram usadas. Os melhores resultados obtidos nas bases 1, 2 e 3 foram respectivamente: 0,73, 0,79 e 0,68 para PF1, 0,66, 0,70, 0.65 para Precisão e 0,87, 0,93 e 0,83 para *Recall*.

Constante nas referências de (HERNÁNDEZ-DEL-TORO; REYES-GARCÍA; PINEDA, 2021) um dos poucos trabalhos que discorreram sobre a identificação de pessoas (MOCTEZUMA *et al.*, 2019) usou CAR para melhorar a SNR dos sinais armazenados e amostrados a 128Hz correspondentes as palavras em espanhol *"arriba", "abajo", "derecha"e "isquierda"* imaginadas por 27 sujeitos. A geração do vetor de características foi feita usando DTWT em 4 níveis e para cada nível foi calculada a Energia de *Teager* ou

Teager Energy Operator (TEO). RF foi usada como classificador. Os resultados variaram entre 85% quando todos os 27 sujeitos foram incluídos até 97% quando apenas 5 foram considerados.

Dada a pouca quantidade de dados e bases existentes quando se trata de EEG, o artigo (PANACHAKEL; RAMAKRISHNAN, 2021) usou uma técnica de expansão de informação baseada em "janelas deslizantes"ao mesmo tempo em que, em vez de considerar separadamente cada sensor, agrupou os dados dos mesmos em matrizes tridimensionais semelhantes a imagens que foram processadas por uma rede Resnet50 (HE *et al.*, 2015a) adaptada usando a técnica de transferência de aprendizado. A base de dados usada (NGUYEN; KARAVAS; ARTEMIADIS, 2018) é composta por EEG capturado de 64 canais a 1000Hz para as seguintes falas imaginadas por 11 pessoas do sexo masculino e 4 do feminino: *"independent", "cooperate", "in", "out", "up", "a", "i", "u"*. As taxas de amostragem foram posteriormente diminuídas para 250Hz e filtradas para remoção de ruídos e artefatos. Os resultados variaram de um mínimo de 79,7% de acurácia para classificação de vogais até um máximo de 95,5% para palavra curtas e longas.

(TAMM; MUHAMMAD; MUHAMMAD, 2020) usou uma base de dados composta por 15 sujeitos imaginando as letras *"a", "e", "i", "o", "u"* e mais seis diferentes palavras (CORETTO; GAREIS; RUFINER, 2017) e simplificou a estrutura de uma CNN criada em outro estudo usando uma técnica de transferência de aprendizado enquanto tentou manter a mesma acurácia. Os dados iniciais foram submetidos a sub-amostragem para que se chegasse a uma taxa de amostragem de 128Hz e dispostos em uma matriz de duas dimensões. O classificador simplificado atingiu uma acurácia média de 23,98%.

(PANACHAKEL; RAMAKRISHNAN; ANANTHAPADMANABHA, 2019) utilizou 11 palavras da base de dados (ZHAO; RUDZICZ, 2015), extraindo de cada canal características baseadas em transformadas *Wavelet* de nível 7, alcançando uma acurácia média de 57,15%. A inovação aqui foi tratar separadamente os vetores de características dos 11 canais, inserindo-os, um por vez, em uma rede neural profunda com 2 camadas ocultas. A classificação foi realizada por votação de maioria simples após o processamento dos 11 sinais da fala imaginada a ser classificada. A base de dados é composta por 7 fonemas e 4 palavras imaginadas, com uma taxa de amostragem de 1KHz. Os dados foram filtrados em uma banda de 1 a 50Hz.

Usando uma rede neural profunda de 4 camadas ocultas como classificador para duas palavras (*"in"* e *"cooperate"*) presentes no banco de dados referenciado em (DASALLA *et al.*, 2009), (PANACHAKEL; RAMAKRISHNAN; ANANTHAPADMANABHA, 2020) criou vetores de características usando a transformada wavelet de 4 níveis, extraindo características como variância, entropia e Root Mean Square (RMS). Esses vetores foram então classificados usando um sistema de votação, onde cada vetor de características de cada canal é avaliado individualmente e a classe é determinada por maioria

simples (similar a (PANACHAKEL; RAMAKRISHNAN; ANANTHAPADMANABHA, 2019)). O banco de dados é composto por amostras coletadas de 15 sujeitos com taxa de amostragem de 1KHz. O sistema obteve uma acurácia média de 71,8%.

A revisão (SEN *et al.*, 2023), cujo objetivo foi analisar artigos cuja temática fosse a escrita e fala imaginadas a partir de sinais captados por técnicas de EEG invasivas ou não, possibilitou uma visão geral do estudo da fala imaginada e as respectivas técnicas de pré-processamento e classificação já usadas. A revisão coletou trabalhos de 2014 até 2022 e identificou que os métodos usados no intervalo de tempo considerado foram os clássicos SVM, RF, *Hidden Markov Model* (HMM) e *Gaussian Mixed Models* (GMM), além desses, as técnicas de aprendizado profundo usadas foram CNN, Rede Neurais Recorrentes (RNN), *Gate Recurrent Unit* (GRU) e *Long Short Term Memory* (LSTM), sendo as técnicas de aprendizado profundo começando a serem usadas a partir do ano de 2020, ou seja, relativamente recente. Quanto a extração de características o MFCC e a (Transformada de Fourier Discreta) DFT foram as mais utilizadas seguidas por PCA, ICA, DTWT e Média Quadrática (RMS).

Apesar da autenticação por voz não ser um tema novo, há poucos trabalhos recentes que tratam do assunto, em sua maioria os artigos relacionados ao reconhecimento de voz focam mais em detecção de patologias. A busca original não encontrou trabalhos recentes sobre a verificação de locutores disfônicos; a atualização encontrou um ((Tayebi Arasteh *et al.*, 2023), discutido na subseção 2.2.3). Dito isso (WANG *et al.*, 2023) combinou a arquitetura Res2Net (GAO *et al.*, 2021a) com *Perceptual Wavelet Packet Entropy* (PWPE) e um bloco *Efficient Channel Attention* (ECA) (WANG *et al.*, 2019) para reconhecer locutores cujas vozes constam da base de dados (FAN *et al.*, 2020) composta por vozes de celebridades chinesas em várias situações (gravação em estúdio, palestras, gravações em ambientes ruidosos, etc.). PWPE consiste em "podar"os nós da árvore de decomposição *wavelet package* segundo seus "centros de frequência"e energia definidos anteriormente de acordo com a amplitude de audição da espécie (no caso: Humanos), dessa forma apenas as frequências pertencentes à escala auditiva humana permanecem. Em seguida é aplicado o operador não normalizado de entropia de Shannon, gerando assim os vetores de características. Nesse artigo o objetivo foi verificar como os modelos se comportariam em termos de EER se fossem treinados em um contexto e depois aplicados a outros com, por exemplo, treinar em uma palestra em um auditório e testar com dados vindos de ambientes externos. Os resultados de classificação foram, em média, de menos do que 8% de EER para contextos de médio e alto ruído.

No estudo de (ALI *et al.*, 2022), embora o foco não fosse a identificação dos locutores, os classificadores concentraram-se na classificação do gênero das pessoas envolvidas. Para a criação dos vetores de características, foram utilizados MFCC e *Linear Prediction Coefficients* (LPC). Os dados utilizados foram coletados de uma base de dados com 93

locutores (HILLENBRAND *et al.*, 1995). Como classificadores, foram empregadas Análises Discriminantes e redes neurais artificiais. Os melhores resultados foram alcançados pela combinação de uma rede neural com MFCC, obtendo uma acurácia de 97,07%.

Dos estudos apresentados até o momento todos avaliaram a fala (imaginada ou não) do locutor ao pronunciar uma certa palavra, frase ou sílaba, nesses trabalhos o acesso ao sistema deve ser feito no esquema de um porteiro que libera ou não o acesso sem uma verificação contínua da identidade do locutor. Em (MENG; ALTAF; JUANG, 2020) implementou-se o *active voice authentication* (AVA) ou sistema de autenticação ativa que consiste na verificação constante e em tempo real da identidade de quem fala. O sistema extrai os dados coletando sinais com um esquema de janela móvel que acumula 1 segundo de dados e, usando essa amostra, calcula coeficientes MFCC para gerar os vetores de características que alimentam uma HMM para treinamento e classificação. Os dados usados no trabalho foram coletados de 25 locutores (14 mulheres e 11 homens) a uma taxa 8Khz contendo um serie de locuções de textos longos, curtos, alguma senha escolhida pelo locutor e pares de dígitos totalizando um total de 2 horas e meia para todos os locutores. Como medida de desempenho uma versão adaptada do ERR foi criado: O *Window-based equal error rate* (WEER) alcançando uma taxa média de 3% a 4%.

Captando a fonação distorcida pelos tecidos e ossos do usuário através de microfones instalados em fones de ouvido, o estudo (GAO *et al.*, 2021b) teve como objetivo aproveitar a anatomia individual para gerar uma impressão digital. Essa impressão digital é obtida comparando o áudio captado por outro dispositivo, permitindo assim a identificação do locutor. Para a realização do trabalho, uma base de dados amostrada a 48 kHz com 23 locutores (5 mulheres e 18 homens) entre 24 e 30 anos foi criada. Os dados foram submetidos a um filtro para remover frequências acima de 4 kHz. Dois classificadores (GMM e Floresta de Árvores de Decisão) utilizando um sistema de votação ponderada foram usados para autenticar os locutores. Em termos de características, foram extraídos 20 coeficientes MFCC. O resultado foi um EER de 3,64

Na mesma linha de aproveitar características outras que não só a fonação, (JIANG *et al.*, 2023) usa os *"sons de estalos"* (*pop noises*) emitidos durante a fala para prevenção de *voice spoofing*, tais sons são típicos de quando uma certa pressão do ar se acumula no aparelho fonador sendo liberado em ondas de maior pressão, geralmente durante a pronúncia de palavras com consoantes, tais sons são específicos de cada locutor ou locutora e é de difícil reprodução já que a captação de som deve ser feita a, no máximo, 12 centímetros de distância. Para desenvolver o trabalho foram coletadas por cinco vezes senhas faladas por 30 locutores a uma taxa de 44.1kHz, tais senhas continham de 3 a 10 palavras. Para classificação foi empregado um modelo de regressão logística que avalia um vetor de características de 3 dimensões $f = \{pro1, pro2, pro3\}$ sendo $pro1$ a medida de *"estalos"* nos fonemas vozeados (geralmente vogais), $pro2$ a medida de *"estalos"* nos

fonemas não vozeados (geralmente consoantes) e $pro3$ que é a medida de similaridade entre os *"estalos"* da atual tentativa de autenticação com os dados de cadastro já armazenado em uma fase anterior.

O estudo (FURLAN, 2021) usou dois métodos principais para classificação: um baseado no cálculo de distâncias Euclidiana e Manhattan entre pontos de dados e outro usando uma SVM. Para extrair características úteis dos sinais de fala, primeiro aplicou-se transformadas usando várias wavelets para destacar informações de tempo e frequência. Em seguida, esses sinais transformados foram agrupados de acordo com as escalas MEL ou BARK, que refletem a percepção humana do som, e a energia dentro de cada grupo foi calculada para criar vetores de características. Tais combinações de escala e wavelet foram testadas usando a engenharia paraconsistente de características a fim de encontrar qual geraria o melhor vetor de características. Os dados vieram de gravações de 21 pessoas falando dígitos de 0 a 9 em inglês e português em ambientes com diferentes níveis de ruído. Essas gravações foram categorizadas em grupos genuínos e falsificados. O sistema diferenciou corretamente as falas autênticas das falsificadas com mais de 99% de precisão e um EER de 0,024390 usando uma combinação específica da escala BARK e wavelet Haar.

2.2.3 Atualização: trabalhos de 2023 a 2026

Biometria por EEG. Duas revisões recentes resumem o campo. A de (ALBAIATI *et al.*, 2025), sistemática (PRISMA, 34 trabalhos de 2018 a 2024), relata que redes convolucionais, recorrentes, adversariais e *Transformers* atingem mais de 90% de acurácia de identificação e EER baixo, e aponta como problemas em aberto a generalização entre bases e entre sujeitos e a estabilidade da assinatura ao longo do tempo. A de (ATAIDE *et al.*, 2026) chega a desafios semelhantes: variabilidade entre sessões e entre sujeitos, idade e condições de saúde mental. O estudo de (FALLAHI; ARIAS-CABARCOS; STRUFE, 2025) mede essa instabilidade em escala: com 345 sujeitos e 6007 sessões gravadas ao longo de cinco anos, o EER cresce de 6,7% quando cadastro e teste estão separados por um dia para 14,3% quando estão separados por um ano; extratores aprendidos superam os manuais. O mesmo efeito aparece em (HOLLER; BATHKE; UHL, 2019): com 60 sujeitos, o melhor EER passa de 5,34% com uma única gravação a 22% na validação cruzada entre sessões, e idade, sexo e condição neurológica interagem com a estabilidade das características. As respostas propostas são treinar com vários protocolos de estímulo (DEBIE; MOUSTAFA; VASILAKOS, 2022), combinar o EEG com outra biometria, como a dinâmica de digitação, separando treino e teste por dia de gravação (RAHMAN *et al.*, 2022), ou calibrar com poucos dados da sessão de teste: em (CHEN *et al.*, 2026), essa calibração leva o EER entre dias a 1,04%. Em uma única base com 38 sujeitos e estímulos que evocam os potenciais P300 e N400, (AL-NAFJAN *et al.*, 2025) relatam 99% de acurácia

com uma rede convolucional.

Fala imaginada como biometria. Que o EEG da fala imaginada carrega a identidade de quem imagina já tinha sido mostrado por (BRIGHAM; KUMAR, 2010), com 99,76% de acurácia de identificação a partir de coeficientes autorregressivos e uma **SVM!**[12], e por (MOCTEZUMA *et al.*, 2019), na busca original. O trabalho mais recente encontrado, (DERAKHSHESH *et al.*, 2025), retira as pistas visuais e auditivas que as bases anteriores usam para indicar o que imaginar — os sujeitos escolhem a palavra de uma lista — e testa em sessões não vistas no treino: com 11 sujeitos, cinco sessões e mais de 4350 tentativas, o melhor modelo atinge 97,93% de acurácia de identificação. As duas revisões sistemáticas recentes sobre fala imaginada (ALZAHRANI; BANJAR; MIRZA, 2024; TATES *et al.*, 2025) tratam da decodificação do conteúdo imaginado, e não de quem imagina.

Redes de pulso. A identificação de pessoas por EEG com uma rede de pulsos aparece em (LIN; CAI; LI, 2025): um *Transformer* de pulsos atinge 100% de acurácia sobre 26 sujeitos que ouviam música, com menos de 10% da energia de uma rede profunda convencional. A vantagem energética das redes de pulso, porém, depende de como a energia é contada. As análises que incluem os acessos à memória, e não apenas as operações aritméticas, chegam a conclusões mais estreitas: em (DAMPFHOFFER *et al.*, 2023), redes de pulso com neurônios integra-e-dispara só competem com implementações eficientes de redes convencionais quando a atividade é muito esparsa (entre 0,15 e 1,38 disparos por sinapse por inferência); em (YAN *et al.*, 2024), com $T = 5$ passos de tempo, a rede de pulsos precisa de uma taxa média de disparo abaixo de 5,7% para superar uma rede convencional quantizada de capacidade equivalente. Para redes de pulso com codificação por taxa obtidas a partir de uma rede convencional, (DAVIDSON; FURBER, 2021) concluem que, na mesma tecnologia de silício, a maioria das implementações não é mais eficiente que a rede original. O modelo de energia desta tese conta a memória pelo mesmo motivo (subseção 3.3.1.2).

Voz patológica. O estudo de (Tayebi Arasteh *et al.*, 2023), com mais de 3800 falantes, mostra que a patologia, por si só, não impede a verificação: quando cadastro e teste vêm do mesmo grupo, adultos disfônicos têm EER *menor* que o do grupo de controle (2,40% contra 3,12%), e a disartria não difere do controle. O caso desta tese é outro: o de um locutor cadastrado com a voz saudável e testado com a voz degradada, em que a degradação é um descasamento entre cadastro e teste. Para a disartria, (SALIM; SHAHNAWAZUDDIN; AHMAD, 2024) melhoram a verificação combinando coeficientes cepstrais em escala Mel e linear e aumentando os dados de treino, e (SALIM; AHMAD, 2024) geram voz disártrica sintética a partir de voz saudável, por conversão de voz, para aumentar o treino — a mesma ideia de simular a degradação que esta tese aplica à disfonia.

[12] **SVM!**

Fusão de voz e EEG. O trabalho mais próximo desta tese é a base BIOMEX-DB (MORENO-RODRIGUEZ *et al.*, 2021), pública (RODRÍGUEZ, 2021): voz e EEG de 14 canais adquiridos simultaneamente (e vídeo para 39 deles), com 51 sujeitos pronunciando em voz alta sequências de dígitos em espanhol, em duas sessões por sujeito, 140 amostras por sujeito. A base não tem fala imaginada. Entre os experimentos iniciais da base, uma identificação bimodal por EEG e voz atinge 97,6% de acurácia — identificação de conjunto fechado, sem degradação da voz. A atualização não encontrou trabalho que avalie a fusão de voz e EEG em verificação com locutores fora do treino, nem sob degradação da voz. As demais fusões multimodais com EEG o combinam com a assinatura manuscrita (DAS *et al.*, 2025) ou com a dinâmica de digitação (RAHMAN *et al.*, 2022); a voz aparece fundida ao eletrocardiograma, no nível das pontuações (ZEHIR; HAFS; DAAS, 2025).

2.2.4 Síntese comparativa

A Tabela 8 reúne os trabalhos que identificam ou autenticam pessoas e que informam o número de sujeitos e o resultado.

Tabela 8 – Trabalhos de identificação e autenticação por voz e por EEG. "Identificação" escolhe o sujeito entre os vistos no treino (conjunto fechado); "verificação" aceita ou recusa uma identidade declarada

Trabalho	Sinal	Sujeitos	Tarefa e método	Resultado
Furlan (2021)	voz (dígitos)	21	verificação; DTWPT e engenharia paraconsistente	EER 2,44%
Meng, Altaf e Juang (2020)	voz	25	verificação contínua; MFCC e HMM	EER por janela de 3 a 4%
Gao *et al.* (2021b)	voz captada no fone de ouvido	23	verificação; MFCC, GMM e árvores de decisão	EER 3,64%
Wang *et al.* (2023)	voz	base CN-Celeb	verificação entre contextos de gravação; Res2Net e entropia de pacotes *wavelet*	EER abaixo de 8% (ruído médio e alto)
Tayebi Arasteh *et al.* (2023)	voz patológica	mais de 3800	verificação; rede profunda	EER 0,89%; disfonia 2,40%, controle 3,12%
Moctezuma *et al.* (2019)	EEG, fala imaginada	27	identificação; DTWT e floresta aleatória	acurácia de 85% (27 sujeitos) a 97% (5)
Derakhshesh *et al.* (2025)	EEG, fala imaginada sem pista	11	identificação, teste em sessão não vista; EEG Conformer	acurácia 97,93%
Al-Nafjan *et al.* (2025)	EEG, potenciais evocados	38	autenticação medida por acurácia; rede convolucional	acurácia 99%
Lin, Cai e Li (2025)	EEG, escuta musical	26	identificação; *Transformer* de pulsos	acurácia 100%

Trabalho	Sinal	Sujeitos	Tarefa e método	Resultado
Holler, Bathke e Uhl (2019)	EEG	60	verificação, mesma sessão e entre sessões; coeficientes autorregressivos	EER 5,34% (mesma sessão); 22% (entre sessões)
Fallahi, Arias-Cabarcos e Strufe (2025)	EEG	345	verificação entre sessões; redes profundas	EER 6,7% (1 dia) a 14,3% (1 ano)
Moreno-Rodriguez *et al.* (2021)	voz e EEG síncronos (14 canais), fala pronunciada	51	identificação bimodal	acurácia 97,6%
Esta tese	voz e EEG (6 canais), fala pronunciada e imaginada	15	verificação, locutores de teste fora do treino, sessão única; DTWPT e DSNN	EER 0,2205 (fusão); 0,3180 (voz)

O que é e o que não é comparável. Os números da tabela não formam um *ranking*, por três razões. Primeiro, a tarefa: a acurácia de identificação escolhe entre sujeitos já vistos no treino, e o EER de verificação avalia, como nesta tese, pessoas que o modelo nunca viu; a segunda tarefa é mais difícil e seus números não se convertem nos da primeira. Segundo, o número de sessões: (FALLAHI; ARIAS-CABARCOS; STRUFE, 2025) mostram o EER dobrar de um dia para um ano entre cadastro e teste, (HOLLER; BATHKE; UHL, 2019) o veem quadruplicar entre sessões, e os resultados de sessão única — o desta tese incluído — são, por isso, limites superiores do desempenho entre sessões. Terceiro, o número de sujeitos: em (MOCTEZUMA *et al.*, 2019), a acurácia cai de 97% para 85% quando se passa de 5 para 27 sujeitos. O trabalho de protocolo mais próximo ao desta tese é (FALLAHI; ARIAS-CABARCOS; STRUFE, 2025) (verificação), com uma base 23 vezes maior e várias sessões por sujeito; o de sinais mais próximos é (MORENO-RODRIGUEZ *et al.*, 2021) (voz e EEG síncronos), avaliado em identificação.

2.2.5 Implicações para esta tese

A lacuna. O EEG carrega a identidade de quem fala ou imagina (BRIGHAM; KUMAR, 2010; MOCTEZUMA *et al.*, 2019; DERAKHSHESH *et al.*, 2025), a voz patológica, cadastrada como patológica, ainda é verificável (Tayebi Arasteh *et al.*, 2023), e voz e EEG juntos identificam pessoas em conjunto fechado (MORENO-RODRIGUEZ *et al.*, 2021). A combinação das duas para *verificar* um locutor que o sistema não viu no treino, e cuja voz se degradou depois do cadastro, não apareceu em nenhuma das duas buscas. É essa combinação que esta tese avalia, com a ressalva de que a degradação é simulada (subseção 3.3.1.2).

A variabilidade entre sessões é o problema central da biometria por EEG (ALBAIATI *et al.*, 2025; ATAIDE *et al.*, 2026; FALLAHI; ARIAS-CABARCOS;

STRUFE, 2025), e a base usada aqui tem uma única sessão por sujeito. Os resultados de EEG desta tese não podem respondê-la; o Capítulo 4 os trata como limite superior.

Extração por *wavelets*. A transformada *wavelet* é o extrator mais usado nos estudos de fala imaginada da busca original (SHAH *et al.*, 2022), e a seleção de nós da árvore de pacotes por faixa de frequência (WANG *et al.*, 2023) se aplica tanto à voz quanto ao EEG. É o ponto de partida do extrator manual desta tese. A recomendação de usar mais de uma métrica (SHAH *et al.*, 2022) é atendida com o EER e a AUC[13].

Pré-processamento do EEG que a literatura usa e esta tese não adota. Quatro técnicas aparecem nos trabalhos revisados. Limpar o sinal tem custo e benefício em biometria: a limpeza pode remover parte da assinatura individual, e (USMAN *et al.*, 2026) propõem por isso uma limpeza branda, que melhorou a acurácia em 5,3% em relação ao sinal bruto. Nenhuma das quatro é aplicada aqui: o EEG é lido como a base o distribui, e as tentativas que a base marca com piscada ocular (2653 das 9315) não são excluídas. Antes das razões, uma medida do que a base distribui. O espectro de potência médio das 9315 tentativas (Tabela 9) confirma o filtro que os autores da base declaram aplicar, um FIR passa-faixa de 2 a 40 Hz (CORETTO; GAREIS; RUFINER, 2017): a potência cai 12 dB entre a faixa α e 30 Hz, 29 dB em 46 Hz e 58 dB em 50 Hz; 98,1% da potência está abaixo de 32 Hz, 1,9% entre 32 e 64 Hz e praticamente nada acima disso.

Tabela 9 – Distribuição da potência do EEG da base (já filtrado pelos autores entre 2 e 40 Hz), média das 9315 tentativas e dos seis canais, e nível em algumas frequências em relação ao da faixa α (8–12 Hz). Cada faixa da esquerda corresponde a uma sub-banda da DTWPT de nível 4

Faixa	Potência	Frequência	Nível
0–32 Hz (sub-banda 0)	98,1%	10 Hz	0,9 dB
32–64 Hz (sub-banda 1)	1,9%	30 Hz	−12,0 dB
64–512 Hz (sub-bandas 2 a 15)	0,0%	46 Hz	−29,4 dB
		50 Hz	−58,5 dB
		64 Hz	−99,9 dB

Fonte: Elaborado pelo autor, 2026. Calculado com SciPy (Apêndice B).

As razões para cada ausência, e o que ela implica, são estas:

- **Referência pela média comum** (CAR) (AGARWAL; KUMAR, 2022; HERNÁNDEZ-DEL-TORO; REYES-GARCÍA; PINEDA, 2021; MOCTEZUMA *et al.*, 2019): subtrai de cada eletrodo a média de todos. Com seis eletrodos, todos frontais, centrais ou parietais, essa média é uma estimativa pobre de uma referência neutra e subtrairia atividade comum aos seis canais (argumento de projeto, não medido aqui);

[13] Área sob a Curva (*Area Under the Curve*)

- **Análise de componentes independentes** (ICA) (MAHAPATRA; BHUYAN, 2022): com seis canais há no máximo seis componentes a separar, o que limita a remoção de artefatos (mesmo argumento, não medido);
- **Filtro da frequência da rede elétrica** (MAHAPATRA; BHUYAN, 2023): desnecessário nesta base. A interferência da rede argentina estaria em 50 Hz, onde o nível medido fica 58,5 dB abaixo do da faixa α (Tabela 9): o filtro passa-faixa de 2 a 40 Hz aplicado pelos autores da base já a remove;
- **Separação dos ritmos δ, θ, α e β** (AGARWAL; KUMAR, 2022): com a DTWPT de nível 4 a 1024 Hz, cada sub-banda tem 32 Hz (Tabela 1), e os quatro ritmos, todos abaixo de cerca de 30 Hz, caem na *primeira*. Somada ao filtro de 2 a 40 Hz da base, essa partição concentra 98,1% da potência na sub-banda 0 e deixa as sub-bandas 2 a 15 praticamente sem sinal. As características manuais do EEG desta tese não distinguem os ritmos, e a maior parte das 16 sub-bandas descreve resíduo do filtro, e não atividade cerebral (leitura a partir da distribuição da potência; o conteúdo de cada característica não foi medido). Reamostrar o EEG para 128 Hz antes da decomposição, o que o filtro de 2 a 40 Hz da base permite sem perda, daria sub-bandas de 4 Hz no mesmo nível 4. É uma limitação do extrator manual para o EEG, registrada no Capítulo 5.

Energia das redes de pulso. A literatura que conta os acessos à memória (DAMPFHOFFER *et al.*, 2023; YAN *et al.*, 2024) prevê vantagem para a rede de pulsos apenas com atividade muito esparsa e poucos passos de tempo. Esta tese mede a energia com um modelo que inclui a memória (LEMAIRE *et al.*, 2023) e compara a DSNN com uma gêmea não pulsante de mesmo grafo (subseção 3.3.1.2), em vez de presumir a vantagem.

3 Abordagem proposta

3.1 A Base de sinais

Os experimentos deste trabalho utilizam a base pública de sinais descrita em (CORETTO; GAREIS; RUFINER, 2017), que reúne registros de eletroencefalograma (EEG) de 15 locutores, falantes nativos de espanhol. Cada locutor produziu onze classes de enunciados: cinco vogais (/a/, /e/, /i/, /o/, /u/) e seis comandos direcionais (*arriba*, *abajo*, *adelante*, *atras*, *derecha*, *izquierda*), em duas modalidades. A principal é a **fala imaginada**: imaginar a pronúncia da palavra sem mover os músculos nem emitir som, e só o EEG é gravado. Para comparação, alguns blocos foram gravados em **fala pronunciada**, com o áudio e o EEG adquiridos simultaneamente (CORETTO; GAREIS; RUFINER, 2017). Só esses blocos têm voz.

Os sinais de voz foram gravados a 44100 Hz com canal único. Os sinais de EEG foram capturados com seis eletrodos posicionados em F3, F4, C3, C4, P3 e P4, conforme o sistema internacional 10-20, com taxa de amostragem de 1024 Hz, e a base os distribui já filtrados pelos autores com um filtro FIR passa-faixa de 2 a 40 Hz, para remoção de artefatos (CORETTO; GAREIS; RUFINER, 2017). Cada trial corresponde a uma janela de 4 segundos da fase de imaginar/pronunciar, resultando em 4096 amostras por canal de EEG e 176400 amostras de áudio por trial.

Os dados são organizados em arquivos MATLAB (`.mat`) por locutor, com dois arquivos por locutor: `S##_EEG.mat` e `S##_Audio.mat`. Cada arquivo contém uma matriz cujas linhas representam trials individuais. No arquivo de EEG, cada linha possui 24576 colunas de sinal (6 canais $\times$ 4096 amostras, concatenados) seguidas de 3 colunas de metadados: modalidade (imaginada ou fonatória), código do estímulo e indicador de artefato de piscada ocular. No arquivo de áudio, cada linha contém 176400 amostras seguidas de 2 colunas: código do estímulo e índice da linha correspondente na matriz de EEG, garantindo o alinhamento temporal entre as duas modalidades. A Figura 41 ilustra essa organização.

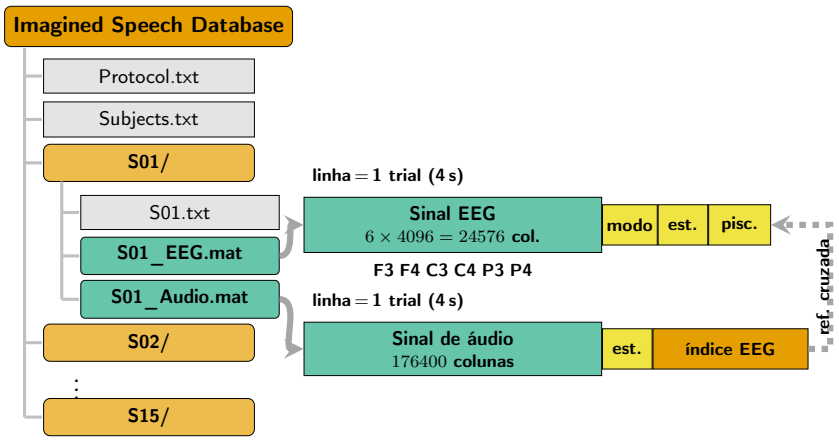
Quais tentativas têm áudio. Das tentativas da base, 1974 são de fala pronunciada, e só elas têm áudio; outras 7341 são de fala imaginada e têm apenas EEG. Cada tentativa de voz tem, portanto, um EEG gravado no mesmo instante — o da própria tentativa, de fala *pronunciada* —, mas nenhum EEG de fala *imaginada* gravado com ela. Por isso o EEG entra nos experimentos em duas condições, tratadas como um fator:

- **EEG de fala pronunciada**: o EEG da mesma tentativa da voz (mesmo locutor, mesmo enunciado, mesmo instante);

- **EEG de fala imaginada**: o EEG de uma tentativa imaginada do mesmo locutor e do mesmo enunciado, sorteada sem reposição com semente fixa. Não é simultâneo à voz.

O índice que liga cada linha de áudio à sua linha de EEG conta a partir de zero. Até 12 de novembro de 2026, o carregador deste trabalho o lia como se contasse a partir de um e entregava, para cada voz, o EEG da tentativa *anterior*: em 1833 casos um EEG de fala pronunciada e em 141 um de fala imaginada, com o mesmo enunciado da voz em apenas 193 das 1974 tentativas. O erro não produzia falha alguma, porque o locutor e o formato estavam corretos. Todos os resultados de EEG e de fusão anteriores a essa data foram descartados; os deste texto usam o pareamento pela identidade da tentativa, que o carregador agora verifica (modalidade e enunciado) antes de entregar cada amostra.

Figura 41 – Estrutura dos arquivos da base de sinais (CORETTO; GAREIS; RUFINER, 2017)



Fonte: Elaborado pelo autor, 2025.

3.1.1 Conferência da base contra o artigo e contra uma cópia independente

Os experimentos não leem os arquivos `.mat`, e sim uma base SQLite montada a partir deles por um programa de importação. Um erro nessa importação (um deslocamento de coluna, uma linha trocada de locutor) não interromperia nada: os resultados continuariam plausíveis. Por isso a base foi conferida por dois caminhos que o importador não usa.

Contra o artigo. As contagens de tentativas por locutor, modalidade e enunciado foram comparadas com as Tabelas 3 e 4 de (CORETTO; GAREIS; RUFINER, 2017). Todas coincidem, exceto uma célula: o locutor S01 tem 11 tentativas pronunciadas de /o/ na base, e o artigo lista 10. São tentativas distintas, vindas de linhas distintas da matriz original, e nenhum bloco de sinal se repete na base. A diferença está entre o artigo e os dados distribuídos, e não na importação.

Contra uma cópia independente. A pasta original dos autores passou a exigir autenticação, o que impede baixá-la de novo. A única outra cópia pública é uma redistribuição apenas do EEG, feita por terceiros no repositório Zenodo (CORETTO; GAREIS; RUFINER, 2026). Cada uma das 9315 tentativas da base foi comparada com a linha correspondente dessa cópia: os seis canais, depois de arredondados para a precisão em que a base os guarda (ponto flutuante de 32 bits), a modalidade, o enunciado e a marcação de piscada. Resultado: 9315 de 9315 tentativas iguais. Uma primeira comparação, feita sem o arredondamento, acusou diferenças em todos os canais, todas do tamanho do arredondamento para 32 bits, o que mostra que a conferência enxerga diferenças mínimas. Dois limites: a cópia não é dos autores, de modo que a concordância significa que duas derivações independentes coincidem, e não que alguma delas foi certificada; e o áudio, que não tem segunda cópia, não pôde ser conferido.

3.2 A segunda base: replicação confirmatória na BIOMEX-DB

Por que uma segunda base, e por que confirmatória. Todos os resultados das seções seguintes vêm de 15 locutores, e o extrator foi escolhido nessa mesma base (Fase 00). Um resultado que vale ali pode valer só ali. Uma segunda base, independente, responde a isso, mas só se nada for escolhido nela: uma nova busca na segunda base faria do seu melhor resultado outra seleção, e não um teste. Por isso o desenho é *confirmatório*. Os vencedores da Fase 00 da base de Coretto, Gareis e Rufiner (2017) foram congelados antes de qualquer resultado da segunda base, e as configurações da Fase 01 sobre as quais esta tese conclui são executadas uma única vez nela, sem Fase 00 e sem validação cruzada aninhada: a DSNN e seus dois controles sobre a voz, o EEG de fala pronunciada e as fusões precoce e tardia, nos dois modos de texto, e a disfonia simulada nas fontes que leem a voz.

A base. A BIOMEX-DB (MORENO-RODRIGUEZ *et al.*, 2021; RODRÍGUEZ, 2021) gravou 51 voluntários (25 mulheres e 26 homens) falando dígitos de 0 a 9 em espanhol, com o EEG (Emotiv Epoc, 14 canais, 128 Hz) e a voz (16000 Hz) adquiridos ao mesmo tempo. O protocolo tem duas sessões, uma de séries de dez dígitos e outra de séries de quatro, com sequências fixas, iguais para todos os voluntários (Tabela 1 de (MORENO-RODRIGUEZ *et al.*, 2021)), num total de 140 pares de voz e EEG por voluntário. Ela não tem fala imaginada, de modo que o EEG de fala imaginada e as fusões que o usam não existem nesta replicação. As duas sessões de um voluntário foram gravadas no mesmo dia, com poucos minutos de intervalo: a base não permite avaliar entre dias.

O mesmo formato na entrada do classificador. O classificador recebe das duas bases um vetor do mesmo tamanho, mas uma coluna só significa a mesma coisa se medir a mesma faixa de frequências. O extrator vencedor divide o intervalo de 0 à

frequência de Nyquist em 16 sub-bandas iguais, e a largura de cada sub-banda depende, portanto, da taxa de amostragem. Na taxa nativa da BIOMEX-DB, a coluna "energia da sub-banda 0" mediria uma faixa de frequências diferente da mesma coluna na base de Coretto, Gareis e Rufiner (2017). Nada falharia, e cada execução relataria um EER. Por isso a BIOMEX-DB é reamostrada para as taxas da outra base (44100 Hz para a voz e 1024 Hz para o EEG). A reamostragem é feita por filtragem polifásica sobre o sinal inteiro de cada série ou sessão, antes do recorte, e não acrescenta conteúdo acima da frequência de Nyquist original. O carregador recusa um arquivo da BIOMEX-DB em qualquer outra taxa.

Como um par é formado. O EEG e a voz de uma série estão em relógios que não concordam, de modo que cada sinal é recortado no seu próprio relógio, e os dois são pareados pela ordem dentro da série. O dígito do marcador do EEG e a palavra rotulada no áudio precisam coincidir, e uma série em que não coincidem é recusada. A amostra de EEG são os 2 s após o marcador do dígito. A amostra de voz é 1 s a partir do início rotulado da palavra. Quando esse segundo alcançaria a palavra seguinte, a janela é antecipada apenas o suficiente para terminar onde ela começa (15 janelas), e uma janela que nem assim cabe é recusada. As palavras mais longas que a janela ficam cortadas no fim (49 palavras).

O filtro do EEG é o dos autores da outra base. O EEG do Emotiv vem somado a um nível contínuo de alguns milhares de microvolts, diferente por eletrodo e pelo ajuste do equipamento na cabeça. Sem filtragem, as características de energia e de espectro leriam esse ajuste e identificariam o voluntário por ele, uma confusão silenciosa que pareceria um bom EER. O EEG da BIOMEX-DB passa, por isso, pelo mesmo filtro que Coretto, Gareis e Rufiner (2017) publicaram: retira-se a média de cada canal na sessão (o nível contínuo); o sinal é reamostrado para 1024 Hz; e aplicam-se um filtro FIR passa-baixa de ordem 372 em 40 Hz e um passa-alta de ordem 1204 em 2 Hz, com o atraso de grupo compensado. A retirada da média vem antes porque a atenuação do filtro na frequência zero não basta para um nível dessa grandeza. A voz da outra base também passou por um passa-baixa em 10 kHz, que não se aplica aqui, porque a gravação da BIOMEX-DB não tem conteúdo acima da metade da sua taxa nativa, abaixo desse corte. Com o filtro digital idêntico, resta uma diferença que vem das gravações, e não do processamento: 19,0% da potência do EEG da base de Coretto, Gareis e Rufiner (2017) está abaixo de 2 Hz, contra 3,1% na BIOMEX-DB.

Quais gravações entram: uma regra, sem exceções. Algumas pastas da base distribuída não seguem o protocolo: uma sessão gravada com o nome de outro voluntário, duas gravações completas da mesma sessão, um arquivo cujo nome não é de sessão alguma do protocolo, uma sessão interrompida no meio e regravada. Cada caso tem uma correção que parece óbvia, mas cada correção é um palpite sobre um arquivo, e um palpite errado

junta o EEG de uma pessoa à voz de outra sem que nada acuse o erro. A regra adotada é, por isso, mecânica: um voluntário entra somente se a sua pasta tiver exatamente uma gravação completa de cada sessão com o seu próprio nome. Gravações sem nenhum dígito (inícios abortados) e sessões gravadas em outro dia, fora do protocolo, são ignoradas. Qualquer outra irregularidade exclui o voluntário inteiro. Entram 45 dos 51 voluntários (24 mulheres e 21 homens), e saem F007, M001, M007, M010, M018, M024.

Os pares que saem. O filtro calcula cada amostra a partir de 788 amostras de cada lado. Em 2 voluntários (M015, M019) a gravação termina antes dessa margem depois do último dígito, e o filtro leria zeros no lugar do EEG no fim dessa época. A regra é a mesma para todos: sai o par cuja época de EEG fica a menos de 788 amostras de uma das pontas da sessão. Sai também 1 par cujo dígito foi falado, mas não tem rótulo no arquivo de anotação do áudio. A base fica com 6297 pares.

Conferência. Um conversor não vê os próprios erros, de modo que a base convertida é conferida contra fontes que o conversor não lê. O EEG lido do arquivo EDF é comparado com a exportação em CSV da mesma sessão, gerada por outro programa, exceto em 5 sessões que não têm exportação. A sequência de dígitos de cada série, tanto nos marcadores quanto nas palavras rotuladas, é comparada com a Tabela 1 do artigo. Cada par é reconstruído dos arquivos originais por outro caminho de leitura. A regra de inclusão e a regra da margem do filtro são reimplementadas na conferência, que precisa chegar aos mesmos voluntários e aos mesmos pares. Resultado: os 6297 pares são iguais aos reconstruídos dos originais. Um teste de mutação (uma voz trocada, um rótulo alterado e uma época de EEG trocada numa cópia da base) mostrou que a conferência acusa cada uma dessas falhas. Só uma base que passou na conferência é enviada ao ambiente de execução.

Uma ressalva que vale para as duas bases. O EEG gravado durante a fala carrega atividade muscular do rosto e dos olhos. Parte do que o EEG de fala pronunciada identifica pode ser, portanto, movimento, e não atividade cerebral.

3.3 Estrutura da estratégia proposta

Primeiramente, os sinais são decompostos pela DTWPT; em seguida, realizam-se os agrupamentos energéticos em três esquemas de particionamento espectral — bandas lineares, Mel e Bark — gerando, na Categoria 1, os vetores de *Linear-band energies*, *Mel-band energies* e *Bark-band energies*, respectivamente. Para a Categoria 2, aplica-se adicionalmente o logaritmo e a DCT sobre cada um desses vetores, produzindo os coeficientes LFCC, MFCC e BFCC. Por fim, conduz-se a análise paraconsistente de características a fim de selecionar as melhores combinações entre agrupamento energético e *wavelet*, visando gerar características as mais disjuntas possíveis.

Em segundo lugar, tanto os dados de voz quanto os de EEG são submetidos a *autoencoders* para extração de características — a Categoria 3 da taxonomia introduzida na seção 2.1. Ao lado deles entra a PCA, extrator de características clássico, como referência linear da extração automatizada (justificada adiante). As três categorias e a PCA são, portanto, os extratores comparados nesta tese.

As características extraídas, tanto automatizadas quanto as manualmente obtidas, servem de entrada para uma rede neural residual profunda de pulsos (DSNN), que determina as classes de cada um dos sinais. A arquitetura dessa rede e o protocolo de avaliação são detalhados na subseção 3.3.1.2.

Como o tema central deste trabalho é a autenticação biométrica combinando fala pronunciada e fala imaginada, cada configuração é avaliada em três modos, para medir a contribuição individual e conjunta das duas fontes:

- **apenas fala pronunciada**: somente o sinal de voz (áudio) alimenta o classificador;
- **apenas EEG**: somente o sinal de EEG alimenta o classificador, em cada uma das duas condições da seção 3.1 (fala pronunciada e fala imaginada);
- **voz + EEG (fundida)**: as duas fontes são combinadas antes da classificação, também com o EEG em cada condição.

No modo fundido, o *instante* em que as duas fontes se combinam é, ele próprio, um eixo experimental, pois desloca a fronteira entre o que é modelado separadamente e o que é modelado em conjunto:

- **fusão precoce** (*early fusion*): os sinais brutos de voz e EEG são concatenados *antes* da extração de características, de modo que um único extrator opera sobre o sinal conjunto e pode capturar interações entre as modalidades. Não há reamostragem: as 176400 amostras de voz são seguidas das 24576 de EEG, cada uma como foi gravada, e a taxa da voz (44100 Hz), dominante em número de amostras, é atribuída ao vetor inteiro quando as bandas da decomposição são convertidas em frequências. É uma aproximação: na parte de EEG (12% do vetor), as frequências nominais das bandas ficam erradas por um fator de cerca de 43, embora a divisão em bandas seja a mesma para todas as amostras;
- **fusão tardia** (*late fusion*): cada sinal é submetido *independentemente* à extração de características, e apenas os vetores resultantes são concatenados. Preserva a taxa nativa e o extrator próprio de cada fonte, ao custo de nunca observar as duas conjuntamente.

Ambas as estratégias são comparadas, uma vez que não há garantia a priori de qual delas produz características mais separáveis segundo a engenharia paraconsistente.

Como o modo fundido se desdobra nessas duas variantes, e o EEG entra em duas condições, os *três* modos acima correspondem, no eixo experimental da Fase 01 (subseção 3.3.1.2), a *sete* fontes distintas: voz; EEG de fala pronunciada; EEG de fala imaginada; e as fusões precoce e tardia, cada uma com o EEG em uma das duas condições.

Quanto à extração automatizada, comparam-se dois *autoencoders* de Categoria 3 — um de pulsos (SNN-AE) e um convencional (ANN-AE) — e um extrator linear de referência, a PCA, e os três são confrontados com a extração manual (*handcrafted*), usando a engenharia paraconsistente de características como critério de comparação (seção 2.1).

Por que a PCA entra na comparação. A PCA é um dos extratores de características mais consolidados: projeta cada amostra nos k eixos ao longo dos quais os dados mais variam, obtidos em forma fechada a partir da matriz de covariância, sem treino iterativo e sem outro hiperparâmetro além de k (JOLLIFFE, 2002). Nesta tese, ela recebe exatamente a entrada dos *autoencoders* — os 256 valores do espectro de potência de cada amostra, descritos na subseção 3.3.1 — e k assume os mesmos tamanhos dos seus latentes (8, 16 e 32). Serve, assim, de régua para a pergunta que os *autoencoders* precisam responder para se justificar: o treino de um modelo não linear acrescenta algo a uma projeção linear do mesmo tamanho? A régua não é retórica. Em um estudo preliminar do autor (FURLAN, 2026), com validação cruzada agrupada por locutor ou sujeito em quatro bases (duas de fala, duas de EEG), a PCA com k igual à dimensão latente reconstruiu melhor que o ANN-AE e que o SNN-AE em todas elas. Há ainda uma razão própria desta tese: por não ter regime de treino, a PCA permite separar as duas leituras possíveis do colapso dos latentes observado na Fase 00 (seção 4.1). Se o latente da PCA também apresentar $\bar{\beta}$ próximo de 1, a sobreposição entre classes é da representação de dimensão k desses sinais, e não de um treino insuficiente dos *autoencoders*.

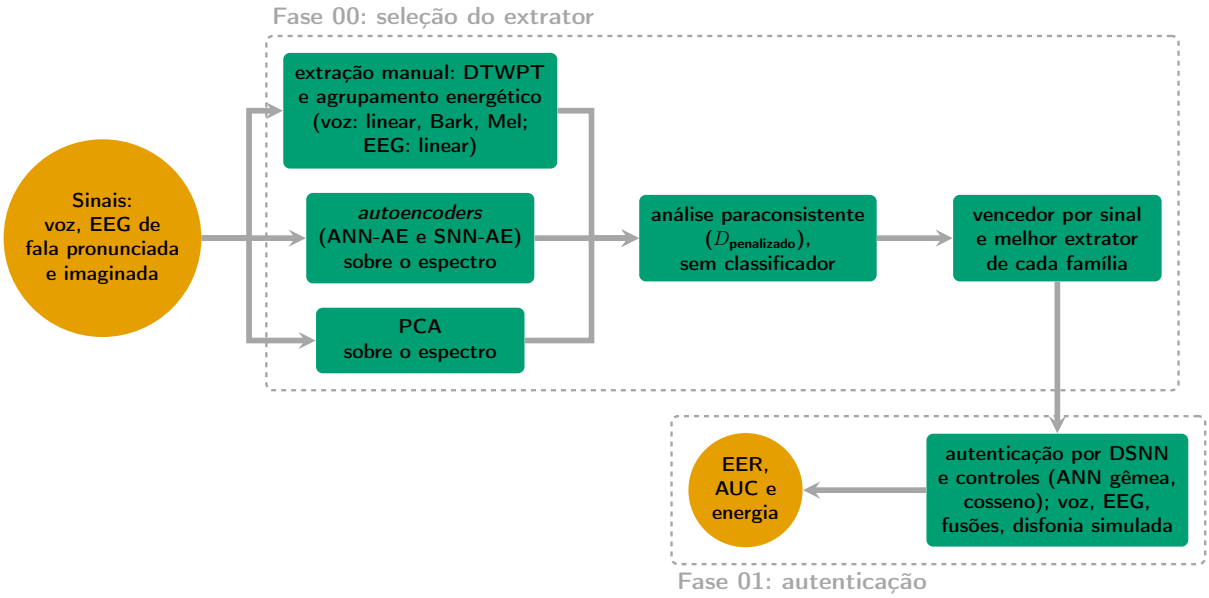
Por que não *autoencoders* de sequência. LSTM[1]-AE, GRU[2]-AE e Transformer-AE foram pré-validados no mesmo estudo preliminar (FURLAN, 2026), em uma base de fala (FSDD) e uma de EEG (EEGMMIDB), e descartados. O motivo principal é a qualidade: nenhum deles reconstruiu melhor que a PCA, e o LSTM-AE ficou próximo de um preditor que apenas devolve a média da janela, cujo erro quadrático médio é de cerca de 1 em janelas padronizadas. Seu erro de teste foi 0,967 no FSDD, contra 0,675 da PCA, e $0{,}821 \pm 0{,}255$ no EEGMMIDB, contra 0,192 — um desvio que indica que o treino ora convergia, ora não. O custo reforça o descarte: pelo modelo de energia do estudo, o LSTM-AE consumiu de 257 a 338 vezes a energia por janela do ANN-AE, e cada dobra levou de 30 a 55 vezes o tempo de parede da dobra do SNN-AE (18,1 e 16,9 horas).

[1] *Long Short-Term Memory* (Memória de Longo e Curto Prazo)
[2] *Gated Recurrent Unit* (Unidade Recorrente com Portas)

O descarte vale no escopo em que foi medido — orçamento de busca reduzido, apenas as dobras de desenvolvimento, critério de reconstrução e janelas curtas de 256 amostras, justamente o regime em que a memória longa de uma recorrência tem menos a oferecer — e não estabelece que modelos de sequência sejam piores extratores de identidade em locuções longas. A dinâmica temporal não fica, contudo, sem representante: o SNN-AE carrega estado no potencial de membrana ao longo dos passos, e a DTWPT descreve explicitamente a estrutura tempo-frequência. O LSTM-AE permanece implementado no *framework* (`autoencoder.model = "lstm-ae"`) e pode ser reavaliado nessas condições.

Uma visão geral do processo é mostrada na Figura 42.

Figura 42 – Fluxograma da estratégia proposta. Na Fase 00, as três famílias de extratores são ordenadas pela análise paraconsistente, sem classificador; na Fase 01, o extrator escolhido alimenta a autenticação.

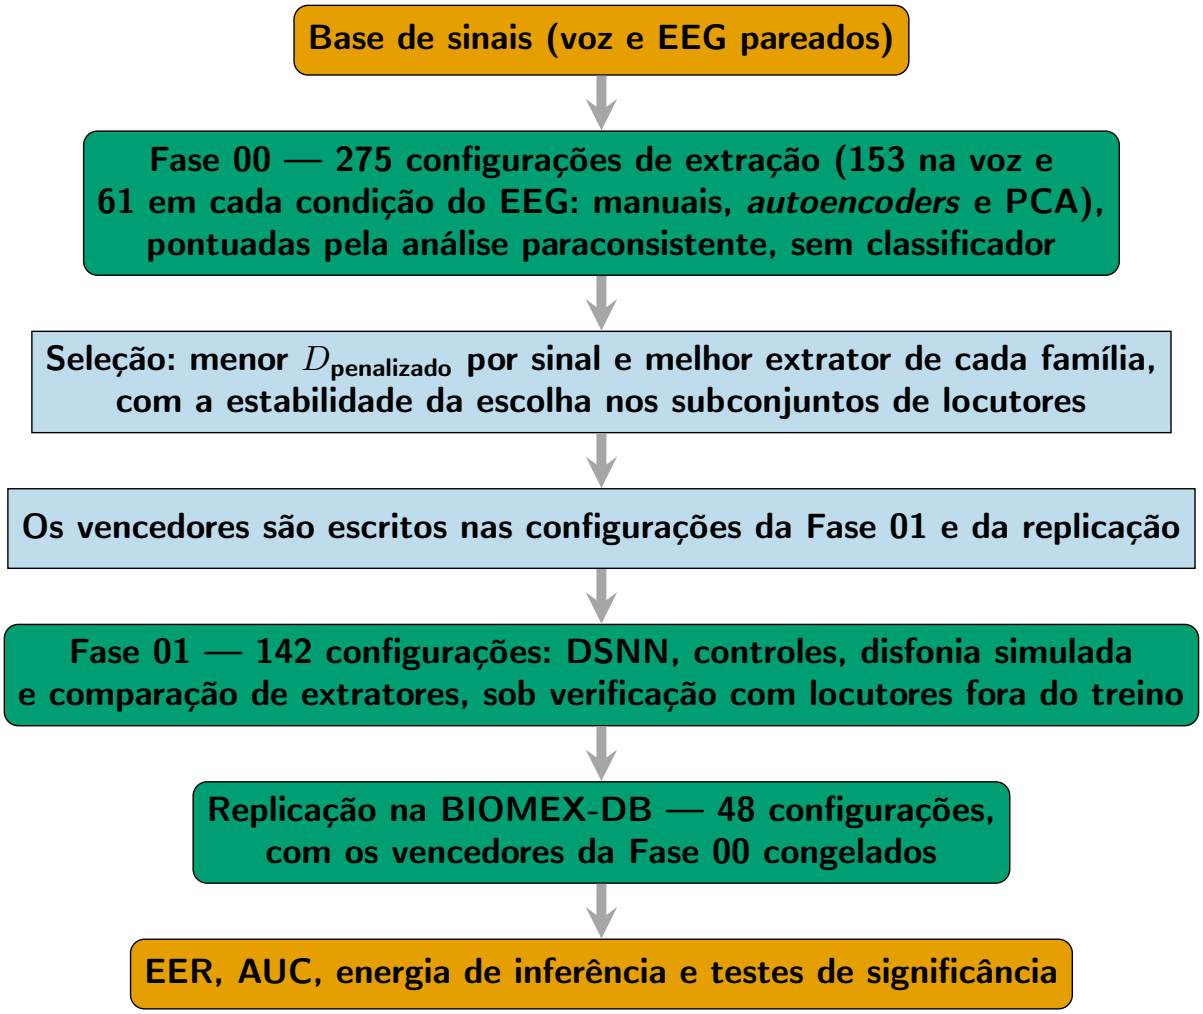


Fonte: Elaborado pelo autor, 2026.

3.3.1 Protocolo experimental em duas fases

O experimento é dividido em duas fases independentes, executadas em sequência. A **Fase 00** constrói o vetor de características e escolhe, por sinal, o melhor extrator segundo a engenharia paraconsistente. A **Fase 01** recebe apenas o vetor vencedor e treina o classificador para medir o desempenho de autenticação. A separação é controlada por um único parâmetro de configuração, `classifier.enabled`: quando falso, a execução para após o ranking (Fase 00); quando verdadeiro, o classificador é treinado (Fase 01). A Figura 43 mostra o encadeamento completo.

Figura 43 – Encadeamento das duas fases e da replicação na segunda base



Fonte: Elaborado pelo autor, 2026.

3.3.1.1 Fase 00 — construção e seleção do vetor de características

A Fase 00 é aplicada separadamente a três sinais: a voz, o EEG de fala pronunciada e o EEG de fala imaginada. Para o método manual, varrem-se duas escolhas: a **wavelet-mãe** da DTWPT (23 opções: `haar` e `daub4` a `daub46`) e a **escala** de agrupamento espectral (*bark*, *mel*, *lfcc*). Além disso, escolhe-se a **categoria** do descritor: Categoria 1 usa as energias de banda diretamente; Categoria 2 aplica logaritmo e DCT sobre essas energias, gerando os coeficientes cepstrais LFCC, MFCC ou BFCC (para escala *lfcc*, *mel* ou *bark*). Para a **voz**, isso dá $23 \times 3 \times 2 = 138$ combinações manuais. Para o **EEG**, porém, o eixo da escala não se aplica: *bark* e *mel* são escalas cocleares — modelam a resolução em frequência da *audição* humana — e não há base fisiológica para aplicá-las a um sinal que não é som. Essa exclusão é também empiricamente inócua: sobre o agrupamento espectral usado aqui, as três escalas produzem para o EEG exatamente o mesmo particionamento (subseção 2.1.3.9), de modo que as três variantes eram numericamente idênticas. O EEG usa portanto apenas a escala linear (*lfcc*), dando $23 \times 1 \times 2 = 46$ combinações manuais

em cada condição. A cada um dos três sinais somam-se 12 *autoencoders* compactos, sem wavelet ou escala: 9 SNN-AE (3 tamanhos × 3 codificações temporais) e 3 ANN-AE (3 tamanhos) — e 3 projeções PCA, uma para cada dimensão latente ($k = 8$, 16 e 32), sobre a mesma entrada. Ambas as famílias de *autoencoders* consomem um vetor de 256 valores por amostra (o espectro de potência do sinal, descrito a seguir), usam uma única camada oculta (rasa, adequada a dispositivos de baixo poder) e razão de compressão $2:1$ entre a camada oculta e o gargalo latente (dimensões latentes 8, 16 e 32, tamanhos `tiny`/`small`/`base`). O latente é o próprio vetor de características, então um gargalo menor gera vetor menor, barateando o classificador a jusante — princípio da literatura de autoencoders leves para borda.

3.3.1.1.1 O que os *autoencoders* e a PCA leem: o espectro, e não a forma de onda.

Um extrator só pode repassar o que a sua entrada contém, e o que distingue um locutor está no conteúdo em frequência do sinal, não no valor de uma amostra isolada. A entrada é, por isso, o espectro de potência do sinal, estimado pelo método de Welch (WELCH, 1967): o sinal é cortado em quadros de 512 amostras com sobreposição de metade; cada quadro é multiplicado por uma janela de Hann e transformado por Fourier; a potência é promediada sobre os quadros; descarta-se a componente contínua, restando 256 bandas do zero à frequência de Nyquist; toma-se o logaritmo e normaliza-se o vetor para $[0, 1]$ (min-max por amostra), faixa que as codificações de pulso leem como taxa ou instante de disparo. O sinal é o mesmo que o extrator manual lê: a voz com pré-ênfase, os seis canais de EEG um após o outro. Como a posição de um quadro deixa de importar, duas locuções de um mesmo locutor produzem vetores próximos mesmo que comecem em instantes diferentes.

Essa escolha corrige um defeito que invalidou uma rodada inteira de resultados, e que se registra aqui porque foi silencioso. Até 12 de novembro de 2026, a entrada era a própria forma de onda, reduzida a 256 valores pela média de blocos contíguos. A média de um bloco é um filtro passa-baixas. Na voz, cada bloco cobria 689 amostras (15,6 ms), e nada acima de cerca de 32 Hz sobrevivia — abaixo da frequência fundamental da fala (85 a 255 Hz) e muito abaixo dos formantes. No EEG, cada bloco cobria 96 amostras, e nada acima de cerca de 5 Hz sobrevivia: os ritmos alfa e beta desapareciam. A Tabela 10 mede a consequência sem usar nenhum componente do *pipeline*: um classificador linear tenta identificar o locutor a partir de cada entrada.

Com a entrada antiga, todos os *autoencoders* treinavam, todos os classificadores convergiam no treino, e o único sintoma era um EER de teste entre 0,48 e 0,52 para todo extrator automatizado — um resultado que se lê como "*autoencoders* são extratores ruins" quando o que faltava era informação na entrada. A implementação do espectro é verificada

Tabela 10 – Acurácia de identificação do locutor por um classificador linear, a partir dos 256 valores de cada entrada (15 locutores; acaso: 0,067; validação cruzada estratificada em 5 dobras; EEG de fala pronunciada). A entrada antiga, a forma de onda promediada em blocos, foi usada até 12/11/2026

Entrada (256 valores)	Voz	EEG	Fusão precoce
Forma de onda em blocos (antiga)	0,13	0,26	0,17
Espectro de potência (adotada)	0,85	0,62	0,65

Fonte: Elaborado pelo autor, 2026. Calculado com SciPy e PyTorch (Apêndice B).

contra a função `welch` da biblioteca SciPy, e a PCA sobre ele contra a decomposição em valores singulares da biblioteca PyTorch, em testes automatizados.

SNN-AE (codificador `Linear`→`LIF`, decodificador `Linear`→`LIF-integrador`) só carrega informação através de pulsos: um único vetor analógico apresentado em um só passo (equivalente a $T = 1$) deixa o neurônio LIF quase sempre abaixo do limiar de disparo, colapsando o latente a zero. Por isso cada amostra normalizada é expandida em T (padrão 16) quadros de pulso por uma de duas codificações temporais, comparadas nesta tese com a apresentação direta do vetor, sem pulsos (Figura 44) — 27 = 3 tamanhos × 3 codificações × 3 sinais:

- `poisson` — cada componente dispara com probabilidade de Bernoulli igual ao seu valor normalizado (codificação por taxa);
- `latency` — componentes de maior valor disparam mais cedo ($t_{\text{disparo}} = \text{round}((1 - v)(T - 1))$) e, a partir desse instante, continuam disparando em todos os passos seguintes;
- `direct` — passagem analógica direta, sem pulsos (linha de base não-temporal; $T = 1$).

O estado de membrana é *reiniciado uma única vez por amostra* e depois *integra ao longo dos T quadros* (sem reset entre quadros) — é essa integração temporal que permite a uma corrente sub-limiar por passo acumular até disparar. A característica de cada amostra é a *taxa de disparo média do latente sobre os T quadros*. O limiar de disparo do codificador é reduzido para 0,2 (padrão LIF = 1,0) nas variantes `poisson`/`latency`, já que quadros de pulso normalizados têm amplitude baixa; `direct` mantém o limiar padrão 1,0, reproduzindo intencionalmente o regime não-temporal, que serve de linha de base para as duas codificações temporais. Em todas as variantes, o codificador usa a regularização da taxa de disparo ($\lambda = 0{,}5$, faixa [0,10; 0,80]), que impede o colapso do latente em uma saída constante (subseção 2.1.11.5).

3.3.1.1.2 Codificação temporal e função de perda do treinamento.

Embora as três codificações produzam padrões de pulso distintos na entrada do codificador, o SNN-AE é treinado com a **mesma** função de perda de reconstrução — erro quadrático médio (EQM) — nas três variantes (`poisson`, `latency`, `direct`), pois o alvo da reconstrução é sempre o sinal analógico original de entrada, e não um trem de pulsos: a codificação temporal afeta apenas como a informação flui pelo codificador, não o que o decodificador precisa reproduzir. É importante notar que o *framework* desenvolvido para esta tese também implementa duas funções de perda casadas a codificações de pulso — `SpikeCountLoss` (EQM sobre a contagem total de disparos, adequada quando o próprio alvo supervisionado é uma taxa de disparo) e `SpikeTimeLoss` (EQM sobre o instante do primeiro disparo, adequada quando o alvo é um único evento temporal) — seguindo a convenção da codificação temporal usada por (COMŞA *et al.*, 2021) e a discussão de funções de perda sob medida para predição de pulsos de (MANNA *et al.*, 2024). Usar a função casada errada quebra o treino: `SpikeTimeLoss` sobre um alvo de taxa enxerga apenas o primeiro disparo e ignora a contagem; `SpikeCountLoss` sobre um alvo de latência trata a ausência de disparo como contagem zero, gerando gradiente incorreto para disparos tardios. Essa correspondência codificação–perda é, no entanto, uma capacidade geral do *framework*, exercitada apenas nos seus testes automatizados — o SNN-AE da Fase 00 não a utiliza, precisamente porque seu alvo de treino nunca é um trem de pulsos, e sim o sinal contínuo original.

3.3.1.1.3 Comparação entre as codificações temporais: uma previsão que não se confirmou.

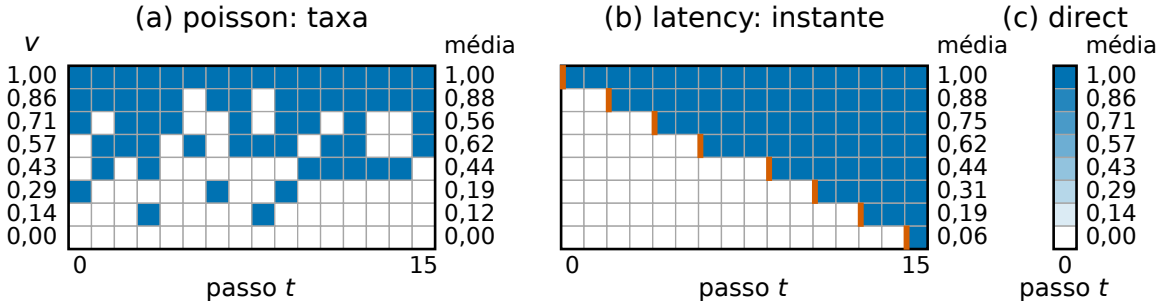
As três codificações diferem no ruído que injetam na entrada *antes de qualquer aprendizado*, e esse ruído se calcula em fechado. A `poisson` sorteia um Bernoulli independente a cada passo de tempo, de modo que a média sobre T quadros tem variância $v(1-v)/T$; para $v = 0{,}5$ (pior caso) e $T = 16$, isso dá desvio-padrão

$$\sigma_{\text{poisson}} = \sqrt{\frac{0{,}25}{16}} = 0{,}125\,, \tag{3.1}$$

isto é, 12,5% da faixa $[0, 1]$ da característica, somados a cada amostra de forma independente. A `latency` é determinística: o mesmo v sempre produz o mesmo instante de disparo, e seu erro é de quantização, limitado a meio degrau, $\frac{1}{2}\cdot\frac{1}{T-1} \approx 0{,}033$. A `direct` não injeta ruído algum. Como α é definido a partir da *amplitude* (mínimo–máximo) intraclasse (seção 2.1), e é por isso sensível a valores extremos, esse escalonamento prevê uma ordem entre as codificações segundo o critério paraconsistente: `direct` $\succ$ `latency` $\succ$ `poisson`.

Os resultados da Fase 00 (seção 4.1) **não confirmam essa previsão**. Nos três sinais, a codificação de menor $\bar{d}_{\text{pen}}$ médio é a `latency`, seguida da `poisson`, e a `direct`

Figura 44 – As três codificações temporais do SNN-AE aplicadas ao mesmo vetor de entrada, de oito componentes com valores v igualmente espaçados entre 0 e 1 (uma linha por componente). Cada coluna é um quadro apresentado ao codificador; azul é pulso (1), branco é ausência de pulso (0), e em (c) a intensidade do azul é o próprio valor analógico. À direita de cada painel, a média sobre os quadros, que é o que o neurônio LIF integra. (a) `poisson`: cada quadro é um sorteio independente, e a média só se aproxima de v — neste sorteio, as linhas de $v = 0{,}71$ e $v = 0{,}57$ trocam de ordem. (b) `latency`: o componente começa a disparar no instante marcado em vermelho-alaranjado e não para mais; a média, $(T - t_{\text{disparo}})/T$, é determinística e cresce com v (preserva a ordem entre os componentes), mas é quantizada e não é o próprio v: mesmo $v = 0$ dispara no último passo. (c) `direct`: um único quadro analógico, sem pulsos e sem integração temporal.



Fonte: Elaborado pelo autor, 2026, com as regras de `spike_frame()` do *framework* (`images/generate_encoding_figure.py`); o sorteio de (a) é ilustrativo, não o de uma execução.

— a que não injeta ruído — fica em último (na voz, 1,7802, 1,7940 e 1,8099; no EEG de fala imaginada, 1,7376, 1,8796 e 1,9046). O piso de ruído existe, mas não é o que decide a ordem. A leitura mais simples dos dados é que pesa mais a quantidade de informação que atravessa o gargalo de pulsos: a `direct` apresenta o vetor uma única vez, sem integração temporal, e a maior parte dos neurônios do latente não chega a disparar — suas variantes menores têm os menores $\bar{\alpha}$ das tabelas e, no EEG, os maiores $\bar{\beta}$, o padrão de um latente próximo do colapso que a penalização de $D_{\text{penalizado}}$ existe para apontar. Essa leitura é uma hipótese; o experimento que a testaria (variar T e o limiar de disparo, mantendo o resto fixo) não foi executado.

Registra-se o histórico porque ele ilustra um risco do método. Uma versão anterior deste texto relatava a ordem prevista como *confirmada*. Aqueles números vinham de execuções em que os *autoencoders* recebiam a entrada sem informação de locutor descrita acima, e em que, portanto, a única coisa que distinguia as codificações era de fato o ruído que cada uma injetava. A concordância entre a previsão e a medição não validava o mecanismo como explicação do desempenho dos extratores: ela mostrava que nada mais estava sendo medido.

Cada combinação gera um vetor de características, avaliado pela distância D_{verdade} — a distância ao vértice *Verdade* no plano paraconsistente (seção 2.1); quanto menor, mais separáveis são as classes antes de qualquer classificador. O vencedor do sinal, porém, **não** é a combinação de menor D_{verdade}, e sim a de menor $D_{\text{penalizado}} = D_{\text{verdade}} + \lambda|G_2|$, com $\lambda = 2 - \sqrt{2}$ (subseção 2.1.5.1): D_{verdade} isolado é vulnerável a extratores degenerados, que produzem uma saída praticamente constante e assim obtêm uma pontuação artificialmente boa sem carregar qualquer informação de classe. O termo $\lambda|G_2|$ penaliza exatamente essa degenerescência. A escolha altera o resultado na prática, e não apenas em princípio — as consequências sobre o vencedor de cada sinal são discutidas no Capítulo 4. O vencedor é escolhido entre *todas* as combinações do sinal, manuais e *autoencoders* conjuntamente. Nenhum classificador é treinado nesta fase. O Algoritmo 3.1 descreve o procedimento e a Figura 45 o resume.

```
/* WAVELETS: 23 wavelets-mae (haar, daub4, ..., daub46)          */
/* ESCALAS : 3 escalas espectrais (bark, mel, lfcc)              */
/* sinal   : vetor de amostras de um sinal (voz OU EEG)          */
/* Retorna a melhor combinacao (menor D_verdade).                */

Combinacao seleciona_vencedor(double sinal[], int n)
{
    Combinacao vencedor;
    vencedor.d_verdade = INFINITO;      /* comeca no pior valor  */

    /* 1) parte handcrafted: varre wavelet X escala             */
    for (int w = 0; w < 23; w++) {
        for (int e = 0; e < 3; e++) {
            double vetor[MAX_CARACT];
            int m = extrai_handcrafted(sinal, n, WAVELETS[w],
                                       ESCALAS[e], vetor);

            /* alpha, beta -> ponto no plano paraconsistente     */
            double d = calcula_d_verdade(vetor, m);

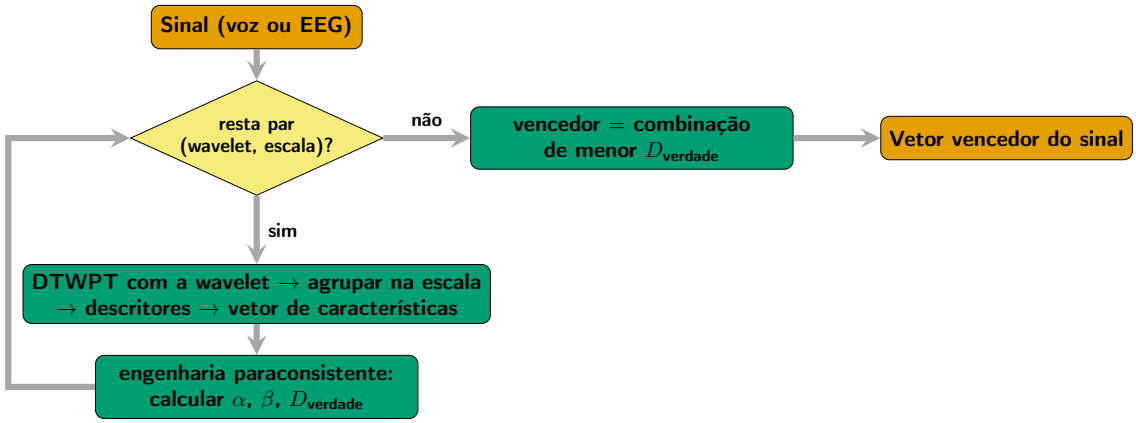
            if (d < vencedor.d_verdade) {   /* mais separavel    */
                vencedor.d_verdade = d;
                vencedor.estrategia = HANDCRAFTED;
                vencedor.wavelet = WAVELETS[w];
                vencedor.escala  = ESCALAS[e];
            }
        }
    }

    /* 2) parte automatizada: um autoencoder (sem wavelet/escala) */
    double vetor_ae[MAX_CARACT];
    int mae = extrai_autoencoder(sinal, n, vetor_ae);
    double d_ae = calcula_d_verdade(vetor_ae, mae);
```

```
34      if (d_ae < vencedor.d_verdade) {
35          vencedor.d_verdade = d_ae;
36          vencedor.estrategia = AUTOENCODER;
37      }
38
39      return vencedor;                        /* NAO treina classificador */
40  }
```

Algoritmo 3.1 – Fase 00 — varredura de extratores e seleção do vencedor por sinal via engenharia paraconsistente. Executada uma vez para a voz e uma vez para o EEG.

Figura 45 – Seleção do vetor vencedor de um sinal na Fase 00



Fonte: Elaborado pelo autor, 2026.

Considerando os três sinais, a Fase 00 tem $(138 + 12 + 3) = 153$ configurações para a voz e $(46 + 12 + 3) = 61$ para cada condição do EEG, isto é, $153 + 2 \times 61 = 275$ configurações, cada uma executada três vezes. O vetor fundido não é varrido aqui: ele é montado na Fase 01, a partir dos vencedores de cada sinal.

3.3.1.1.4 Quão estável é a escolha.

A Fase 00 escolhe o extrator olhando os rótulos de todos os locutores, inclusive os que a Fase 01 usará como teste. Além disso, os extratores manuais e a PCA são determinísticos: suas três repetições produzem o mesmo número, e o desvio entre elas, que é zero, nada diz sobre a incerteza da escolha. Para medir essa incerteza, cada configuração é pontuada também em 30 subconjuntos de locutores: os 15 conjuntos que deixam um locutor de fora, e os conjuntos de locutores de treino de cada uma das 15 dobras externas da Fase 01 (5 dobras $\times$ 3 repetições). O ranking é refeito em cada subconjunto. As tabelas do Capítulo 4 trazem, para cada configuração, o desvio padrão de d_{pen} entre os 15 primeiros e em quantas das 15 dobras ela seria a escolhida se a seleção olhasse apenas os locutores de treino daquela dobra.

3.3.1.2 Fase 01 — autenticação com o vetor vencedor

A Fase 01 treina o classificador sobre a combinação vencedora da Fase 00 e mede o desempenho de autenticação. Ela tem quatro conjuntos de execuções, cada um desenhado para uma pergunta:

- a **grade principal** (56 configurações): a DSNN sobre o extrator vencedor, variando quatro eixos — fonte, modo de texto, esquema de validação cruzada e padronização —, $7 \times 2 \times 2 \times 2$;
- os **controles** ($14 + 14$ configurações): o que a rede de pulsos acrescenta, respondido por dois classificadores de comparação sobre as mesmas características e as mesmas dobras;
- a **disfonia simulada** (40 configurações): o que acontece quando a voz de teste é degradada;
- a **comparação de extratores** (18 configurações): o melhor extrator de cada família — manual, *autoencoder* e PCA — levado ao mesmo classificador. É a forma em que a Questão 3 foi formulada (Capítulo 1).

São 142 configurações, cada uma executada três vezes. O Algoritmo 3.2 mostra a montagem da fonte e o laço de autenticação; a Figura 47 resume o fluxo.

3.3.1.2.1 Arquitetura do classificador DSNN.

O classificador é uma rede de pulsos residual, construída a partir da especificação declarativa `["linear:128:relu", "residual:2", "linear:N:identity"]` do perfil, onde N é o número de locutores de treino. Concretamente, ela é composta por:

- um **estágio de entrada** `Linear`$(d \to 128)$ seguido de um neurônio LIF, onde d é a dimensão do vetor de características vindo da Fase 00;
- **um bloco residual** `Linear`$(128 \to 128)$ seguido de LIF, envolto por uma conexão de atalho identidade, $h_{\text{saída}} = \text{bloco}(h) + h$ (a profundidade 2 da especificação conta o estágio de entrada e esse bloco). O atalho não tem parâmetros e existe para que o gradiente alcance a camada inicial sem se dissipar através da não-linearidade de disparo — é o desenho de RNP residual de (ZHENG *et al.*, 2021). Os estágios de entrada e de saída não recebem atalho porque suas larguras diferem de 128, o que impediria a soma elemento a elemento;
- um **estágio de saída** `Linear`$(128 \to N)$, cuja saída é a média dos logits sobre os $T = 16$ passos de tempo. O vetor de características é apresentado, constante, em todos os passos.

O treino usa retropropagação através do tempo (BPTT) com gradiente substituto. Nas configurações desta tese, o decaimento de peso, a regularização da taxa de disparo e a tdBN estão desligados.

3.3.1.2.2 Controles: o que a rede de pulsos acrescenta.

Um EER isolado não diz se o classificador contribui com algo. Dois controles rodam sobre as mesmas características, as mesmas dobras e o mesmo protocolo de pontuação:

- a **rede gêmea não pulsante** (ANN): o mesmo grafo da DSNN, com ReLU no lugar de cada LIF, sem passos de tempo, e *com os mesmos pesos iniciais*. Ela difere da DSNN apenas no neurônio, de modo que a diferença entre as duas mede o que o pulso custa ou acrescenta;
- o **cosseno direto**: nenhuma rede. As próprias características padronizadas são usadas como vetor de representação. Mede o que *qualquer* rede treinada acrescenta ao extrator.

3.3.1.2.3 Protocolo de verificação: como EER e AUC são calculados.

Esta é a parte do protocolo que a definição textual de EER não revela, e sem a qual os números do Capítulo 4 não são interpretáveis. A camada de saída tem uma unidade por locutor de *treino*, mas ela **não** é usada como decisão de classe — sob o protocolo de verificação os locutores de teste nunca aparecem no treino, de modo que nenhuma dessas unidades corresponde ao locutor sendo verificado. O vetor de logits é usado, em vez disso, como um **vetor de representação** (*embedding*) do sinal. A partir dele:

1. a primeira amostra de cada locutor de teste é o seu **cadastro**: o vetor de representação dela, normalizado, é o modelo (*template*) do locutor;
2. as demais amostras de teste são **sondas**. Cada sonda é comparada com o modelo de *todos* os locutores de teste; a comparação com o seu próprio locutor é uma tentativa *genuína*, e as demais são *impostoras*;
3. a pontuação de cada tentativa é a **similaridade de cosseno** entre o vetor da sonda e o modelo;
4. varre-se um limiar sobre essas pontuações; o EER é o ponto em que a taxa de falsa aceitação iguala a de falsa rejeição;
5. a AUC é estimada pela estatística de Wilcoxon–Mann–Whitney, AUC $= P(\text{pontuação genuína} > \text{pontuação impostora})$, que equivale à área sob a curva ROC[3] das duas distribuições de pontuação.

[3] Característica de Operação do Receptor (*Receiver Operating Characteristic*)

É por isso que as métricas de conjunto fechado são `NaN` nos resultados: elas exigiriam que a identidade de teste estivesse entre as classes treinadas, o que este protocolo deliberadamente proíbe.

3.3.1.2.4 Os quatro eixos da grade principal.

O experimento é o produto cartesiano completo:

- **Fonte** (7 níveis): voz; EEG de fala pronunciada; EEG de fala imaginada; e as fusões precoce e tardia, cada uma com o EEG em uma das duas condições (seção 3.3);
- **Modo de texto** (2 níveis): *frases vistas* e *frases não vistas*. Os 11 enunciados são embaralhados com a semente da execução; os 5 primeiros são os de treino *nos dois modos*; o teste usa esses mesmos 5 (frases vistas) ou os 5 seguintes (frases não vistas). Os locutores de teste são sempre outros. Como o conjunto de treino é idêntico nos dois modos, a diferença entre eles mede apenas o efeito de o enunciado de teste ter sido visto no treino. É o eixo da Questão 4 (Capítulo 1); "frases vistas" corresponde ao que a literatura chama de dependente de texto, e "frases não vistas", de independente;
- **Esquema de validação cruzada** (2 níveis). Em ambos os esquemas as dobras são *disjuntas por locutor* (*group k-fold*, $k = 5$), o que é o que torna o protocolo de verificação válido. Na **plana**, cada dobra é treinada e pontuada uma vez, sem conjunto de validação e sem parada antecipada. Na **aninhada**, um laço interno — também $k = 5$, com semente distinta — separa um conjunto de validação usado para selecionar o melhor modelo por parada antecipada, e só então o modelo escolhido é pontuado uma única vez na dobra externa. A aninhada é o estimador não enviesado quando há seleção de modelo; a plana é mais barata e não descarta dados para validação;
- **Padronização das características** (2 níveis): *z-score* por característica ligado ou desligado. Quando ligado, média e desvio padrão são estimados *apenas* sobre o conjunto de treino de cada dobra e então aplicados à de teste, evitando vazamento de informação.

Os controles, a disfonia e a comparação de extratores usam validação plana e características padronizadas.

3.3.1.2.5 Disfonia simulada.

As duas bases têm apenas vozes saudáveis, e a motivação deste trabalho é justamente a voz que falha. A disfonia é, por isso, **simulada** sobre a voz de teste; nenhum locutor disfônico real foi avaliado. O modelo parte da descrição fonte–filtro da fala. As

pregas vocais produzem a *fonte*: uma sequência de pulsos de ar periódicos, que dá à voz a sua altura e os seus harmônicos. O trato vocal — faringe, boca, lábios — age como um *filtro*, que realça algumas faixas de frequência, os formantes, que determinam qual vogal se diz e carregam parte da identidade de quem fala. A disfonia é sobretudo uma falha da fonte: as pregas vibram de modo irregular ou incompleto, o ar escapa e a voz fica soprosa; no extremo, a afonia, não há vibração alguma e resta o sussurro — o mesmo filtro, excitado por ruído de ar em vez de pulsos. A simulação troca a fonte e preserva o filtro.

Para cada locução x, gravada a 44,1 kHz, o sussurro w é sintetizado em quatro passos:

1. o sinal é dividido em quadros de 25 ms (1102 amostras), com passo de meio quadro (551 amostras), cada um ponderado por uma janela de Hann;
2. em cada quadro, estima-se por predição linear (LPC[4]) o filtro só de polos $1/A(z)$ que melhor prevê cada amostra a partir das anteriores — o envelope espectral do quadro, isto é, os seus formantes —, pelo método da autocorrelação e pela recursão de Levinson–Durbin (MAKHOUL, 1975), com ordem $2 + f_s/1000$, a regra usual para o trato vocal (RABINER; SCHAFER, 2011), que dá 46 a 44,1 kHz;
3. um ruído branco gaussiano passa por esse filtro, o que produz um sinal com o mesmo envelope e sem periodicidade, e é escalado para ter a energia do quadro original;
4. os quadros sintetizados são sobrepostos e somados com a raiz quadrada da janela de Hann, de modo que a potência esperada do sussurro é a da voz original. Um quadro sem energia (silêncio) continua silencioso.

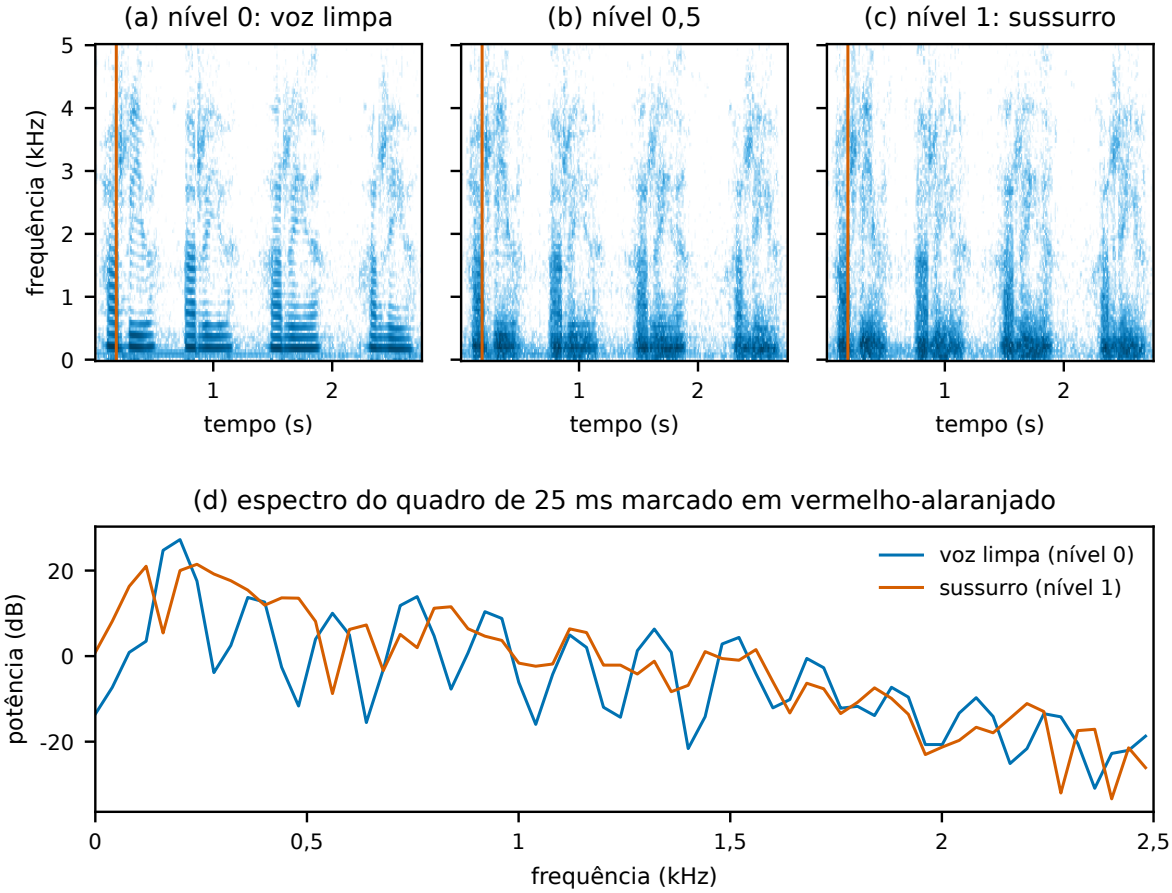
A voz degradada é a mistura $y = \sqrt{1-m}\,x + \sqrt{m}\,w$, em que m é o nível de degradação. Como x e w não são correlacionados, a potência de y é, em valor esperado, a de x para qualquer m, e m é a fração dessa potência que deixa de ser voz e passa a ser sopro:

Nível m	**0**	**0,25**	**0,5**	**0,75**	**1**
potência que ainda é voz	100 %	75 %	50 %	25 %	0 % (sussurro: afonia)

Preservar a potência não é um detalhe: se a voz degradada ficasse mais fraca ou mais forte, uma variação do EER poderia vir do volume, e não da perda da vibração. A Figura 46 mostra o efeito numa locução da base: os harmônicos — as listras horizontais do espectrograma, o pente do espectro — desaparecem, e o envelope, com os formantes, permanece.

[4] *Linear Predictive Coding* (Codificação por Predição Linear)

Figura 46 – Disfonia simulada numa tentativa de fala pronunciada da base de Coretto, Gareis e Rufiner (2017) (locutor S01, estímulo *Arriba*). (a)–(c) Espectrogramas da voz nos níveis 0 (voz limpa), 0,5 e 1 (sussurro), até 5 kHz; azul mais escuro é mais energia. (d) Espectro do quadro de 25 ms marcado em vermelho-alaranjado, o mais periódico da locução: a voz limpa (azul) tem o pente de harmônicos da vibração das pregas vocais; o sussurro (vermelho-alaranjado) segue o mesmo envelope, sem o pente.



Fonte: Elaborado pelo autor, 2026, com a própria implementação usada no experimento (`VoiceDegradation.cpp`, chamada por `images/generate_dysphonia_figure.py`); a semente do ruído é fixa, e não a de uma execução.

Onde a degradação entra no protocolo. Ela é aplicada à forma de onda armazenada, antes da pré-ênfase e da extração, e as características da voz degradada são extraídas pelo mesmo extrator que as da voz limpa. O treino usa sempre voz limpa: o sistema é treinado com vozes saudáveis e encontra, no teste, uma voz que falha. As características de teste degradadas são padronizadas com as médias e os desvios do treino limpo. Nos locutores de teste há dois cenários: *só sondas*, em que o cadastro de cada locutor — a sua primeira locução de teste — permanece limpo (alguém cadastrado antes de adoecer), e *cadastro e sondas*, em que toda a voz de teste é degradada. Nas fusões, apenas a metade de voz é degradada; o EEG nunca é alterado. Os níveis avaliados são 0,25, 0,5, 0,75 e 1, e o nível 0 é a execução com voz limpa. Cada locução recebe uma

semente de ruído própria, derivada da semente do perfil, de modo que o resultado não depende da ordem de execução.

O que o modelo não cobre. É um modelo de voz soprosa ou afônica, e não de toda disfonia: a rouquidão (irregularidade de ciclo a ciclo da vibração), a aspereza, o tremor e as quebras de sonoridade não são simulados; o ruído de excitação é branco, e não o ruído turbulento real da glote; e o esforço compensatório de quem tenta falar com a voz comprometida também não. Os resultados sob disfonia simulada medem, portanto, a perda da vibração das pregas vocais, e não a voz de pacientes.

3.3.1.2.6 Comparação de extratores pelo classificador.

O melhor extrator de cada família na Fase 00 (manual, *autoencoder*, PCA) alimenta a mesma DSNN, para cada um dos três sinais e cada modo de texto, com 100 épocas de treino nas três famílias.

3.3.1.2.7 Energia de inferência medida.

A justificativa para uma rede de pulsos é o consumo de energia, e ele é medido em vez de presumido. Na passagem de teste de cada dobra, contam-se os disparos de cada camada da DSNN; a partir deles, e das operações de ponto flutuante e dos acessos à memória que cada camada executa, estima-se a energia por amostra pelo modelo analítico de (LEMAIRE *et al.*, 2023), com os custos por operação de (HOROWITZ, 2014) (tecnologia de 45 nm). A rede gêmea não pulsante é medida pelo mesmo modelo. O extrator de características fica fora da conta, por ser o mesmo para os dois classificadores. Como a estimativa depende de hipóteses de *hardware*, a comparação é repetida sob cinco variações — a primeira camada recalculada a cada passo, toda a memória em um único tamanho de SRAM (8 KB, 32 KB ou 1 MB), e apenas a aritmética — e o texto relata se a ordem entre as duas redes se mantém em todas.

3.3.1.2.8 Protocolo de treino, de repetição e de comparação.

Todas as execuções da grade compartilham os mesmos hiperparâmetros: otimizador Adam com taxa de aprendizado 10^{-3}, 50 épocas, lotes de 32 amostras, e parada antecipada ativa apenas na validação cruzada aninhada, já que a plana não reserva conjunto de validação. Cada configuração é executada **três vezes**, com sementes distintas derivadas da semente base 42; os valores reportados no Capítulo 4 são as médias sobre essas três repetições, e o desvio padrão ali tabelado é calculado entre elas. Como cada repetição percorre $k = 5$ dobras, cada configuração contribui com 15 medidas de EER. Essas 15 medidas **não são independentes**: as dobras de uma repetição compartilham dados de treino, e as repetições reutilizam os mesmos locutores. Um teste que as trate como 15

amostras independentes produz p-valores otimistas. As comparações entre configurações usam, por isso, o teste t corrigido para validação cruzada repetida (NADEAU; BENGIO, 2003), que infla a variância pela razão entre os tamanhos de teste e de treino, com a correção de Holm (HOLM, 1979) sobre a família de comparações, e com a configuração de referência fixada antes de olhar os resultados.

```
/* v_voz, v_eeg: vencedores da Fase 00 (um por sinal)            */
/* fonte : VOZ | EEG | FUNDIDA_PRECOCE | FUNDIDA_TARDIA         */
/* Preenche X (vetores de caracteristicas) e devolve a dimensao. */

int monta_fonte(Amostra a, int fonte,
                Combinacao v_voz, Combinacao v_eeg, double X[])
{
    if (fonte == VOZ)
        return extrai(a.audio, v_voz, X);
    if (fonte == EEG)
        return extrai(a.eeg,   v_eeg, X);

    if (fonte == FUNDIDA_PRECOCE) {         /* funde sinal bruto */
        double s[MAX_AMOSTRAS];
        int n = concatena(a.audio, a.eeg, s);
        return extrai(s, v_voz, X);         /* uma extracao so   */
    }
    /* FUNDIDA_TARDIA: extrai cada sinal, concatena os vetores   */
    double xv[MAX_CARACT], xe[MAX_CARACT];
    int mv = extrai(a.audio, v_voz, xv);
    int me = extrai(a.eeg,   v_eeg, xe);
    return concatena_vetores(xv, mv, xe, me, X);
}

/* Loop de autenticacao: fonte X modo de texto X esquema de CV.  */
Metricas autentica(Amostra base[], int fonte,
                   int modo_texto, int cv_aninhada,
                   Combinacao v_voz, Combinacao v_eeg)
{
    double X[MAX_AMOSTRAS][MAX_CARACT];
    for (int i = 0; i < N_AMOSTRAS; i++)
        monta_fonte(base[i], fonte, v_voz, v_eeg, X[i]);

    /* grupos disjuntos por locutor (protocolo de verificacao)   */
    Folds f = divide_por_locutor(base, modo_texto, cv_aninhada);

    Metricas m = treina_e_avalia_dsnn(X, f);  /* LIF + BPTT       */
    return m;                                 /* EER e AUC        */
}
```

Algoritmo 3.2 – Fase 01 — autenticação com o vencedor da Fase 00. O extrator nao e mais variado: usa-se apenas a combinacao escolhida por sinal.

Figura 47 – Autenticação DSNN na Fase 01



Fonte: Elaborado pelo autor, 2026.

3.3.1.3 Configuração das execuções e transição entre fases

Cada execução é descrita por um arquivo de configuração próprio: 275 na Fase 00 (um por combinação varrida) e 142 na Fase 01 (os quatro conjuntos descritos acima). Todos são escritos por um único programa gerador, e um teste automatizado recusa qualquer arquivo de configuração que o gerador não tenha declarado. Os nomes dos arquivos e programas estão no Apêndice B. O vencedor da Fase 00 só é conhecido após a execução; por isso as configurações da Fase 01 nascem com um extrator provisório, substituído pelo vencedor antes de rodar.

Dois programas automatizam a transição, evitando edição manual (Figura 43):

- o **ordenador** lê os resultados paraconsistentes das 275 configurações — exatamente os arquivos que cada configuração declara, recusando um conjunto incompleto —, calcula a média de $D_{\text{penalizado}}$ sobre as três repetições, registra o vencedor de cada sinal, o melhor de cada família e a posição do vencedor em cada subconjunto de locutores, e sinaliza explicitamente eventuais empates exatos, para que uma escolha feita por desempate de ordenação não seja confundida com um resultado de mérito;

- o **gerador de configurações** escreve cada vencedor nas 142 configurações da Fase 01 e nas 48 da replicação na BIOMEX-DB, ao gerá-las (nenhuma configuração é editada depois) — a voz recebe o vencedor da voz, cada condição do EEG o da sua condição, as configurações de comparação o melhor da família que declaram, e as fontes fundidas recebem o vencedor do sinal declarado na chamada; o *pipeline* declara a voz (sinal dominante em número de amostras).

3.3.2 Métricas

A autenticação segue o protocolo de **verificação** (*verification*), no qual os locutores de teste não aparecem no treino: os grupos de validação cruzada são disjuntos por locutor. Nesse protocolo, as métricas primárias são a **EER** (o ponto em que a taxa de falsa aceitação iguala a de falsa rejeição) e a **área sob a curva ROC** (AUC). As métricas de classificação de conjunto fechado (acurácia, F1, precisão, recall, especificidade) só se aplicam quando as classes de teste também estão no treino; sob o protocolo de verificação elas não são reportadas — nos arquivos de resultado da Fase 01 elas aparecem literalmente como `NaN`, e não como zero, justamente para que a ausência de valor não seja confundida com um desempenho nulo. As métricas adotadas são as mesmas dos trabalhos de verificação da Tabela 8; a comparação direta dos números, porém, depende do protocolo de cada trabalho (seção 2.2):

- **Taxa de Erro Igual (EER)** — primária, protocolo de verificação;
- **área sob a Curva ROC (AUC)** — primária, protocolo de verificação;
- acurácia, pontuação F1, precisão, recall, sensitividade, especificidade — reportadas apenas em avaliações de classificação de conjunto fechado;
- erro quadrático médio (EQM) — usado na reconstrução dos *autoencoders*, não na classificação.

3.3.3 Desenvolvimento e Validação de Algoritmos

Quanto aos algoritmos de classificação, empregam-se redes neurais de pulsos em uma arquitetura residual (a DSNN detalhada na subseção 3.3.1.2), com o objetivo de minimizar o gasto de energia, memória e processamento, adequando-se a dispositivos com baixo poder computacional para garantir portabilidade e eficiência energética.

Há, no entanto, um obstáculo prático: o número de locutores e de amostras por locutor é pequeno. Com poucos dados, a rede tende a "decorar" os exemplos de treino em vez de aprender padrões gerais — o chamado *overfitting*. Para combatê-lo, o *framework* implementa duas técnicas de regularização complementares, descritas em detalhe no Apêndice C. No classificador, nas execuções relatadas no Capítulo 4, as duas estão desligadas (coeficientes iguais a zero): os resultados medem a rede sem elas, e o efeito de ligá-las não foi avaliado. A regularização da taxa de disparo é usada em outro lugar, no codificador do SNN-AE da Fase 00, e com outro fim: impedir o colapso do latente (subseção 2.1.11.5).

A primeira é o **decaimento de peso L2**, que penaliza pesos muito grandes e, com isso, favorece soluções mais simples e que generalizam melhor. Nas redes de pulso,

atua apenas sobre as matrizes de peso; os parâmetros biofísicos dos neurônios de pulso (R, C e V_{th}) são preservados, pois reduzi-los descaracterizaria o neurônio.

A segunda é a **regularização da taxa de disparo**, exclusiva das redes de pulso. Ela mantém a frequência média de disparos de cada camada dentro de uma faixa saudável, evitando dois extremos: neurônios mortos, que param de disparar e interrompem o aprendizado, e neurônios saturados, que disparam o tempo todo e perdem a capacidade de distinguir entradas. Como bônus, ao incentivar disparos comedidos, essa técnica reforça a própria razão de ser das redes de pulso: a eficiência energética.

4 Testes e Resultados

Este capítulo apresenta os resultados das duas fases do experimento, na ordem em que foram executadas: a Fase 00, que constrói e ordena os vetores de características segundo o critério paraconsistente (seção 4.1), e a Fase 01, que treina o classificador de autenticação e mede EER e AUC (seção 4.2). A seção 4.4 retoma, à luz desses resultados, as quatro questões de pesquisa formuladas no Capítulo 1. O protocolo experimental está descrito no Capítulo 3.

De onde vêm os números. A Fase 00 tem 275 configurações e a Fase 01, 142; cada uma foi executada três vezes, em um processo de um único *thread*, no *cluster* GridUnesp, com o mesmo código de extração e de classificação nas duas fases. Os resultados aqui apresentados substituem todos os anteriores, que foram descartados por dois defeitos descritos no Capítulo 3: o EEG lido da tentativa errada (seção 3.1) e a entrada sem informação de locutor dos *autoencoders* e da PCA (subseção 3.3.1). Tanto as tabelas quanto os números citados nas frases são lidos por *scripts* dos arquivos de resultado; nenhum foi digitado.

4.1 Fase 00 — Ranking por grau de verdade paraconsistente

As tabelas desta seção trazem todas as configurações avaliadas na Fase 00, separadas por sinal (voz, EEG de fala pronunciada, EEG de fala imaginada) e por família de extrator (manual, *autoencoder*, PCA), ordenadas de forma **crescente** por $\bar{d}_{\text{pen}}$. As grandezas d e d_{pen} são *distâncias* ao vértice *Verdade* do plano paraconsistente, de modo que **quanto menor, melhor**: a posição #1 de cada tabela é a melhor configuração daquela família.

As colunas são:

- $\bar{d}_{\text{pen}}$: média, sobre as três repetições, do grau de verdade penalizado por contradição, $d_{\text{pen}} = d + \lambda|G_2|$, com $\lambda = 2 - \sqrt{2}$ (subseção 2.1.5.1). É o critério de ordenação e de escolha do vencedor;
- σ_{rep}: desvio padrão de d_{pen} entre as três repetições. Só existe para os *autoencoders*, cujo treino depende da semente. Os extratores manuais e a PCA são determinísticos: as três repetições dão o mesmo número, e a coluna traz "—" em vez de um zero que sugeriria uma precisão que não foi medida;
- σ_{loc}: desvio padrão de d_{pen} entre os 15 subconjuntos que deixam um locutor de fora. Mede o quanto a pontuação depende de quais locutores foram observados;

- *dobras*: em quantas das 15 dobras da Fase 01 a configuração teria o menor d_{pen} do sinal se a seleção olhasse apenas os locutores de treino daquela dobra;
- $\bar{d}$: média do grau de verdade sem penalização — a grandeza chamada D_{verdade} no Capítulo 3 e $D_{1,0}$ na seção 2.1;
- $\bar{\alpha}$ e $\bar{\beta}$: médias do grau de crença e do grau de descrença.

O mesmo extrator vence nos três sinais. O vencedor de cada sinal, marcado com †, é escolhido entre as três famílias, e não dentro de cada tabela. Para a voz, para o EEG de fala pronunciada e para o de fala imaginada, venceu a extração manual com a *wavelet* Haar e energias de banda em escala linear, sem a etapa cepstral — a configuração "Haar + Linear (c1)" das tabelas —, com $\bar{d}_{\text{pen}}$ de 1,4836, 1,5788 e 1,5128, respectivamente. A marca aparece, portanto, apenas nas Tabelas 17, 18 e 19; a posição #1 das tabelas de *autoencoder* e de PCA é o melhor extrator daquela família, não o vencedor da fase.

O critério de ordenação é $\bar{d}_{\text{pen}}$, e não $\bar{d}$, e a diferença decide o vencedor da voz. Pelo $\bar{d}$ isolado, a melhor configuração da voz seria "Daubechies 22 + Linear (c1)" ($\bar{d} = 1{,}3929$, contra 1,4055 do vencedor). O termo $\lambda|G_2|$ a penaliza por contradição e a leva a $\bar{d}_{\text{pen}} = 1{,}4973$, acima dos 1,4836 do vencedor. Por isso as duas colunas são exibidas lado a lado.

Quão firme é a escolha. A resposta difere entre os sinais, e a diferença importa para a leitura de todo o resto.

- **No EEG, a escolha é firme.** O vencedor tem o menor d_{pen} em 15 das 15 dobras na fala pronunciada e em 15 das 15 na imaginada, e em todos os subconjuntos que deixam um locutor de fora. A distância para o segundo colocado é de 0,0477 e 0,0241.
- **Na voz, a escolha é frágil.** A distância para o segundo colocado é de apenas 0,0137, menor que o σ_{loc} do próprio vencedor (0,0241). O vencedor tem o menor d_{pen} em 10 das 15 dobras; nas outras 5, uma seleção feita só com os locutores de treino teria escolhido outro extrator, e em uma delas o vencedor cai para a 55ª posição. Essa queda parece maior do que é: as 55 melhores configurações da voz cabem em uma faixa de 0,0597 de d_{pen}, de modo que pequenas variações trocam muitas posições.

O que varia entre as dobras, na voz, é a *wavelet*. Os 4 extratores que vencem alguma dobra no lugar do vencedor são todos de Categoria 1 (sem a etapa cepstral), e 3 deles usam a escala linear. A afirmação que os dados sustentam para a voz é, portanto, "energias de banda sem etapa cepstral, preferencialmente em escala linear", e não "a *wavelet* Haar é a melhor". Como a Fase 01 usa o vencedor escolhido com todos os locutores, há nela um viés de seleção otimista na voz; ele é pequeno diante das diferenças discutidas adiante, mas existe e não foi removido.

Os extratores automatizados ficam atrás do manual nos três sinais. O melhor *autoencoder* é o ANN-AE (base) na voz ($\bar{d}_{\text{pen}} = 1{,}7479$), o ANN-AE (base) no EEG de fala pronunciada (1,7354) e o ANN-AE (base) no de fala imaginada (1,6697). A melhor PCA é a de $k = 8$ nos três, com 1,7230, 1,7149 e 1,6649. O extrator manual vencedor tem 1,4836, 1,5788 e 1,5128. A distância entre o manual e o melhor automatizado é de cerca de dez vezes o σ_{loc} de qualquer um deles: pelo critério paraconsistente, a ordem entre as famílias não depende de quais locutores foram observados.

Dentro dos automatizados, três padrões se repetem nos três sinais.

- **A PCA não fica atrás dos *autoencoders*.** A melhor PCA tem $\bar{d}_{\text{pen}}$ menor que o melhor *autoencoder* nos três sinais, por margens da ordem do σ_{rep} dos *autoencoders*. Comparando tamanho a tamanho ($k = 8$, 16 e 32 contra os latentes `tiny`, `small` e `base`), a PCA vence 2 das 3 comparações na voz, 1 no EEG de fala pronunciada e 1 no de fala imaginada. O treino de um modelo não linear não produziu, nesta dimensão e neste orçamento, uma representação mais separável que uma projeção linear.
- **O *autoencoder* convencional fica à frente do de pulsos.** As três variantes do ANN-AE ocupam as três primeiras posições das tabelas de *autoencoder* nos três sinais.
- **Entre as codificações do SNN-AE, a de latência é a melhor e a direta, a pior**, em média, nos três sinais — o oposto do que o ruído de cada codificação faria prever (subseção 3.3.1).

Os $\bar{\beta}$ dos extratores automatizados continuam altos — de 0,8983 a 0,9331 nos *autoencoders* da voz e de 0,8908 a 0,9279 na PCA, contra 0,7663 do manual —, o que indica sobreposição grande entre as classes. Como a PCA, que não tem treino, chega a valores iguais aos dos *autoencoders*, essa sobreposição não pode ser atribuída a um treino insuficiente: ela é da representação de dimensão k do espectro desses sinais.

Os dados das tabelas são gerados automaticamente a partir dos arquivos de resultado da Fase 00 (Apêndice B).

Tabela 11 – *Autoencoders* (voz) ordenados por $\bar{d}_{\text{pen}}$ crescente (menor = melhor)

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
1	ANN-AE (base)	1,7479	0,0131	0,0050	0/15	1,6486	0,2649	0,9046
2	ANN-AE (small)	1,7531	0,0050	0,0051	0/15	1,6649	0,2462	0,9043
3	ANN-AE (tiny)	1,7571	0,0257	0,0063	0/15	1,6957	0,2065	0,8983
4	SNN-AE latency (base)	1,7673	0,0072	0,0032	0/15	1,6616	0,2644	0,9161
5	SNN-AE latency (small)	1,7703	0,0135	0,0043	0/15	1,6907	0,2253	0,9105

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
6	SNN-AE direct (base)	1,7824	0,0032	0,0041	0/15	1,6824	0,2484	0,9222
7	SNN-AE poisson (small)	1,7868	0,0117	0,0051	0/15	1,7075	0,2167	0,9187
8	SNN-AE poisson (tiny)	1,7908	0,0232	0,0057	0/15	1,7388	0,1762	0,9124
9	SNN-AE direct (small)	1,8026	0,0126	0,0046	0/15	1,7348	0,1924	0,9233
10	SNN-AE latency (tiny)	1,8031	0,0044	0,0033	0/15	1,7323	0,1964	0,9244
11	SNN-AE poisson (base)	1,8044	0,0039	0,0039	0/15	1,7047	0,2369	0,9331
12	SNN-AE direct (tiny)	1,8448	0,0121	0,0056	0/15	1,8191	0,1127	0,9312

Tabela 12 – *Autoencoders* (EEG de fala pronunciada) ordenados por $\bar{d}_{\text{pen}}$ crescente (menor = melhor)

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
1	ANN-AE (base)	1,7354	0,0059	0,0102	0/15	1,6407	0,2644	0,8972
2	ANN-AE (small)	1,7609	0,0011	0,0092	0/15	1,6699	0,2464	0,9090
3	ANN-AE (tiny)	1,7703	0,0134	0,0079	0/15	1,6629	0,2653	0,9180
4	SNN-AE latency (small)	1,8141	0,0148	0,0075	0/15	1,7355	0,2021	0,9320
5	SNN-AE latency (base)	1,8156	0,0048	0,0055	0/15	1,7234	0,2206	0,9368
6	SNN-AE latency (tiny)	1,8194	0,0122	0,0073	0/15	1,7316	0,2125	0,9374
7	SNN-AE direct (base)	1,8685	0,0057	0,0063	0/15	1,8076	0,1497	0,9542
8	SNN-AE poisson (base)	1,8828	0,0008	0,0011	0/15	1,7562	0,2367	0,9795
9	SNN-AE poisson (tiny)	1,8860	0,0044	0,0017	0/15	1,7752	0,2120	0,9771
10	SNN-AE poisson (small)	1,8863	0,0034	0,0011	0/15	1,7730	0,2155	0,9779
11	SNN-AE direct (small)	1,9217	0,0189	0,0043	0/15	1,8856	0,0890	0,9728
12	SNN-AE direct (tiny)	1,9799	0,0244	0,0042	0/15	1,9726	0,0152	0,9877

Tabela 13 – *Autoencoders* (EEG de fala imaginada) ordenados por $\bar{d}_{\text{pen}}$ crescente (menor = melhor)

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
1	ANN-AE (base)	1,6697	0,0111	0,0141	0/15	1,5764	0,2954	0,8638
2	ANN-AE (small)	1,6995	0,0165	0,0141	0/15	1,6189	0,2622	0,8753
3	ANN-AE (tiny)	1,7118	0,0263	0,0119	0/15	1,6313	0,2559	0,8814
4	SNN-AE latency (tiny)	1,7285	0,0183	0,0148	0/15	1,6269	0,2780	0,8955
5	SNN-AE latency (small)	1,7399	0,0181	0,0118	0/15	1,6334	0,2793	0,9026
6	SNN-AE latency (base)	1,7443	0,0033	0,0104	0/15	1,6163	0,3085	0,9099
7	SNN-AE direct (base)	1,8584	0,0047	0,0089	0/15	1,8084	0,1396	0,9458
8	SNN-AE poisson (tiny)	1,8756	0,0119	0,0034	0/15	1,7660	0,2157	0,9714

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
9	SNN-AE poisson (small)	1,8816	0,0020	0,0019	0/15	1,7674	0,2192	0,9758
10	SNN-AE poisson (base)	1,8816	0,0017	0,0014	0/15	1,7582	0,2326	0,9781
11	SNN-AE direct (small)	1,8828	0,0225	0,0151	0/15	1,8404	0,1171	0,9553
12	SNN-AE direct (tiny)	1,9727	0,0307	0,0056	0/15	1,9523	0,0323	0,9841

Tabela 14 – PCA (voz) ordenada por $\bar{d}_{\text{pen}}$ crescente (menor = melhor)

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
1	PCA (k = 8)	1,7230	—	0,0058	0/15	1,6286	0,2702	0,8908
2	PCA (k = 16)	1,7430	—	0,0037	0/15	1,6235	0,2967	0,9073
3	PCA (k = 32)	1,7777	—	0,0036	0/15	1,6449	0,2988	0,9279

Tabela 15 – PCA (EEG de fala pronunciada) ordenada por $\bar{d}_{\text{pen}}$ crescente (menor = melhor)

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
1	PCA (k = 8)	1,7149	—	0,0056	0/15	1,5943	0,3125	0,8934
2	PCA (k = 16)	1,8120	—	0,0064	0/15	1,7208	0,2209	0,9347
3	PCA (k = 32)	1,8300	—	0,0023	0/15	1,6930	0,2785	0,9553

Tabela 16 – PCA (EEG de fala imaginada) ordenada por $\bar{d}_{\text{pen}}$ crescente (menor = melhor)

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
1	PCA (k = 8)	1,6649	—	0,0082	0/15	1,5602	0,3144	0,8643
2	PCA (k = 16)	1,7673	—	0,0052	0/15	1,6585	0,2689	0,9169
3	PCA (k = 32)	1,8250	—	0,0050	0/15	1,7137	0,2435	0,9466

Tabela 17 – Características manuais (voz) ordenadas por $\bar{d}_{\text{pen}}$ crescente (menor = melhor); † = vencedor do sinal

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
1†	Haar + Linear (c1)	1,4836	—	0,0241	10/15	1,4055	0,3671	0,7663
2	Haar + Mel (c1)	1,4973	—	0,0229	0/15	1,4191	0,3603	0,7731
3	Daubechies 22 + Linear (c1)	1,4973	—	0,0177	1/15	1,3929	0,3984	0,7798
4	Daubechies 26 + Linear (c1)	1,4988	—	0,0184	0/15	1,3983	0,3920	0,7797

#	Configuração	$\bar{d}_{\mathbf{pen}}$	$\sigma_{\mathbf{rep}}$	$\sigma_{\mathbf{loc}}$	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
5	Daubechies 30 + Linear (c1)	1,5011	—	0,0175	0/15	1,4039	0,3859	0,7800
6	Daubechies 42 + Linear (c1)	1,5014	—	0,0176	0/15	1,4043	0,3856	0,7801
7	Daubechies 20 + Linear (c1)	1,5016	—	0,0161	2/15	1,4075	0,3812	0,7795
8	Daubechies 32 + Linear (c1)	1,5016	—	0,0179	0/15	1,4068	0,3822	0,7797
9	Daubechies 38 + Linear (c1)	1,5018	—	0,0183	0/15	1,4058	0,3838	0,7800
10	Daubechies 36 + Linear (c1)	1,5019	—	0,0179	0/15	1,4024	0,3889	0,7810
11	Daubechies 40 + Linear (c1)	1,5021	—	0,0172	0/15	1,4077	0,3814	0,7798
12	Daubechies 16 + Linear (c1)	1,5022	—	0,0184	0/15	1,4014	0,3907	0,7814
13	Daubechies 46 + Linear (c1)	1,5028	—	0,0167	1/15	1,4094	0,3796	0,7799
14	Daubechies 34 + Linear (c1)	1,5037	—	0,0175	0/15	1,4098	0,3797	0,7805
15	Daubechies 28 + Linear (c1)	1,5041	—	0,0173	0/15	1,4127	0,3760	0,7800
16	Daubechies 18 + Linear (c1)	1,5043	—	0,0173	0/15	1,4078	0,3832	0,7814
17	Daubechies 14 + Linear (c1)	1,5043	—	0,0180	0/15	1,4078	0,3833	0,7814
18	Daubechies 24 + Linear (c1)	1,5043	—	0,0167	0/15	1,4119	0,3774	0,7804
19	Daubechies 44 + Linear (c1)	1,5052	—	0,0165	0/15	1,4125	0,3773	0,7809
20	Daubechies 12 + Linear (c1)	1,5058	—	0,0187	0/15	1,4097	0,3819	0,7821
21	Haar + Bark (c1)	1,5100	—	0,0226	0/15	1,4245	0,3645	0,7815
22	Daubechies 4 + Linear (c1)	1,5145	—	0,0245	0/15	1,4478	0,3353	0,7786
23	Daubechies 18 + Mel (c1)	1,5191	—	0,0161	0/15	1,4123	0,3909	0,7914
24	Daubechies 32 + Mel (c1)	1,5199	—	0,0161	0/15	1,4188	0,3822	0,7904
25	Daubechies 22 + Mel (c1)	1,5200	—	0,0168	0/15	1,4180	0,3834	0,7907
26	Daubechies 26 + Mel (c1)	1,5203	—	0,0165	0/15	1,4178	0,3840	0,7909
27	Daubechies 16 + Mel (c1)	1,5205	—	0,0171	0/15	1,4164	0,3862	0,7914
28	Daubechies 20 + Mel (c1)	1,5211	—	0,0156	0/15	1,4232	0,3768	0,7902
29	Daubechies 30 + Mel (c1)	1,5211	—	0,0160	0/15	1,4224	0,3781	0,7905
30	Daubechies 40 + Mel (c1)	1,5217	—	0,0154	0/15	1,4218	0,3795	0,7910
31	Daubechies 24 + Mel (c1)	1,5218	—	0,0159	0/15	1,4220	0,3794	0,7911
32	Daubechies 28 + Mel (c1)	1,5228	—	0,0162	0/15	1,4241	0,3772	0,7913
33	Daubechies 34 + Mel (c1)	1,5229	—	0,0162	0/15	1,4245	0,3767	0,7913
34	Daubechies 14 + Mel (c1)	1,5233	—	0,0172	0/15	1,4207	0,3826	0,7925
35	Daubechies 42 + Mel (c1)	1,5234	—	0,0154	0/15	1,4255	0,3757	0,7914
36	Daubechies 10 + Linear (c1)	1,5234	—	0,0250	0/15	1,4546	0,3339	0,7837
37	Daubechies 36 + Mel (c1)	1,5236	—	0,0162	0/15	1,4228	0,3800	0,7923
38	Daubechies 44 + Mel (c1)	1,5252	—	0,0150	0/15	1,4283	0,3733	0,7920
39	Daubechies 38 + Mel (c1)	1,5252	—	0,0157	0/15	1,4295	0,3716	0,7917
40	Daubechies 8 + Linear (c1)	1,5253	—	0,0239	0/15	1,4580	0,3307	0,7842
41	Daubechies 46 + Mel (c1)	1,5258	—	0,0148	0/15	1,4338	0,3659	0,7911
42	Daubechies 12 + Mel (c1)	1,5265	—	0,0175	0/15	1,4318	0,3696	0,7922
43	Daubechies 4 + Mel (c1)	1,5294	—	0,0197	0/15	1,4577	0,3349	0,7874
44	Daubechies 6 + Linear (c1)	1,5342	—	0,0250	0/15	1,4772	0,3117	0,7857
45	Daubechies 22 + Bark (c1)	1,5385	—	0,0155	0/15	1,4382	0,3717	0,7996

#	Configuração	$\bar{d}_{\mathbf{pen}}$	$\sigma_{\mathbf{rep}}$	$\sigma_{\mathbf{loc}}$	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
46	Daubechies 10 + Mel (c1)	1,5395	—	0,0205	0/15	1,4595	0,3417	0,7948
47	Daubechies 32 + Bark (c1)	1,5404	—	0,0147	0/15	1,4448	0,3638	0,7993
48	Daubechies 4 + Bark (c1)	1,5406	—	0,0209	0/15	1,4543	0,3502	0,7970
49	Daubechies 26 + Bark (c1)	1,5406	—	0,0153	0/15	1,4448	0,3639	0,7995
50	Daubechies 30 + Bark (c1)	1,5413	—	0,0149	0/15	1,4450	0,3644	0,8000
51	Daubechies 24 + Bark (c1)	1,5415	—	0,0145	0/15	1,4470	0,3617	0,7997
52	Daubechies 20 + Bark (c1)	1,5427	—	0,0154	0/15	1,4503	0,3580	0,7997
53	Daubechies 36 + Bark (c1)	1,5432	—	0,0146	0/15	1,4459	0,3648	0,8012
54	Daubechies 8 + Mel (c1)	1,5433	—	0,0180	0/15	1,4737	0,3250	0,7939
55	Daubechies 42 + Bark (c1)	1,5433	—	0,0142	1/15	1,4480	0,3620	0,8008
56	Daubechies 34 + Bark (c1)	1,5436	—	0,0143	0/15	1,4499	0,3594	0,8005
57	Daubechies 40 + Bark (c1)	1,5436	—	0,0142	0/15	1,4493	0,3604	0,8007
58	Daubechies 14 + Bark (c1)	1,5440	—	0,0166	0/15	1,4466	0,3647	0,8016
59	Daubechies 12 + Bark (c1)	1,5445	—	0,0170	0/15	1,4470	0,3645	0,8019
60	Daubechies 28 + Bark (c1)	1,5446	—	0,0147	0/15	1,4531	0,3557	0,8004
61	Daubechies 16 + Bark (c1)	1,5450	—	0,0167	0/15	1,4527	0,3567	0,8009
62	Daubechies 44 + Bark (c1)	1,5451	—	0,0140	0/15	1,4499	0,3609	0,8016
63	Daubechies 46 + Bark (c1)	1,5451	—	0,0136	0/15	1,4536	0,3555	0,8007
64	Daubechies 18 + Bark (c1)	1,5459	—	0,0155	0/15	1,4536	0,3563	0,8013
65	Daubechies 38 + Bark (c1)	1,5476	—	0,0139	0/15	1,4581	0,3513	0,8015
66	Daubechies 6 + Mel (c1)	1,5517	—	0,0196	0/15	1,4893	0,3104	0,7960
67	Daubechies 10 + Bark (c1)	1,5572	—	0,0193	0/15	1,4722	0,3400	0,8050
68	Daubechies 8 + Bark (c1)	1,5631	—	0,0186	0/15	1,4925	0,3164	0,8041
69	Daubechies 6 + Bark (c1)	1,5638	—	0,0195	0/15	1,4903	0,3203	0,8053
70	Haar + MFCC (c2)	1,6069	—	0,0139	0/15	1,5120	0,3293	0,8326
71	Haar + LFCC (c2)	1,6077	—	0,0140	0/15	1,5048	0,3406	0,8351
72	Haar + BFCC (c2)	1,6124	—	0,0144	0/15	1,5131	0,3330	0,8365
73	Daubechies 22 + LFCC (c2)	1,6199	—	0,0119	0/15	1,4893	0,3752	0,8478
74	Daubechies 32 + MFCC (c2)	1,6205	—	0,0112	0/15	1,4913	0,3728	0,8477
75	Daubechies 26 + MFCC (c2)	1,6207	—	0,0116	0/15	1,4898	0,3753	0,8482
76	Daubechies 22 + MFCC (c2)	1,6211	—	0,0116	0/15	1,4929	0,3710	0,8478
77	Daubechies 42 + LFCC (c2)	1,6213	—	0,0123	0/15	1,4934	0,3705	0,8479
78	Daubechies 30 + MFCC (c2)	1,6215	—	0,0111	0/15	1,4942	0,3695	0,8478
79	Daubechies 26 + LFCC (c2)	1,6216	—	0,0125	0/15	1,4958	0,3673	0,8475
80	Daubechies 18 + MFCC (c2)	1,6216	—	0,0108	0/15	1,4896	0,3765	0,8489
81	Daubechies 20 + MFCC (c2)	1,6216	—	0,0105	0/15	1,4968	0,3658	0,8473
82	Daubechies 24 + MFCC (c2)	1,6218	—	0,0109	0/15	1,4936	0,3708	0,8482
83	Daubechies 30 + LFCC (c2)	1,6220	—	0,0119	0/15	1,4966	0,3664	0,8476
84	Daubechies 16 + MFCC (c2)	1,6221	—	0,0117	0/15	1,4917	0,3737	0,8488
85	Daubechies 40 + MFCC (c2)	1,6222	—	0,0106	0/15	1,4941	0,3704	0,8484
86	Daubechies 32 + LFCC (c2)	1,6225	—	0,0124	0/15	1,4998	0,3622	0,8473

#	Configuração	$\bar{d}_{\mathbf{pen}}$	$\sigma_{\mathbf{rep}}$	$\sigma_{\mathbf{loc}}$	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
87	Daubechies 34 + MFCC (c2)	1,6227	—	0,0116	0/15	1,4941	0,3709	0,8487
88	Daubechies 42 + MFCC (c2)	1,6229	—	0,0108	0/15	1,4944	0,3705	0,8488
89	Daubechies 46 + LFCC (c2)	1,6233	—	0,0114	0/15	1,5001	0,3626	0,8478
90	Daubechies 38 + LFCC (c2)	1,6233	—	0,0126	0/15	1,4995	0,3634	0,8480
91	Daubechies 40 + LFCC (c2)	1,6234	—	0,0118	0/15	1,5010	0,3612	0,8476
92	Daubechies 28 + MFCC (c2)	1,6235	—	0,0113	0/15	1,4968	0,3676	0,8487
93	Daubechies 20 + LFCC (c2)	1,6238	—	0,0104	0/15	1,5036	0,3578	0,8474
94	Daubechies 36 + LFCC (c2)	1,6239	—	0,0124	0/15	1,4976	0,3668	0,8488
95	Daubechies 36 + MFCC (c2)	1,6242	—	0,0114	0/15	1,4949	0,3711	0,8496
96	Daubechies 34 + LFCC (c2)	1,6244	—	0,0121	0/15	1,5015	0,3615	0,8483
97	Daubechies 38 + MFCC (c2)	1,6250	—	0,0112	0/15	1,4992	0,3656	0,8492
98	Daubechies 16 + LFCC (c2)	1,6251	—	0,0121	0/15	1,5008	0,3632	0,8489
99	Daubechies 46 + MFCC (c2)	1,6253	—	0,0103	0/15	1,5025	0,3609	0,8487
100	Daubechies 28 + LFCC (c2)	1,6253	—	0,0119	0/15	1,5065	0,3550	0,8478
101	Daubechies 44 + MFCC (c2)	1,6254	—	0,0104	0/15	1,4997	0,3651	0,8494
102	Daubechies 44 + LFCC (c2)	1,6254	—	0,0112	0/15	1,5035	0,3595	0,8486
103	Daubechies 22 + BFCC (c2)	1,6257	—	0,0100	0/15	1,5017	0,3624	0,8492
104	Daubechies 24 + LFCC (c2)	1,6257	—	0,0112	0/15	1,5065	0,3554	0,8481
105	Daubechies 14 + MFCC (c2)	1,6257	—	0,0114	0/15	1,4997	0,3655	0,8497
106	Daubechies 32 + BFCC (c2)	1,6260	—	0,0094	0/15	1,5064	0,3558	0,8483
107	Daubechies 30 + BFCC (c2)	1,6269	—	0,0097	0/15	1,5055	0,3580	0,8492
108	Daubechies 26 + BFCC (c2)	1,6270	—	0,0099	0/15	1,5073	0,3555	0,8489
109	Daubechies 18 + LFCC (c2)	1,6271	—	0,0111	0/15	1,5077	0,3550	0,8489
110	Daubechies 42 + BFCC (c2)	1,6272	—	0,0093	0/15	1,5039	0,3607	0,8498
111	Daubechies 24 + BFCC (c2)	1,6275	—	0,0092	0/15	1,5087	0,3539	0,8489
112	Daubechies 14 + LFCC (c2)	1,6278	—	0,0116	0/15	1,5105	0,3515	0,8487
113	Daubechies 34 + BFCC (c2)	1,6281	—	0,0093	0/15	1,5078	0,3557	0,8495
114	Daubechies 12 + MFCC (c2)	1,6281	—	0,0116	0/15	1,5078	0,3558	0,8496
115	Daubechies 12 + LFCC (c2)	1,6287	—	0,0119	0/15	1,5104	0,3525	0,8494
116	Daubechies 36 + BFCC (c2)	1,6289	—	0,0094	0/15	1,5079	0,3564	0,8501
117	Daubechies 46 + BFCC (c2)	1,6289	—	0,0090	0/15	1,5099	0,3535	0,8497
118	Daubechies 20 + BFCC (c2)	1,6293	—	0,0098	0/15	1,5131	0,3492	0,8492
119	Daubechies 40 + BFCC (c2)	1,6293	—	0,0091	0/15	1,5107	0,3528	0,8498
120	Daubechies 44 + BFCC (c2)	1,6300	—	0,0091	0/15	1,5096	0,3550	0,8505
121	Daubechies 28 + BFCC (c2)	1,6312	—	0,0093	0/15	1,5167	0,3457	0,8498
122	Daubechies 4 + MFCC (c2)	1,6313	—	0,0127	0/15	1,5352	0,3189	0,8453
123	Daubechies 38 + BFCC (c2)	1,6321	—	0,0090	0/15	1,5158	0,3479	0,8506
124	Daubechies 16 + BFCC (c2)	1,6327	—	0,0106	0/15	1,5172	0,3464	0,8507
125	Daubechies 14 + BFCC (c2)	1,6330	—	0,0103	0/15	1,5154	0,3493	0,8514
126	Daubechies 12 + BFCC (c2)	1,6337	—	0,0107	0/15	1,5160	0,3492	0,8518
127	Daubechies 18 + BFCC (c2)	1,6342	—	0,0095	0/15	1,5205	0,3430	0,8511

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
128	Daubechies 4 + LFCC (c2)	1,6361	—	0,0136	0/15	1,5447	0,3096	0,8464
129	Daubechies 4 + BFCC (c2)	1,6373	—	0,0131	0/15	1,5391	0,3189	0,8488
130	Daubechies 10 + MFCC (c2)	1,6427	—	0,0127	0/15	1,5415	0,3204	0,8522
131	Daubechies 8 + MFCC (c2)	1,6452	—	0,0114	0/15	1,5525	0,3069	0,8513
132	Daubechies 10 + LFCC (c2)	1,6459	—	0,0121	0/15	1,5547	0,3044	0,8513
133	Daubechies 8 + LFCC (c2)	1,6477	—	0,0122	0/15	1,5585	0,3006	0,8516
134	Daubechies 10 + BFCC (c2)	1,6490	—	0,0123	0/15	1,5489	0,3157	0,8551
135	Daubechies 6 + MFCC (c2)	1,6541	—	0,0112	0/15	1,5702	0,2898	0,8534
136	Daubechies 8 + BFCC (c2)	1,6544	—	0,0111	0/15	1,5676	0,2937	0,8543
137	Daubechies 6 + LFCC (c2)	1,6557	—	0,0117	0/15	1,5758	0,2833	0,8531
138	Daubechies 6 + BFCC (c2)	1,6571	—	0,0115	0/15	1,5689	0,2945	0,8561

Tabela 18 – Características manuais (EEG de fala pronunciada) ordenadas por $\bar{d}_{\text{pen}}$ crescente (menor = melhor); † = vencedor do sinal

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
1†	Haar + Linear (c1)	1,5788	—	0,0134	15/15	1,5285	0,2799	0,8060
2	Haar + LFCC (c2)	1,6264	—	0,0108	0/15	1,5488	0,2947	0,8378
3	Daubechies 4 + Linear (c1)	1,7543	—	0,0056	0/15	1,6559	0,2604	0,9077
4	Daubechies 4 + LFCC (c2)	1,7734	—	0,0050	0/15	1,6548	0,2800	0,9224
5	Daubechies 28 + LFCC (c2)	1,7885	—	0,0041	0/15	1,6416	0,3142	0,9366
6	Daubechies 30 + LFCC (c2)	1,7913	—	0,0040	0/15	1,6490	0,3059	0,9370
7	Daubechies 26 + LFCC (c2)	1,7917	—	0,0040	0/15	1,6477	0,3082	0,9375
8	Daubechies 6 + Linear (c1)	1,7938	—	0,0042	0/15	1,6949	0,2412	0,9277
9	Daubechies 40 + LFCC (c2)	1,7940	—	0,0038	0/15	1,6516	0,3048	0,9384
10	Daubechies 20 + LFCC (c2)	1,7956	—	0,0041	0/15	1,6548	0,3015	0,9388
11	Daubechies 24 + LFCC (c2)	1,7964	—	0,0035	0/15	1,6542	0,3032	0,9395
12	Daubechies 46 + LFCC (c2)	1,7973	—	0,0038	0/15	1,6589	0,2972	0,9392
13	Daubechies 44 + LFCC (c2)	1,7974	—	0,0037	0/15	1,6639	0,2898	0,9380
14	Daubechies 32 + LFCC (c2)	1,7975	—	0,0036	0/15	1,6648	0,2886	0,9379
15	Daubechies 34 + LFCC (c2)	1,7975	—	0,0036	0/15	1,6638	0,2901	0,9382
16	Daubechies 36 + LFCC (c2)	1,7979	—	0,0038	0/15	1,6596	0,2966	0,9394
17	Daubechies 42 + LFCC (c2)	1,7986	—	0,0038	0/15	1,6641	0,2907	0,9389
18	Daubechies 38 + LFCC (c2)	1,7986	—	0,0039	0/15	1,6658	0,2881	0,9385
19	Daubechies 22 + LFCC (c2)	1,7988	—	0,0035	0/15	1,6599	0,2972	0,9400
20	Daubechies 18 + LFCC (c2)	1,7996	—	0,0038	0/15	1,6627	0,2938	0,9400
21	Daubechies 28 + Linear (c1)	1,7997	—	0,0030	0/15	1,6740	0,2772	0,9374
22	Daubechies 14 + LFCC (c2)	1,7999	—	0,0035	0/15	1,6506	0,3120	0,9428
23	Daubechies 30 + Linear (c1)	1,8000	—	0,0033	0/15	1,6781	0,2715	0,9366

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
24	Daubechies 16 + LFCC (c2)	1,8009	—	0,0033	0/15	1,6643	0,2927	0,9406
25	Daubechies 6 + LFCC (c2)	1,8019	—	0,0041	0/15	1,6828	0,2664	0,9369
26	Daubechies 26 + Linear (c1)	1,8030	—	0,0031	0/15	1,6798	0,2718	0,9384
27	Daubechies 40 + Linear (c1)	1,8031	—	0,0031	0/15	1,6814	0,2697	0,9382
28	Daubechies 10 + LFCC (c2)	1,8035	—	0,0037	0/15	1,6619	0,2987	0,9429
29	Daubechies 8 + Linear (c1)	1,8051	—	0,0038	0/15	1,7056	0,2363	0,9335
30	Daubechies 20 + Linear (c1)	1,8057	—	0,0033	0/15	1,6854	0,2663	0,9391
31	Daubechies 46 + Linear (c1)	1,8063	—	0,0030	0/15	1,6870	0,2645	0,9392
32	Daubechies 24 + Linear (c1)	1,8074	—	0,0028	0/15	1,6874	0,2650	0,9399
33	Daubechies 10 + Linear (c1)	1,8077	—	0,0032	0/15	1,6934	0,2565	0,9386
34	Daubechies 44 + Linear (c1)	1,8080	—	0,0030	0/15	1,6951	0,2543	0,9384
35	Daubechies 34 + Linear (c1)	1,8083	—	0,0029	0/15	1,6956	0,2539	0,9385
36	Daubechies 36 + Linear (c1)	1,8084	—	0,0031	0/15	1,6923	0,2588	0,9394
37	Daubechies 18 + Linear (c1)	1,8089	—	0,0030	0/15	1,6927	0,2586	0,9397
38	Daubechies 8 + LFCC (c2)	1,8089	—	0,0036	0/15	1,6847	0,2703	0,9417
39	Daubechies 22 + Linear (c1)	1,8091	—	0,0030	0/15	1,6917	0,2603	0,9401
40	Daubechies 32 + Linear (c1)	1,8093	—	0,0028	0/15	1,6987	0,2503	0,9385
41	Daubechies 38 + Linear (c1)	1,8096	—	0,0031	0/15	1,6976	0,2522	0,9390
42	Daubechies 42 + Linear (c1)	1,8100	—	0,0030	0/15	1,6969	0,2536	0,9395
43	Daubechies 16 + Linear (c1)	1,8103	—	0,0026	0/15	1,6939	0,2583	0,9405
44	Daubechies 12 + LFCC (c2)	1,8108	—	0,0035	0/15	1,6789	0,2806	0,9444
45	Daubechies 14 + Linear (c1)	1,8123	—	0,0028	0/15	1,6859	0,2719	0,9439
46	Daubechies 12 + Linear (c1)	1,8172	—	0,0029	0/15	1,7088	0,2432	0,9419

Tabela 19 – Características manuais (EEG de fala imaginada) ordenadas por $\bar{d}_{\text{pen}}$ crescente (menor = melhor); † = vencedor do sinal

#	Configuração	$\bar{d}_{\text{pen}}$	σ_{rep}	σ_{loc}	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
1†	Haar + Linear (c1)	1,5128	—	0,0174	15/15	1,4698	0,3027	0,7707
2	Haar + LFCC (c2)	1,5369	—	0,0149	0/15	1,4311	0,3804	0,8001
3	Daubechies 4 + Linear (c1)	1,7328	—	0,0071	0/15	1,6495	0,2495	0,8928
4	Daubechies 4 + LFCC (c2)	1,7445	—	0,0064	0/15	1,6285	0,2908	0,9072
5	Daubechies 6 + Linear (c1)	1,7679	—	0,0050	0/15	1,6683	0,2553	0,9148
6	Daubechies 6 + LFCC (c2)	1,7723	—	0,0048	0/15	1,6424	0,2972	0,9246
7	Daubechies 20 + LFCC (c2)	1,7802	—	0,0039	0/15	1,6459	0,2998	0,9296
8	Daubechies 16 + LFCC (c2)	1,7834	—	0,0038	0/15	1,6670	0,2719	0,9270
9	Daubechies 18 + LFCC (c2)	1,7860	—	0,0038	0/15	1,6687	0,2718	0,9284
10	Daubechies 28 + LFCC (c2)	1,7865	—	0,0040	0/15	1,6592	0,2862	0,9311
11	Daubechies 30 + LFCC (c2)	1,7868	—	0,0043	0/15	1,6664	0,2759	0,9296

#	Configuração	$\bar{d}_{\mathbf{pen}}$	$\sigma_{\mathbf{rep}}$	$\sigma_{\mathbf{loc}}$	dobras	$\bar{d}$	$\bar{\alpha}$	$\bar{\beta}$
12	Daubechies 14 + LFCC (c2)	1,7872	—	0,0040	0/15	1,6596	0,2863	0,9315
13	Daubechies 12 + LFCC (c2)	1,7874	—	0,0034	0/15	1,6574	0,2898	0,9322
14	Daubechies 32 + LFCC (c2)	1,7875	—	0,0046	0/15	1,6640	0,2802	0,9307
15	Daubechies 26 + LFCC (c2)	1,7892	—	0,0041	0/15	1,6672	0,2771	0,9312
16	Daubechies 22 + LFCC (c2)	1,7905	—	0,0040	0/15	1,6658	0,2803	0,9325
17	Daubechies 24 + LFCC (c2)	1,7910	—	0,0042	0/15	1,6698	0,2750	0,9319
18	Daubechies 8 + Linear (c1)	1,7943	—	0,0042	0/15	1,7182	0,2083	0,9216
19	Daubechies 8 + LFCC (c2)	1,7944	—	0,0039	0/15	1,6902	0,2485	0,9293
20	Daubechies 38 + LFCC (c2)	1,7944	—	0,0047	0/15	1,6804	0,2628	0,9319
21	Daubechies 40 + LFCC (c2)	1,7953	—	0,0044	0/15	1,6811	0,2627	0,9324
22	Daubechies 34 + LFCC (c2)	1,7955	—	0,0044	0/15	1,6798	0,2647	0,9329
23	Daubechies 42 + LFCC (c2)	1,7961	—	0,0045	0/15	1,6815	0,2627	0,9328
24	Daubechies 10 + LFCC (c2)	1,7968	—	0,0037	0/15	1,6871	0,2553	0,9320
25	Daubechies 46 + LFCC (c2)	1,7974	—	0,0048	0/15	1,6824	0,2627	0,9336
26	Daubechies 36 + LFCC (c2)	1,7980	—	0,0046	0/15	1,6806	0,2659	0,9345
27	Daubechies 44 + LFCC (c2)	1,8010	—	0,0045	0/15	1,6931	0,2506	0,9336
28	Daubechies 20 + Linear (c1)	1,8012	—	0,0033	0/15	1,6948	0,2483	0,9334
29	Daubechies 16 + Linear (c1)	1,8026	—	0,0038	0/15	1,7168	0,2180	0,9285
30	Daubechies 10 + Linear (c1)	1,8044	—	0,0031	0/15	1,7197	0,2155	0,9291
31	Daubechies 28 + Linear (c1)	1,8046	—	0,0040	0/15	1,7029	0,2398	0,9338
32	Daubechies 12 + Linear (c1)	1,8048	—	0,0028	0/15	1,7092	0,2309	0,9323
33	Daubechies 32 + Linear (c1)	1,8048	—	0,0046	0/15	1,7045	0,2376	0,9336
34	Daubechies 30 + Linear (c1)	1,8052	—	0,0039	0/15	1,7085	0,2324	0,9328
35	Daubechies 26 + Linear (c1)	1,8055	—	0,0043	0/15	1,7066	0,2353	0,9335
36	Daubechies 18 + Linear (c1)	1,8055	—	0,0039	0/15	1,7169	0,2205	0,9308
37	Daubechies 22 + Linear (c1)	1,8069	—	0,0038	0/15	1,7063	0,2370	0,9347
38	Daubechies 24 + Linear (c1)	1,8073	—	0,0043	0/15	1,7120	0,2292	0,9335
39	Daubechies 14 + Linear (c1)	1,8076	—	0,0031	0/15	1,7108	0,2311	0,9340
40	Daubechies 34 + Linear (c1)	1,8116	—	0,0046	0/15	1,7183	0,2242	0,9351
41	Daubechies 36 + Linear (c1)	1,8129	—	0,0049	0/15	1,7187	0,2248	0,9360
42	Daubechies 42 + Linear (c1)	1,8133	—	0,0045	0/15	1,7206	0,2225	0,9358
43	Daubechies 46 + Linear (c1)	1,8136	—	0,0051	0/15	1,7211	0,2220	0,9359
44	Daubechies 38 + Linear (c1)	1,8143	—	0,0051	0/15	1,7239	0,2187	0,9357
45	Daubechies 40 + Linear (c1)	1,8144	—	0,0041	0/15	1,7227	0,2205	0,9361
46	Daubechies 44 + Linear (c1)	1,8173	—	0,0047	0/15	1,7312	0,2110	0,9360

4.2 Fase 01 — Autenticação

A Fase 01 treina o classificador sobre o extrator vencedor da Fase 00 e mede EER e AUC por dobra de validação cruzada, em quatro conjuntos de execuções (subseção 3.3.1.2): a grade principal, os controles, a disfonia simulada e a comparação de extratores. As tabelas são geradas automaticamente a partir dos resultados (Apêndice B). Em todas, o EER é a média das três repetições, e σ é o desvio padrão entre elas. Um EER de 0,5 e uma AUC de 0,5 correspondem a um classificador que decide ao acaso.

Como ler as comparações. Cada configuração fornece 15 valores de EER (3 repetições × 5 dobras), que não são independentes entre si. As comparações usam o teste t corrigido para validação cruzada repetida, com correção de Holm dentro de cada família de comparações, e as famílias foram fixadas antes da execução (subseção 3.3.1.2). Com 15 locutores, esse teste tem pouco poder: diferenças de EER de vários pontos percentuais podem não atingir significância. "Não significativo" deve ser lido, neste capítulo, como "os dados não permitem afirmar", e não como "não há diferença".

4.2.1 Grade principal

A Tabela 20 traz as 56 configurações da grade — fonte × modo de texto × esquema de validação cruzada × padronização — ordenadas por EER crescente. A melhor configuração da grade é "Fusão tardia (imaginada), frases vistas, k-fold plano, padronizado", com EER = 0,2205 e AUC = 0,8547: longe do acaso, e ainda longe de uma autenticação utilizável na prática. Quatro padrões emergem da tabela.

(i) O EEG e as fusões ficam à frente da voz. A primeira configuração de voz aparece na 25ª posição (EER = 0,3180); todas as anteriores são de EEG ou de fusão com características padronizadas. A diferença é grande em tamanho de efeito (o d de Cohen das 12 comparações com a voz vai de $-0{,}51$ a $-1{,}23$), mas *nenhuma* dessas comparações é significativa após a correção ($p_{\text{Holm}} \geq 0{,}313$; o menor p sem correção é 0,052). A vantagem do EEG sobre a voz é, portanto, uma tendência consistente, e não um resultado estabelecido. A seção 4.4 discute por que ela pede cautela mesmo como tendência.

(ii) A fusão não se distingue do EEG sozinho. Com frases vistas, a fusão tardia tem EER de 0,2205 (fala imaginada) e 0,2220 (pronunciada), contra 0,2476 e 0,2665 do EEG sozinho. Nenhuma das 8 comparações entre uma fusão e o EEG da mesma condição é significativa ($p_{\text{Holm}} \geq 0{,}690$), e com frases não vistas a ordem chega a se inverter. A fusão supera a voz isolada na mesma medida em que o EEG a supera; os dados não mostram que somar a voz ao EEG acrescente algo.

(iii) A padronização é necessária. As características padronizadas têm EER menor que as brutas em 28 das 28 combinações de fonte, modo de texto e esquema de

validação. O efeito é pequeno na voz (média de 0,3302 contra 0,3634) e decisivo no EEG e nas fusões (0,2568 contra 0,4594): sem padronização, essas fontes ficam entre 0,4121 e 0,4817, perto do acaso. A explicação mais simples é de escala: as energias de banda do EEG, em unidades do amplificador, têm ordens de grandeza muito diferentes entre si e das da voz, e sem padronização as de maior valor dominam a entrada da rede. Essa explicação não foi testada isoladamente.

(iv) A validação plana dá EER menor que a aninhada. Isso ocorre em 13 das 14 combinações de fonte e modo de texto com características padronizadas (média de 0,2573 contra 0,2773). A direção é a esperada: a aninhada reserva parte do treino para validação, e cada modelo treina com menos dados. Como nenhum hiperparâmetro foi ajustado com os dados de teste em nenhum dos dois esquemas, a validação plana não é, aqui, uma estimativa otimista por seleção; a diferença mede o custo de reservar dados.

A condição do EEG quase não muda o resultado. O EEG de fala imaginada e o de fala pronunciada dão EER próximos em todas as fontes, e nenhuma das 6 comparações entre as duas condições é significativa ($p_{\text{Holm}} \geq 0{,}700$). Para a proposta deste trabalho o achado é favorável — o EEG de fala imaginada, que não exige fonação, autentica tão bem quanto o de fala pronunciada —, mas ele também é o que se esperaria se o classificador estivesse reconhecendo características do registro de EEG que não dependem do que o locutor faz. A seção 4.4 retoma esse ponto.

Tabela 20 – Grade principal da Fase 01 (autenticação com a DSNN), ordenada por EER médio crescente

#	Configuração	EER	σ_{EER}	AUC	σ_{AUC}
1	Fusão tardia (imaginada) · frases vistas · *k*-fold plano · padronizado	0,2205	0,0562	0,8547	0,0561
2	Fusão tardia (pronunciada) · frases vistas · *k*-fold plano · padronizado	0,2220	0,0544	0,8513	0,0500
3	Fusão precoce (imaginada) · frases vistas · *k*-fold plano · padronizado	0,2353	0,0280	0,8436	0,0258
4	Fusão precoce (pronunciada) · frases vistas · *k*-fold plano · padronizado	0,2367	0,0409	0,8420	0,0459
5	Fusão tardia (pronunciada) · frases vistas · *k*-fold aninhado · padronizado	0,2408	0,0354	0,8341	0,0389
6	Fusão precoce (imaginada) · frases vistas · *k*-fold aninhado · padronizado	0,2422	0,0507	0,8258	0,0504
7	EEG (fala pronunciada) · frases não vistas · *k*-fold plano · padronizado	0,2451	0,0297	0,8313	0,0295
8	EEG (fala imaginada) · frases vistas · *k*-fold plano · padronizado	0,2476	0,0466	0,8277	0,0454
9	Fusão precoce (imaginada) · frases não vistas · *k*-fold plano · padronizado	0,2505	0,0169	0,8127	0,0214
10	EEG (fala imaginada) · frases não vistas · *k*-fold plano · padronizado	0,2515	0,0344	0,8123	0,0289
11	Fusão precoce (pronunciada) · frases não vistas · *k*-fold plano · padronizado	0,2529	0,0434	0,8144	0,0516
12	EEG (fala imaginada) · frases não vistas · *k*-fold aninhado · padronizado	0,2541	0,0316	0,8081	0,0464
13	Fusão tardia (imaginada) · frases não vistas · *k*-fold plano · padronizado	0,2558	0,0185	0,8147	0,0272
14	Fusão tardia (pronunciada) · frases não vistas · *k*-fold aninhado · padronizado	0,2586	0,0306	0,8142	0,0306
15	Fusão precoce (imaginada) · frases não vistas · *k*-fold aninhado · padronizado	0,2607	0,0316	0,8086	0,0309
16	Fusão tardia (pronunciada) · frases não vistas · *k*-fold plano · padronizado	0,2645	0,0385	0,8101	0,0460
17	EEG (fala pronunciada) · frases vistas · *k*-fold plano · padronizado	0,2665	0,0122	0,8223	0,0161
18	Fusão precoce (pronunciada) · frases vistas · *k*-fold aninhado · padronizado	0,2732	0,0498	0,7998	0,0565
19	EEG (fala imaginada) · frases vistas · *k*-fold aninhado · padronizado	0,2751	0,0396	0,7936	0,0376
20	Fusão tardia (imaginada) · frases vistas · *k*-fold aninhado · padronizado	0,2768	0,0624	0,8030	0,0590
21	EEG (fala pronunciada) · frases vistas · *k*-fold aninhado · padronizado	0,2789	0,0155	0,7998	0,0121
22	EEG (fala pronunciada) · frases não vistas · *k*-fold aninhado · padronizado	0,2793	0,0412	0,7988	0,0309
23	Fusão tardia (imaginada) · frases não vistas · *k*-fold aninhado · padronizado	0,2794	0,0122	0,7795	0,0194

#	Configuração	EER	σ_{EER}	AUC	σ_{AUC}
24	Fusão precoce (pronunciada) · frases não vistas · k-fold aninhado · padronizado	0,2961	0,0343	0,7742	0,0459
25	Voz · frases vistas · k-fold plano · padronizado	0,3180	0,0569	0,7420	0,0753
26	Voz · frases vistas · k-fold aninhado · padronizado	0,3240	0,0533	0,7270	0,0758
27	Voz · frases vistas · k-fold plano · bruto	0,3287	0,0333	0,7258	0,0451
28	Voz · frases não vistas · k-fold plano · padronizado	0,3356	0,0173	0,7277	0,0346
29	Voz · frases não vistas · k-fold aninhado · padronizado	0,3430	0,0240	0,7144	0,0370
30	Voz · frases não vistas · k-fold plano · bruto	0,3504	0,0421	0,7053	0,0389
31	Voz · frases vistas · k-fold aninhado · bruto	0,3769	0,0173	0,6759	0,0162
32	Voz · frases não vistas · k-fold aninhado · bruto	0,3977	0,0249	0,6427	0,0357
33	EEG (fala imaginada) · frases vistas · k-fold aninhado · bruto	0,4121	0,0050	0,6063	0,0098
34	EEG (fala imaginada) · frases não vistas · k-fold aninhado · bruto	0,4141	0,0331	0,6044	0,0448
35	Fusão precoce (imaginada) · frases vistas · k-fold aninhado · bruto	0,4382	0,0525	0,5704	0,0571
36	Fusão tardia (pronunciada) · frases não vistas · k-fold aninhado · bruto	0,4394	0,0309	0,5736	0,0368
37	EEG (fala pronunciada) · frases não vistas · k-fold aninhado · bruto	0,4399	0,0240	0,5669	0,0222
38	Fusão precoce (imaginada) · frases não vistas · k-fold aninhado · bruto	0,4419	0,0589	0,5695	0,0700
39	Fusão tardia (imaginada) · frases vistas · k-fold aninhado · bruto	0,4435	0,0421	0,5728	0,0496
40	EEG (fala pronunciada) · frases não vistas · k-fold plano · bruto	0,4525	0,0375	0,5505	0,0358
41	Fusão precoce (imaginada) · frases vistas · k-fold plano · bruto	0,4539	0,0611	0,5514	0,0680
42	Fusão precoce (imaginada) · frases não vistas · k-fold plano · bruto	0,4587	0,0630	0,5506	0,0765
43	Fusão tardia (pronunciada) · frases não vistas · k-fold plano · bruto	0,4645	0,0511	0,5468	0,0573
44	Fusão tardia (pronunciada) · frases vistas · k-fold aninhado · bruto	0,4657	0,0272	0,5441	0,0373
45	Fusão precoce (pronunciada) · frases não vistas · k-fold aninhado · bruto	0,4672	0,0222	0,5425	0,0243
46	EEG (fala pronunciada) · frases vistas · k-fold aninhado · bruto	0,4700	0,0072	0,5359	0,0103
47	EEG (fala imaginada) · frases não vistas · k-fold plano · bruto	0,4737	0,0269	0,5330	0,0332
48	EEG (fala pronunciada) · frases vistas · k-fold plano · bruto	0,4738	0,0035	0,5299	0,0074
49	Fusão tardia (imaginada) · frases não vistas · k-fold plano · bruto	0,4743	0,0156	0,5281	0,0162
50	Fusão tardia (imaginada) · frases não vistas · k-fold aninhado · bruto	0,4745	0,0508	0,5474	0,0628
51	Fusão tardia (pronunciada) · frases vistas · k-fold plano · bruto	0,4750	0,0270	0,5320	0,0369
52	EEG (fala imaginada) · frases vistas · k-fold plano · bruto	0,4753	0,0179	0,5297	0,0217
53	Fusão precoce (pronunciada) · frases não vistas · k-fold plano · bruto	0,4774	0,0148	0,5344	0,0217
54	Fusão tardia (imaginada) · frases vistas · k-fold plano · bruto	0,4777	0,0155	0,5318	0,0178
55	Fusão precoce (pronunciada) · frases vistas · k-fold aninhado · bruto	0,4804	0,0198	0,5242	0,0236
56	Fusão precoce (pronunciada) · frases vistas · k-fold plano · bruto	0,4817	0,0120	0,5236	0,0153

4.2.2 Controles: o que a rede de pulsos acrescenta

A Tabela 21 compara, para cada fonte e modo de texto, a DSNN com seus dois controles: a rede gêmea não pulsante (ANN), que difere dela apenas no neurônio, e o cosseno direto sobre as características, sem rede alguma.

A rede de pulsos não se distingue da rede gêmea. A DSNN tem EER menor que a ANN em 10 das 14 combinações, com diferença média de $-0{,}0066$ (de $-0{,}0213$ a $0{,}0133$), e nenhuma das 14 comparações é significativa ($p \geq 0{,}264$ mesmo sem correção). Trocar o neurônio de pulso por uma ReLU não muda o desempenho de autenticação de forma detectável.

A rede acrescenta pouco ao extrator. O cosseno direto tem EER médio de 0,2922, contra 0,2573 da DSNN e 0,2639 da ANN. A DSNN é melhor em 12 das 14 combinações, mas também aqui nenhuma das 14 comparações é significativa ($p_{\text{Holm}} \geq 0{,}246$).

A maior parte do desempenho medido na Fase 01 já está nas características extraídas e padronizadas; o classificador treinado contribui com uma melhora de alguns pontos percentuais que os dados não permitem confirmar.

Tabela 21 – EER da DSNN e dos dois controles, por fonte e modo de texto (validação plana, características padronizadas)

Fonte	Frases	DSNN	σ	ANN gêmea	σ	Cosseno
Voz	frases vistas	0,3180	0,0569	0,3047	0,0628	0,3813
Voz	frases não vistas	0,3356	0,0173	0,3297	0,0100	0,3615
EEG (fala pronunciada)	frases vistas	0,2665	0,0122	0,2706	0,0056	0,2831
EEG (fala pronunciada)	frases não vistas	0,2451	0,0297	0,2545	0,0441	0,2804
EEG (fala imaginada)	frases vistas	0,2476	0,0466	0,2577	0,0300	0,2746
EEG (fala imaginada)	frases não vistas	0,2515	0,0344	0,2601	0,0334	0,2780
Fusão precoce (pronunciada)	frases vistas	0,2367	0,0409	0,2568	0,0419	0,3047
Fusão precoce (pronunciada)	frases não vistas	0,2529	0,0434	0,2536	0,0315	0,2875
Fusão precoce (imaginada)	frases vistas	0,2353	0,0280	0,2566	0,0311	0,3066
Fusão precoce (imaginada)	frases não vistas	0,2505	0,0169	0,2630	0,0190	0,2792
Fusão tardia (pronunciada)	frases vistas	0,2220	0,0544	0,2321	0,0500	0,2825
Fusão tardia (pronunciada)	frases não vistas	0,2645	0,0385	0,2591	0,0439	0,2569
Fusão tardia (imaginada)	frases vistas	0,2205	0,0562	0,2414	0,0687	0,2733
Fusão tardia (imaginada)	frases não vistas	0,2558	0,0185	0,2545	0,0150	0,2417

4.2.3 Energia de inferência

A Tabela 22 traz a energia estimada por amostra de teste para a DSNN e para a rede gêmea, medida na passagem de teste (subseção 3.3.1.2), e a razão entre as duas sob a estimativa primária e sob as cinco variações de hipótese.

A rede de pulsos gasta mais energia que a gêmea, em todas as hipóteses. Na estimativa primária, a DSNN gasta de 4,37 a 6,18 vezes a energia da ANN (na voz, 4589 nJ contra 809 nJ por amostra). A razão vai de 1,24 a 13,47 conforme a hipótese, e em nenhuma das combinações de fonte e hipótese a DSNN é a mais econômica. Contando apenas a aritmética, as duas redes quase empatam (de 1,24 a 1,35 vezes); a diferença vem dos acessos à memória, que o modelo cobra a cada evento de disparo.

A razão desse resultado é aritmética, e não um defeito da medição. A rede gêmea faz uma única passagem; a DSNN repete a sua por $T = 16$ passos de tempo, e só economiza onde os neurônios ficam em silêncio. Com cerca de 1411 disparos por amostra em uma rede de duas camadas de 128 neurônios, a atividade não é esparsa o bastante para compensar os 16 passos. Como o EER das duas redes não se distingue (seção anterior), a escolha da rede de pulsos **não se justifica por energia** nesta arquitetura e neste modelo de custo.

O resultado vale para uma estimativa analítica em tecnologia de 45 nm, e não para um *hardware* neuromórfico específico, que não foi avaliado.

Tabela 22 – Energia de inferência estimada por amostra (apenas o classificador; frases vistas, validação plana, características padronizadas). As seis últimas colunas são a razão DSNN/ANN sob cada hipótese: primária; primeira camada recalculada a cada passo; toda a memória em SRAM de 8 KB, 32 KB e 1 MB; apenas aritmética

Fonte	Disparos	DSNN (nJ)	ANN (nJ)	Prim.	Exec.	8 KB	32 KB	1 MB	Aritm.
Voz	1410,8	4588,61	809,15	5,67	11,62	7,48	8,61	9,85	1,28
EEG (fala pronunciada)	1467,4	4999,87	809,15	6,18	12,13	8,13	9,37	10,73	1,35
EEG (fala imaginada)	1457,7	4894,26	809,15	6,05	12,00	7,97	9,17	10,50	1,34
Fusão precoce (pronunciada)	1465,1	4977,19	809,15	6,15	12,10	8,10	9,32	10,68	1,35
Fusão precoce (imaginada)	1422,0	4709,70	809,15	5,82	11,77	7,67	8,83	10,11	1,30
Fusão tardia (pronunciada)	1448,5	5445,07	1224,39	4,45	13,47	6,15	7,05	8,04	1,26
Fusão tardia (imaginada)	1431,2	5348,54	1224,39	4,37	13,39	6,04	6,92	7,89	1,24

4.2.4 Disfonia simulada

A Tabela 23 mostra o EER de cada fonte que contém voz conforme a voz de teste é substituída pela sua versão sussurrada (subseção 3.3.1.2.5), do nível 0 (voz limpa) ao nível 1 (sussurro puro), nos dois cenários: só as sondas degradadas, ou cadastro e sondas.

A voz piora; as fusões quase não mudam. Do nível 0 ao nível 1, o EER da voz sobe 0,0409 quando só as sondas são degradadas e 0,0273 quando o cadastro também é. Nas fusões, a subida não passa de 0,0350. Esse é o comportamento que motivou o trabalho: quando a voz se degrada, a fonte que também tem EEG se mantém.

Três ressalvas limitam essa leitura. Primeiro, nenhuma das 10 comparações entre a voz limpa e o sussurro puro é significativa ($p_{\text{Holm}} \geq 0{,}265$): nem a piora da voz está estabelecida. Segundo, a voz parte de um EER já alto (0,3180), de modo que há pouco a perder; e as fusões se mantêm porque seu desempenho já vinha quase todo do EEG (seção anterior), não porque as duas fontes se compensem. Terceiro, o sussurro sintético remove a periodicidade e preserva os formantes; ele modela uma voz soprosa ou afônica, e não a disfonia em geral. O experimento mostra que o sistema não depende da periodicidade da voz; não mostra como ele se comporta com locutores disfônicos reais.

Tabela 23 – EER sob disfonia simulada, por nível de degradação da voz de teste (frases vistas, validação plana, características padronizadas)

Fonte	Voz degradada	0	0,25	0,5	0,75	1
Voz	só sondas	0,3180	0,3252	0,3442	0,3511	0,3589

Fonte	Voz degradada	0	0,25	0,5	0,75	1
Voz	cadastro e sondas	0,3180	0,3379	0,3312	0,3451	0,3453
Fusão precoce (pronunciada)	só sondas	0,2367	0,2353	0,2405	0,2428	0,2467
Fusão precoce (pronunciada)	cadastro e sondas	0,2367	0,2420	0,2424	0,2500	0,2433
Fusão precoce (imaginada)	só sondas	0,2353	0,2366	0,2411	0,2458	0,2445
Fusão precoce (imaginada)	cadastro e sondas	0,2353	0,2601	0,2462	0,2627	0,2580
Fusão tardia (pronunciada)	só sondas	0,2220	0,2252	0,2269	0,2307	0,2330
Fusão tardia (pronunciada)	cadastro e sondas	0,2220	0,2292	0,2313	0,2314	0,2337
Fusão tardia (imaginada)	só sondas	0,2205	0,2239	0,2239	0,2276	0,2317
Fusão tardia (imaginada)	cadastro e sondas	0,2205	0,2378	0,2402	0,2483	0,2555

4.2.5 Extratores comparados pelo classificador

A Fase 00 compara extratores sem treinar classificador algum. A Tabela 24 faz a comparação que faltava: o melhor extrator de cada família, segundo a Fase 00, alimenta a mesma DSNN, para cada sinal e cada modo de texto.

Pelo classificador, as três famílias não se distinguem. Nenhuma das 12 comparações entre o extrator manual e um automatizado é significativa ($p_{\text{Holm}} \geq 0{,}229$; o menor p sem correção é 0,115), e a direção da diferença muda de sinal para sinal:

- na **voz**, os dois automatizados ficam a menos de três pontos percentuais do manual, um de cada lado (com frases vistas, 0,3243 para o manual, 0,3053 para o *autoencoder* e 0,3523 para a PCA);
- no **EEG de fala pronunciada**, o manual fica à frente (0,2688 contra 0,3521 e 0,3757);
- no **EEG de fala imaginada**, os automatizados ficam à frente (0,2504 contra 0,2302 e 0,1934). O EER da PCA nessa condição é o menor de todo o experimento, abaixo do da melhor configuração da grade principal (0,2205).

O critério paraconsistente não antecipou esse resultado. Na Fase 00, o extrator manual ficou à frente do melhor automatizado por uma margem cerca de dez vezes maior que a variação entre subconjuntos de locutores, nos três sinais. Pelo EER, essa vantagem não aparece na voz, aparece no EEG de fala pronunciada e se inverte no de fala imaginada. A separabilidade medida por $D_{\text{penalizado}}$ e o desempenho de verificação medido pelo EER são, nestes dados, grandezas diferentes: a primeira olha a amplitude e a sobreposição de cada característica entre classes, uma a uma; a segunda, o que um classificador consegue combinar a partir de todas elas. Um extrator pode ter características que individualmente se sobrepõem muito e que, em conjunto, separam os locutores. A

consequência para o método é direta: o critério paraconsistente serviu para escolher entre extratores de uma mesma família (as Questões 1 e 2), mas não deve ser usado, sozinho, para comparar famílias diferentes.

Tabela 24 – EER do melhor extrator de cada família, pela mesma DSNN (validação plana, características padronizadas, 100 épocas). O extrator manual é o vencedor da Fase 00 (Haar + Linear (c1)) nos três sinais

Sinal	Frases	EER manual	σ	Autoencoder	EER	σ	PCA	EER	σ
Voz	frases vistas	0,3243	0,0620	ann-ae/latente 32	0,3053	0,0391	k = 8	0,3523	0,0220
Voz	frases não vistas	0,3411	0,0206	ann-ae/latente 32	0,3367	0,0325	k = 8	0,3630	0,0012
EEG (fala pronunciada)	frases vistas	0,2688	0,0130	ann-ae/latente 32	0,3521	0,0228	k = 8	0,3757	0,0164
EEG (fala pronunciada)	frases não vistas	0,2448	0,0322	ann-ae/latente 32	0,3100	0,0089	k = 8	0,2983	0,0028
EEG (fala imaginada)	frases vistas	0,2504	0,0454	ann-ae/latente 32	0,2302	0,0420	k = 8	0,1934	0,0425
EEG (fala imaginada)	frases não vistas	0,2474	0,0284	ann-ae/latente 32	0,2198	0,0154	k = 8	0,2094	0,0282

4.3 Replicação na BIOMEX-DB

Esta seção responde a uma única pergunta: o que a Fase 01 concluiu na base de Coretto, Gareis e Rufiner (2017) vale numa segunda base? O desenho está na seção 3.2: os vencedores da Fase 00 foram congelados, e as 48 configurações foram executadas uma vez na BIOMEX-DB, com 45 locutores, três repetições cada (144 execuções). Os testes de significância são os mesmos da Fase 01 (mesma referência, mesmo pareamento, mesma correção de Holm dentro de cada família), restritos às fontes que a BIOMEX-DB tem, e foram declarados antes de qualquer número da replicação ser lido. A Tabela 25 põe cada célula ao lado da mesma célula da outra base.

Os números se repetem. O EER médio da DSNN nas 8 células é 0,2580, contra 0,2677 nas mesmas células da outra base; célula a célula, a diferença vai de −0,0326 a 0,0276, e a BIOMEX-DB tem o EER menor em 6 das 8. A melhor célula é a mesma nas duas bases (Fusão tardia (pronunciada), frases vistas, EER = 0,2190), e a pior também (Voz, frases não vistas). Como na outra base, toda célula de EEG ou de fusão fica à frente das duas células de voz.

A fusão tardia passa a superar a voz. Na outra base, nenhuma fonte era significativamente melhor que a voz. Na BIOMEX-DB, a fusão tardia é, nos dois modos de texto: frases vistas, $\Delta = -0{,}0664$, $p_{\text{Holm}} = 0{,}007$; frases não vistas, $\Delta = -0{,}0844$, $p_{\text{Holm}} = 0{,}005$. O EEG sozinho não é ($p_{\text{Holm}} \geq 0{,}441$ com frases vistas e 0,207 com não vistas). A leitura que os dados permitem é a de poder estatístico, e não a de contradição: na outra base, a mesma comparação tinha $\Delta = -0{,}0960$ com frases vistas, com 15 locutores; com 45, uma diferença dessa ordem passa a ser detectável. A ressalva da seção 3.2 vale aqui com força: o EEG de fala pronunciada carrega atividade muscular, de modo que o

ganho da fusão é o de somar à voz um registro do ato de falar, e não necessariamente atividade cerebral.

A fusão não supera o EEG sozinho, como na outra base: nenhuma das 4 comparações é significativa ($p_{\text{Holm}} \geq 0{,}190$).

A rede de pulsos continua indistinguível da gêmea, e a rede passa a superar o cosseno. Nenhuma das 8 comparações entre a DSNN e a ANN é significativa, nem sem correção ($p \geq 0{,}677$); o EER médio das duas é 0,2580 e 0,2576. Já o cosseno direto (EER médio 0,3073) fica atrás da DSNN em todas as 8 células, e a diferença é significativa em 4 delas. Na outra base, nenhuma era: o que lá era "uma melhora de alguns pontos percentuais que os dados não permitem confirmar" se confirma com três vezes mais locutores. A energia repete a outra base: a DSNN gasta de 6,25 a 8,37 vezes a energia da gêmea, e em nenhuma célula é a mais econômica.

A disfonia simulada e o modo de texto não têm efeito significativo, como na outra base. A Tabela 26 mostra a mesma forma: do nível 0 ao 1, o EER da voz sobe 0,0223 (só sondas) e 0,0237 (cadastro e sondas), mais que o de qualquer fusão, mas nenhuma das 6 comparações é significativa ($p_{\text{Holm}} \geq 0{,}068$). Frases não vistas dão EER maior em todas as fontes, sem significância em nenhuma ($p_{\text{Holm}} \geq 0{,}125$).

Tabela 25 – EER na BIOMEX-DB, ao lado da mesma célula da DSNN na outra base (vencedores da Fase 00 congelados; validação plana, características padronizadas). A última coluna é a razão entre a energia de inferência da DSNN e a da rede gêmea

Fonte	Frases	Coretto	DSNN	σ	ANN gêmea	σ	Cosseno	Energia
Voz	frases vistas	0,3180	0,2854	0,0123	0,2826	0,0090	0,3135	8,20
Voz	frases não vistas	0,3356	0,3167	0,0108	0,3116	0,0034	0,3433	8,37
EEG (fala pronunciada)	frases vistas	0,2665	0,2521	0,0214	0,2563	0,0238	0,3355	7,73
EEG (fala pronunciada)	frases não vistas	0,2451	0,2727	0,0156	0,2730	0,0103	0,3371	7,72
Fusão precoce (pronunciada)	frases vistas	0,2367	0,2325	0,0150	0,2282	0,0081	0,2847	8,08
Fusão precoce (pronunciada)	frases não vistas	0,2529	0,2532	0,0184	0,2527	0,0112	0,3065	8,10
Fusão tardia (pronunciada)	frases vistas	0,2220	0,2190	0,0007	0,2211	0,0028	0,2598	6,25
Fusão tardia (pronunciada)	frases não vistas	0,2645	0,2323	0,0137	0,2353	0,0125	0,2778	6,29

Tabela 26 – EER na BIOMEX-DB sob disfonia simulada, por nível de degradação da voz de teste (frases vistas, validação plana, características padronizadas); as duas últimas colunas são a subida do EER do nível 0 ao 1, nesta base ("Subida") e na outra ("Coretto", Tabela 23)

Fonte	Voz degradada	0	0,25	0,5	0,75	1	Subida	Coretto
Voz	só sondas	0,2854	0,2899	0,2986	0,3049	0,3077	0,0223	0,0409
Voz	cadastro e sondas	0,2854	0,2946	0,2940	0,3007	0,3091	0,0237	0,0273
Fusão precoce (pronunciada)	só sondas	0,2325	0,2331	0,2326	0,2346	0,2340	0,0016	0,0101
Fusão precoce (pronunciada)	cadastro e sondas	0,2325	0,2349	0,2324	0,2359	0,2320	-0,0005	0,0066
Fusão tardia (pronunciada)	só sondas	0,2190	0,2231	0,2273	0,2307	0,2324	0,0135	0,0110
Fusão tardia (pronunciada)	cadastro e sondas	0,2190	0,2194	0,2208	0,2268	0,2267	0,0077	0,0117

Em resumo, das conclusões da Fase 01 que a BIOMEX-DB permite testar, cinco se repetem (fusão não supera o EEG; rede de pulsos indistinguível da gêmea e mais cara que ela; disfonia e modo de texto sem efeito significativo) e duas mudam, ambas na direção de um efeito que a outra base não tinha poder para detectar: a fusão tardia supera a voz, e a rede treinada supera o cosseno direto. Nenhuma conclusão se inverte. A replicação não testa o que depende de fala imaginada, nem a comparação de extratores, que não foi executada nela.

4.4 Retomada das questões de pesquisa

Esta seção confronta as quatro questões formuladas na Capítulo 1 com o que foi efetivamente medido. As duas primeiras são respondidas pela Fase 00; a terceira, pelas duas fases; a quarta, pela Fase 01. Ao final, discute-se uma ressalva que atravessa todos os resultados de EEG.

Questão 1 — O agrupamento espectral influencia a representação?

Sim, mas pouco, e a pergunta só se aplica à voz. No EEG as escalas Mel e Bark degeneram na linear (subseção 2.1.3.9). Restringindo a comparação às representações de Categoria 1 da voz, a melhor configuração de cada escala tem $\bar{d}_{\text{pen}}$ de 1,4836 (linear), 1,4973 (Mel) e 1,5100 (Bark). A ordem favorece o particionamento linear, mas a amplitude entre as três escalas (0,0264) é da mesma ordem do σ_{loc} do vencedor (0,0241) e muito

menor que a diferença entre as categorias (Questão 2) ou entre as famílias de extrator (Questão 3). A escala importa menos do que se poderia supor: nenhuma das escalas cocleares compensou, na voz, o custo de agrupar bandas de forma não uniforme, e a preferência pela linear não é firme o bastante para ser afirmada como regra.

Questão 2 — A transformação cepstral melhora a representação?

Não para a voz, onde ela piora a representação sem exceção; no EEG, o efeito é ambíguo. Na voz, as 69 configurações de Categoria 1 têm $\bar{d}_{\text{pen}}$ médio de 1,5247 (melhor: 1,4836), contra 1,6285 (melhor: 1,6069) nas 69 de Categoria 2. A separação é total, e não apenas de médias: a pior configuração não cepstral (1,5638) ainda supera a melhor cepstral, de modo que as duas categorias não se sobrepõem em nenhum ponto do ranking. Como a única diferença entre cada par é a etapa de logaritmo mais DCT, o resultado é atribuível a ela.

No EEG o quadro é outro, nas duas condições. A melhor configuração continua sendo de Categoria 1 (1,5788 contra 1,6264 na fala pronunciada; 1,5128 contra 1,5369 na imaginada), mas na *média* das 23 configurações de cada categoria as duas praticamente empatam, com leve vantagem cepstral (1,7898 contra 1,7946, e 1,7773 contra 1,7898). No EEG, a etapa cepstral não custa desempenho de forma sistemática; ela apenas não produz o melhor extrator. A conclusão forte da Questão 2 vale para a voz, e não para os dois sinais.

Uma explicação plausível é que a DCT concentra energia nos primeiros coeficientes e descarta estrutura de banda fina que o critério paraconsistente — sensível à amplitude intraclasse — aproveita. Isso não contradiz a utilidade dos coeficientes cepstrais em reconhecimento de fala: ali o objetivo é representar o *conteúdo* falado de forma robusta ao locutor, ao passo que aqui se busca o oposto — preservar o que distingue locutores. Uma etapa que normaliza diferenças de trato vocal é benéfica no primeiro caso e prejudicial no segundo. A explicação é uma hipótese; não foi testada.

Questão 3 — Autoencoders superam as técnicas manuais?

Não superam; e, medidos pelo classificador, também não ficam atrás. A resposta depende de como se mede, e as duas medidas discordam.

Pelo critério paraconsistente (Fase 00), a extração manual vence com folga nos três sinais: 1,4836 contra 1,7479 do melhor *autoencoder* na voz, 1,5788 contra 1,7354 no EEG de fala pronunciada, e 1,5128 contra 1,6697 no de fala imaginada. A PCA, que não tem treino, fica ligeiramente à frente do melhor *autoencoder* nos três.

Pelo desempenho de autenticação (Fase 01, Tabela 24), as três famílias não se distinguem: o manual tem EER menor que o *autoencoder* em 2 das 6 combinações de

sinal e modo de texto, e menor que a PCA em 4; nenhuma diferença é significativa. A afirmação que os dados sustentam é que, nesta base e com este classificador, **a extração automatizada atinge o mesmo nível de autenticação que a manual**, com um vetor de 8 a 32 características.

Duas observações completam a resposta. Primeiro, a PCA acompanha os *autoencoders* nas duas medidas: tem EER menor que o *autoencoder* em 3 das 6 combinações. O treino de um modelo não linear não se justificou diante de uma projeção linear do mesmo espectro. Segundo, o *autoencoder* escolhido pela Fase 00 foi, nos três sinais, o convencional (ANN-AE (base)), e não o de pulsos: o SNN-AE não chegou a ser levado ao classificador, e nada se pode afirmar sobre o seu desempenho de autenticação.

A comparação entre as duas medidas só existe porque a entrada dos extratores automatizados foi corrigida (subseção 3.3.1). Com a entrada anterior, os automatizados ficavam no acaso nas duas medidas, e a conclusão — errada — era que a extração manual os superava em ambas.

Questão 4 — O desempenho é afetado pela dependência de texto?

Pouco, na direção esperada, e sem significância. Os dois modos treinam com as mesmas cinco frases e diferem apenas em o teste usar essas frases ou outras cinco (subseção 3.3.1.2). Com validação plana e características padronizadas, o EER médio das 7 fontes é de 0,2495 com frases vistas e 0,2651 com frases não vistas. As frases vistas dão EER menor em 6 das 7 fontes; a diferença vai de $-0{,}0214$ a 0,0425, e nenhuma das 7 comparações é significativa ($p \geq 0{,}184$). Como os conjuntos de teste dos dois modos são diferentes, essas comparações não são pareadas e usam o teste de Mann–Whitney, que trata as 15 dobras como independentes e é, por isso, otimista: se nem ele encontra diferença, a ausência de efeito detectável é robusta.

A leitura é que o sistema reconhece sobretudo o locutor, e não o enunciado: testar com frases que a rede nunca viu custa, em média, pouco mais de um ponto percentual de EER. A ressalva é o alcance da afirmação: os enunciados são vogais e palavras isoladas de um vocabulário de onze itens, e "frases não vistas" significa, aqui, outros itens desse mesmo vocabulário, ditos pelos mesmos locutores na mesma gravação.

Uma ressalva sobre os resultados de EEG

O EEG supera a voz em todas as comparações deste capítulo, e a condição do EEG — fala pronunciada ou imaginada — quase não importa. Antes de ler isso como "o EEG é melhor biometria que a voz", é preciso considerar uma explicação mais simples, que este experimento não consegue descartar: o classificador pode estar reconhecendo **a gravação**, e não a pessoa.

Em um registro de EEG, a impedância de cada eletrodo, a posição da touca e o ruído do ambiente são fixos durante uma sessão e mudam entre sessões. A base não distingue sessões de gravação por locutor; se todas as tentativas de um locutor vêm de uma única sessão, essas características identificam a sessão tão bem quanto identificariam a pessoa, e nenhuma divisão dos dados em treino e teste as separa. Dois resultados deste trabalho são compatíveis com essa leitura: um classificador linear identifica o locutor a partir do espectro bruto do EEG com acurácia de 0,62 (Tabela 10), sem nenhum aprendizado de representação; e o EER é praticamente o mesmo quer o locutor fale, quer imagine. Na voz, o problema equivalente é menor, porque a gravação de áudio de um locutor depende menos da montagem.

Distinguir as duas explicações exige gravações do mesmo locutor em dias diferentes, que a base não tem. Os resultados de EEG e de fusão deste capítulo devem ser lidos, portanto, como um **limite superior** do que se obteria entre sessões.

5 Conclusões e Trabalhos Futuros

5.1 Síntese dos resultados

Esta tese investigou a autenticação biométrica combinando voz e EEG, comparando extração manual de características (DTWPT com agrupamento energético) e extração automatizada (*autoencoders* e PCA), com seleção conduzida pela engenharia paraconsistente de características e classificação por uma rede neural de pulsos residual (DSNN). O experimento foi organizado em duas fases: 275 configurações de *ranking* na Fase 00 e 142 de autenticação na Fase 01, cada uma repetida três vezes.

A extração manual venceu a seleção paraconsistente nos três sinais, com a mesma configuração — *wavelet* Haar, energias de banda em escala linear, sem etapa cepstral — na voz, no EEG de fala pronunciada e no de fala imaginada. No EEG a escolha é firme: o vencedor é o mesmo em todos os subconjuntos de locutores avaliados. Na voz ela é frágil quanto à *wavelet* (o vencedor se mantém em 10 das 15 dobras) e firme quanto à categoria: todo extrator que vence alguma dobra dispensa a etapa cepstral.

Os extratores automatizados perdem pelo critério paraconsistente e empatam pelo classificador. Na Fase 00, nenhum *autoencoder* e nenhuma PCA se aproximou do extrator manual. Levados ao mesmo classificador, o melhor de cada família atinge EER que não se distingue do manual em nenhum dos três sinais, e no EEG de fala imaginada a PCA com oito componentes tem o menor EER de todo o experimento (0,1934). Duas consequências: a PCA, sem treino, acompanha os *autoencoders* nas duas medidas; e o critério paraconsistente, útil para ordenar extratores de uma mesma família, não antecipou o desempenho relativo entre famílias.

A autenticação opera acima do acaso, e longe de um uso prático. A melhor configuração da grade principal da Fase 01 — Fusão tardia (imaginada), frases vistas, k-fold plano, padronizado — atinge EER = 0,2205 e AUC = 0,8547. O EEG e as fusões ficam à frente da voz (0,3180 na melhor configuração de voz), com tamanho de efeito grande, mas nenhuma dessas diferenças é estatisticamente significativa com 15 locutores. A fusão de voz e EEG não se distingue do EEG sozinho, e o EEG de fala imaginada não se distingue do de fala pronunciada.

Os resultados se repetem numa segunda base. Executadas uma vez na BIOMEX-DB, com os vencedores congelados e 45 locutores (seção 4.3), as mesmas configurações dão EER médio de 0,2580, contra 0,2677 nas mesmas células da outra base, com a mesma melhor e a mesma pior célula. Das conclusões que ela permite testar, cinco se repetem e duas mudam, ambas na direção de um efeito que 15 locutores não tinham poder

para detectar: a fusão tardia passa a superar a voz com significância, nos dois modos de texto, e a rede treinada passa a superar o cosseno direto. Nenhuma conclusão se inverte.

A rede de pulsos não se justificou, nem por desempenho nem por energia. Sua gêmea não pulsante, com o mesmo grafo e os mesmos pesos iniciais, atinge EER que não se distingue do dela, e gasta de 4,37 a 6,18 vezes *menos* energia por amostra na estimativa primária; em nenhuma das hipóteses de custo avaliadas a rede de pulsos é a mais econômica. Um classificador sem rede alguma — o cosseno direto sobre as características — fica a poucos pontos percentuais das duas redes, diferença que não é significativa nesta base e passa a ser, em 4 das 8 células, na BIOMEX-DB; a rede de pulsos e a gêmea continuam indistinguíveis lá. A maior parte do desempenho medido vem do extrator e da padronização das características, sem a qual o EEG e as fusões ficam perto do acaso.

Sob disfonia simulada, a voz piora e as fusões se mantêm, que é o comportamento que motivou o trabalho. A evidência é fraca: a piora da voz não é significativa, as fusões se mantêm porque já dependiam pouco da voz, e o sussurro sintético modela apenas a perda de periodicidade.

Ver ou não a frase no treino muda pouco: o EER médio passa de 0,2495 (frases vistas) a 0,2651 (frases não vistas), sem diferença significativa em nenhuma fonte.

As hipóteses do Capítulo 1. A hipótese principal — o EEG mantém a autenticação quando a voz de teste se degrada — é apoiada apenas na direção dos resultados: sob disfonia simulada, a voz piora e as fusões se mantêm, mas nenhuma das diferenças é significativa. A primeira hipótese secundária não se confirmou: o critério paraconsistente ordena extratores de uma mesma família, mas não antecipou o desempenho entre famílias. A segunda foi refutada nesta tarefa: a rede de pulsos não se distingue da gêmea não pulsante no erro e gasta mais energia.

5.2 Contribuições

Além dos resultados experimentais, as contribuições deste trabalho são de método, e várias nasceram de defeitos detectados durante a própria execução:

1. **A métrica $D_{\text{penalizado}}$** (subseção 2.1.5.1). O grau de verdade $D_{1,0}$, usado isoladamente, premia extratores degenerados: uma rede que emite o mesmo vetor para toda entrada atinge $\alpha = \beta = 1$ e pontua melhor que extratores genuinamente separáveis. A correção proposta soma um termo $\lambda|G_2|$ proporcional ao grau de contradição, com $\lambda = 2 - \sqrt{2}$ escolhido de modo que os três vértices degenerados sejam penalizados igualmente. Nos resultados desta tese, é a penalização que decide o vencedor da voz (seção 4.1).

2. **A medida da incerteza da seleção paraconsistente.** O critério é determinístico para extratores determinísticos, e o desvio entre repetições, nulo, nada informa. Pontuar cada extrator em subconjuntos de locutores — os que deixam um locutor de fora e os conjuntos de treino de cada dobra da etapa seguinte — mostra o quanto a escolha depende dos locutores observados e expõe o viés de selecionar o extrator com os mesmos locutores usados depois no teste.

3. **Um protocolo com controles que isolam o que cada componente acrescenta**: a rede gêmea não pulsante, que difere da DSNN apenas no neurônio; o cosseno direto, que remove a rede; os dois modos de texto com o mesmo conjunto de treino; e a energia de inferência medida na passagem de teste em vez de presumida. Foram esses controles que mostraram que a rede de pulsos não contribui de forma detectável nesta tarefa — um resultado que o EER da DSNN, sozinho, não revelaria.

4. **O registro de três defeitos silenciosos e de como foram detectados** (os oito defeitos desse tipo encontrados durante o desenvolvimento estão no Apêndice A). O EEG lido da tentativa anterior (seção 3.1), a entrada sem informação de locutor dos extratores automatizados (subseção 3.3.1) e a previsão do piso de ruído das codificações temporais, "confirmada" por dados que não mediam outra coisa (subseção 3.3.1), têm em comum não produzirem erro algum: todo o *pipeline* roda, converge e entrega números plausíveis. Os dois primeiros foram confirmados por verificações externas ao *pipeline* — a contagem de tentativas por modalidade na base e um classificador linear sobre a entrada do extrator —, e o terceiro só apareceu quando a entrada foi corrigida. Desde então, a entrada dos extratores automatizados é comparada com bibliotecas de referência em testes automatizados, e as afirmações do Capítulo 4 são conferidas contra os resultados a cada geração do texto.

5.3 Limitações

A limitação dominante é o **tamanho da base**: 15 locutores e 1974 tentativas com voz. Sob protocolo de verificação, com dobras disjuntas por locutor, cada dobra testa três locutores. A consequência mais direta está nos testes de significância: diferenças de EER de até dez pontos percentuais, com tamanho de efeito grande, não atingem significância. Quase todas as conclusões comparativas desta tese são, por isso, da forma "os dados não permitem distinguir", e não "não há diferença". A replicação na BIOMEX-DB, com 45 locutores, mostra o que isso significa na prática: duas dessas comparações passaram a ser significativas, e nenhuma inverteu de sentido.

Outras limitações devem acompanhar qualquer leitura dos resultados:

- **Sessão única de EEG.** A base não tem gravações do mesmo locutor em dias dife-

rentes. Os resultados de EEG e de fusão podem refletir características da gravação — impedância dos eletrodos, posição da touca, ruído do ambiente — e não apenas do locutor, e devem ser lidos como limite superior do desempenho entre sessões (seção 4.4);

- **O EEG de fala imaginada não é simultâneo à voz.** Ele vem de outra tentativa do mesmo locutor e do mesmo enunciado. A fusão com fala imaginada combina, portanto, dois momentos distintos;
- **A disfonia é simulada**, por um modelo de voz sussurrada que remove a periodicidade e preserva os formantes. Nenhum locutor disfônico foi avaliado;
- **O extrator é escolhido com todos os locutores**, inclusive os de teste da Fase 01. O viés é nulo no EEG, onde a escolha é a mesma em todas as dobras, e existe na voz;
- **A energia é estimada**, por um modelo analítico em tecnologia de 45 nm, e cobre apenas o classificador. Nenhum *hardware* neuromórfico foi avaliado, e o custo do extrator de características — que, para a DTWPT de um sinal de 176400 amostras, provavelmente domina o do classificador — não foi medido;
- **As características manuais do EEG têm resolução espectral grossa.** Com a DTWPT de nível 4 a 1024 Hz, cada sub-banda tem 32 Hz. Como a base já distribui o EEG filtrado entre 2 e 40 Hz, 98,1% da potência cai na primeira sub-banda, que contém juntos os ritmos δ, θ, α e β, e as sub-bandas 2 a 15 ficam praticamente sem sinal (Tabela 9). O EEG também não passa por referência pela média comum nem por análise de componentes independentes, e as tentativas com piscada não são excluídas (seção 2.2);
- **O vocabulário é pequeno**: onze enunciados, entre vogais e palavras isoladas. "Frases não vistas" significa outros itens desse mesmo vocabulário;
- **Os hiperparâmetros não foram ajustados.** A arquitetura e o treino do classificador são os mesmos em todas as configurações, sem regularização. Os resultados descrevem essa configuração, e não o melhor que cada família de modelo poderia atingir.

5.4 Trabalhos futuros

O encaminhamento mais direto decorre das limitações acima:

1. **Avaliar entre sessões.** Uma base com gravações do mesmo locutor em dias diferentes é o único modo de separar o que identifica a pessoa do que identifica a gravação, e é a condição para qualquer afirmação sobre o EEG como biometria;

2. **Ampliar o número de locutores**, antes do número de amostras por locutor: é a contagem de identidades que limita tanto o que o classificador aprende quanto o poder dos testes estatísticos. A replicação confirmatória na BIOMEX-DB (MORENO-RODRIGUEZ *et al.*, 2021) (seção 3.2), com 45 locutores depois da conferência da base, é um primeiro passo nessa direção, restrito à fala pronunciada — a base não tem fala imaginada —, e as suas duas sessões, gravadas no mesmo dia, não substituem o item anterior;

3. **Avaliar locutores disfônicos reais**, ou, na falta deles, modelos de degradação que cubram rouquidão, aspereza e tremor, além da voz soprosa;

4. **Refinar a decomposição do EEG**: reamostrá-lo para 128 Hz antes da DTWPT, o que o filtro de 2 a 40 Hz da base permite sem perda, daria sub-bandas de 4 Hz que separam os ritmos δ, θ, α e β; e medir o efeito da exclusão das tentativas com piscada sobre o EER;

5. **Testar a hipótese sobre as codificações temporais**, variando o número de passos T e o limiar de disparo do SNN-AE com o restante fixo, para decidir se a desvantagem da codificação direta vem da falta de integração temporal (subseção 3.3.1);

6. **Medir a energia do sistema completo**, incluindo o extrator, e em *hardware* neuromórfico, onde o custo de um disparo difere do estimado aqui; e avaliar redes de pulso com atividade mais esparsa, condição em que a comparação com a rede convencional pode se inverter;

7. **Entender a discordância entre o critério paraconsistente e o EER**, medindo, sobre muitos extratores, a correlação entre $D_{\text{penalizado}}$ e o desempenho de verificação, e avaliando variantes do critério que considerem as características em conjunto, e não uma a uma;

8. **Levar o SNN-AE ao classificador** e ajustar orçamento de treino e capacidade dos *autoencoders*, para decidir se algum modelo não linear supera a PCA sobre a mesma entrada.

Referências

ABDULGHANI, M. M.; WALTERS, W. L.; ABED, K. H. Imagined speech classification using eeg and deep learning. *Bioengineering*, v. 10, n. 6, 2023. ISSN 2306-5354. Disponível em: <https://www.mdpi.com/2306-5354/10/6/649>.

ABDULGHANI, M. M.; WALTERS, W. L.; ABED, K. H. Imagined speech classification using eeg and deep learning. *Bioengineering (Basel)*, MDPI AG, Switzerland, v. 10, n. 6, p. 649–, 2023. ISSN 2306-5354.

ADDISON, P. S.; WALKER, J.; GUIDO, R. C. Time–frequency analysis of biosignals. *IEEE Engineering in Medicine and Biology Magazine*, v. 28, n. 5, p. 14–29, Sep 2009.

AGARWAL, P.; KUMAR, S. Electroencephalography based imagined alphabets classification using spatial and time-domain features. *International journal of imaging systems and technology*, John Wiley and Sons, Inc, Hoboken, USA, v. 32, n. 1, p. 111–122, 2022. ISSN 0899-9457.

AL-NAFJAN, A.; ALAHAIDEB, L.; ALDAYEL, M.; ALJUMAH, H. EEG-based authentication across various event-related potentials (ERPs). *Sensors*, v. 25, n. 16, p. 4962, 2025.

ALBAIATI, A. E.; AKBAR, M. F.; HSSAYENI, M. D.; KHALIL, A.; WAHAB, M. N. A.; WELI, S. S.; RAHEEM, E. A. Deep learning approaches for EEG-based biometrics: A systematic review. *IEEE Access*, v. 13, p. 171025–171047, 2025.

ALI, Y. M.; NOORSAL, E.; MOKHTAR, N. F.; SAAD, S. Z. M.; ABDULLAH, M. H.; CHIN, L. C. Speech-based gender recognition using linear prediction and mel-frequency cepstral coefficients. *Indonesian J Electric Eng Comput Sci*, v. 28, n. 2, p. 753–761, 2022.

ALZAHRANI, S.; BANJAR, H.; MIRZA, R. Systematic review of EEG-based imagined speech classification methods. *Sensors*, v. 24, n. 24, p. 8168, 2024.

ATAIDE, M. L. de; VETREKAR, N.; PATEL, K.; GAD, R.; RAMACHANDRA, R. Brain signal for secure EEG biometric authentication: A comprehensive survey. *Sensors*, v. 26, n. 13, p. 4045, 2026.

BENGIO, Y.; COURVILLE, A.; VINCENT, P. *Representation Learning: A Review and New Perspectives*. 2014.

BERANEK, L. L. *Acoustic Measurements*. [S.l.]: J. Wiley, 1949.

BIANCHI, G. *Electronic Filter Simulation & Design*. [S.l.]: McGraw-Hill Education, 2007. ISBN 9780071712620.

BIDGOLY, A. J.; BIDGOLY, H. J.; AREZOUMAND, Z. A survey on methods and challenges in eeg based authentication. *Computers and Security*, v. 93, p. 101788, 2020. ISSN 0167-4048. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0167404820300730>.

BOSI, M.; GOLDBERG, R. E. *Introduction to digital audio coding and standards*. [S.l.]: Springer Science & Business Media, 2002. v. 721.

BRIGHAM, K.; KUMAR, B. V. K. V. Subject identification from electroencephalogram (EEG) signals during imagined speech. In: *Fourth IEEE International Conference on Biometrics: Theory, Applications and Systems (BTAS)*. [S.l.: s.n.], 2010. p. 1–8.

BUTTERWORTH, S. On the theory of filters amplifiers. 1930.

CHEN, C.; SUN, J.; LV, D.; TIAN, C.; LI, S.; ZHANG, N.; JING, T. Interpretable spectral features for cross-session EEG biometric identification and verification. *Sensors*, v. 26, n. 15, p. 4811, 2026.

COMŞA, I.-M.; VERSARI, L.; FISCHBACHER, T.; ALAKUIJALA, J. Spiking autoencoders with temporal coding. *Frontiers in Neuroscience*, v. 15, p. 712667, 2021. Finite-penalty-at-T convention for a never-firing unit under time-to-first-spike loss.

CORETTO, G. A. P.; GAREIS, I. E.; RUFINER, H. L. Open access database of EEG signals recorded during imagined speech. In: ROMERO, E.; LEPORE, N.; BRIEVA, J.; BRIEVA, J.; AND, I. L. (Ed.). *12th International Symposium on Medical Information Processing and Analysis*. SPIE, 2017. v. 10160, p. 1016002. Disponível em: <https://doi.org/10.1117/12.2255697>.

CORETTO, G. A. P.; GAREIS, I. E.; RUFINER, H. L. *Pressel2016 — Imagined speech EEG (Spanish vowels and directional commands, re-hosted)*. 2026. Zenodo. Cópia apenas do *EEG*, enviada por terceiros em 11 abr. 2026 para o *framework* MOABB; arquivos renomeados de `S##_EEG.mat` para `sub-##_eeg.mat`.

COSTA, N. C. d.; ABE, J. M. Paraconsistência em informática e inteligência artificial. *Estudos Avançados*, scielo, v. 14, p. 161 – 174, 08 2000.

COSTA, N. da; BÉZIAU, J.; BUENO, O. *Elementos de teoria paraconsistente de conjuntos*. Centro de Lógica, Epistemologia e História da Ciência, UNICAMP, 1998. (Coleção CLE). Disponível em: <https://books.google.com.br/books?id=MGCKGwAACAAJ>.

DAMPFHOFFER, M.; MESQUIDA, T.; VALENTIAN, A.; ANGHEL, L. Are SNNs really more energy-efficient than ANNs? an in-depth hardware-aware study. *IEEE Transactions on Emerging Topics in Computational Intelligence*, v. 7, n. 3, p. 731–741, 2023.

DAS, B. B.; REDDY, C. V.; MATHA, U.; YANDAPALLI, C.; RAM, S. K. Multimodal biometric authentication systems: exploring EEG and signature. *Cognitive Neurodynamics*, v. 20, n. 1, p. 17, 2025.

DASALLA, C. S.; KAMBARA, H.; SATO, M.; KOIKE, Y. Single-trial classification of vowel speech imagery using common spatial patterns. *Neural networks : the official journal of the International Neural Network Society*, Elsevier, v. 22, n. 9, p. 1334–1339, 2009.

DAUBECHIES, I. *Ten Lectures on Wavelets*. [S.l.]: Society for Industrial and Applied Mathematics (SIAM, 3600 Market Street, Floor 6, Philadelphia, PA 19104), 1992. (CBMS-NSF Regional Conference Series in Applied Mathematics).

DAVIDSON, S.; FURBER, S. B. Comparison of artificial and spiking neural networks on digital hardware. *Frontiers in Neuroscience*, v. 15, p. 651141, 2021.

DEBIE, E.; MOUSTAFA, N.; VASILAKOS, A. Session invariant EEG signatures using elicitation protocol fusion and convolutional neural network. *IEEE Transactions on Dependable and Secure Computing*, v. 19, n. 4, p. 2488–2500, 2022.

DERAKHSHESH, A.; DEHGHANIAN, Z.; EBRAHIMPOUR, R.; RABIEE, H. R. *Cueless EEG imagined speech for subject identification: dataset and benchmarks*. 2025. Preprint arXiv:2501.09700. Disponível em: <https://arxiv.org/abs/2501.09700>.

DEWITT, I.; RAUSCHECKER, J. P. Wernicke's area revisited: parallel streams and word processing. *Brain and Language*, Netherlands, v. 127, p. 181–191, 2013. ISSN 0093-934X. Copyright © 2012 Elsevier Inc. All rights reserved.

DUAN, C.; DING, J.; CHEN, S.; YU, Z.; HUANG, T. Temporal effective batch normalization in spiking neural networks. In: *Advances in Neural Information Processing Systems (NeurIPS)*. [S.l.: s.n.], 2022.

ESHRAGHIAN, J. K.; WARD, M.; NEFTCI, E. O.; WANG, X.; LENZ, G.; DWIVEDI, G.; BENNAMOUN, M.; JEONG, D. S.; LU, W. D. Training spiking neural networks using lessons from deep learning. *Proceedings of the IEEE*, v. 111, n. 9, p. 1016–1054, 2023.

FALLAHI, M.; ARIAS-CABARCOS, P.; STRUFE, T. *Advancing Brainwave-Based Biometrics: A Large-Scale, Multi-Session Evaluation*. 2025. Preprint arXiv:2501.17866. Disponível em: <https://arxiv.org/abs/2501.17866>.

FAN, Y.; KANG, J.; LI, L.; LI, K.; CHEN, H.; CHENG, S.; ZHANG, P.; ZHOU, Z.; CAI, Y.; WANG, D. Cn-celeb: a challenging chinese speaker recognition dataset. In: IEEE. *ICASSP 2020-2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. [S.l.], 2020. p. 7604–7608.

FANT, G. *Acoustic Theory of Speech Production*: With calculations based on x-ray studies of russian articulations. 2. ed. The Hague: Mouton, 1960.

FLINKER, A.; KORZENIEWSKA, A.; SHESTYUK, A. Y.; FRANASZCZUK, P. J.; DRONKERS, N. F.; KNIGHT, R. T.; CRONE, N. E. Redefining the role of broca's area in speech. *Proceedings of the National Academy of Sciences*, v. 112, n. 9, p. 2871–2875, 2015. Disponível em: <https://www.pnas.org/doi/abs/10.1073/pnas.1414491112>.

FREITAS, S. Avaliação acústica e áudio percetiva na caracterização da voz humana. Faculdade de Engenharia da Universidade do Porto, 2013.

FURLAN, A. *Caracterização de voice spoofing para fins de verificação de locutores com base na Transformada Wavelet e na Análise Paraconsistente de Características*. Dissertação (Mestrado) — Universidade Estadual Paulista - campus de São José do Rio Preto-SP, São José do Rio Preto, Brasil, 2021.

FURLAN, A. What does spiking cost an autoencoder? A group-disjoint comparison with a non-spiking control on speech and EEG. Artigo em revisão. Dados, perfis e *scripts* em `software/nn/results/meeting01` e `software/nn/scripts/pipeline/meeting01`. 2026.

GAO, S.-H.; CHENG, M.-M.; ZHAO, K.; ZHANG, X.-Y.; YANG, M.-H.; TORR, P. Res2net: A new multi-scale backbone architecture. *IEEE TPAMI*, 2021.

GAO, Y.; JIN, Y.; CHAUHAN, J.; CHOI, S.; LI, J.; JIN, Z. Voice in ear: Spoofing-resistant and passphrase-independent body sound authentication. *Proc. ACM Interact. Mob. Wearable Ubiquitous Technol.*, Association for Computing Machinery, New York, NY, USA, v. 5, n. 1, mar 2021. Disponível em: <https://doi.org/10.1145/3448113>.

GERSTNER, W.; KISTLER, W.; NAUD, R.; PANINSKI, L. *Neuronal Dynamics: From Single Neurons to Networks and Models of Cognition*. Cambridge University Press, 2014. ISBN 9781107060838. Disponível em: <https://neuronaldynamics.epfl.ch/online/Ch2.S2.html>.

GLOROT, X.; BENGIO, Y. Understanding the difficulty of training deep feedforward neural networks. In: *Proceedings of the 13th International Conference on Artificial Intelligence and Statistics (AISTATS)*. [S.l.: s.n.], 2010. p. 249–256. Xavier/Glorot weight initialization.

GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. [S.l.]: MIT Press, 2016. <http://www.deeplearningbook.org>.

GOODMAN, D.; FIERS, T.; GAO, R.; GHOSH, M.; PEREZ, N. *Spiking Neural Network Models in Neuroscience - Cosyne Tutorial 2022*. Zenodo, 2022. Disponível em: <https://doi.org/10.5281/zenodo.7044500>.

GROTHER, P.; NGAN, M.; HANAOKA, K. *Face Recognition Vendor Test (FRVT) Part 3: Demographic Effects*. Gaithersburg, MD, 2019. Disponível em: <https://doi.org/10.6028/NIST.IR.8280>.

GUIDO, R. C. Practical and useful tips on discrete wavelet transforms [sp tips tricks]. *IEEE Signal Processing Magazine*, v. 32, n. 3, p. 162–166, May 2015.

GUIDO, R. C. Paraconsistent feature engineering [lecture notes]. *IEEE Signal Processing Magazine*, v. 36, n. 1, p. 154–158, Jan 2019.

GUO, Y.; ZHANG, Y.; CHEN, Y.; PENG, W.; LIU, X.; ZHANG, L.; HUANG, X.; MA, Z. Membrane potential batch normalization for spiking neural networks. In: *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*. [s.n.], 2023. Disponível em: <https://arxiv.org/abs/2308.08359>.

HANILÇI, C. Linear prediction residual features for automatic speaker verification anti-spoofing. *Multimedia Tools and Applications*, v. 77, n. 13, p. 16099–16111, Jul 2018.

HANSEN, J. H.; HASAN, T. Speaker recognition by machines and humans: A tutorial review. *IEEE Signal processing magazine*, IEEE, v. 32, n. 6, p. 74–99, 2015.

HAYKIN, S.; MOHER, M. *Sistemas de Comunicação-5*. [S.l.]: Bookman Editora, 2011.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep residual learning for image recognition. *CoRR*, abs/1512.03385, 2015. Disponível em: <http://arxiv.org/abs/1512.03385>.

HE, K.; ZHANG, X.; REN, S.; SUN, J. Delving deep into rectifiers: Surpassing human-level performance on imagenet classification. In: *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*. [S.l.: s.n.], 2015. p. 1026–1034. Kaiming/He weight initialization.

HERNÁNDEZ-DEL-TORO, T.; REYES-GARCÍA, C. A.; PINEDA, L. Villaseñor. Toward asynchronous eeg-based bci: Detecting imagined words segments in continuous eeg signals. *arXiv.org*, Cornell University Library, arXiv.org, Ithaca, 2021. ISSN 2331-8422.

HILLENBRAND, J.; GETTY, L. A.; CLARK, M. J.; WHEELER, K. Acoustic characteristics of American English vowels. *The Journal of the Acoustical Society of America*, v. 97, n. 5, p. 3099–3111, 05 1995. ISSN 0001-4966. Disponível em: <https://doi.org/10.1121/1.411872>.

HOLLER, Y.; BATHKE, A. C.; UHL, A. Age, sex, and pathology effects on stability of electroencephalographic biometric features based on measures of interaction. *IEEE Transactions on Information Forensics and Security*, v. 14, n. 2, p. 459–471, 2019.

HOLM, S. A simple sequentially rejective multiple test procedure. *Scandinavian Journal of Statistics*, v. 6, n. 2, p. 65–70, 1979. Disponível em: <https://www.jstor.org/stable/4615733>.

HOROWITZ, M. Computing's energy problem (and what we can do about it). In: *IEEE International Solid-State Circuits Conference (ISSCC) Digest of Technical Papers*. [S.l.: s.n.], 2014. p. 10–14.

IOFFE, S.; SZEGEDY, C. Batch normalization: Accelerating deep network training by reducing internal covariate shift. In: *Proceedings of the 32nd International Conference on Machine Learning (ICML)*. [S.l.: s.n.], 2015. p. 448–456.

JENSEN, A.; COUR-HARBO, A. la. *Ripples in Mathematics*. [S.l.]: Springer Berlin Heidelberg, 2001.

JIANG, P.; WANG, Q.; LIN, X.; ZHOU, M.; DING, W.; WANG, C.; SHEN, C.; LI, Q. Securing liveness detection for voice authentication via pop noises. *IEEE Transactions on Dependable and Secure Computing*, v. 20, n. 2, p. 1702–1718, 2023.

JOLLIFFE, I. *Principal Component Analysis*. Springer, 2002. (Springer Series in Statistics). ISBN 9780387954424. Disponível em: <https://books.google.com.br/books?id=_olByCrhjwIC>.

JONES, I. S.; KORDING, K. P. *Can Single Neurons Solve MNIST? The Computational Power of Biological Dendritic Trees*. 2020. Disponível em: <https://arxiv.org/abs/2009.01269>.

KASABOV, N. K. *Time-space, spiking neural networks and brain-inspired artificial intelligence*. [S.l.]: Springer, 2019.

KAUFMAN, S.; ROSSET, S.; PERLICH, C.; STITELMAN, O. Leakage in data mining: Formulation, detection, and avoidance. *ACM Transactions on Knowledge Discovery from Data*, v. 6, n. 4, p. 1–21, 2012.

KIM, Y.; PANDA, P. Revisiting batch normalization for training low-latency deep spiking neural networks from scratch. *Frontiers in Neuroscience*, v. 15, 2021. Batch Normalization Through Time (BNTT).

KREMER, R. L.; GOMES, M. d. C. A eficiência do disfarce em vozes femininas: uma análise da frequência fundamental. *ReVEL*, v. 12, p. 23, 2014.

KROGH, A.; HERTZ, J. A. A simple weight decay can improve generalization. In: *Advances in Neural Information Processing Systems 4 (NIPS)*. [S.l.]: Morgan Kaufmann, 1991. p. 950–957.

LECUN, Y.; BOTTOU, L.; ORR, G. B.; MÜLLER, K.-R. Efficient backprop. In: *Neural Networks: Tricks of the Trade*. [S.l.]: Springer, 1998, (Lecture Notes in Computer Science, v. 1524). p. 9–50.

LEMAIRE, E.; CORDONE, L.; CASTAGNETTI, A.; NOVAC, P.-E.; COURTOIS, J.; MIRAMOND, B. An analytical estimation of spiking neural networks energy efficiency. In: TANVEER, M.; AGARWAL, S.; OZAWA, S.; EKBAL, A.; JATOWT, A. (Ed.). *Neural Information Processing: 29th International Conference, ICONIP 2022, Proceedings, Part I*. [S.l.]: Springer, 2023. (Lecture Notes in Computer Science, v. 13623), p. 574–587.

LIN, Z.; CAI, S.; LI, H. Decoding listener's identity: Person identification from EEG signals using a lightweight spiking transformer. In: *Interspeech 2025*. [S.l.: s.n.], 2025. p. 5548–5552.

LOSHCHILOV, I.; HUTTER, F. Decoupled weight decay regularization. In: *Proceedings of the 7th International Conference on Learning Representations (ICLR)*. [s.n.], 2019. AdamW; source of the decoupled weight decay update rule. Disponível em: <https://openreview.net/forum?id=Bkg6RiCqY7>.

LOTTE, F.; BOUGRAIN, L.; CICHOCKI, A.; CLERC, M.; CONGEDO, M.; RAKOTOMAMONJY, A.; YGER, F. A review of classification algorithms for eeg-based brain-computer interfaces: A 10-year update. *Journal of Neural Engineering*, v. 15, n. 3, p. 031005, 2018.

MAASS, W.; NATSCHLäGER, T.; MARKRAM, H. Real-time computing without stable states: A new framework for neural computation based on perturbations. *Neural Computation*, v. 14, n. 11, p. 2531–2560, 2002.

MAHAPATRA, N. C.; BHUYAN, P. Multiclass classification of imagined speech vowels and words of electroencephalography signals using deep learning. *Advances in human-computer interaction*, Hindawi, New York, v. 2022, p. 1–10, 2022. ISSN 1687-5893.

MAHAPATRA, N. C.; BHUYAN, P. Eeg-based classification of imagined digits using a recurrent neural network. *Journal of neural engineering*, IOP Publishing, England, v. 20, n. 2, p. 26040–, 2023. ISSN 1741-2560.

MAKHOUL, J. Linear prediction: A tutorial review. *Proceedings of the IEEE*, v. 63, n. 4, p. 561–580, 1975. Disponível em: <https://doi.org/10.1109/PROC.1975.9792>.

MANNA, D. L.; VICENTE-SOLA, A.; KIRKLAND, P.; BIHL, T. J.; CATERINA, G. D. Time series forecasting via derivative spike encoding and bespoke loss functions for spiking neural networks. *Computers*, v. 13, n. 8, p. 202, 2024.

MASTRANGELO BARBARA SCELSAM, F. P. M. Normal awake adult eeg. In: MECARELLI, O. (Ed.). *Clinical Electroencephalography*. [S.l.]: Springer, 2019. cap. 11. ISBN 9783030045722.

MECARELLI, O. Normal awake adult eeg. In: MECARELLI, O. (Ed.). *Clinical Electroencephalography*. [S.l.]: Springer, 2019. cap. 9. ISBN 9783030045722.

MENG, Z.; ALTAF, M. U. B.; JUANG, B.-H. F. Active voice authentication. *DIGITAL SIGNAL PROCESSING*, v. 101, JUN 2020. ISSN 1051-2004.

MOCTEZUMA, L. A.; TORRES-GARCÍA, A. A.; PINEDA, L. V. nor; CARRILLO, M. Subjects identification using eeg-recorded imagined speech. *Expert Systems with Applications*, v. 118, p. 201–208, 2019. ISSN 0957-4174. Disponível em: <https://www.sciencedirect.com/science/article/pii/S0957417418306468>.

MORENO-RODRIGUEZ, J. C.; ATENCO-VAZQUEZ, J. C.; RAMIREZ-CORTES, J. M.; ARECHIGA-MARTINEZ, R.; GOMEZ-GIL, P.; FONSECA-DELGADO, R. BIOMEX-DB: A cognitive audiovisual dataset for unimodal and multimodal biometric systems. *IEEE Access*, v. 9, p. 111267–111276, 2021.

NADEAU, C.; BENGIO, Y. Inference for the generalization error. *Machine Learning*, v. 52, n. 3, p. 239–281, 2003.

NG, A. *Sparse Autoencoder*. 2011. <https://web.stanford.edu/class/cs294a/sparseAutoencoder.pdf>. CS294A Lecture Notes, Stanford University, pp. 1–19.

NGUYEN, C. H.; KARAVAS, G. K.; ARTEMIADIS, P. Inferring imagined speech using eeg signals: a new approach using riemannian manifold features. *Journal of neural engineering*, v. 15, n. 1, p. 016002, 2018. Disponível em: <https://doi.org/10.1088/1741-2552/aa8235>.

PANACHAKEL, J.; RAMAKRISHNAN, A. Decoding imagined speech from eeg using transfer learning. *IEEE Access*, PP, 10 2021.

PANACHAKEL, J. T.; RAMAKRISHNAN, A.; ANANTHAPADMANABHA, T. Decoding imagined speech using wavelet features and deep neural networks. In: *2019 IEEE 16th India Council International Conference (INDICON)*. IEEE, 2019. Disponível em: <http://dx.doi.org/10.1109/INDICON47234.2019.9028925>.

PANACHAKEL, J. T.; RAMAKRISHNAN, A. G.; ANANTHAPADMANABHA, T. V. *A Novel Deep Learning Architecture for Decoding Imagined Speech from EEG*. 2020.

PARK, H.-j.; LEE, B. Multiclass classification of imagined speech eeg using noise-assisted multivariate empirical mode decomposition and multireceptive field convolutional neural network. *Frontiers in human neuroscience*, Frontiers Media S.A, v. 17, p. 1186594–1186594, 2023. ISSN 1662-5161.

PINTO, F. C. G. *Manual de Iniciação em Neurocirurgia*. 2. ed. São Paulo: Santos, 2012. 384 p. ISBN 978-85-7288-979-7.

POLIKAR, R. *et al. The wavelet tutorial*. 1996.

RABINER, L. R.; JUANG, B.-H. *Fundamentals of Speech Recognition*. [S.l.]: Prentice Hall, 1993. (Prentice Hall Signal Processing Series).

RABINER, L. R.; SCHAFER, R. W. *Theory and Applications of Digital Speech Processing*. Upper Saddle River: Pearson, 2011. ISBN 978-0-13-603428-5.

RAHMAN, A.; CHOWDHURY, M. E.; KHANDAKAR, A.; TAHIR, A. M.; IBTEHAZ, N.; HOSSAIN, M. S.; KIRANYAZ, S.; MALIK, J.; MONAWWAR, H.; KADIR, M. A. Robust biometric system using session invariant multimodal EEG and keystroke dynamics by the ensemble of self-onns. *Computers in Biology and Medicine*, v. 142, p. 105238, 2022.

RODRÍGUEZ, J. C. M. *BIOMEX-DB*. 2021. Mendeley Data, versão 1. Licença CC BY 4.0.

SALIM, S.; AHMAD, W. Advancing voice biometrics for dysarthria speakers using multitaper LFCC and voice conversion data augmentation. *IEEE Transactions on Information Forensics and Security*, v. 19, p. 10114–10129, 2024.

SALIM, S.; SHAHNAWAZUDDIN, S.; AHMAD, W. Combined approach to dysarthric speaker verification using data augmentation and feature fusion. *Speech Communication*, v. 160, p. 103070, 2024.

SALOMON, D.; MOTTA, G.; BRYANT, D. *Data Compression: The Complete Reference*. Springer London, 2007. (Molecular biology intelligence unit). ISBN 9781846286032. Disponível em: <https://books.google.com.br/books?id=ujnQogzx_2EC>.

SANEI, S.; CHAMBERS, J. A. *EEG Signal Processing and Machine Learning*. 2. ed. [S.l.]: John Wiley & Sons, 2021. ISBN 9781119386957.

SEN, O.; SHEEHAN, A. M.; RAMAN, P. R.; KHARA, K. S.; KHALIFA, A.; CHATTERJEE, B. Machine-learning methods for speech and handwriting detection using neural signals: A review. *Sensors*, v. 23, n. 12, 2023. ISSN 1424-8220. Disponível em: <https://www.mdpi.com/1424-8220/23/12/5575>.

SHAH, U.; ALZUBAIDI, M.; MOHSEN, F.; ABD-ALRAZAQ, A.; ALAM, T.; HOUSEH, M. The role of artificial intelligence in decoding speech from eeg signals: A scoping review. *Sensors (Basel, Switzerland)*, MDPI AG, Basel, v. 22, n. 18, p. 6975–, 2022. ISSN 1424-8220.

TAMM, M.-O.; MUHAMMAD, Y.; MUHAMMAD, N. Classification of vowels from imagined speech with convolutional neural networks. *Computers*, MDPI, v. 9, n. 2, p. 46, 2020.

TATES, A.; MATRAN-FERNANDEZ, A.; HALDER, S.; DALY, I. Speech imagery brain–computer interfaces: a systematic literature review. *Journal of Neural Engineering*, v. 22, n. 3, p. 031003, 2025.

Tayebi Arasteh, S.; WEISE, T.; SCHUSTER, M.; NOETH, E.; MAIER, A.; YANG, S. H. The effect of speech pathology on automatic speaker verification: a large-scale study. *Scientific Reports*, v. 13, n. 1, p. 20476, 2023.

USMAN, M.; SULTAN, N.; NASIM, A.; AYAZ, B.; FATIMA, J.; NOSHEEN, F. Balancing noise reduction and neural signature preservation in EEG biometrics. *Scientific Reports*, v. 16, n. 1, p. 6674, 2026.

VALENÇA, E. H. O. *et al.* Análise acústica dos formantes em indivíduos com deficiência isolada do hormônio do crescimento. Universidade Federal de Sergipe, 2014.

VANDERAH, T. W. *Nolte's The Human Brain in Photographs and Diagrams*. 5th. ed. [S.l.: s.n.], 2020.

VASKOVIĆ, J.; OSIKA, A.; MCLAREN, N. *Neuroanatomia*. 2024. Kenhub. Disponível em: <https://www.kenhub.com/pt/library/anatomia/neuroanatomia>.

VICENTE, E. *Sistema 10-20 para localizar alvos terapêuticos em EMT*. 2023. Disponível em: <https://www.kandel.com.br/post/como-localizar-os-pontos-de-estimulacao-para-estimulacao-magnetica-transcraniana>.

VIIKKI, O.; LAURILA, K. Cepstral domain segmental feature vector normalization for noise robust speech recognition. *Speech Communication*, v. 25, n. 1–3, p. 133–147, 1998. Foundation of cepstral mean and variance normalization (CMVN).

VIVANCOS, D. *MindBigData*. 2023. <https://mindbigdata.com/opendb/>. Disponível em: <https://mindbigdata.com/opendb/>. Acesso em: 1 maio 2024.

WANG, Q.; WU, B.; ZHU, P.; LI, P.; ZUO, W.; HU, Q. Eca-net: Efficient channel attention for deep convolutional neural networks. *CoRR*, abs/1910.03151, 2019. Disponível em: <http://arxiv.org/abs/1910.03151>.

WANG, S.; ZHANG, H.; ZHANG, X.; SU, Y.; WANG, Z. Voiceprint recognition under cross-scenario conditions using perceptual wavelet packet entropy-guided efficient-channel-attention–res2net–time-delay-neural-network model. *Mathematics*, v. 11, n. 19, 2023. ISSN 2227-7390. Disponível em: <https://www.mdpi.com/2227-7390/11/19/4205>.

WELCH, P. D. The use of fast Fourier transform for the estimation of power spectra: A method based on time averaging over short, modified periodograms. *IEEE Transactions on Audio and Electroacoustics*, v. 15, n. 2, p. 70–73, 1967.

WERTZNER, H. F.; SCHREIBER, S.; AMARO, L. Análise da freqüência fundamental, jitter, shimmer e intensidade vocal em crianças com transtorno fonológico. *Revista Brasileira de Otorrinolaringologia*, SciELO Brasil, v. 71, p. 582–588, 2005.

YAN, Z.; BAI, Z.; TANG, K.; WONG, W.-F. *Reconsidering the Energy Efficiency of Spiking Neural Networks Inference from Analytical Perspectives*. 2024. Preprint arXiv:2409.08290. Disponível em: <https://arxiv.org/abs/2409.08290>.

ZEHIR, H.; HAFS, T.; DAAS, S. Unifying heartbeats and vocal waves: An approach to multimodal biometric identification at the score level. *Arabian Journal for Science and Engineering*, v. 50, n. 23, p. 19535–19554, 2025.

ZHAO, S.; RUDZICZ, F. Classifying phonological categories in imagined and articulated speech. In: *2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. [S.l.: s.n.], 2015. p. 992–996.

ZHENG, H.; WU, Y.; DENG, L.; HU, Y.; LI, G. Going deeper with directly-trained larger spiking neural networks. In: *Proceedings of the 35th AAAI Conference on Artificial Intelligence (AAAI)*. [s.n.], 2021. p. 11062–11070. Threshold-Dependent Batch Normalization (tdBN). Disponível em: <https://arxiv.org/abs/2011.05280>.

ZHOU, X.; GARCIA-ROMERO, D.; DURAISWAMI, R.; ESPY-WILSON, C.; SHAMMA, S. Linear versus mel frequency cepstral coefficients for speaker recognition. In: *IEEE Automatic Speech Recognition and Understanding Workshop (ASRU)*. [S.l.: s.n.], 2011. p. 559–564.

ZWICKER, E. Subdivision of the Audible Frequency Range into Critical Bands (Frequenzgruppen). *The Journal of the Acoustical Society of America*, v. 33, n. 2, p. 248–248, 02 1961. ISSN 0001-4966. Disponível em: <https://doi.org/10.1121/1.1908630>.

APÊNDICE A – Defeitos encontrados e corrigidos durante o desenvolvimento

Um defeito de software que derruba o programa é encontrado na primeira execução. Os defeitos registrados aqui eram de outro tipo: o *pipeline* rodava até o fim, os modelos convergiam e os números tinham a ordem de grandeza esperada. Nenhum deles teria sido notado só pela inspeção dos resultados. Por isso cada um vem com a forma como foi detectado, e com o efeito que teve sobre os números apresentados nesta tese.

Todos os resultados do Capítulo 4 vêm de execuções posteriores à última correção desta lista (12 de novembro de 2026). Nenhum número produzido antes dela é usado no texto.

Tabela 27 – Defeitos silenciosos encontrados durante o desenvolvimento, em ordem de descoberta

#	Encontrado	Defeito	Como foi detectado
1	16/07/2026	A taxa de aprendizado reduzida dos parâmetros biofísicos (subseção 2.1.10.10) era aplicada a *todos* os parâmetros da rede: um divisor por 10 da taxa global, e não uma taxa por grupo.	Ao investigar o latente colapsado do item 2: a taxa efetiva dos pesos era dez vezes menor que a declarada.
2	16/07/2026	Um *autoencoder* de pulsos com latente constante atingia $\alpha = \beta = 1$ e $D_{1,0} = \sqrt{2}$, valor que o punha à frente do extrator manual vencedor no EEG.	O vencedor era uma rede cuja saída não variava entre amostras. Deu origem a $D_{\text{penalizado}}$ (subseção 2.1.5.1) e à regularização da taxa de disparo no codificador (subseção 2.1.11.5).
3	12/11/2026	Os *autoencoders* "base" e "small" eram construídos como a mesma rede: uma largura igual ao valor de reserva do leitor de configuração era tratada como "não informada". O código fora corrigido em 23/07/2026 por outro motivo, mas as tabelas de julho não haviam sido refeitas.	Nas tabelas da Fase 00, os seis pares "base"/"small" tinham resultados idênticos até a oitava casa decimal.

#	Encontrado	Defeito	Como foi detectado
4	12/11/2026	A varredura de limiar do EER estava invertida: aceitava as pontuações *baixas*, e um sistema perfeito obtinha EER = 0,75.	Em 237 de 480 dobras, o par (EER, AUC) relatado era impossível: toda curva ROC com aquele EER tem AUC $\leq 1 - \text{EER}^2$, e a AUC relatada era maior.
5	12/11/2026	A montagem das dobras intersectava listas de índices não ordenadas com um algoritmo que exige listas ordenadas. Os conjuntos de treino perdiam, em média, 62% das amostras (de 15% a 78%), muitas vezes restando 3 dos 12 locutores.	Auditoria do código da validação cruzada; a perda foi então medida sobre os tamanhos reais da base.
6	12/11/2026	Na validação aninhada com frases não vistas, o treino externo incluía as frases reservadas para o teste.	Auditoria do código da validação aninhada, na mesma revisão dos itens 4 e 5.
7	12/11/2026	Cada voz recebia o EEG da tentativa *anterior* (índice lido como se começasse em 1; começa em 0; seção 3.1).	Contagem de tentativas por modalidade: as tentativas com áudio são exatamente as de fala pronunciada, e o EEG entregue era, em 141 casos, de fala imaginada.
8	12/11/2026	Os *autoencoders* e a PCA recebiam a forma de onda promediada em 256 blocos, que não contém informação de locutor (subseção 3.3.1).	Todo extrator automatizado tinha EER entre 0,48 e 0,52. Um classificador linear sobre a própria entrada, sem extrator, identificava o locutor quase ao acaso (Tabela 10).

O que cada defeito invalidou. Os itens 1 a 3 afetaram resultados da Fase 00 anteriores à respectiva correção, todos de julho de 2026; os itens 4 a 6, todos os resultados da Fase 01 de julho de 2026, EER e AUC; o item 7, todo resultado de EEG e de fusão anterior a 12 de novembro de 2026; o item 8, todo resultado de *autoencoder* e de PCA anterior à mesma data. As duas fases foram executadas de novo depois da última correção.

Uma previsão "confirmada" por dados que não mediam nada. Enquanto o item 8 estava ativo, a ordem prevista para as codificações temporais do SNN-AE (subseção 3.3.1) aparecia confirmada nos resultados. Com a entrada sem informação de locutor, a única diferença entre as codificações era o ruído que cada uma injeta, que é exatamente o que a previsão descrevia. Com a entrada corrigida, a ordem se inverte. Uma concordância entre teoria e medição pode, portanto, significar só que o experimento perdeu a capacidade de medir qualquer outra coisa.

O que mudou no método. Três práticas resultaram desses episódios. A entrada dos extratores automatizados é comparada, em testes automatizados, com bibliotecas de referência (SciPy e PyTorch). O programa recusa executar quando falta um valor de configuração, em vez de assumir um valor padrão — a origem do item 3. E cada número citado nos Capítulos 3 a 5 é lido dos resultados no momento da compilação do texto, junto com a verificação de que cada afirmação qualitativa ("não é significativo", "é o menor") ainda vale para os números.

APÊNDICE B – Reprodutibilidade

O texto descreve o procedimento em palavras. Este apêndice dá os nomes concretos — arquivos de configuração, programas e diretórios — para quem quiser repetir as execuções. Todos os caminhos são relativos ao diretório `software/nn/` do repositório <https://github.com/ensismoebius/doutorado>, que guarda, na mesma revisão deste texto, o código, a configuração de cada execução e os resultados brutos.

Tabela 28 – Arquivos e programas do experimento, na ordem em que são usados

Item	O que faz
`scripts/pipeline/thesis/00_thesis_generate_profiles.py`	Escreve os arquivos de configuração ("perfis", em JSON[1]) das duas fases e a lista que os declara; um teste automatizado recusa um perfil que a lista não declare.
`src/experiments/thesis/profiles/phase00/`, `phase01/`	Os perfis: um por execução da Fase 00, um por configuração da Fase 01.
`thesis` (programa C++)	Executa um perfil: carrega a base, extrai as características, pontua pela engenharia paraconsistente (Fase 00) ou treina e avalia o classificador (Fase 01).
`scripts/pipeline/thesis/01_thesis_phase00_rank.py`	Ordena os extratores da Fase 00 por $D_{\text{penalizado}}$, escreve o vencedor de cada sinal e o melhor de cada família, e a posição do vencedor em cada subconjunto de locutores; recusa um conjunto de resultados incompleto e sinaliza empates exatos.
`scripts/pipeline/thesis/02_thesis_apply_winner.py`	Escreve cada vencedor nos perfis da Fase 01.
`scripts/pipeline/thesis/03_thesis_phase01_significance.sh`	Executa os testes de significância de cada família de comparações declarada.
`scripts/pipeline/thesis/thesis_build_phase00_paraconsistent_tables.py`, `thesis_build_phase01_auth_tables.py`	Geram as tabelas do Capítulo 4 a partir dos resultados.
`scripts/pipeline/thesis/thesis_build_text_numbers.py`	Gera cada número citado no texto e verifica as afirmações qualitativas que dependem deles; uma afirmação que deixa de valer impede a geração.

[1] *JavaScript Object Notation*

Item	O que faz
`scripts/analysis/thesis_ae_input_reference.py`	Calcula, com SciPy e PyTorch, a Tabela 10.
`scripts/analysis/thesis_eeg_band_power.py`	Mede, com SciPy, a distribuição da potência do EEG da base (Tabela 9).
`scripts/data/coretto_verify_mirror.py`	Compara cada tentativa da base de Coretto, Gareis e Rufiner (2017) com a cópia independente do Zenodo (subseção 3.1.1) e, se não houver diferença, grava um selo com as contagens.
`scripts/data/biomex_download.py`	Baixa a BIOMEX-DB do Mendeley Data e confere o SHA-256 de cada arquivo.
`scripts/data/biomex_inventory.py`	Lista cada gravação de cada pasta da BIOMEX-DB e aponta as que não seguem o protocolo.
`scripts/data/biomex_to_sqlite.py`	Converte a BIOMEX-DB (seção 3.2): regra de inclusão, filtro, reamostragem para as taxas da outra base e pareamento.
`scripts/data/biomex_verify.py`	Confere a base convertida contra as exportações CSV, a Tabela 1 de Moreno-Rodriguez *et al.* (2021) e os arquivos originais, reimplementando as regras de inclusão e de margem; grava o selo sem o qual a base não é enviada para execução.
`src/experiments/thesis/profiles/biomex/`	Os perfis da replicação na BIOMEX-DB, com os vencedores da Fase 00 congelados em `results/thesis/biomex/coretto_phase00_winners_frozen.json`.
`scripts/analysis/thesis_base_facts.py`	Lê das duas bases e dos dois selos os números da subseção 3.1.1 e da seção 3.2.
`results/thesis/phase00/`, `phase01/`, `biomex/`	Resultados brutos de cada execução, os modelos treinados e os testes de significância.

APÊNDICE C – Regularização em redes neurais

C.1 Decaimento de Peso (Regularização L2)

Suponha que tenhamos uma rede neural simples com pesos W. Sejam L_{dados} a perda de dados (por exemplo, erro quadrático médio para tarefas de regressão), λ o parâmetro de regularização e $\|W\|_2^2$ a norma L2 dos pesos. Durante o treinamento, adicionamos um termo de regularização à função de perda, que penaliza o quadrado dos pesos (KROGH; HERTZ, 1991):

$$L_{\text{total}} = L_{\text{dados}} + \lambda \|W\|_2^2 \tag{C.1}$$

Vamos supor que nossa matriz de pesos W seja:

$$W = \begin{bmatrix} 1 & 0.5 \\ -0.3 & 0.8 \end{bmatrix}$$

Se definirmos $\lambda = 0.1$, o termo de regularização seria $0.1 \times (1^2 + 0.5^2 + (-0.3)^2 + 0.8^2) = 0.1 \times (1 + 0.25 + 0.09 + 0.64) = 0.1 \times 1.98 = 0.198$. Durante o treinamento, o otimizador atualiza os pesos considerando tanto a perda de dados quanto o termo de regularização. O termo de regularização incentiva pesos menores, prevenindo o sobreajuste.

O exemplo acima soma a penalidade diretamente à perda, que é a forma clássica da regularização L2. Neste trabalho usa-se uma forma equivalente, porém mais estável quando combinada com o otimizador Adam: o **decaimento de peso desacoplado** (*decoupled weight decay*), proposto por (LOSHCHILOV; HUTTER, 2019) no algoritmo AdamW.

A ideia é simples: em vez de modificar o gradiente, encolhe-se cada peso por uma pequena fração a cada passo de treinamento, logo após a atualização normal do otimizador. Sejam θ um peso qualquer da rede, η a taxa de aprendizado e λ o parâmetro que controla a força do decaimento:

$$\theta \leftarrow \theta - \eta\, \lambda\, \theta, \tag{C.2}$$

Em outras palavras, a cada iteração o peso perde uma fração $\eta\lambda$ do seu valor. Por exemplo, com $\eta = 0{,}01$ e $\lambda = 0{,}1$, cada peso é multiplicado por $(1 - 0{,}001) = 0{,}999$ a cada passo, sendo lentamente puxado em direção a zero. Pesos realmente úteis recebem gradientes que compensam esse encolhimento e sobrevivem; pesos irrelevantes, que quase não recebem gradiente, definham até desaparecer.

Por que separar o encolhimento do gradiente? O Adam divide cada gradiente por uma estimativa da sua própria escala (o fator $1/\sqrt{\hat{v}}$). Se a penalidade fosse somada ao

gradiente, ela também seria dividida por esse fator e o decaimento ficaria mais forte para alguns pesos e mais fraco para outros. Mantendo o encolhimento à parte, todos os pesos diminuem na mesma proporção.

Um cuidado importante: o decaimento é aplicado **apenas às matrizes de peso** das camadas densas. Os vieses (*bias*) e os parâmetros biofísicos dos neurônios de pulso — resistência R, capacitância C e limiar de disparo V_{th} — ficam de fora. O motivo é direto: esses valores não são "pesos" a serem reduzidos. Empurrar R ou C para zero destruiria a constante de tempo da membrana $\tau = R \cdot C$, e empurrar V_{th} para zero faria o neurônio disparar o tempo todo.

C.2 Penalidade de Esparsidade

Vamos considerar um autoencoder esparsificado com uma penalidade de esparsidade adicionada à função de perda para encorajar a esparsidade nas ativações das unidades ocultas.

Suponha que tenhamos uma camada oculta com valores de ativação $h = [0.9, 0.1, 0.8, 0.05]$.

Segundo (NG, 2011), o termo de penalidade de esparsidade pode ser definido como a divergência Kullback-Leibler (KL) entre o nível de esparsidade desejado ρ e $\hat{\rho}_i$, a média da ativação da unidade oculta i, somada sobre todas as unidades ocultas:

$$\Omega(h) = \sum_i (\rho \log(\rho/\hat{\rho}) + (1-\rho) \log((1-\rho)/(1-\hat{\rho}))) \tag{C.3}$$

Vamos supor $\rho = 0.2$. Se a média da ativação da unidade oculta i for $\hat{\rho}_i = 0.5$, então a penalidade de esparsidade para essa unidade seria:

$$\begin{aligned} \Omega(h_i) &= (0.2 \log(0.2/0.5) + 0.8 \log(0.8/0.5)) \\ &= (0.2 \times -0.3219 + 0.8 \times 0.3219) \\ &= -0.0644 + 0.2575 \\ &= 0.1931 \end{aligned} \tag{C.4}$$

Durante o treinamento, a penalidade de esparsidade incentiva a rede a ter ativações esparsas, focando em características importantes dos dados.

C.3 Regularização da Taxa de Disparo em Redes Neurais de Pulsos

A penalidade de taxa de disparo descrita nesta seção é uma técnica **proposta neste trabalho** para o treinamento das RNPs do Capítulo 2 — não é uma reprodução

de uma técnica publicada, mas uma adaptação da ideia geral de penalidade de esparsidade (seção anterior) ao caráter binário e temporal dos neurônios de pulso.

Diferentemente de um neurônio clássico, que produz um número real, um neurônio de pulso só pode emitir 0 ou 1 a cada instante. A informação que ele transmite está, portanto, na **frequência** com que dispara ao longo do tempo — a chamada *taxa de disparo*. Um detalhe simples ilustra o problema: se um neurônio quase nunca dispara, ou se dispara a toda hora, ele praticamente não distingue um exemplo de outro. Surgem assim dois extremos que prejudicam o aprendizado:

- **Neurônios mortos** (*dead neurons*): a taxa de disparo cai para perto de zero. O neurônio para de contribuir para a saída. Pior: como o gradiente substituto só existe nas proximidades do limiar, deixa de chegar gradiente ao neurônio, que nunca mais é ajustado e fica "preso" inativo.
- **Neurônios saturados** (*bursting neurons*): a taxa de disparo sobe para perto de um. O neurônio dispara em quase todo instante, responde igual a qualquer entrada (perde seletividade) e ainda gasta energia à toa — o oposto da economia que motiva o uso de RNP.

A solução é tratar a taxa de disparo como algo que deve ficar dentro de uma faixa saudável $[r_{\min}, r_{\max}]$ — nem baixa demais, nem alta demais. Seja r_ℓ a média dos pulsos (0 ou 1) da camada ℓ sobre todos os neurônios e instantes de tempo, e λ o parâmetro que regula a intensidade da penalidade. Adiciona-se à perda uma penalidade que só "acende" quando r_ℓ sai da faixa saudável, funcionando como duas cercas elásticas que a empurram de volta:

$$\Omega_{\text{disparo}} = \lambda \sum_{\ell \,\in\, \text{camadas}} \Big(\underbrace{\max(0,\ r_{\min} - r_\ell)^2}_{\text{pune taxa baixa}} + \underbrace{\max(0,\ r_\ell - r_{\max})^2}_{\text{pune taxa alta}} \Big), \tag{C.5}$$

Enquanto r_ℓ estiver dentro da faixa, os dois termos $\max(0, \cdot)$ valem zero e nada é penalizado; fora dela, a penalidade cresce com o quadrado da distância até a borda.

Um exemplo torna isso concreto. Sejam $r_{\min} = 0{,}05$, $r_{\max} = 0{,}80$ e $\lambda = 0{,}01$. Para uma camada com taxa média $r_\ell = 0{,}02$ (quase morta), apenas o primeiro termo atua:

$$\Omega = 0{,}01 \times (0{,}05 - 0{,}02)^2 = 0{,}01 \times 0{,}0009 = 9 \times 10^{-6}. \tag{C.6}$$

Já uma camada com $r_\ell = 0{,}40$, dentro da faixa, recebe penalidade nula. Sejam s_j o pulso (0 ou 1) do j-ésimo neurônio-instante da camada, n o número total desses elementos (n neurônios $\times$ passos de tempo) e $\text{clamp}(r_\ell, r_{\min}, r_{\max})$ a função que satura r_ℓ nos limites $r_{\min}$ e $r_{\max}$. O gradiente dessa penalidade em relação a cada pulso é

$$\frac{\partial \Omega_{\text{disparo}}}{\partial s_j} = \frac{2\lambda}{n} \big(r_\ell - \text{clamp}(r_\ell, r_{\min}, r_{\max}) \big), \tag{C.7}$$

Exemplo numérico. Continuando o caso $r_\ell = 0{,}02$ (quase morta) com $\lambda = 0{,}01$, para uma camada de $n = 20$ elementos (por exemplo, 4 neurônios $\times$ 5 passos de tempo): clamp(0,02, 0,05, 0,80) = 0,05 (satura no limite inferior), logo $\frac{\partial \Omega_{\text{disparo}}}{\partial s_j} = \frac{2 \times 0{,}01}{20}(0{,}02 - 0{,}05) = 0{,}001 \times (-0{,}03) = -3 \times 10^{-5}$. O gradiente negativo empurra s_j para cima durante a atualização (que subtrai o gradiente), ou seja, incentiva mais disparos — consistente com a camada estar abaixo de $r_{\min}$.

Esse gradiente é somado ao que já chega a cada camada pulsante durante a retropropagação: se a taxa está baixa, ele empurra os neurônios a disparar mais; se está alta, a disparar menos. Em resumo, esta é uma forma de regularização de esparsidade adaptada ao mundo temporal e binário das RNP, complementar à penalidade de esparsidade da seção anterior.

APÊNDICE D – Aplicação de um filtro *Wavelet*

Figura 48 – Demonstração numérica das transformadas Wavelet e *wavelet-packet*: Por razões didáticas, a *Wavelet* Haar foi considerada como tendo os valores $1/2$ e $-1/2$

***Packet-wavelet* para filtro haar = {0.5, 0.5}**

Sinal	32	10	20	38	37	28	38	34	18	24	24	9	23	24	28	34
	h								g							
Nível 01	21	29	32,5	36	21	16,5	23,5	31	11	-9	4,5	2	-3	7,5	-0,5	-3
	h				g				g				h			
Nível 02	25	34,25	18,75	27,25	-4	-1,75	2,25	-3,75	10	1,25	-5,25	1,25	1	3,25	2,25	-1,75
	h		g		g		h		h		g		g		h	
Nível 03	29,62	23	-4,625	-4,25	-1,125	3	-2,875	-0,75	5,625	-2	4,375	-3,25	-1,125	2	2,125	0,25
	h	g	g	h	h	g	g	h	h	g	g	h	h	g	g	h
Nível 04	26,3125	3,3125	-0,1875	-4,4375	0,9375	-2,0625	-1,0625	-1,8125	1,8125	3,8125	3,8125	0,5625	0,4375	-1,5625	0,9375	1,1875

← **resultado do passa-baixas (h)**
← **resultado do passa-altas (g)**

Comparação

Transformada wavelet regular

Sinal	32	10	20	38	37	28	38	34	18	24	24	9	23	24	28	34
Nível 01	21	29	32,5	36	21	16,5	23,5	31	11	-9	4,5	2	-3	7,5	-0,5	-3
Nível 02	25	34,25	18,75	27,25	-4	-1,75	2,25	-3,75	11	-9	4,5	2	-3	7,5	-0,5	-3
Nível 03	29,62	23	-4,625	-4,25	-4	-1,75	2,25	-3,75	11	-9	4,5	2	-3	7,5	-0,5	-3
Nível 04	26,3125	3,3125	-4,625	-4,25	-4	-1,75	2,25	-3,75	11	-9	4,5	2	-3	7,5	-0,5	-3

Transformada packet-wavelet

Sinal	32	10	20	38	37	28	38	34	18	24	24	9	23	24	28	34
Nível 01	21	29	32,5	36	21	16,5	23,5	31	11	-9	4,5	2	-3	7,5	-0,5	-3
Nível 02	25	34,25	18,75	27,25	-4	-1,75	2,25	-3,75	10	1,25	-5,25	1,25	1	3,25	2,25	-1,75
Nível 03	29,62	23	-4,625	-4,25	-1,125	3	-2,875	-0,75	5,625	-2	4,375	-3,25	-1,125	2	2,125	0,25
Nível 04	26,3125	3,3125	-0,1875	-4,4375	0,9375	-2,0625	-1,0625	-1,8125	1,8125	3,8125	3,8125	0,5625	0,4375	-1,5625	0,9375	1,1875

Fonte: Elaborado pelo autor, 2023.